

线性代数 (I)

Lecturer: 杨启哲

Last modified: 2026 年 3 月 2 日

线性代数研究的核心对象是

- **线性空间** (又称**向量空间**)
- 和线性空间之间的**线性映射** (又称**线性变换**)。

线性空间可以视为我们熟悉的一维实数轴 $\mathbb{R}$ 、二维平面 $\mathbb{R}^2$ 和三维空间 $\mathbb{R}^3$ 的推广, 而线性映射则是线性函数的推广。

1 线性函数

例 1.1

考察函数

$$y := 3x.$$

等价地, 我们可以定义 $f: \mathbb{R} \rightarrow \mathbb{R}$ 满足 $f(x) = 3x$ 。这就是一个最简单的**线性函数**。

- 在几何意义下, f 刻画了在二维平面 $\mathbb{R}^2$ 上的一条直线。
- 从代数角度看, 对于所有的 $x_1, x_2, c, x \in \mathbb{R}$

$$\begin{aligned} f(x_1 + x_2) &= f(x_1) + f(x_2) \\ f(cx) &= cf(x). \end{aligned} \tag{1}$$

这就是代数意义下的**线性性**。

这里符号 $:=$ 表达了赋值, 即对每一 $x \in \mathbb{R}$ 我们取相应的 y 为 $3x$ 。

例 1.2 牛顿第二定律

一个大小为 F 的力作用在质量为 m 的物体上会产生加速度 a , 即

$$F = ma, \text{ 这也可以等价地表示为 } a = \frac{F}{m}.$$

如果我们固定了物体的质量, 那么加速度 a 和力 F 之间就构成了一个线性函数。

在二维平面 $\mathbb{R}^2$ 上, 力 F 是一个**二维向量** (F_x, F_y) 。其中 F_x 和 F_y 分别是 F 在 x 轴方向与 y 轴方向上的大小。类似的, 加速度 a 是一个由在 x 轴上加速度 a_x 和 y 轴上加速度 a_y 构成的二维向

量 (a_x, a_y) 。牛顿第二定律在二维平面上可以表述成

$$\mathbf{a} = (a_x, a_y) = \left(\frac{F_x}{m}, \frac{F_y}{m} \right).$$

这仍然是一个线性函数，满足前述的两条代数性质 (1):

$$\begin{aligned} \left(\frac{F_x + F'_x}{m}, \frac{F_y + F'_y}{m} \right) &= \left(\frac{F_x}{m}, \frac{F_y}{m} \right) + \left(\frac{F'_x}{m}, \frac{F'_y}{m} \right), \\ \left(\frac{c \cdot F_x}{m}, \frac{c \cdot F_y}{m} \right) &= c \cdot \left(\frac{F_x}{m}, \frac{F_y}{m} \right). \end{aligned}$$

在三维空间里，力 F 和加速度 $\mathbf{a}$ 由 x 、 y 和 z 轴上的分量构成的三维向量表示：

$$\mathbf{F} = (F_x, F_y, F_z) \quad \text{且} \quad \mathbf{a} = (a_x, a_y, a_z).$$

那么

$$\begin{aligned} a_x &= \frac{1}{m} \cdot F_x + 0 \cdot F_y + 0 \cdot F_z \\ a_y &= 0 \cdot F_x + \frac{1}{m} \cdot F_y + 0 \cdot F_z \\ a_z &= 0 \cdot F_x + 0 \cdot F_y + \frac{1}{m} \cdot F_z. \end{aligned}$$

我们以后会看到，这个线性函数能由如下**矩阵**来描述

$$\begin{bmatrix} 1/m & 0 & 0 \\ 0 & 1/m & 0 \\ 0 & 0 & 1/m \end{bmatrix}.$$

- **代数**：研究某些对象的抽象计算规则，建立它们之间的相等关系。例如，

$$(x - 3)(x + 5) = x^2 + 2x - 15.$$

线性代数研究的对象不仅包括标量，还有向量、线性空间、矩阵和线性映射。

- **分析**：对某些对象进行估值和近似逼近，研究它们的定性性质而不是定量性质。
- **组合**：对某些对象进行计数，研究它们的数量并进行比较。

2 向量

向量是某个给定**线性空间**的元素；而一个线性空间是由一组可以相加且可以与标量相乘的对象（即向量）构成的集合。我们先从最熟悉的线性空间 -- **二维平面** $\mathbb{R}^2$ 开始，然后将其推广到三维空间 $\mathbb{R}^3$ ，进而任意 n 维的 $\mathbb{R}^n$ 。而一般线性空间的定义会在后续章节给出。

向量的表示。 $\mathbb{R}^2$ 中的每个向量都由其 x 坐标和 y 坐标唯一确定，它们给出了二维平面 $\mathbb{R}^2$ 上的一个点 (x, y) ，而几何上我们视其为由原点 $(0, 0)$ 至 (x, y) 的一个箭头。




图 1 向量 $\mathbf{v}$ 和 $\mathbf{w}$ 。这里 $\begin{bmatrix} 4 \\ 2 \end{bmatrix}$ 是 $(4, 2)$ **矩阵形式** 的表示。采用这种表示的原因在后续讨论中会慢慢显现。

图1中的两个向量的三种不同表示由如下表格给出。

向量	数字表示	点表示	箭头表示
$\mathbf{v}$	4, 2	$(4, 2)$	$(0, 0) \rightarrow (4, 2)$
$\mathbf{w}$	-1, 2	$(-1, 2)$	$(0, 0) \rightarrow (-1, 2)$

向量加法。 两个 $\mathbb{R}^2$ 向量的加法就是分别将它们 x 坐标和 y 坐标相加：

$$\begin{array}{ccc} \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} & + & \begin{bmatrix} w_1 \\ w_2 \end{bmatrix} = \begin{bmatrix} v_1 + w_1 \\ v_2 + w_2 \end{bmatrix} \\ \mathbf{v} & & \mathbf{w} \qquad \mathbf{v} + \mathbf{w} \end{array}$$

几何上我们可以视其为将第二个向量 $\mathbf{w}$ （的箭头表示）的起点平移到第一个向量 $\mathbf{v}$ （的箭头表示）的终点得到的向量。图 2 给出了图 1 中的两个向量相加的表示。




图 2 $\mathbf{v} + \mathbf{w} = \begin{bmatrix} 4 \\ 2 \end{bmatrix} + \begin{bmatrix} -1 \\ 2 \end{bmatrix} = \begin{bmatrix} 3 \\ 4 \end{bmatrix}$

标量乘法. 我们可以对一个向量的长度进行缩放, 这就是对向量进行**标量乘法**运算的几何意义。**标量**是能由数字表示的量。目前我们关心的大多数场合下, 标量就是一个实数 $c \in \mathbb{R}$ 。给定 $\mathbb{R}^2$ 向量 $\mathbf{v} = (v_1, v_2)$ 我们定义

$$\begin{array}{ccc} c & \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} & = \begin{bmatrix} cv_1 \\ cv_2 \end{bmatrix} \\ \text{标量} & \mathbf{v} & \mathbf{cv} \end{array}$$

图3中我们将向量 $\mathbf{v}$ 的长度放大了 3 倍, 得到了向量 $3\mathbf{v}$ 。注意到 $\mathbf{v}$ 和 $3\mathbf{v}$ 的方向完全一致。




图 3 标量乘法

线性组合. 现在我们可以将向量加法和标量乘法统一到**线性组合**这一概念之下。在图4中我们将两个具体向量做了线性组合。更一般的,




图 4 $2\mathbf{v} - \mathbf{w} = 2 \begin{bmatrix} 2 \\ 1 \end{bmatrix} + (-1) \begin{bmatrix} -1 \\ 2 \end{bmatrix} = \begin{bmatrix} 4 \\ 2 \end{bmatrix} - \begin{bmatrix} -1 \\ 2 \end{bmatrix} = \begin{bmatrix} 5 \\ 0 \end{bmatrix}$

$$\begin{array}{ccc} c \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} & + & d \begin{bmatrix} w_1 \\ w_2 \end{bmatrix} = \begin{bmatrix} cv_1 + dw_1 \\ cv_2 + dw_2 \end{bmatrix} \\ \mathbf{cv} & & \mathbf{dw} \quad \mathbf{cv + dw}. \end{array}$$

2.1 高维空间 $\mathbb{R}^n$ 中的向量

我们可以将二维的 $\mathbb{R}^2$ 向量推广到三维 $\mathbb{R}^3$ 中的向量 $\mathbf{v} = (v_1, v_2, v_3)$, 即每个向量由 x 、 y 和 z 轴坐标确定, 如图5。




图 5 $\mathbf{v} = \begin{bmatrix} 2 \\ 3 \\ 2 \end{bmatrix}$

$\mathbb{R}^3$ 中的线性组合. 考察如下的三个 $\mathbb{R}^3$ 向量

$$\mathbf{u} = \begin{bmatrix} 1 \\ 0 \\ 3 \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}, \quad \text{和} \quad \mathbf{w} = \begin{bmatrix} 2 \\ 3 \\ -1 \end{bmatrix}.$$

我们可以对它们做如下的线性组合:

$$\begin{aligned} \mathbf{u} &= 1\mathbf{u} = \begin{bmatrix} 1 \\ 0 \\ 3 \end{bmatrix}, \\ \mathbf{u} + 4\mathbf{v} &= \begin{bmatrix} 1 \\ 0 \\ 3 \end{bmatrix} + 4 \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} = \begin{bmatrix} 5 \\ 8 \\ 7 \end{bmatrix}, \\ \mathbf{u} + 4\mathbf{v} - 2\mathbf{w} &= \begin{bmatrix} 1 \\ 0 \\ 3 \end{bmatrix} + 4 \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix} - 2 \begin{bmatrix} 2 \\ 3 \\ -1 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 9 \end{bmatrix}. \end{aligned}$$

很自然地, 对任意 $n \geq 1$, 我们可以考察形为

$$\mathbf{v} = (v_1, \dots, v_n) = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix}$$

的向量, 即 $\mathbb{R}^n$ 向量。它们的加法、标量乘法以及线性组合都能很容易地定义。

2.2 关于线性组合的重要问题

对给定的一组向量 $\mathbf{u}, \mathbf{v}, \mathbf{w}, \dots$, 我们经常需要回答以下的一些问题。

1. 所有的线性组合 $c\mathbf{u}$, 即集合 $\{c\mathbf{u} \mid c \in \mathbb{R}\}$, 构成了什么 (几何) 对象?
2. 所有的 $c\mathbf{u} + d\mathbf{v}$ 构成了什么对象?
3. 所有的 $c\mathbf{u} + d\mathbf{v} + e\mathbf{w}$ 构成了什么对象?

我们甚至可以研究由 1000 个向量的所有线性组合构成的几何对象。

考察如下的三个向量:

$$\mathbf{u} = \begin{bmatrix} 1 \\ 0 \\ 3 \end{bmatrix}, \quad \mathbf{v} = \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}, \quad \text{和} \quad \mathbf{w} = \begin{bmatrix} 2 \\ 3 \\ -1 \end{bmatrix}.$$

那么我们可以验证:

1. 所有的线性组合 $c\mathbf{u}$ 构成了一条经过原点 $(0, 0, 0)$ 的**直线**。
2. 所有的线性组合 $c\mathbf{u} + d\mathbf{v}$ 是经过原点 $(0, 0, 0)$ 的一个**平面**。
3. 所有的线性组合 $c\mathbf{u} + d\mathbf{v} + e\mathbf{w}$ **填满**了整个三维空间 $\mathbb{R}^3$ 。换言之, 对所有的 $a, b, c \in \mathbb{R}$ 方程组

$$x + y + 2z = a$$

$$2y + 3z = b$$

$$3x + y - z = c$$

有解。

2.3 向量的长度和点积

在研究 $\mathbb{R}^2$ 向量的时候, 我们经常关心的它们的一些几何性质。

1. 向量 $\mathbf{v} = (v_1, v_2)$ 的**长度**是

$$\|\mathbf{v}\| = \sqrt{v_1^2 + v_2^2}. \quad (2)$$

2. 两个向量 $\mathbf{v} = (v_1, v_2)$ 和 $\mathbf{w} = (w_1, w_2)$ 的**夹角**满足

$$\cos \theta = \frac{v_1 w_1 + v_2 w_2}{\|\mathbf{v}\| \|\mathbf{w}\|}.$$

它们都能归约到如下的点积概念。

定义 2.1

任意两个 $\mathbb{R}^2$ 向量 $\mathbf{v} = (v_1, v_2)$ 和 $\mathbf{w} = (w_1, w_2)$ 的**点积** (又称**内积**) 是

$$\mathbf{v} \cdot \mathbf{w} = v_1 w_1 + v_2 w_2.$$

更一般的，对两个 $\mathbb{R}^n$ 中的向量 $\mathbf{v} = (v_1, \dots, v_n)$ 和 $\mathbf{w} = (w_1, \dots, w_n)$ ，它们的内积是

$$\mathbf{v} \cdot \mathbf{w} = v_1 w_1 + v_2 w_2 + \dots + v_n w_n = \sum_{i \in [n]} v_i w_i. \quad (3)$$

内积的一些性质.

1. $\mathbb{R}^2$ 向量 $\mathbf{v}$ 和 $\mathbf{w}$ 互相垂直 (参见定理2.8) 当且仅当

$$\mathbf{v} \cdot \mathbf{w} = 0.$$

2. 点积满足交换律，即对任意 $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$ 我们都有

$$\mathbf{v} \cdot \mathbf{w} = \mathbf{w} \cdot \mathbf{v}.$$

这个性质可以根据内积的定义2.1非常容易地验证。

根据(2)和(3)，我们定义任意 $\mathbb{R}^n$ 向量的长度概念。

定义 2.2

令 $n \geq 1$ 。任意 $\mathbf{v} = (v_1, \dots, v_n) \in \mathbb{R}^n$ 的长度是

$$\|\mathbf{v}\| := \sqrt{\mathbf{v} \cdot \mathbf{v}} = \sqrt{v_1^2 + \dots + v_n^2}.$$




图 6 直角三角形

注 2.3

如图6所示，著名的勾股定理 (又称毕达哥拉斯定理) 是定义2.2的直接推论。

引理 2.4

对任意向量 $\mathbf{v} \in \mathbb{R}^n$ ，它的长度为 0，即 $\|\mathbf{v}\| = 0$ ，当且仅当

$$\mathbf{v} = (0, \dots, 0),$$

即 $\mathbf{v}$ 是零向量, 简记为 $\mathbf{v} = \mathbf{0}$ 。

证明: 令 $\mathbf{v} = (v_1, \dots, v_n)$ 。那么

$$|\mathbf{v}| = 0 \iff \sqrt{v_1^2 + \dots + v_n^2} = 0 \iff v_1 = \dots = v_n = 0 \iff \mathbf{v} = \mathbf{0}.$$

□

定义 2.5

对向量 $\mathbf{v} \in \mathbb{R}^n$, 如果 $\|\mathbf{v}\| = 1$, 即 $\mathbf{v}$ 的长度为 1, 那么我们就称 $\mathbf{v}$ 为一单位向量。

例 2.6

一些典型的单位向量:

$$\mathbf{i} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{j} = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad \text{和} \quad \mathbf{u} = \begin{bmatrix} \cos \theta \\ \sin \theta \end{bmatrix}.$$

考察 $\mathbb{R}^3$ 向量 $\mathbf{u} = (2, 2, 1)$, 它的长度是

$$\|\mathbf{u}\| = \sqrt{2^2 + 2^2 + 1} = 3.$$

我们可以将其“缩短”为单位向量

$$\left(\frac{2}{3}, \frac{2}{3}, \frac{1}{3}\right).$$

引理 2.7 (标准化)

假设 $\mathbf{v}$ 是一 $\mathbb{R}^n$ 非零向量, 那么

$$\frac{\mathbf{v}}{\|\mathbf{v}\|} = \frac{1}{\|\mathbf{v}\|} \mathbf{v} = \left(\frac{v_1}{\|\mathbf{v}\|}, \frac{v_2}{\|\mathbf{v}\|}, \dots, \frac{v_n}{\|\mathbf{v}\|} \right)$$

是一个和 $\mathbf{v}$ 方向一致的单位向量。这个过程称为对 $\mathbf{v}$ 进行**标准化**。

定理 2.8

令 $\mathbf{v}, \mathbf{w} \in \mathbb{R}^2$ 。如果 $\mathbf{v}$ 垂直于 $\mathbf{w}$, 那么 $\mathbf{v} \cdot \mathbf{w} = 0$ 。

在证明定理2.8之前, 我们先讨论 $\mathbb{R}^2$ 向量间的夹角问题。

定理 2.9

假设单位向量 $\mathbf{u}, \mathbf{u} \in \mathbb{R}^2$ 夹角为 θ , 那么

$$\cos \theta = \mathbf{u} \cdot \mathbf{u}.$$

证明: 图7给出了基于几何的证明。

□




图 7 单位向量间的夹角

定理 2.10

假设两个非零向量 $\mathbf{v}, \mathbf{w} \in \mathbb{R}^2$ 的夹角为 θ , 那么

$$\cos \theta = \frac{\mathbf{v} \cdot \mathbf{w}}{\|\mathbf{v}\| \|\mathbf{w}\|}.$$

证明: 由引理2.7和定理2.9。 □

现在定理2.8就是定理2.10的直接推论。由于 $|\cos \theta|$ 始终 ≤ 1 , 对任意 $\mathbf{v}, \mathbf{w} \in \mathbb{R}^2$ 我们马上就得到如下的 Cauchy-Schwarz-Buniakowsky 不等式。我们以后会看到该不等式的一个不基于 $\cos$ 且对所有 $\mathbb{R}^n$ 向量都成立的证明。

定理 2.11 Cauchy-Schwarz-Buniakowsky

对任意 $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$

$$|\mathbf{v} \cdot \mathbf{w}| \leq \|\mathbf{v}\| \|\mathbf{w}\|.$$

著名的三角不等式是定理2.11的直接推论。

定理 2.12 三角不等式

对任意 $\mathbf{v}, \mathbf{w} \in \mathbb{R}^n$

$$\|\mathbf{v} + \mathbf{w}\| \leq \|\mathbf{v}\| + \|\mathbf{w}\|.$$

证明: 假设 $\mathbf{v} = (v_1, \dots, v_n)$ 和 $\mathbf{w} = (w_1, \dots, w_n)$ 。

$$\begin{aligned} \|\mathbf{v} + \mathbf{w}\|^2 &= \|(v_1 + w_1, \dots, v_n + w_n)\|^2 \\ &= \sum_{i \in [n]} (v_i + w_i)^2 \\ &= \sum_{i \in [n]} v_i^2 + \sum_{i \in [n]} w_i^2 + 2 \sum_{i \in [n]} v_i w_i \\ &= \|\mathbf{v}\|^2 + \|\mathbf{w}\|^2 + 2\mathbf{v} \cdot \mathbf{w} \\ &\leq \|\mathbf{v}\|^2 + \|\mathbf{w}\|^2 + 2|\mathbf{v} \cdot \mathbf{w}| \\ &\leq \|\mathbf{v}\|^2 + \|\mathbf{w}\|^2 + 2\|\mathbf{v}\| \|\mathbf{w}\| \end{aligned}$$

$$\begin{aligned} & (\text{Cauchy-Schwarz-Buniakowsky 不等式}) \\ & = (\|\mathbf{v}\| + \|\mathbf{w}\|)^2. \end{aligned}$$

□

3 矩阵与线性方程组

给定三个 $\mathbb{R}^3$ 向量

$$\mathbf{u} = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} \quad \mathbf{v} = \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix} \quad \mathbf{w} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

对任意标量 $x_1, x_2, x_3 \in \mathbb{R}$, 我们可以构造线性组合 $x_1\mathbf{u} + x_2\mathbf{v} + x_3\mathbf{w}$, 即

$$x_1 \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} + x_2 \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix} + x_3 \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} x_1 \\ x_2 - x_1 \\ x_3 - x_2 \end{bmatrix}. \quad (4)$$

在引入**矩阵**和**矩阵乘法**的精确定义后, 我们可以将其写成如下的形式:

$$A\mathbf{x} = \underbrace{\begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix}}_A \underbrace{\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}}_{\mathbf{x}} = \begin{bmatrix} x_1 \\ x_2 - x_1 \\ x_3 - x_2 \end{bmatrix}. \quad (5)$$

需要指出的是, 这不仅仅是个形式的变换: (4)是对三个向量进行线性组合, x_1, x_2, x_3 是相应的系数 (标量); 而(5)是将矩阵 A 直接“作用”在向量 (x_1, x_2, x_3) 上得到的结果。

事实上, 我们还有一个通过内积理解(5)的方式:

$$A\mathbf{x} = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} (1, 0, 0) \cdot (x_1, x_2, x_3) \\ (-1, 1, 0) \cdot (x_1, x_2, x_3) \\ (0, -1, 1) \cdot (x_1, x_2, x_3) \end{bmatrix} = \begin{bmatrix} x_1 \\ x_2 - x_1 \\ x_3 - x_2 \end{bmatrix}.$$

3.1 线性方程组

在(5)中, 取定 $\mathbf{x} = (1, 2, 3)$, 那么

$$A\mathbf{x} = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} x_1 \\ x_2 - x_1 \\ x_3 - x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix} = \mathbf{b}. \quad (6)$$

这个过程就是给定 $\mathbf{x} = (x_1, x_2, x_3)$ 计算向量 $\mathbf{b} = A\mathbf{x}$. 而作为相反过程, 我们也可以给定 $\mathbf{b}$ 求解 $\mathbf{x}$. 这是线性代数要解决的核心问题之一: 求解线性方程组

$$A\mathbf{x} = \mathbf{b}.$$

很容易看出上面线性方程组的一般²解为

$$\begin{aligned}x_1 &= b_1 \\x_2 &= b_1 + b_2 \\x_3 &= b_1 + b_2 + b_3.\end{aligned}$$

它的矩阵乘法形式为

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \underbrace{\begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}}_{A^{-1}} \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix} = A^{-1}\mathbf{b}.$$

上面已经提到这是计算 $\mathbf{b} = A\mathbf{x}$ 的逆过程，因此我们使用了类似反函数的符号 A^{-1} 。如果带入(6)中得到的向量 $\mathbf{b} = (1, 1, 1)$ ，我们就得到

$$A^{-1}\mathbf{b} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_1 + b_2 \\ b_1 + b_2 + b_3 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \mathbf{x}.$$

这恰好是(6)中的向量 $\mathbf{x}$ 。因此我们以后会看到上述两个矩阵

$$A = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \quad \text{和} \quad A^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}$$

互为**逆矩阵**；而基于它们的乘法运算互为逆过程，如

$$A\mathbf{x} = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \quad \text{和} \quad A^{-1}\mathbf{b} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

我们也会看到并不是所有的矩阵都有逆矩阵。考察向量

$$\mathbf{u} = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} \quad \mathbf{v} = \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix} \quad \mathbf{w}^* = \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}.$$

它们线性组合的一般形式是 $x_1\mathbf{u} + x_2\mathbf{v} + x_3\mathbf{w}^*$ ，即

$$x_1 \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} + x_2 \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix} + x_3 \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix} = \begin{bmatrix} x_1 - x_3 \\ x_2 - x_1 \\ x_3 - x_2 \end{bmatrix}.$$

写成矩阵形式我们得到

$$C\mathbf{x} = \begin{bmatrix} 1 & 0 & -1 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} x_1 - x_3 \\ x_2 - x_1 \\ x_3 - x_2 \end{bmatrix}.$$

²指对所有 $\mathbf{b}$ 都成立。

对于 $\mathbf{b} = (1, 3, 5)$, 线性方程组

$$\mathbf{C}\mathbf{x} = \begin{bmatrix} 1 & 0 & -1 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} x_1 - x_3 \\ x_2 - x_1 \\ x_3 - x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 3 \\ 5 \end{bmatrix} = \mathbf{b}$$

就没有解 (为什么?)。几何上这说明所有的线性组合

$$x_1\mathbf{u} + x_2\mathbf{v} + x_3\mathbf{w} = x_1 \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix} + x_2 \begin{bmatrix} 0 \\ 1 \\ -1 \end{bmatrix} + x_3 \begin{bmatrix} -1 \\ 0 \\ 1 \end{bmatrix}$$

不能填满整个三维空间 $\mathbb{R}^3$ 。

线性代数 (II)

Lecturer: 杨启哲

Last modified: 2026 年 3 月 10 日

1 线性方程组

1.1 求解线性方程组

考察线性方程组

$$\begin{aligned} x - 2y &= 1 \\ 3x + 2y &= 11. \end{aligned} \quad (1)$$

如图1所示, 每个方程定义了 $\mathbb{R}^2$ 上的一条直线。因此方程组(1)的解就是两条直线的交点。这是所谓方程组的**行观点**。




图 1 从行的观点理解线性方程组

我们还能从线性组合的观点来理解方程组求解。方程组(1)等价于

$$x \begin{bmatrix} 1 \\ 3 \end{bmatrix} + y \begin{bmatrix} -2 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 \\ 11 \end{bmatrix}.$$

图2给出了向量 $(1, 3)$ 和 $(-2, 2)$ 的一个等于 $(1, 11)$ 的线性组合, 其系数就是方程组的解。这是方程组的**列观点**。

方程组的矩阵表示 我们可以将(1)写成**矩阵乘法**的形式:

$$\begin{bmatrix} 1 & -2 \\ 3 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 1 \\ 11 \end{bmatrix} \quad (2)$$

矩阵 $\begin{bmatrix} 1 & -2 \\ 3 & 2 \end{bmatrix}$ 称为线性方程组(1)的**系数矩阵**。因为(2)等价于(1), 所以

$$\begin{bmatrix} 1 & -2 \\ 3 & 2 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} x - 2y \\ 3x + 2y \end{bmatrix} = \begin{bmatrix} (1, -2) \cdot (x, y) \\ (3, 2) \cdot (x, y) \end{bmatrix}.$$




图 2 从列的观点理解线性方程组

我们后面会看到，一般的矩阵乘法都可由向量的点积定义。在上面的例子中，当 $x = 3$ 且 $y = 1$ 时，我们就能得到

$$\begin{bmatrix} 1 & -2 \\ 3 & 2 \end{bmatrix} \begin{bmatrix} 3 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \times 3 - 2 \times 1 \\ 3 \times 3 + 2 \times 1 \end{bmatrix} = \begin{bmatrix} (1, -2) \cdot (3, 1) \\ (3, 2) \cdot (3, 1) \end{bmatrix} = \begin{bmatrix} 1 \\ 11 \end{bmatrix}.$$

这恰好对应了 $x = 3$ 、 $y = 1$ 是方程组(1)的解。

类似的我们可以讨论 $\mathbb{R}^3, \dots$, 至任意高维 $\mathbb{R}^n$ 中的线性方程组及其矩阵表示。例如对方程组

$$\begin{aligned} 2x_1 + 4x_2 - 2x_3 &= 2 \\ 4x_1 + 9x_2 - 3x_3 &= 8 \\ -2x_1 - 3x_2 + 7x_3 &= 10 \end{aligned} \tag{3}$$

从几何上看我们有

行观点	三个平面相交于一点
列观点	三个列向量的线性组合得到向量 (2, 8, 10)

而(3)的矩阵表示为

$$\begin{bmatrix} 2 & 4 & -2 \\ 4 & 9 & -3 \\ -2 & -3 & 7 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2 \\ 8 \\ 10 \end{bmatrix}$$

$\mathbf{A} \qquad \mathbf{x} \qquad \mathbf{b}$

$\mathbf{Ax} = \mathbf{b}$ 中的变元是 $\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$ 。很容易验证 $\begin{bmatrix} -1 \\ 2 \\ 2 \end{bmatrix}$ ，即 $x = -1$ ， $y = 2$ 和 $z = 2$ 满足方程组(3)。所以

我们需要定义 $\mathbf{Ax}$ 使得

$$\begin{bmatrix} 2 & 4 & -2 \\ 4 & 9 & -3 \\ -2 & -3 & 7 \end{bmatrix} \begin{bmatrix} -1 \\ 2 \\ 2 \end{bmatrix} = \begin{bmatrix} 2 \\ 8 \\ 10 \end{bmatrix}.$$

矩阵和向量的乘法. 为了能将

$$\begin{aligned} a_{11}x_1 + \dots + a_{1n}x_n &= b_1 \\ &\vdots \\ a_{m1}x_1 + \dots + a_{mn}x_n &= b_m \end{aligned}$$

写成

$$\underbrace{\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}}_A \underbrace{\begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}}_x = \underbrace{\begin{bmatrix} b_1 \\ \vdots \\ b_m \end{bmatrix}}_b,$$

对任意 $i \in [m]$ 我们令 Ax 的第 i 个坐标为

$$a_{i1}x_1 + \dots + a_{in}x_n = \sum_{j \in [n]} a_{ij}x_j = (a_{i1}, \dots, a_{in}) \cdot (x_1, \dots, x_n).$$

那么

$$Ax = \begin{bmatrix} (a_{11}, \dots, a_{1n}) \cdot (x_1, \dots, x_n) \\ (a_{21}, \dots, a_{2n}) \cdot (x_1, \dots, x_n) \\ \vdots \\ (a_{m1}, \dots, a_{mn}) \cdot (x_1, \dots, x_n) \end{bmatrix}. \quad (4)$$

有了这个定义后, 就可以将我们熟悉的**高斯消元**通过矩阵乘法来理解。

高斯消元的乘法解释. 考察如下的线性方程组

$$\begin{aligned} x - 2y &= 1 \\ 3x + 2y &= 11. \end{aligned} \quad (5)$$

通过一步简单消元就能得到

$$\begin{aligned} x - 2y &= 1 \quad (\text{将(5)中的第一个等式乘以 } 3) \\ 8y &= 8 \quad ((5) \text{ 中的第二个等式减去上面的结果就可以消去 } 3x). \end{aligned}$$

我们称这个新的方程组是**上三角**的, 而我们能很容易地解出这样的上三角方程组。

图3给出了这个过程的几何解释。

类似的, 对方程组

$$\begin{aligned} 4x - 8y &= 4 \\ 3x + 2y &= 11 \end{aligned}$$

我们可以得到

$$\begin{aligned} 4x - 8y &= 4 \quad (\text{将第一个等式乘以 } 3/4) \\ 8y &= 8 \quad (\text{第二个等式减去上面的结果就可以消去 } 3x). \end{aligned} \quad (6)$$

每一步高斯消元都涉及两个重要的量




图 3 高斯消元对应的几何变换

主元 (pivot)	用于消元的方程中第一个非零项
乘的系数	以待消去项的系数除以主元的系数

我们重新考察方程组(3)，即

$$\begin{aligned}
 2x_1 + 4x_2 - 2x_3 &= 2 \\
 4x_1 + 9x_2 - 3x_3 &= 8 \\
 -2x_1 - 3x_2 + 7x_3 &= 10
 \end{aligned} \tag{7}$$

写成矩阵乘法 $A\mathbf{x} = \mathbf{b}$ 的形式：

$$\begin{bmatrix} 2 & 4 & -2 \\ 4 & 9 & -3 \\ -2 & -3 & 7 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2 \\ 8 \\ 10 \end{bmatrix}. \tag{8}$$

$A \qquad \qquad \mathbf{x} \qquad \qquad \mathbf{b}$

作为消元的第一步我们将(7)中的第二个等式减去 2 倍的第一个等式，得到

$$\begin{aligned}
 2x_1 + 4x_2 - 2x_3 &= 2 \\
 x_2 + x_3 &= 4 \\
 -2x_1 - 3x_2 + 7x_3 &= 10
 \end{aligned} \tag{9}$$

其矩阵表示为

$$\begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ -2 & -3 & 7 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ 10 \end{bmatrix}. \tag{10}$$

因此从矩阵的角度看，我们将矩阵等式(8)转换成了矩阵等式(10)。而这个过程会由一个所谓的**消去矩阵**

$$\begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

刻画。如果我们将该矩阵乘以(8)的右侧，根据(4)就能得到(10)的右侧：

$$\begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 8 \\ 10 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ 10 \end{bmatrix}.$$

而根据我们将引入的矩阵乘法（定义2.2），将消去矩阵乘以(8)的左侧系数矩阵，就能得到(10)的左侧系数矩阵：

$$\begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 4 & -2 \\ 4 & 9 & -3 \\ -2 & -3 & 7 \end{bmatrix} = \begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ -2 & -3 & 7 \end{bmatrix}.$$

作为第二步我们将(9)中的第一个等式加到第三个等式上，得到

$$\begin{aligned} 2x_1 + 4x_2 - 2x_3 &= 2 \\ x_2 + x_3 &= 4 \\ x_2 + 5x_3 &= 12 \end{aligned} \quad (11)$$

其矩阵表示为

$$\begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ 0 & 1 & 5 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ 12 \end{bmatrix}. \quad (12)$$

这样变元 x_1 在第二、第三个方程中就被完全消去。而这步消元所对应的消去矩阵为

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix}.$$

将其分别乘以等式(10)的两侧，就能得到等式(12)的两侧：

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 4 \\ 10 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ 12 \end{bmatrix} \quad \text{和} \quad \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ -2 & -3 & 7 \end{bmatrix} = \begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ 0 & 1 & 5 \end{bmatrix}.$$

在第三步，我们将(11)中的第三个等式减去第二个等式，那么就有

$$\begin{aligned} 2x_1 + 4x_2 - 2x_3 &= 2 \\ x_2 + x_3 &= 4 \\ 4x_3 &= 8 \end{aligned} \quad (13)$$

写成矩阵形式：

$$\begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ 0 & 0 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ 8 \end{bmatrix}. \quad (14)$$

这里变元 x_2 在第三个方程中被消去。我们得到了一个上三角方程组，也就很容易得到（原）方程组的解。这最后一步消元对应的消去矩阵是

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix}.$$

将其分别乘以等式(12)的两侧，就能得到等式(14)的两侧：

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 4 \\ 12 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ 8 \end{bmatrix} \quad \text{和} \quad \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ 0 & 1 & 5 \end{bmatrix} = \begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ 0 & 0 & 4 \end{bmatrix}.$$

我们可以将上述三步消元过程对原始方程组(7)的系数矩阵，即(8)等式的左侧，的作用写成如下的矩阵连乘：

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \left(\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \left(\begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 4 & -2 \\ 4 & 9 & -3 \\ -2 & -3 & 7 \end{bmatrix} \right) \right) \quad (15)$$

根据我们马上要引入的矩阵乘法，可以得到(15)等于

$$\begin{aligned} & \left(\left(\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \right) \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \right) \begin{bmatrix} 2 & 4 & -2 \\ 4 & 9 & -3 \\ -2 & -3 & 7 \end{bmatrix} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 3 & -1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 4 & -2 \\ 4 & 9 & -3 \\ -2 & -3 & 7 \end{bmatrix} = \begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ 0 & 0 & 4 \end{bmatrix}. \end{aligned}$$

事实上，矩阵

$$\begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ 0 & 0 & 4 \end{bmatrix}$$

在整体上刻画了上述的高斯消元过程：

$$\begin{aligned} 2x_1 + 4x_2 - 2x_3 &= 2 & 2x_1 + 4x_2 - 2x_3 &= 2 \\ 4x_1 + 9x_2 - 3x_3 &= 8 & \implies x_2 + x_3 &= 4 \\ -2x_1 - 3x_2 + 7x_3 &= 10 & 4x_3 &= 8 \end{aligned}$$

即从矩阵的观点看，我们有如下的两个等式：

$$\begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 3 & -1 & 1 \end{bmatrix} \begin{bmatrix} 2 & 4 & -2 \\ 4 & 9 & -3 \\ -2 & -3 & 7 \end{bmatrix} = \begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ 0 & 0 & 4 \end{bmatrix}$$

和

$$\begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 3 & -1 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 8 \\ 10 \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ 8 \end{bmatrix}.$$

2 矩阵和矩阵上的运算

定义 2.1

令 $m, n \geq 1$ 。一个 m 行 n 列矩阵（即 $m \times n$ 矩阵） A 有如下的形式：

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}.$$

其中每一 $a_{ij} \in \mathbb{R}$ ，我们也称其为第 i 行第 j 列项（或元素），记为

$$A(i, j).$$

一些常用的特殊矩阵

- **方阵**：行数和列数相等 ($m = n$) 的矩阵。
- **全零矩阵**：所有元素都为 0 的矩阵，记为 $O_{m \times n}$ ，在不引起误会的前提下，也会直接用 O 。
- **单位矩阵**：所有元素都为 1 的方阵，记为 $E_{n \times n}$ ，在不引起误会的前提下，也会直接用 E 。
- **对角矩阵**：只有对角线 $A(i, i)$ 上非零的方阵，记为 $\text{diag}(a_1, \dots, a_n)$ 。

有了矩阵的定义后，我们最重要的目标之一是将线性方程组

$$\begin{aligned} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n &= b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n &= b_2 \\ &\vdots \\ a_{m1}x_1 + a_{m2}x_2 + \dots + a_{mn}x_n &= b_m \end{aligned}$$

转换为

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix}$$

$m \times n$ 矩阵 $n \times 1$ 矩阵 $m \times 1$ 矩阵

的形式。但除了这里所需的矩阵乘法，我们也会看到矩阵加法及标量乘法也有重要的意义及应用。

矩阵加法。 对两个行数和列数相同的矩阵，我们可以定义它们的加法：

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} + \begin{bmatrix} a'_{11} & a'_{12} & \cdots & a'_{1n} \\ a'_{21} & a'_{22} & \cdots & a'_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a'_{m1} & a'_{m2} & \cdots & a'_{mn} \end{bmatrix}$$

$$= \begin{bmatrix} a_{11} + a'_{11} & a_{12} + a'_{12} & \cdots & a_{1n} + a'_{1n} \\ a_{21} + a'_{21} & a_{22} + a'_{22} & \cdots & a_{2n} + a'_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} + a'_{m1} & a_{m2} + a'_{m2} & \cdots & a_{mn} + a'_{mn} \end{bmatrix}$$

直观上，它对应了将两个线性方程组相加：由

$$\begin{array}{rclcl} a_{11}x_1 + \cdots + a_{1n}x_n & = & b_1 & a'_{11}x_1 + \cdots + a'_{1n}x_n & = & b'_1 \\ & & \vdots & & & \vdots \\ & & \ddots & & & \ddots \\ a_{m1}x_1 + \cdots + a_{mn}x_n & = & b_m & a'_{m1}x_1 + \cdots + a'_{mn}x_n & = & b'_m \end{array}$$

我们得到

$$\begin{array}{rcl} (a_{11} + a'_{11})x_1 + \cdots + (a_{1n} + a'_{1n})x_n & = & b_1 + b'_1 \\ & & \vdots \\ (a_{m1} + a'_{m1})x_1 + \cdots + (a_{mn} + a'_{mn})x_n & = & b_m + b'_m \end{array}$$

标量乘法.

$$c \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} = \begin{bmatrix} ca_{11} & ca_{12} & \cdots & ca_{1n} \\ ca_{21} & ca_{22} & \cdots & ca_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ ca_{m1} & ca_{m2} & \cdots & ca_{mn} \end{bmatrix}$$

矩阵乘法. 下面我们定义最一般的矩阵乘法。

定义 2.2

假设 $m, n, p \geq 1$ 。给定 $m \times n$ 矩阵 A 和 $n \times p$ 矩阵 B ，即

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix} \quad \text{且} \quad B = \begin{bmatrix} b_{11} & b_{12} & \cdots & b_{1p} \\ b_{21} & b_{22} & \cdots & b_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ b_{n1} & b_{n2} & \cdots & b_{np} \end{bmatrix}.$$

那么 AB 是形式为

$$AB = \begin{bmatrix} c_{11} & c_{12} & \cdots & c_{1p} \\ c_{21} & c_{22} & \cdots & c_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ c_{m1} & c_{m2} & \cdots & c_{mp} \end{bmatrix},$$

的 $m \times p$ 矩阵，其中每个 c_{ij} 是 A 的第 i 个行向量与 B 的第 j 个列向量的内积定义：

$$c_{ij} = (a_{i1}, \dots, a_{in}) \cdot (b_{1j}, \dots, b_{nj}) = a_{i1}b_{1j} + \cdots + a_{in}b_{nj} = \sum_{k \in [n]} a_{ik}b_{kj}.$$

当 $p = 1$ ，即矩阵 B 为一列向量，上面的定义恰好是我们已经讨论过的(4)。

矩阵乘法可以由线性方程组的代入来解释。考察如下的两个线性方程组：

$$\begin{array}{rcl} a_{11}x_1 + \cdots + a_{1n}x_n & = & y_1 \\ & \vdots & \\ a_{m1}x_1 + \cdots + a_{mn}x_n & = & y_m \end{array} \quad \text{即} \quad \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix}$$

和

$$\begin{array}{rcl} b_{11}z_1 + \cdots + b_{1p}z_p & = & x_1 \\ & \vdots & \\ b_{n1}z_1 + \cdots + b_{np}z_p & = & x_n \end{array} \quad \text{即} \quad \begin{bmatrix} b_{11} & \cdots & b_{1p} \\ \vdots & \ddots & \vdots \\ b_{n1} & \cdots & b_{np} \end{bmatrix} \begin{bmatrix} z_1 \\ \vdots \\ z_p \end{bmatrix} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$$

将 $z_1, \dots, z_p$ 代入 $x_1, \dots, x_n$ ，那么对于任意 $i \in [m]$

$$\begin{aligned} y_i &= a_{i1}x_1 + \cdots + a_{in}x_n = \sum_{k \in [n]} a_{ik}x_k \\ &= \sum_{k \in [n]} a_{ik} \left(\sum_{j \in [p]} b_{kj}z_j \right) = \sum_{k \in [n]} \sum_{j \in [p]} a_{ik}b_{kj}z_j = \sum_{j \in [p]} \left(\sum_{k \in [n]} a_{ik}b_{kj} \right) z_j \\ &= \sum_{j \in [p]} (a_{i1}, \dots, a_{in}) \cdot (b_{1j}, \dots, b_{nj}) z_j. \end{aligned}$$

我们可以将上面的过程写成矩阵形式：

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} \quad \text{和} \quad \begin{bmatrix} b_{11} & \cdots & b_{1p} \\ \vdots & \ddots & \vdots \\ b_{n1} & \cdots & b_{np} \end{bmatrix} \begin{bmatrix} z_1 \\ \vdots \\ z_p \end{bmatrix} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}.$$

那么

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \left(\begin{bmatrix} b_{11} & \cdots & b_{1p} \\ \vdots & \ddots & \vdots \\ b_{n1} & \cdots & b_{np} \end{bmatrix} \begin{bmatrix} z_1 \\ \vdots \\ z_p \end{bmatrix} \right)$$

因为每一 $y_i = \sum_{j \in [p]} (a_{i1}, \dots, a_{in}) \cdot (b_{1j}, \dots, b_{nj}) z_j$ ，这完美符合我们的矩阵乘法定义：

$$\begin{bmatrix} y_1 \\ \vdots \\ y_m \end{bmatrix} = \left(\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} \begin{bmatrix} b_{11} & \cdots & b_{1p} \\ \vdots & \ddots & \vdots \\ b_{n1} & \cdots & b_{np} \end{bmatrix} \right) \begin{bmatrix} z_1 \\ \vdots \\ z_p \end{bmatrix}.$$

除了线性方程组，我们还能通过别的一些角度来理解矩阵乘法。

- **AB 的每一列都是 A 的列向量的线性组合：** 将 B 写成

$$[b_1 \cdots b_p].$$

那么

$$AB = [Ab_1 \cdots Ab_p].$$

- AB 的每一行都是 B 的行向量的线性组合：将 A 写成：

$$\begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_m \end{bmatrix}.$$

那么

$$AB = \begin{bmatrix} \mathbf{a}_1 B \\ \vdots \\ \mathbf{a}_m B \end{bmatrix}.$$

- 将 A 写成由列向量构成的矩阵

$$\begin{bmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_n \end{bmatrix},$$

将 B 写成行向量构成的矩阵

$$\begin{bmatrix} \mathbf{b}_1 \\ \vdots \\ \mathbf{b}_n \end{bmatrix}.$$

那么

$$AB = \mathbf{a}_1 \mathbf{b}_1 + \cdots + \mathbf{a}_n \mathbf{b}_n.$$

线性代数 (III)

Lecturer: 杨启哲

Last modified: 2026 年 3 月 23 日

1 矩阵和矩阵上的运算

1.1 矩阵运算的一些法则

定理 1.1 (矩阵加法法则)

我们假设下面的表达式中的运算都是良定义的（如 $A + B$ 中 A 和 B 有相同的行数和列数）。

(交换律) $A + B = B + A$ 。

(标量乘法分配律) $c(A + B) = cA + cB$ 。

(结合律) $A + (B + C) = (A + B) + C$ 。

定理 1.2 (矩阵乘法法则)

我们假设下面的表达式中的运算都是良定义的。

(左侧矩阵乘法分配律) $A(B + C) = AB + AC$ 。

(右侧乘法分配律) $(A + B)C = AC + BC$ 。

(结合律) $A(BC) = (AB)C$ ，因此我们在写多个矩阵的连续乘法不需要括号。

矩阵乘法的交换律不成立！ 我们始终要强调的是，矩阵乘法是不满足**交换律**的，即即使假设下面的运算都是良定义的，依旧有：

$$AB \neq BA.$$

考察如下的两个矩阵：

$$A = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix}, B = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$

则我们有：

$$\begin{aligned} AB &= \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 2 \end{bmatrix} \\ BA &= \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 2 & 1 \\ 1 & 1 \end{bmatrix} \end{aligned}$$

矩阵的乘法次数

矩阵的乘法在不同的运算顺序下执行的次数差别会非常大。考察如下三个形式的矩阵：

$$A : 1 \times M, \quad B : M \times 1, \quad C : 1 \times M$$

这里 $M \in \mathbb{N}^*$ ，则我们有：

1. $A(BC)$ 所需的乘法次数为 $1 \times M \times M + M \times 1 \times M = 2M^2$.
2. $(AB)C$ 所需的乘法次数为 $1 \times M \times 1 + 1 \times 1 \times M = 2M$.

足足相差 M 倍！因此我们可以挑选合适的乘法顺序减小计算量。

1.2 分块矩阵和分块上的乘法

上述矩阵乘法的不同视角提示了我们，在计算矩阵的乘法时，我们可以通过将矩阵进行一些分块再来分别计算，如：

$$AB = \begin{bmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_n \end{bmatrix} \begin{bmatrix} \mathbf{b}_1 \\ \vdots \\ \mathbf{b}_n \end{bmatrix} = \mathbf{a}_1 \mathbf{b}_1 + \cdots + \mathbf{a}_n \mathbf{b}_n.$$

分块矩阵. 一个矩阵 A 可以划分成若干个子矩阵：

$$A = \begin{bmatrix} A_{11} & A_{12} & \cdots & A_{1q} \\ A_{21} & A_{22} & \cdots & A_{2q} \\ \vdots & \vdots & \ddots & \vdots \\ A_{p1} & A_{p2} & \cdots & A_{pq} \end{bmatrix}$$

其中每个 A_{ij} 是一个 $m_i \times n_j$ 的矩阵。如如下矩阵可以表示为：

$$\begin{bmatrix} 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 1 \\ 1 & 0 & 1 & 0 & 1 & 0 \\ 0 & 1 & 0 & 1 & 0 & 1 \end{bmatrix} = \begin{bmatrix} I_2 & I_2 & I_2 \\ I_2 & I_2 & I_2 \end{bmatrix}$$

其中 $I_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ ，也被称为是 2×2 的单位矩阵。

分块矩阵的乘法. 仿照矩阵乘法的形式，我们其实也可以写出在分块矩阵意义下的乘法，如：

$$AB = \begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \begin{bmatrix} B_{11} & B_{12} \\ B_{21} & B_{22} \end{bmatrix} = \begin{bmatrix} A_{11}B_{11} + A_{12}B_{21} & A_{11}B_{12} + A_{12}B_{22} \\ A_{21}B_{11} + A_{22}B_{21} & A_{21}B_{12} + A_{22}B_{22} \end{bmatrix}$$

幸运的是，只要每个具体的运算都是良定义的，即每个矩阵的乘法 $A_{ik}B_{kj}$ 都是良定义的，上述运算就是成立的。因此实际上其与矩阵乘法并无二致。

例 1.3

考察如下矩阵乘法：

$$\begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ -5 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 3 \\ 2 & 1 & 2 \\ 5 & 2 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 3 \\ 0 & -1 & -6 \\ 0 & -3 & -14 \end{bmatrix}$$

其可以视为下列线性方程组对 x_1 的消元过程：

$$\begin{aligned} x_1 + x_2 + 3x_3 &= 2 & x_1 + x_2 + 3x_3 &= 2 \\ 2x_1 + x_2 + 2x_3 &= 8 & \implies -x_2 - 6x_3 &= 4 \\ 5x_1 + 2x_2 + x_3 &= 10 & -3x_2 - 14x_3 &= 0 \end{aligned}$$

我们也可以利用分块的角度来理解上述乘法：

$$\begin{aligned} \left[\begin{array}{c|cc} 1 & 0 & 0 \\ -2 & 1 & 0 \\ -5 & 0 & 1 \end{array} \right] \left[\begin{array}{c|cc} 1 & 1 & 3 \\ 2 & 1 & 2 \\ 5 & 2 & 1 \end{array} \right] &= \begin{bmatrix} \begin{bmatrix} 1 \end{bmatrix} \begin{bmatrix} 1 \end{bmatrix} + \begin{bmatrix} 0 & 0 \end{bmatrix} \begin{bmatrix} 2 \\ 5 \end{bmatrix} & \begin{bmatrix} 1 \end{bmatrix} \begin{bmatrix} 1 & 3 \end{bmatrix} + \begin{bmatrix} 0 & 0 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix} \\ \begin{bmatrix} -2 \\ -5 \end{bmatrix} \begin{bmatrix} 1 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 2 \\ 5 \end{bmatrix} & \begin{bmatrix} -2 \\ -5 \end{bmatrix} \begin{bmatrix} 1 & 3 \end{bmatrix} + \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 1 \end{bmatrix} \end{bmatrix} \\ &= \begin{bmatrix} 1 & 1 & 3 \\ 0 & -1 & -6 \\ 0 & -3 & -14 \end{bmatrix} \end{aligned}$$

事实上，一般来说我们有如果 A 是可逆的（定义见下一节1.3），我们有：

$$\begin{bmatrix} I & O \\ -CA^{-1} & I \end{bmatrix} \begin{bmatrix} A & B \\ C & D \end{bmatrix} = \begin{bmatrix} A & B \\ O & D - CA^{-1}B \end{bmatrix}$$

上述的 $D - CA^{-1}B$ 被称作矩阵 A 的舒尔补 (Schur complement)，其在图像处理、优化等领域有着重要的应用。

1.3 逆矩阵

回顾在之前解方程的过程中存在一组矩阵：

$$A = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \quad \text{和} \quad A^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix}$$

基于它们的乘法运算互为逆过程，如

$$Ax = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \quad \text{和} \quad A^{-1}b = \begin{bmatrix} 1 & 0 & 0 \\ 1 & 1 & 0 \\ 1 & 1 & 1 \end{bmatrix} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}.$$

我们已经通过类似反函数的符号来进行表示这个过程，并称其互为**逆**矩阵。现在我们给出一个精确的定义：

定义 1.4 (可逆矩阵, Inverse Matrix)

称一个 $n \times n$ 的方阵 A 是可逆的, 如果存在一个矩阵 B , 使得:

$$AB = BA = I$$

则将 B 称为 A 的逆矩阵, 特别的, 我们将矩阵 B 记为 A^{-1} ,

例 1.5

对角矩阵:

$$D = \begin{bmatrix} d_1 & 0 & 0 & \cdots & 0 \\ 0 & d_2 & 0 & \cdots & 0 \\ 0 & 0 & d_3 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & d_n \end{bmatrix}$$

是可逆的, 其逆矩阵 D^{-1} 也是对角矩阵:

$$D^{-1} = \begin{bmatrix} \frac{1}{d_1} & 0 & 0 & \cdots & 0 \\ 0 & \frac{1}{d_2} & 0 & \cdots & 0 \\ 0 & 0 & \frac{1}{d_3} & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & \frac{1}{d_n} \end{bmatrix}$$

可以验证:

$$DD^{-1} = D^{-1}D = I$$

即使我们仅考虑方阵的情况下, 也不是所有的矩阵都有逆矩阵。考察一个 2×2 矩阵 A :

$$A = \begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

如果其存在逆矩阵 $A^{-1} = \begin{bmatrix} x & y \\ z & w \end{bmatrix}$, 则其必须满足:

$$A^{-1}A = I \implies \begin{aligned} ax + cy &= 1 \\ bx + dy &= 0 \\ az + cw &= 1 \\ cz + dw &= 0 \end{aligned}$$

上述方程仅在 $ad - bc \neq 0$ 时有解, 此时:

$$x = \frac{1}{ad - bc} \cdot d, y = \frac{1}{ad - bc} \cdot (-b), z = \frac{1}{ad - bc} \cdot (-c), w = \frac{1}{ad - bc} \cdot a$$

并且可以验证:

$$AA^{-1} = \begin{bmatrix} a & b \\ c & d \end{bmatrix} \frac{1}{ad-bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix} = \frac{1}{ad-bc} \begin{bmatrix} ad-bc & 0 \\ 0 & ad-bc \end{bmatrix} = I$$

从而 A 是可逆的, 当且仅当 $ad-bc \neq 0$, 此时其逆矩阵为:

$$A^{-1} = \frac{1}{ad-bc} \begin{bmatrix} d & -b \\ -c & a \end{bmatrix}$$

逆矩阵的一些性质. 下述引理说明, 如果逆矩阵是存在的, 那么其是唯一的。

定理 1.6

若方阵 A 是可逆的, 那么其逆矩阵是唯一的。

证明: 假设存在两个不同的矩阵 B, C , 使得 $BA = AC = I$, 则:

$$\begin{aligned} B(AC) &= (BA)C = IC = C \\ B(AC) &= BI = B \end{aligned} \implies B = C$$

□

定理 1.7

若 $n \times n$ 的方阵 A, B 都是可逆的, 则矩阵 $C = AB$ 也是可逆的, 且 $C^{-1} = B^{-1}A^{-1}$.

证明: 显然 $B^{-1}A^{-1}$ 是良定义的, 从而:

$$\begin{aligned} (AB)(B^{-1}A^{-1}) &= A(B(B^{-1})A^{-1}) = AIA^{-1} = AA^{-1} = I \\ (B^{-1}A^{-1})(AB) &= B^{-1}(A^{-1}A)B = B^{-1}IB = B^{-1}B = I \end{aligned}$$

从而由引理1.6, C 是可逆的, 并且 $C^{-1} = B^{-1}A^{-1}$.

□

考虑那些系数构成方阵的线性方程组:

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_n \end{bmatrix} \quad \text{和} \quad \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 0 \end{bmatrix}$$

$A \qquad \qquad \mathbf{x} \qquad \qquad \mathbf{b} \qquad \qquad A \qquad \qquad \mathbf{x} \qquad \qquad \mathbf{0}$

下列引理说明了 A 是否可逆决定了方程的解是否唯一。

定理 1.8

若方阵 A 是可逆的, 则对于任意的 $\mathbf{b}$, $A\mathbf{x} = \mathbf{b}$ 有唯一解。

证明： 只需注意到：

$$A^{-1}(Ax) = A^{-1}b \implies (A^{-1}A)x = A^{-1}b \implies x = A^{-1}b$$

□

推论 1.9

令 A 是方阵，若 $Ax = 0$ 存在一个非零解，则 A 不可逆。

证明： 由引理1.8直接可得。

□

本节的最后，让我们注意到，由于矩阵的乘法不满足交换律，因而在定义逆矩阵的时候我们需要满足：

$$AB = BA = I$$

若上述等式只满足 $AB = I$ 或者 $BA = I$ ，其是否还是逆矩阵？

问题 1.10

给定两个方阵 A, B ，若 $AB = I$ ， A 和 B 是否互为可逆矩阵？

答案是肯定的，相关证明将在后续章节中进一步给出。

1.4 转置矩阵和置换矩阵

转置矩阵。 矩阵的行和列扮演了不同的角色，因此我们定义如下的新矩阵：

定义 1.11 (转置矩阵, Transpose Matrix)

给定一个 $m \times n$ 的矩阵 A ，其转置矩阵 A^T 是一个 $n \times m$ 的矩阵，其满足：

$$(A^T)(i, j) = A(j, i)$$

考虑如下的矩阵： $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$ 其转置矩阵为：

$$A^T = \begin{bmatrix} 1 & 4 \\ 2 & 5 \\ 3 & 6 \end{bmatrix}$$

可以看到，转置矩阵可能改变矩阵的形式。

定理 1.12 (转置矩阵的运算法则)

假设下面表达式中的运算都是良定义的。

1. $(A^T)^T = A$
2. $(cA)^T = cA^T$
3. $(A + B)^T = A^T + B^T$
4. $(AB)^T = B^T A^T$
5. $(A^{-1})^T = (A^T)^{-1}$

证明： 我们只证明最后两个。

- $(AB)^T = B^T A^T$ 的证明.

注意到对任意的 i, j 有:

$$(AB)^T(i, j) = AB(j, i) = \sum_{l=1}^k A(j, l)B(l, i) = \sum_{l=1}^k B^T(i, l)A^T(l, j) = B^T A^T(i, j).$$

这里假定 k 是 A 的列数。

- $(A^{-1})^T = (A^T)^{-1}$ 的证明.

利用上述结论有:

$$\begin{aligned} (A^{-1})^T A^T &= (AA^{-1})^T = I, \\ A^T (A^{-1})^T &= (A^{-1}A)^T = I. \end{aligned}$$

□

关于 $(AB)^T = B^T A^T$ 的一个简单理解。 注意到:

$$\underbrace{\begin{bmatrix} 1 & 2 & 3 \\ -1 & 1 & 2 \\ 3 & -1 & 1 \end{bmatrix}}_A \underbrace{\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}}_x = x_1 \begin{bmatrix} 1 \\ -1 \\ 3 \end{bmatrix} + x_2 \begin{bmatrix} 2 \\ 1 \\ -1 \end{bmatrix} + x_3 \begin{bmatrix} 3 \\ 2 \\ 1 \end{bmatrix} = \begin{bmatrix} x_1 + 2x_2 + 3x_3 \\ 2x_3 + x_2 - x_1 \\ 3x_1 + x_3 - x_2 \end{bmatrix}$$

即: Ax 是对矩阵 A 的列进行的线性组合。另一方面:

$$\begin{aligned} \underbrace{\begin{bmatrix} x_1 & x_2 & x_3 \end{bmatrix}}_{x^T} \underbrace{\begin{bmatrix} 1 & -1 & 3 \\ 2 & 1 & -1 \\ 3 & 2 & 1 \end{bmatrix}}_{A^T} &= x_1 \begin{bmatrix} 1 & -1 & 3 \end{bmatrix} + x_2 \begin{bmatrix} 2 & 1 & -1 \end{bmatrix} + x_3 \begin{bmatrix} 3 & 2 & 1 \end{bmatrix} \\ &= \begin{bmatrix} x_1 + 2x_2 + 3x_3 & 2x_3 + x_2 - x_1 & 3x_1 + x_3 - x_2 \end{bmatrix} \end{aligned}$$

即: $x^T A^T$ 是对矩阵 A^T 的行进行的线性组合。从而: $(Ax)^T = x^T A^T$ 。

对称矩阵。 考虑如下矩阵：

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 5 \\ 3 & 5 & 6 \end{bmatrix}$$

我们有：

$$A^T = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 5 \\ 3 & 5 & 6 \end{bmatrix} = A$$

我们称这样的矩阵为**对称矩阵**。

定义 1.13 (对称矩阵, Symmetric Matrix)

一个 $n \times n$ 的方阵 S 如果满足其转置矩阵和其相等，即：

$$S^T = S$$

则称 S 为**对称矩阵**。

例 1.14

一个**无向图** G 由顶点和相连的边组成，令表示顶点和边的集合分别为 V 和 $E(G = (V, E))$ ，其中每条边 $e \in E$ 可以表示为 V 的一个大小为 2 的子集，如 $\{u, v\}$ 。

为了方便描述，不妨令顶点集由 $[n] = \{1, 2, \dots, n\}$ 来表示。则 G 可以由如下的一个 $n \times n$ 的矩阵 $A = A(G)$ 来表示：

$$A(i, j) = \begin{cases} 1 & \text{如果 } \{i, j\} \in E \\ 0 & \text{其他} \end{cases}$$

我们称 A 是图 G 的**邻接矩阵**，不难验证 A 是对称的。

下述引理阐述了对称矩阵的一些性质。

定理 1.15

关于对称矩阵，我们有下列结论：

1. 若 A 是一个可逆的对称矩阵，则 A^{-1} 也是对称矩阵。
2. 对任意矩阵 A (不需要一定是方阵)， AA^T 和 A^TA 都是对称矩阵。

证明： 由引理1.12直接可得。

□

转置矩阵跟内积的关系。 在之前的课程中我们介绍了向量点积的概念，下述引理说明点积也可以利用转置矩阵来表示：

定理 1.16

1. 令 $\mathbf{x}, \mathbf{y}$ 是两个 $n \times 1$ 的矩阵, 即 $\mathbb{R}^n$ 中的列向量, 则:

$$\mathbf{x} \cdot \mathbf{y} = \mathbf{x}^T \mathbf{y}$$

2. 令 A 是一个 $m \times n$ 的矩阵, $\mathbf{x} \in \mathbb{R}^n, \mathbf{y} \in \mathbb{R}^m$, 则:

$$A\mathbf{x} \cdot \mathbf{y} = \mathbf{x} \cdot A^T \mathbf{y}$$

证明: 由定义直接可得。 □

置换矩阵. 我们直接给出**置换矩阵**的定义。

定义 1.17

置换矩阵 P 是将单位矩阵 I 的行进行重排列得到的矩阵。

所有 3×3 的置换矩阵为:

$$\begin{aligned} I &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} & P_{21} &= \begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} & P_{32}P_{21} &= \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix} \\ P_{31} &= \begin{bmatrix} 0 & 0 & 1 \\ 0 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix} & P_{32} &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} & P_{21}P_{32} &= \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \end{aligned}$$

命题 1.18

$n \times n$ 的置换矩阵一共有 $n!$ 个。

证明: 只需注意到 n 个元素不同的排列有 $n!$ 个即可。 □

置换矩阵与解线性方程组. 考察如下的方程组:

$$\begin{aligned} 4x_2 - 2x_3 &= 2 \\ 4x_1 + 9x_2 - 3x_3 &= 8 \\ -2x_1 - 3x_2 + 7x_3 &= 10 \end{aligned}$$

第一个方程 x_1 的系数为 0, 但后两个方程则不是。为了能够消元, 我们需要将后两个方程之一换到最上面, 如:

$$\begin{aligned} 4x_1 + 9x_2 - 3x_3 &= 8 \\ 4x_2 - 2x_3 &= 2 \\ -2x_1 - 3x_2 + 7x_3 &= 10 \end{aligned}$$

即从矩阵的角度来说，我们需要：

$$\begin{bmatrix} 0 & 4 & -2 \\ 4 & 9 & -3 \\ -2 & -3 & 7 \end{bmatrix} \Rightarrow \begin{bmatrix} 4 & 9 & -3 \\ 0 & 4 & -2 \\ -2 & -3 & 7 \end{bmatrix}$$

从线性组合的角度来看，我们有：

$$\underbrace{\begin{bmatrix} 0 & 1 & 0 \\ 1 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix}}_{P_{21}} \begin{bmatrix} 0 & 4 & -2 \\ 4 & 9 & -3 \\ -2 & -3 & 7 \end{bmatrix} = \begin{bmatrix} 4 & 9 & -3 \\ 0 & 4 & -2 \\ -2 & -3 & 7 \end{bmatrix}$$

一般来说，对于如下的一个置换矩阵 P_{ij} (交换单位矩阵第 i 行和第 j 行得到的矩阵)，我们有

$$\begin{array}{l} \text{第 } i \text{ 行} \\ \text{第 } j \text{ 行} \end{array} \underbrace{\begin{bmatrix} 1 & \cdots & 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & \cdots & 1 \end{bmatrix}}_{P_{ij}} \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_i \\ \vdots \\ \mathbf{a}_j \\ \vdots \\ \mathbf{a}_n \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_j \\ \vdots \\ \mathbf{a}_i \\ \vdots \\ \mathbf{a}_n \end{bmatrix}$$

置换矩阵的逆矩阵. 我们先考虑上述提到的置换矩阵 P_{ij} ，其是由单位矩阵仅仅交换第 i 行和第 j 行所得到的，不难发现我们有：

$$\begin{aligned} P_{ij} &= P_{ij}^T \\ P_{ij}^T P_{ij} &= P_{ij} P_{ij}^T = P_{ij} P_{ij} = I \end{aligned}$$

从而：

$$P_{ij}^{-1} = P_{ij} = P_{ij}^T$$

有趣的是，所有的置换矩阵都是可逆的，而且其逆矩阵恰好都是自己的转置矩阵！

定理 1.19

令 P 是一个置换矩阵，则 P 是可逆的，并且：

$$P^{-1} = P^T$$

证明： 注意到任意的置换矩阵 P ，其都表示成有限个形如置换矩阵 P_{ij} 的乘积，即：

$$P = P_{i_1 j_1} P_{i_2 j_2} \cdots P_{i_k j_k}$$

从而:

$$\begin{aligned} \mathbf{p}^T &= (\mathbf{p}_{i_1 j_1} \mathbf{p}_{i_2 j_2} \cdots \mathbf{p}_{i_k j_k})^T = \mathbf{p}_{i_k j_k}^T \mathbf{p}_{i_{k-1} j_{k-1}}^T \cdots \mathbf{p}_{i_1 j_1}^T = \mathbf{p}_{i_k j_k} \mathbf{p}_{i_{k-1} j_{k-1}} \cdots \mathbf{p}_{i_1 j_1} \\ \mathbf{p}^{-1} &= (\mathbf{p}_{i_1 j_1} \mathbf{p}_{i_2 j_2} \cdots \mathbf{p}_{i_k j_k})^{-1} = \mathbf{p}_{i_k j_k}^{-1} \mathbf{p}_{i_{k-1} j_{k-1}}^{-1} \cdots \mathbf{p}_{i_1 j_1}^{-1} = \mathbf{p}_{i_k j_k} \mathbf{p}_{i_{k-1} j_{k-1}} \cdots \mathbf{p}_{i_1 j_1} \end{aligned}$$

即:

$$\mathbf{p}^{-1} = \mathbf{p}^T$$

□

线性代数 (IV)

Lecturer: 杨启哲

Last modified: 2026 年 3 月 9 日

1 向量空间

我们先介绍一个基本的**向量空间** $\mathbb{R}^n$:

定义 1.1

空间 $\mathbb{R}^n$ 包含了所有如下的 n 维列向量 $\mathbf{v}$:

$$\mathbf{v} = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix}$$

其中对于任意的 $i \in [n]$, $v_i \in \mathbb{R}$, 这里的 $\mathbb{R}$ 是实数集。

简而言之, $\mathbb{R}^i$ 就是所有每个分量都是实数的 i 维列向量的全体。如果我们允许分量是复数, 那么我们可以定义复数域上的向量空间 $\mathbb{C}^n$:

定义 1.2

空间 $\mathbb{C}^n$ 包含了所有如下的 n 维列向量 $\mathbf{v}$:

$$\mathbf{v} = \begin{bmatrix} v_1 \\ \vdots \\ v_n \end{bmatrix}$$

其中对于任意的 $i \in [n]$, $v_i \in \mathbb{C}$, 这里的 $\mathbb{C}$ 是复数集。

例 1.3

1. $\begin{bmatrix} 1 \\ 2 \end{bmatrix}$ 是 $\mathbb{R}^2$ 中的一个元素, 通常我们喜欢用 xOy 平面来表示 $\mathbb{R}^2$, 每个向量都表示了一个点 (x, y) 。
2. $\begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$ 是 $\mathbb{R}^3$ 中的一个元素, 通常我们喜欢用三维空间来表示 $\mathbb{R}^3$, 每个向量都表示了一个点 (x, y, z) 。

3. $\begin{bmatrix} 1+2i \\ 3-4i \end{bmatrix}$ 则是 $\mathbb{C}^2$ 中的一个元素。

在 $\mathbb{R}^n$ 我们定义过两种运算：

1. 向量的加法运算：

$$\forall \mathbf{u}, \mathbf{v} \in \mathbb{R}^n, \text{ 有 } \mathbf{u} + \mathbf{v} = \begin{bmatrix} u_1 + v_1 \\ \vdots \\ u_n + v_n \end{bmatrix}$$

2. 向量的数乘运算：

$$\forall k \in \mathbb{R}, \mathbf{v} \in \mathbb{R}^n, \text{ 有 } k\mathbf{v} = \begin{bmatrix} kv_1 \\ \vdots \\ kv_n \end{bmatrix}$$

这两个运算具备的一个重要特点是，在运算后的结果仍然是 $\mathbb{R}^n$ 中的元素，即 $\mathbf{u} + \mathbf{v}, k\mathbf{v} \in \mathbb{R}^n$ 。这就是我们所说的这两个运算对于 $\mathbb{R}^n$ 是封闭的。除此以外，向量加法和数乘运算还具备如下的性质：

对向量加法来说：

1. 加法满足交换律：

$$\mathbf{u} + \mathbf{v} = \mathbf{v} + \mathbf{u}.$$

2. 加法满足结合律：

$$\mathbf{u} + (\mathbf{v} + \mathbf{w}) = (\mathbf{u} + \mathbf{v}) + \mathbf{w}.$$

3. 加法存在一个零元素（唯一的） $\mathbf{0} \in \mathbb{R}^n$ ，其满足 $\mathbf{u} + \mathbf{0} = \mathbf{u}$ 对任意的 $\mathbf{u} \in \mathbb{R}^n$ 。

4. 加法存在一个负元素（逆元），即对于任意的 $\mathbf{u} \in \mathbb{R}^n$ ，存在一个 $\mathbf{v} \in \mathbb{R}^n$ ，使得 $\mathbf{u} + \mathbf{v} = \mathbf{0}$ ，特别的，将 $\mathbf{v}$ 记为 $-\mathbf{u}$ 。

对数乘运算来说：

5. 数乘存在单位元 $1 \in \mathbb{R}$ ，使得 $1\mathbf{u} = \mathbf{u}$ 对于任意的 $\mathbf{u} \in \mathbb{R}^n$ 。

6. 数乘满足结合律：

$$c_1(c_2\mathbf{u}) = (c_1c_2)\mathbf{u}.$$

7. 数乘是线性的，即对于任意的 $c \in \mathbb{R}$ 和 $\mathbf{u}, \mathbf{v} \in \mathbb{R}^n$ 均有：

$$c(\mathbf{u} + \mathbf{v}) = c\mathbf{u} + c\mathbf{v}.$$

8. 数乘对于加法满足分配律，即对于任意的 $c_1, c_2 \in \mathbb{R}$ 和 $\mathbf{u} \in \mathbb{R}^n$ 均有：

$$(c_1 + c_2)\mathbf{u} = c_1\mathbf{u} + c_2\mathbf{u}.$$

我们将上述**向量空间**的概念进行一下扩展，不在局限于 $\mathbb{R}^n$ 和其上的这两种运算上：

定义 1.4 (向量空间, 或者线性空间)

令 V 是一个非空集合, 定义 V 上的两种封闭的运算:

1. V 上的加法运算:

$$\forall \mathbf{u}, \mathbf{v} \in V, \text{ 有 } \mathbf{u} + \mathbf{v} \in V.$$

2. V 在 $\mathbb{R}^a$ 上的数乘运算:

$$\forall k \in \mathbb{R}, \mathbf{v} \in V, \text{ 有 } k\mathbf{v} \in V.$$

并且这两种运算具备如下的性质:

1. 加法满足交换律:

$$\mathbf{u} + \mathbf{v} = \mathbf{v} + \mathbf{u}.$$

2. 加法满足结合律:

$$\mathbf{u} + (\mathbf{v} + \mathbf{w}) = (\mathbf{u} + \mathbf{v}) + \mathbf{w}.$$

3. 加法存在一个零元素 (唯一的) $\mathbf{0} \in V$, 其满足 $\mathbf{u} + \mathbf{0} = \mathbf{u}$ 对任意的 $\mathbf{u} \in V$ 。

4. 加法存在一个负元素 (逆元), 即对于任意的 $\mathbf{u} \in V$, 存在一个 $\mathbf{v} \in V$, 使得 $\mathbf{u} + \mathbf{v} = \mathbf{0}$, 特别的, 将 $\mathbf{v}$ 记为 $-\mathbf{u}$ 。

5. 数乘存在单位元 $1 \in \mathbb{R}$, 使得 $1\mathbf{u} = \mathbf{u}$ 对于任意的 $\mathbf{u} \in V$ 。

6. 数乘满足结合律:

$$c_1(c_2\mathbf{u}) = (c_1c_2)\mathbf{u}.$$

7. 数乘是线性的, 即对于任意的 $c \in \mathbb{R}$ 和 $\mathbf{u}, \mathbf{v} \in V$ 均有:

$$c(\mathbf{u} + \mathbf{v}) = c\mathbf{u} + c\mathbf{v}.$$

8. 数乘对于加法满足分配律, 即对于任意的 $c_1, c_2 \in \mathbb{R}$ 和 $\mathbf{u} \in V$ 均有:

$$(c_1 + c_2)\mathbf{u} = c_1\mathbf{u} + c_2\mathbf{u}.$$

则称 V 是 $\mathbb{R}$ 上的一个**向量空间**或者**线性空间**^{bc}; 特别的, 在讨论 V 的时候, 其中的元素被称为**向量**, 零元素和负元素被称为**零向量**和**负向量**。

^a这里的数域可以不一定是 $\mathbb{R}$, 是复数域 $\mathbb{C}$ 上的满足四则运算封闭的子集 $\mathbb{F}$ 就可以, 这样定义的就是 $\mathbb{F}$ 上的线性空间, 但本课程关注的主要还是**实数集 $\mathbb{R}$ 上的线性空间**。

^b实际上, 如果数域不同, 也不能算是相同的线性空间。

^c后面, 我们将不加区分的滥用**向量空间**和**线性空间**的称呼。

下面我们再通过一些其他的例子来理解线性空间的概念:

- **只有一个元素的线性空间**: 考察如下的集合 $\mathbb{Z} = \{0\}$, 其只有一个**零元素**, 显然我们可以定义上面

的加法和在 $\mathbb{R}$ 上的运算:

1. 加法: $0 + 0 = 0$ 。
2. 数乘: $\forall c \in \mathbb{R}, c0 = 0$ 。

显然 Z 符合定义1.4中的所有条件, 因此 Z 是一个线性空间¹。

- **由所有 $m \times n$ 矩阵组成的线性空间:** 对于 $m, n \geq 1$, 令 $M_{m \times n}(\mathbb{R})$ 表示所有的 $m \times n$ 的实数矩阵的集合:
 - o 其中的**加法**就定义成**矩阵的加法**。
 - o 其中的**数乘**就定义成**矩阵在 $\mathbb{R}$ 上的数乘**。

注意到:

1. 矩阵的加法满足交换律和结合律。
2. 其零元为全零矩阵 $O_{m \times n}$, 即所有的入口都是 0。
3. 对于任意的 $M \in M_{m \times n}(\mathbb{R})$, 其负元 $-M$ 为: $-M = (-1)M$ 。
4. 数乘的单位元就是 $1 \in \mathbb{R}$ 。
5. 数乘满足结合律和分配律。
6. 数乘满足线性性质。

因此 $M_{m \times n}(\mathbb{R})$ 是 $\mathbb{R}$ 上的线性空间。

- **无限维向量 (?) 组成的线性空间 $\mathbb{R}^\infty$:** 显然 $\mathbb{R}^n$ 都是 $\mathbb{R}$ 上的线性空间, 那如果将 $n \rightarrow \infty$, 则 $\mathbb{R}^\infty$ 应该是这样的:

1. $\mathbb{R}^\infty = \{(x_1, x_2, \dots) \mid \text{对所有的 } i, x_i \in \mathbb{R}\}$ 。
2. $c(x_1, x_2, \dots) = (cx_1, cx_2, \dots)$ 。
3. $(x_1, x_2, \dots) + (y_1, y_2, \dots) = (x_1 + y_1, x_2 + y_2, \dots)$ 。

实际上我们可以发现, $(x_1, x_2, \dots)$ 实际上定义的是一个 $\mathbb{N} \rightarrow \mathbb{R}$ 上的函数!

定义集合 F :

$$F = F(\mathbb{N} \rightarrow \mathbb{R}) = \{f \mid f: \mathbb{N} \rightarrow \mathbb{R}\}$$

- o 给定 $f_1, f_2 \in F$, 定义函数 $f_1 + f_2: \mathbb{N} \rightarrow \mathbb{R}$ 为:

$$(f_1 + f_2)(x) = f_1(x) + f_2(x)$$

- o 对于任意的 $f \in F$ 和 $c \in \mathbb{R}$, 定义函数 $cf: \mathbb{N} \rightarrow \mathbb{R}$ 为:

$$(cf)(x) = cf(x)$$

不难验证, F 上的加法和数乘满足线性空间的所有条件, 因此 F 是 $\mathbb{R}$ 上的一个线性空间。

我们再来考虑如下一个特殊的例子。

¹ $\mathbb{R}^0$ 可以被认为是 Z 的一个特殊情况。

例 1.5 (一个特殊的例子)

考虑如下的集合:

$$\mathcal{V} = \mathbb{R}^+ = \{x \mid x \in \mathbb{R} \text{ and } x > 0\}$$

- 对于任意的 $x, y \in \mathcal{V}$, 定义加法运算 $\oplus$: $x \oplus y$ 为 $x \oplus y = xy$ 。
- 对于任意的 $x \in \mathcal{V}$ 和 $c \in \mathbb{R}$, 定义数乘运算 $\otimes$: $c \otimes x$ 为 $c \otimes x = x^c$ 。

可以验证, $\mathcal{V}$ 是 $\mathbb{R}$ 上的线性空间。

线性空间的一些性质: 我们下面介绍线性空间上的一些普遍性质。

引理 1.6

零向量 $\mathbf{0}$ 是唯一的。

证明: 反设存在两个零向量 $\mathbf{0}_1, \mathbf{0}_2$, 则有:

$$\mathbf{0}_1 = \mathbf{0}_1 + \mathbf{0}_2 = \mathbf{0}_2 + \mathbf{0}_1 = \mathbf{0}_2$$

□

引理 1.7

对于任何向量 $\mathbf{v}$, 其负向量是唯一的。

证明: 反设存在两个负向量 $\mathbf{v}_1, \mathbf{v}_2$, 则有:

$$\mathbf{v}_1 = \mathbf{v}_1 + \mathbf{0} = \mathbf{v}_1 + (\mathbf{v} + \mathbf{v}_2) = (\mathbf{v}_1 + \mathbf{v}) + \mathbf{v}_2 = \mathbf{0} + \mathbf{v}_2 = \mathbf{v}_2$$

□

引理 1.8 (向量的消去律 (Cancellation Law))

如果 $\mathbf{u} + \mathbf{v} = \mathbf{u} + \mathbf{w}$, 则 $\mathbf{v} = \mathbf{w}$ 。

证明: 由:

$$\mathbf{v} = \mathbf{0} + \mathbf{v} = (-\mathbf{u} + \mathbf{u}) + \mathbf{v} = -\mathbf{u} + (\mathbf{u} + \mathbf{v}) = -\mathbf{u} + (\mathbf{u} + \mathbf{w}) = (-\mathbf{u} + \mathbf{u}) + \mathbf{w} = \mathbf{0} + \mathbf{w} = \mathbf{w}$$

□

引理 1.9

1. $0\mathbf{v} = \mathbf{0}$ 。
2. $(-1)\mathbf{v} = -\mathbf{v}$ 。
3. $-(\mathbf{u} + \mathbf{v}) = (-\mathbf{u}) + (-\mathbf{v})$ 。
4. $c\mathbf{0} = \mathbf{0}$ 。
5. $c(-\mathbf{u}) = (-c)\mathbf{u} = -(\mathbf{cu})$ 。

证明:

1. $0\mathbf{v} = (0 + 0)\mathbf{v} = 0\mathbf{v} + 0\mathbf{v}$, 由消去律可得 $0\mathbf{v} = \mathbf{0}$ 。
2. $(-1)\mathbf{v} + \mathbf{v} = (-1)\mathbf{v} + 1\mathbf{v} = (-1 + 1)\mathbf{v} = \mathbf{0}$, 从而 $(-1)\mathbf{v} = -\mathbf{v}$ 。
3. $((-\mathbf{u}) + (-\mathbf{v})) + (\mathbf{u} + \mathbf{v}) = (-\mathbf{u} + \mathbf{u}) + (-\mathbf{v} + \mathbf{v}) = \mathbf{0}$, 从而 $-(\mathbf{u} + \mathbf{v}) = (-\mathbf{u}) + (-\mathbf{v})$ 。
4. $c\mathbf{0} = c(\mathbf{0} + \mathbf{0}) = c\mathbf{0} + c\mathbf{0}$, 从而 $c\mathbf{0} = \mathbf{0}$ 。
5. $\mathbf{cu} + (-c)\mathbf{u} = \mathbf{0u} = c(\mathbf{u} + (-\mathbf{u})) = \mathbf{cu} + c(-\mathbf{u}) = \mathbf{0}$, 从而 $c(-\mathbf{u}) = (-c)\mathbf{u} = -(\mathbf{cu})$ 。

□

注 1.10

上述引理1.9阐述的一个重要的点是, 一个向量 $\mathbf{u}$ 的负向量 $-\mathbf{u}$ 实际上就是 $(-1)\mathbf{u}$, 因此在后续的过程中 $-\mathbf{u}$ 和 $(-1)\mathbf{u}$ 可以互相替换。

2 子空间

我们来考察 $\mathbb{R}^2$ 上的两个子集:

1. $L_1 = \{(x, 0) \mid x \in \mathbb{R}\}$ 。
2. $L_2 = \{(x, x + 1) \mid x \in \mathbb{R}\}$ 。

显然 L_1, L_2 都是 $\mathbb{R}^2$ 的子集, 但是对于定义的两组运算上:

- L_1 对于加法和数乘运算是封闭的。
- L_2 对于加法和数乘运算不是封闭的。

更进一步可以发现, L_1 上的加法和数乘运算满足线性空间的所有性质, 从而 L_1 也是 $\mathbb{R}$ 上的**线性空间**。这给了我们一种构造线性空间的方法, 即寻找线性空间的子集, 使得这个子集对于线性空间的运算是封闭的, 这样的子集被称为**子空间**。下面我们给出正式的定义:

定义 2.1 (子空间 (Subspace))

给定一个向量空间 V , 如果 W 是 V 的一个**非空子集**, 并且 W 满足如下两个条件:

1. 对于任意的 $\mathbf{u}, \mathbf{v} \in W$, $\mathbf{u} + \mathbf{v} \in W$ 。
2. 对于任意的 $c \in \mathbb{R}$ 和 $\mathbf{u} \in W$, $c\mathbf{u} \in W$ 。

则称 W 是 V 的一个**子空间**。

下面定理告诉我们, 子空间也是一个线性空间:

定理 2.2

如果 W 是向量空间 V 的一个子空间, 则 W 对于 V 上定义加法和数乘运算构成一个向量空间。

证明: 只需验证 W 上的加法和数乘运算满足线性空间的所有条件即可。 □

我们同样给出一些子空间的例子:

- 考察如下集合:

$$W = \{(x, y, 0) \mid x, y \in \mathbb{R}\}$$

则子集 $W \subseteq \mathbb{R}^3$ 是 $\mathbb{R}^3$ 的一个子空间, 原因在于:

- 对于任意的 $\mathbf{u} = (x_1, y_1, 0), \mathbf{v} = (x_2, y_2, 0) \in W$, $\mathbf{u} + \mathbf{v} = (x_1 + x_2, y_1 + y_2, 0) \in W$ 。
- 对于任意的 $c \in \mathbb{R}$ 和 $\mathbf{u} = (x, y, 0) \in W$, $c\mathbf{u} = (cx, cy, 0) \in W$ 。

并且不难验证, W 是 $\mathbb{R}$ 上的一个线性空间。

- 考察如下由所有的 $n \times n$ 矩阵中的对角矩阵组成的集合:

$$\mathcal{D}_n(\mathbb{R}) := \{A \in M_{n \times n}(\mathbb{R}) \mid A = \text{diag}(x_1, \dots, x_n)\}.$$

则 $\mathcal{D}_n(\mathbb{R})$ 是 $M_{n \times n}(\mathbb{R})$ 的一个子空间, 同样其也是一个 $\mathbb{R}$ 上的线性空间。

子空间的一些性质: 我们下面介绍子空间上的一些普遍性质。

引理 2.3

如果 W 是线性空间 V 的一个子空间, 则 $\mathbf{0} \in W$ 。

证明: 取 $\mathbf{w} \in W$, $0\mathbf{w} = \mathbf{0} \in W$. □

引理 2.4

令 $\mathbf{u}, \mathbf{v} \in W$, 则所有 $\mathbf{u}, \mathbf{v}$ 的线性组合 $c\mathbf{u} + d\mathbf{v}$ 均在 W 中。

证明：由子空间的定义，对于任意的 $c, d \in \mathbb{R}$ ，均有：

$$cu, dv \in \mathcal{W}$$

从而：

$$cu + dv \in \mathcal{W}$$

□

引理 2.5

令 $\mathcal{V}$ 是一个线性空间， $\mathcal{W}$ 是 $\mathcal{V}$ 的一个子集。则 $\mathcal{W}$ 是 $\mathcal{V}$ 的一个子空间当且仅当：对于任意的 $k \geq 0$, $c_1, \dots, c_k \in \mathbb{R}$ 和 $v_1, \dots, v_k \in \mathcal{W}$ 均有：

$$c_1 v_1 + \dots + c_k v_k \in \mathcal{W}$$

特别的，当 $k = 0$ 时我们令上述和为 0.

证明：充分性是显然的，直接可由定义得到；必要性可通过引理2.4进行归纳得到。

□

2.1 如何生成一个子空间？

注 2.6

在后续的讨论中，我们会省略掉“在 $\mathbb{R}$ 上的线性空间”，而简单的称为是“线性空间”或者“向量空间”。这是因为在本课程的学习中，我们暂时不会涉及到其他数域上的线性空间；同时，当前后文没有歧义的时候，也会经常这么直接表示。

由前面的讨论可以知道，给定一个线性空间 $\mathcal{V}$ 和其上的一个非空子集 $S \subseteq \mathcal{V}$ ， S 不一定是一个子空间，当然也不是一个线性空间。所以我们会产生如下的一个问题：

问题

如何从一个线性空间 $\mathcal{V}$ 的一个非空子集 S 生成一个包含 S 的子空间？

事实上，这个问题的答案非常简单，我们只需要包含 S 中的元素的所有线性组合即可。我们定义如下的操作 $\text{span}(\cdot)$ ：

$$\text{span}(S) := \{c_1 v_1 + \dots + c_k v_k \mid k \geq 0, c_1, \dots, c_k \in \mathbb{R}, v_1, \dots, v_k \in S\}$$

由于运算的封闭性，显然 $\text{span}(S)$ 是 $\mathcal{V}$ 的一个子集。下面的定理进一步说明了， $\text{span}(S)$ 还是一个 $\mathcal{V}$ 中包含 S 的一个最小子空间：

定理 2.7

令 $S \subseteq V$, 则 $\text{span}(S)$ 是 V 的包含 S 的最小子空间, 即:

1. $\text{span}(S)$ 是 V 的子空间。
2. 令 $W \subseteq V$ 是一个 V 的子空间, 且 $S \subseteq W$, 则 $\text{span}(S) \subseteq W$ 。

证明: 由引理2.5可知, $\text{span}(S)$ 是 V 的子空间; 对于第二点, 只需要注意到 W 也是个线性空间, 其对加法和数乘运算是封闭的, 从而 $\text{span}(S) \subseteq W$ 。□

例 2.8

考察 $\mathbb{R}^3$ 上的如下集合:

1. $S_1 = \{(1, 0, 0), (0, 1, 0)\}$ 。
2. $S_2 = \{(1, 0, 0), (0, 1, 0), (0, 0, 1)\}$ 。
3. $S_3 = \{(x, y, z) \mid x \leq y, (x, y, z) \in \mathbb{R}^3\}$ 。

则我们有:

1. $\text{span}(S_1) = \{\lambda(1, 0, 0) + \mu(0, 1, 0) \mid \lambda, \mu \in \mathbb{R}\} = \{(x, y, 0) \mid x, y \in \mathbb{R}\}$ 。
2. $\text{span}(S_2) = \{\lambda(1, 0, 0) + \mu(0, 1, 0) + \eta(0, 0, 1) \mid \lambda, \mu, \eta \in \mathbb{R}\} = \mathbb{R}^3$ 。
3. 注意到:

$$(0, 1, 0), (0, 0, 1) \in S_3$$

$$1(1, 2, 0) + (-1)(0, 2, 0) = (1, 0, 0) \in \text{span}(S_3)$$

从而 $\text{span}(S_3) = \text{span}(S_2) = \mathbb{R}^3$ 。

并且可以很轻松的验证对所有的 i , $\mathbb{R}^3$ 包含 S_i 的最小子空间为 $\text{span}(S_i)$ 。

矩阵 A 上的线性空间: 下面这部分没有出现在课本上, 但这会是我们理解矩阵与解方程组起到非常重要的作用, 因此请各位同学一定要记住这部分内容。给定一个 $m \times n$ 的矩阵 A , 我们可以写成如下的形式:

$$A = \begin{bmatrix} \mathbf{a}_1 & \mathbf{a}_2 & \cdots & \mathbf{a}_n \end{bmatrix}$$

其中每个 $\mathbf{a}_i$ 是一个 $m \times 1$ 的列向量, 我们称其为矩阵 A 的列向量, 进而可以定义如下的集合:

1. A 的列空间 $C(A)$:

$$C(A) = \{A\mathbf{x} \mid \mathbf{x} \in \mathbb{R}^n\}$$

即 $C(A)$ 是所有由 A 的列向量的线性组合而成的集合。

2. A 的零空间 $\mathbf{N}(A)$:

$$\mathbf{N}(A) = \{\mathbf{x} \mid A\mathbf{x} = \mathbf{0}\}$$

即 $\mathbf{N}(A)$ 是所有使得 $A\mathbf{x} = \mathbf{0}$ 的 $\mathbf{x}$ 的集合。

3. A 的行空间 $\mathbf{C}(A^T)$: 我们用 A^T 的列空间 来定义 A 的行空间²。

4. A 的左零空间 $\mathbf{N}(A^T)$: 我们用 A^T 的零空间 来定义 A 的左零空间。

例 2.9

给定如下的矩阵:

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 4 & 6 \end{bmatrix} \quad \text{和其转置矩阵} \quad A^T = \begin{bmatrix} 1 & 2 \\ 2 & 4 \\ 3 & 6 \end{bmatrix}$$

则:

1. 其列空间 $\mathbf{C}(A)$ 为:

$$\mathbf{C}(A) = \{A\mathbf{x} \mid \mathbf{x} \in \mathbb{R}^3\} = \text{span} \left(\left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \begin{bmatrix} 2 \\ 4 \end{bmatrix}, \begin{bmatrix} 3 \\ 6 \end{bmatrix} \right\} \right) = \text{span} \left(\left\{ \begin{bmatrix} 1 \\ 2 \end{bmatrix} \right\} \right).$$

2. 其零空间 $\mathbf{N}(A)$ 为:

$$\mathbf{N}(A) = \{\mathbf{x} \mid A\mathbf{x} = \mathbf{0}\} = \text{span} \left(\left\{ \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \begin{bmatrix} -3 \\ 0 \\ 1 \end{bmatrix} \right\} \right).$$

3. 其行空间 $\mathbf{C}(A^T)$ 为:

$$\mathbf{C}(A^T) = \{A^T\mathbf{x} \mid \mathbf{x} \in \mathbb{R}^2\} = \text{span} \left(\left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \begin{bmatrix} 2 \\ 4 \\ 6 \end{bmatrix} \right\} \right) = \text{span} \left(\left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} \right\} \right).$$

4. 其左零空间 $\mathbf{N}(A^T)$ 为:

$$\mathbf{N}(A^T) = \{\mathbf{x} \mid A^T\mathbf{x} = \mathbf{0}\} = \text{span} \left(\left\{ \begin{bmatrix} -2 \\ 1 \end{bmatrix}, \begin{bmatrix} -3 \\ 0 \end{bmatrix} \right\} \right).$$

不难验证, $\mathbf{C}(A^T), \mathbf{N}(A)$ 都是 $\mathbb{R}^n$ 的子空间, $\mathbf{C}(A), \mathbf{N}(A^T)$ 都是 $\mathbb{R}^m$ 的子空间:

²这样定义的方法保证了尽管想从行向量去进行考虑, 但形式上依旧是列向量。

定理 2.10

令 A 是一个 $m \times n$ 的矩阵, 则:

1. $C(A)$ 是 $\mathbb{R}^m$ 的子空间。
2. $N(A)$ 是 $\mathbb{R}^n$ 的子空间。
3. $C(A^T)$ 是 $\mathbb{R}^n$ 的子空间。
4. $N(A^T)$ 是 $\mathbb{R}^m$ 的子空间。

这四个空间与方程 $Ax = b$ 的解有着密切的联系, 在本节的最后我们仅仅展示一个例子:

定理 2.11

令 A 是一个 $m \times n$ 的矩阵, $b \in \mathbb{R}^m$, 则:

$$Ax = b \text{ 有解当且仅当 } b \in C(A).$$

证明: 令矩阵 A 的列向量为 $a_1, \dots, a_n$, 则:

$$\begin{aligned} Ax = b \text{ 有解} &\Leftrightarrow \exists x_1, \dots, x_n \in \mathbb{R}, \text{ 使得 } b = x_1 a_1 + \dots + x_n a_n. \\ &\Leftrightarrow b \in \text{span}(\{a_1, \dots, a_n\}) \\ &\Leftrightarrow b \in C(A) \end{aligned}$$

□

线性代数 (V)

Lecturer: 杨启哲

Last modified: 2026 年 3 月 31 日

1 线性相关与线性无关

考察 $\mathbb{R}^3$ 上的如下四个向量:

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{v}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_3 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \quad \mathbf{v}_4 = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}.$$

- 对于 $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_3$ 来说, 我们可以用其中两个向量的线性组合来表示另一个向量, 如:

$$\mathbf{v}_3 = \mathbf{v}_1 + \mathbf{v}_2.$$

- 对于 $\mathbf{v}_1, \mathbf{v}_2, \mathbf{v}_4$ 来说, 我们无法用其中两个向量的线性组合来表示另一个向量, 换句话说:

$$c_1\mathbf{v}_1 + c_2\mathbf{v}_2 + c_4\mathbf{v}_4 = \mathbf{0} \quad \text{当且仅当} \quad c_1 = c_2 = c_4 = 0.$$

我们将上述第一种这样可以互相表示的一组向量称为线性相关的, 而第二种这样无法用其中某些向量的线性组合来表示的一组向量称为线性无关的。

为了方便叙述, 在后面的讨论中, 如果没有明确指明, 则我们固定一个在 $\mathbb{R}$ 上的线性空间 V 进行讨论。我们称 V 上的一组向量 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 为一个向量组。下面给出线性无关和线性相关正式的定义:

定义 1.1 (线性无关 (Linearly Independent))

给定一个向量组 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 。如果对于任意的 $c_1, \dots, c_n \in \mathbb{R}$, 当且仅当 $c_1 = \dots = c_n = 0$ 时有:

$$c_1\mathbf{v}_1 + \dots + c_n\mathbf{v}_n = \mathbf{0}$$

则称 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 是线性无关的。

定义 1.2 (线性相关 (Linearly Dependent))

给定一个向量组 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 。如果存在 $c_1, \dots, c_n \in \mathbb{R}$ 满足至少一个 $c_i \neq 0$, 使得:

$$c_1\mathbf{v}_1 + \dots + c_n\mathbf{v}_n = \mathbf{0}$$

则称 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 是线性相关的。

一些例子: 我们给出一些例子来进一步理解这两个概念。

例 1.3

考察 $\mathbb{R}^3$ 上的一些向量:

1. $\{(1, 0, 0), (0, 1, 0), (0, 0, 1)\}$ 是线性无关 的。
2. $\{(1, 0, 0), (1, 1, 0)\}$ 是线性无关 的。
3. $\{(2, 2, 0), (1, 1, 0)\}$ 是线性相关 的。
4. $\{(1, 0, 0), (0, 1, 0), (0, 0, 1), (1, 1, 1)\}$ 是线性相关 的。

例 1.4

我们再给出两个特殊的例子:

1. 只包含一个非零向量 $\mathbf{v}$ 的向量组是线性无关 的, 因为:

$$c\mathbf{v} = \mathbf{0} \quad \text{当且仅当} \quad c = 0.$$

2. 如果一个向量组 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 包含 $\mathbf{0}$ (不妨令为 $\mathbf{v}_1$), 则该向量组是线性相关 的, 这是因为:

$$c\mathbf{v}_1 (= \mathbf{0}) + 0\mathbf{v}_2 + \dots + 0\mathbf{v}_n = \mathbf{0} \quad \text{对任意 } c \in \mathbb{R} \text{ 都成立.}$$

线性相关和线性无关性的一些性质: 我们首先给出关于这两个性质的一些刻画:

引理 1.5

给定一个向量组 $\mathcal{A} = \{\mathbf{v}_1, \dots, \mathbf{v}_n\}$:

1. 若 $\mathcal{A}$ 是线性无关的, 则 $\mathcal{A}$ 的任何一个子集都是线性无关 的。
2. 向量组 $\mathcal{A}$ 是线性相关的当且仅当至少有一个 $\mathbf{v}_i$ 可以表示成其余向量的线性组合。

证明:

1. 反设存在 $\mathcal{A}' = \{\mathbf{v}_{i_1}, \dots, \mathbf{v}_{i_k}\} \subseteq \mathcal{A}$ 是线性相关的, 则存在不全为 0 的 $c_1, \dots, c_k$ 使得:

$$c_1\mathbf{v}_{i_1} + \dots + c_k\mathbf{v}_{i_k} = \mathbf{0}.$$

则令:

$$c'_i = \begin{cases} c_i, & i \in \{i_1, \dots, i_k\}, \\ 0, & i \notin \{i_1, \dots, i_k\}, \end{cases}$$

则有:

$$c'_1\mathbf{v}_1 + \dots + c'_n\mathbf{v}_n = \mathbf{0}.$$

与 $\mathcal{A}'$ 是线性无关的矛盾。

2. ($\Rightarrow$) 若 $\mathcal{A}$ 是线性相关的, 则存在不全为 0 的 $c_1, \dots, c_n$ 使得:

$$c_1 \mathbf{v}_1 + \dots + c_n \mathbf{v}_n = \mathbf{0}.$$

不妨设 $c_1 \neq 0$, 则有:

$$\mathbf{v}_1 = -\frac{c_2}{c_1} \mathbf{v}_2 - \dots - \frac{c_n}{c_1} \mathbf{v}_n.$$

($\Leftarrow$) 若至少有一个 $\mathbf{v}_i$ 可以表示成其余向量的线性组合, 不妨设 $\mathbf{v}_1$ 可以表示成其余向量的线性组合, 则存在 $c_2, \dots, c_n$ 使得:

$$\mathbf{v}_1 = c_2 \mathbf{v}_2 + \dots + c_n \mathbf{v}_n. \quad \Rightarrow \quad 1\mathbf{v}_1 + (-c_2)\mathbf{v}_2 + \dots + (-c_n)\mathbf{v}_n = \mathbf{0}.$$

□

下面的定理说明, 矩阵 A 上的列向量组 是否线性相关决定了对应方程 $A\mathbf{x} = \mathbf{b}$ 解的情况:

引理 1.6

给定一个矩阵 A , 则:

1. 其列向量是线性无关的当且仅当方程 $A\mathbf{x} = \mathbf{0}$ 只有**唯一解** $\mathbf{x} = \mathbf{0}$ 。
2. 其列向量是线性相关的当且仅当方程 $A\mathbf{x} = \mathbf{0}$ 有**非零解**。

证明: 令 A 表示为:

$$A = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_n].$$

则 $A\mathbf{x} = \mathbf{0}$ 可以表示为:

$$x_1 \mathbf{a}_1 + \dots + x_n \mathbf{a}_n = \mathbf{0}.$$

1. $\mathbf{a}_1, \dots, \mathbf{a}_n$ 是线性无关的当且仅当 $x_1 = \dots = x_n = 0$, 即方程 $A\mathbf{x} = \mathbf{0}$ 只有**唯一解** $\mathbf{x} = \mathbf{0}$ 。
2. $\mathbf{a}_1, \dots, \mathbf{a}_n$ 是线性相关的当且仅当存在不全为 0 的 $c_1, \dots, c_n$ 使得:

$$c_1 \mathbf{a}_1 + \dots + c_n \mathbf{a}_n = \mathbf{0}.$$

则 $\mathbf{x} = (c_1, \dots, c_n)$ 为方程 $A\mathbf{x} = \mathbf{0}$ 的**非零解**。

□

线性无关的另一个好处是**唯一的表示**。考察一组线性无关的向量组 $\mathcal{A} = \{\mathbf{v}_1, \dots, \mathbf{v}_k\}$ 和一个向量 $\mathbf{v}$, 如果存在两组不同的数 $c_1, \dots, c_k$ 和 $d_1, \dots, d_k$ 使得:

$$c_1 \mathbf{v}_1 + \dots + c_k \mathbf{v}_k = d_1 \mathbf{v}_1 + \dots + d_k \mathbf{v}_k = \mathbf{v},$$

则有:

$$(c_1 - d_1) \mathbf{v}_1 + \dots + (c_k - d_k) \mathbf{v}_k = \mathbf{0}.$$

这意味着 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 是线性相关的, 与前提矛盾。这表示**给定一个线性无关的向量组, 如果一个向量可以尤其表示, 那么这种表示是唯一的**。这是很好的性质, 比如我们习惯意义上的坐标便是在单位向量 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 下的线性组合表示。

2 线性空间的基和维度

回顾由子集 $S \subseteq V$ 生成的子空间:

$$\text{span}(S) = \{c_1\mathbf{v}_1 + \cdots + c_k\mathbf{v}_k \mid k \geq 0, c_1, \dots, c_k \in \mathbb{R}, \mathbf{v}_1, \dots, \mathbf{v}_k \in S\}$$

由之前的讨论可知, $\text{span}(S)$ 是一个线性空间。进一步的, 我们称 $\text{span}(S)$ 这个线性空间是由 S 生成的。下面是一个正式的定义:

定义 2.1

给定一个向量集合 $S \subseteq V^\alpha$ 和向量空间 V , 如果 $V = \text{span}(S)$, 则称 S 生成了向量空间 V 。

^α这里请大家再次注意, 我们后面的讨论都是假定在一个线性空间 V 下进行讨论的, 和定义后面的 V 并不相同。

一些例子: 下面我们给出一些例子来进行理解。

例 2.2

$V_1 = \{(x, y, 0) \mid x, y \in \mathbb{R}\} \subseteq \mathbb{R}^3$ 是 $\mathbb{R}^3$ 的一个子空间, 从而也是 $\mathbb{R}$ 上的一个线性空间, 考察如下 $\mathbb{R}^3$ 上的一些向量组:

- $S_1 = \{(0, 1, 0), (1, 0, 0)\}$.
- $S_2 = \{(1, 1, 0), (2, 0, 0)\}$.
- $S_3 = \{(1, 1, 0), (0, 4, 0), (1, 1, 0)\}$.
- $S_4 = \{(x, y, 0) \mid x \leq y, x, y \in \mathbb{R}\}$.

不难验证:

$$V_1 = \text{span}(S_1) = \text{span}(S_2) = \text{span}(S_3) = \text{span}(S_4).$$

即 $S_1, \dots, S_4$ 都生成了 V_1 。

例 2.3

考察 3×3 实矩阵组成的线性空间 $M_{3 \times 3}(\mathbb{R})$ 上的一些向量组 (即一些 3×3 的矩阵):

1. 令: $L_1 = \left\{ \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 1 \end{bmatrix} \right\}$, 则 L_1 生成的向量空间为:

$$\text{span}(L_1) = \left\{ \begin{bmatrix} a & 0 & 0 \\ 0 & b & 0 \\ 0 & 0 & c \end{bmatrix} \mid a, b, c \in \mathbb{R} \right\}$$

即所有 3×3 的实对角矩阵 $\text{diag}(a, b, c)$ 组成的线性空间 $\mathcal{D}_3$ 。

2. 令 $L_2 = \{M_1, \dots, M_9\}$, 其中 $M_1, \dots, M_9$ 分别为:

$$M_i(j, k) = \begin{cases} 1, & j = i/3, k = i\%3, \\ 0, & \text{其他情况.} \end{cases}$$

即 $\{M_i\}_{i \in [9]}$ 遍历了所有的 3×3 只有一个位置为 1 其余都为 0 的实矩阵。不难验证:

$$\text{span}(L_2) = \mathbb{M}_{3 \times 3}(\mathbb{R}).$$

即 L_2 生成了 $\mathbb{M}_{3 \times 3}(\mathbb{R})$ 。

线性空间的基: 上述两个例子说明, 不同的向量组可能生成同样一个空间, 比如在例子中, 尽管 S_1, S_2, S_3, S_4 都生成了 $\mathcal{V}_1$, 但其各不相同。进一步的可以发现:

1. S_1, S_2 只有 2 个元素。
2. S_3 有 3 个元素。
3. S_4 有无穷多个元素。

所以一个很自然的问题是:

问题 2.4

给定一个线性空间 $\mathcal{V}$, 我们需要一个多大的集合 S 才能够生成 $\mathcal{V}$?

我们当然希望用来生成的 S 越小越好, 一个很直观的发现是, 如果 S 中有些向量是可以用其他向量的线性组合来表示的, 那么这些向量就是多余的, 具体来说, 比如对于 $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$, 如果存在不全为 0 的 $c_2, \dots, c_n$ 使得:

$$\mathbf{v}_1 = c_2 \mathbf{v}_2 + \dots + c_n \mathbf{v}_n,$$

则:

$$\text{span}(\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n) = \text{span}(\mathbf{v}_2, \dots, \mathbf{v}_n).$$

这样的向量 $\mathbf{v}_1$ 就是多余的。所以我们总可以减少 S 中的元素是的最终集合 S' 应该是线性无关的。我们也称 $S' \subseteq S$ 是 S 一个最大无关组, 其满足:

1. S' 是线性无关的。
2. S 中的任意一个向量都可以用 S' 中的向量的线性组合来表示。

这也就说明 $\text{span}(S') = \text{span}(S)$ 。事实上从生成线性空间的角度来说, 我们将这个 S 称为 $\mathcal{V}$ 的基 (basis), S 的元素个数称为 $\mathcal{V}$ 的维度, 从而我们可以给出如下的两个定义:

定义 2.5 (线性空间的基 (A Basis for a Vector Space))

一组向量 S 是一个线性空间 V 的基 如果其满足:

1. S 是线性无关的。
2. S 生成了 V , 即 $\text{span}(S) = V$ 。

定义 2.6 (维度 (Dimension))

向量空间 V 的维度, 记作 $\dim(V)$, 是指 V 的一个基中的向量个数。

一些例子: 我们先来看一些例子来帮助理解。

例 2.7

1. 在例子2中:

- (1) S_1, S_2 是线性无关的。
- (2) S_3, S_4 是线性相关的。

从而 S_1, S_2 是 V_1 的基, 而 S_3, S_4 不是 V_1 的基, 并且:

$$|S_1| = |S_2| = 2 \implies \dim(V_1) = 2.$$

2. 在例子2.3中:

- L_1 是线性无关的。
- L_2 是线性相关的。

从而:

- L_1 是 $\mathcal{D}_3$ 的基, 并且 $\dim(\mathcal{D}_3) = |L_1| = 3$ 。
- L_2 是 $M_{3 \times 3}(\mathbb{R})$ 的基, 并且 $\dim(M_{3 \times 3}(\mathbb{R})) = |L_2| = 9$ 。

线性空间 Z : 回顾只有一个元素的线性空间 Z :

$$Z = \{0\}.$$

我们有

定理 2.8

$\dim(Z) = 0$, 即 Z 不需要任何向量就可以生成。

证明: 其中的关键在于:

$$\sum_{v \in \emptyset} v = 0.$$

注意到**加法是可交换的**，令 T 是一个有限的向量集，考察 T 的一个划分：

$$T = T_1 \cup T_2, \text{ 其中 } T_1, T_2 \text{ 满足: } T_1 \cap T_2 = \emptyset, T_1 \cup T_2 = T$$

则我们有：

$$\sum_{v \in T} v = \sum_{v \in T_1} v + \sum_{v \in T_2} v$$

显然有：

$$\sum_{v \in T} v = \sum_{v \in \emptyset} v + \sum_{v \in T} v$$

从而：

$$\sum_{v \in \emptyset} v = \sum_{v \in T} v - \sum_{v \in T} v = 0$$

□

线性空间 $\mathbb{R}^\infty$ ：回顾之前提到的 $\mathbb{R}^\infty$ ，即由函数组成的线性空间 F ：

$$F = F(\mathbb{N} \rightarrow \mathbb{R}) = \{f \mid f: \mathbb{N} \rightarrow \mathbb{R}\}$$

其中：

- 给定 $f_1, f_2 \in F$ ，定义函数 $f_1 + f_2: \mathbb{N} \rightarrow \mathbb{R}$ 为：

$$(f_1 + f_2)(x) = f_1(x) + f_2(x)$$

- 对于任意的 $f \in F$ 和 $c \in \mathbb{R}$ ，定义函数 $cf: \mathbb{N} \rightarrow \mathbb{R}$ 为：

$$(cf)(x) = cf(x)$$

我们有：

定理 2.9

$\dim(F) = \infty$ ，即 F 需要无穷多个向量来生成。

证明：事实上，对于任意的 $i \in \mathbb{N}$ ，定义：

$$f_i: \mathbb{N} \rightarrow \mathbb{R}, f_i(x) = \begin{cases} 1, & \text{如果 } x = i \\ 0, & \text{其他情况} \end{cases}$$

则对于任意的 $n \in \mathbb{N}$ ，我们有：

$$f_0, f_1, \dots, f_n$$

是**线性无关**的。

□

注 2.10

定理2.9说明, 存在线性空间 V , 其维度是**无限的**, 我们称 V 是**无限维的**; 同样的, 如果线性空间 V 存在一个有限大小的基, 则称 V 是**有限维的**^a。

^a本课程主要关注的还是有限维的线性空间。

遗留的一个问题: 目前看上去一切都很好, 但事实上我们还有一个问题没有解决, 回顾例子2中的 V_1 , 我们发现:

- S_1, S_2 作为**不同的集合**, 其都是 V_1 的基。

这就产生一个问题, 线性空间的基在不唯一的情况下, 其维度是否还能这样定义? 或者说, 会不会存在一个线性空间 V , 其有两个不同的基, 并且他们的大小不同? 这会导致我们对维度的定义2.6**不是一个好定义**。

注

这一部分的说明主要是为了整个体系的完备性, 事实上, 如果只是运用, 我们只需要知道任何线性空间的基其个数都是相同的即可。但尽管我们的课程是面向基础介绍的, 我们还是能够希望大家能对整个逻辑有一个严格清晰的刻画, 因此我们补上了这一块的原因。因此, 在一部分的知识补充完毕后, 应该可以认识到:

1. 一个线性空间的基可以有无数多个, 但每组基的个数是相同的, 这也是为什么可以定义**维度**这个概念。
2. 一个线性空间的基实际上就是这个线性空间中可以构造出的**最大的线性无关的向量组**。

幸运的是, 我们不必为此担心, 下面的**Steinitz 交换引理** 能消除这个问题:

引理 2.11 (Steinitz Exchange Lemma)

令 $e_1, \dots, e_n$ 是线性空间 V 的一个基, $v_1, \dots, v_m$ 是 V 的一个线性无关的向量组, 其中 $1 \leq m \leq n$ 。则存在 $1 \leq i_1 < i_2 < \dots < i_{n-m} < n$, 使得 $v_1, \dots, v_m, e_{i_1}, \dots, e_{i_{n-m}}$ 是 V 的一组基。^a

^a $m = 0$ 时, 上述引理是平凡的。

在完成 Steinitz 交换引理的证明之前, 我们先来看其如何回答上面的问题:

推论 2.12

给定一个线性空间 V , 并且 $\dim(V) = n$, 则:

1. 若 $f_1, \dots, f_m$ 也是 V 的一组基, 则 $n = m$ 。
2. 若 $v_1, \dots, v_m \in V$ 是线性无关的, 则 $m \leq n$ 。
3. 若 $v_1, \dots, v_n \in V$ 是线性无关的, 则 $v_1, \dots, v_n$ 是 V 的一组基。

证明：令 $e_1, \dots, e_n$ 是 V 的一组基：

1. 反设 $m \neq n$ ，由对称性不妨令 $m < n$ ，则由 Steinitz 交换引理：

$$f_1, \dots, f_m, e_{i_1}, \dots, e_{i_{n-m}}$$

是 V 的一组基，从而其是线性无关的。另一方面，由于 $f_1, \dots, f_m$ 也是 V 的一组基， $e_{i_{n-m}} \in V$ ，从而存在不全为 0 的 $c_1, \dots, c_m$ 使得：

$$e_{i_{n-m}} = c_1 f_1 + \dots + c_m f_m,$$

从而 $e_{i_{n-m}}$ 可以由 $f_1, \dots, f_m$ 的线性组合表示，与其是线性无关的矛盾。

2. 反设 $m > n$ ，则由 Steinitz 交换引理：

$$v_1, \dots, v_n \text{ 是 } V \text{ 的一个基,}$$

从而对 $n+1 \leq m$ 来说，存在不全为 0 的 $c_1, \dots, c_n$ 使得：

$$v_{n+1} = c_1 v_1 + \dots + c_n v_n,$$

与 $v_1, \dots, v_m$ 是线性无关的矛盾。

3. 在 Steinitz 交换引理中直接令 $m = n$ 即可。

□

现在让我们回到Steinitz 交换引理的证明：

证明：[Steinitz 交换引理的证明] 我们对 m 使用归纳法。

$m = 1$ 的情况：

由于 $e_1, \dots, e_n$ 是 V 的一个基，从而存在 $c_1, \dots, c_n$ 使得：

$$v_1 = c_1 e_1 + \dots + c_n e_n$$

显然 $v_1 \neq 0$ ，从而存在 $c_i \neq 0$ ，因此我们有：

$$e_i = \frac{1}{c_i} v_1 - \frac{c_1}{c_i} e_1 - \dots - \frac{c_{i-1}}{c_i} e_{i-1} - \frac{c_{i+1}}{c_i} e_{i+1} - \dots - \frac{c_n}{c_i} e_n$$

即： $v_1, e_1, \dots, e_{i-1}, e_{i+1}, \dots, e_n$ 是 V 的一组基。

我们还需要证明：

$$v_1, \dots, v_m, e_{i_1}, \dots, e_{i_{n-m}}$$

是线性无关的。考察如下的线性组合：

$$c_1 e_1 + \dots + c_{i-1} e_{i-1} + \textcolor{red}{c} v_1 + \dots + c_n e_n = 0$$

- 如果 $c = 0$ ，则由于 e_i 是线性无关的，从而 $c_1 = \dots = c_{i-1} = c_{i+1} = \dots = c_n = 0$ 。

- 如果 $c \neq 0$, 由于 $\mathbf{v}_1 \neq \mathbf{0}$, 从而 $\mathbf{v}_1$ 可以由 $\mathbf{e}_1, \dots, \mathbf{e}_{i-1}, \mathbf{e}_{i+1}, \dots, \mathbf{e}_n$ 的线性组合表示, 从而 $\mathbf{e}_i$ 可以由 $\mathbf{e}_1, \dots, \mathbf{e}_{i-1}, \mathbf{e}_{i+1}, \dots, \mathbf{e}_n$ 的线性组合表示, 矛盾。

归纳步骤:

假设命题对于 $\leq m-1$ 的情况成立, 对于 $= m$ 的情况, 令 $\mathbf{v}_1, \dots, \mathbf{v}_m$ 是线性无关的, 注意到 $\mathbf{v}_1, \dots, \mathbf{v}_{m-1}$ 也是线性无关的, 从而由归纳假设, 存在 $1 \leq i_1 < \dots < i_{n-m+1} \leq n$, 使得:

$$\mathbf{v}_1, \dots, \mathbf{v}_{m-1}, \mathbf{e}_{i_1}, \dots, \mathbf{e}_{i_{n-m+1}}$$

是 V 中的一组基。从而存在不全为 0 的 $c_1, \dots, c_{m-1}, d_1, d_2, \dots, d_{n-m+1}$ 使得:

$$\mathbf{v}_m = c_1 \mathbf{v}_1 + \dots + c_{m-1} \mathbf{v}_{m-1} + d_1 \mathbf{e}_{i_1} + \dots + d_{n-m+1} \mathbf{e}_{i_{n-m+1}}$$

注意到存在 $l \in [n-m+1]$ 使得 $d_l \neq 0$, 从而:

$$\mathbf{e}_{i_l} = \frac{1}{d_l} \mathbf{v}_m - \frac{c_1}{d_l} \mathbf{v}_1 - \dots - \frac{c_{m-1}}{d_l} \mathbf{v}_{m-1} - \frac{d_1}{d_l} \mathbf{e}_{i_1} - \dots - \frac{d_{l-1}}{d_l} \mathbf{e}_{i_{l-1}} - \frac{d_{l+1}}{d_l} \mathbf{e}_{i_{l+1}} - \dots - \frac{d_{n-m+1}}{d_l} \mathbf{e}_{i_{n-m+1}}$$

即: $\mathbf{e}_{i_l}$ 可以由 $\mathbf{v}_1, \dots, \mathbf{v}_m, \mathbf{e}_{i_1}, \dots, \mathbf{e}_{i_{l-1}}, \mathbf{e}_{i_{l+1}}, \dots, \mathbf{e}_{i_{n-m+1}}$ 表示。

进一步可以验证:

$$\mathbf{v}_1, \dots, \mathbf{v}_m, \mathbf{e}_{i_1}, \dots, \mathbf{e}_{i_{l-1}}, \mathbf{e}_{i_{l+1}}, \dots, \mathbf{e}_{i_{n-m+1}}$$

是 V 的一组基, 即归纳步骤成立, 引理得证。 □

子空间的维度: 回顾例子 2.3 中的线性空间 $M_{3 \times 3}(\mathbb{R})$ 和 $\mathcal{D}_3$, 我们有:

1. $\mathcal{D}_3$ 是 $M_{3 \times 3}(\mathbb{R})$ 的一个子空间。
2. $\dim(\mathcal{D}_3) = 3 < \dim(M_{3 \times 3}(\mathbb{R})) = 9$.

事实上, 这一情况在维度是有限的的情形下是成立的:

定理 2.13

给定一个向量空间 V 和其子空间 W , 如果 $\dim(V)$ 是有限的, 则 $\dim(W)$ 也是有限的, 并且:

$$\dim(W) \leq \dim(V).$$

证明: 令量空间 V 的维度 $\dim(V) = n$, 我们的目标是希望从 $W \subseteq V$ 中慢慢的扩展出一组基 $\mathbf{v}_1, \dots, \mathbf{v}_k$ 使得:

$$\text{span}(\mathbf{v}_1, \dots, \mathbf{v}_k) = W.$$

我们对 k 进行归纳构造。初始化 $k = 0$, 此时 $\{\mathbf{v}_i\}$ 为空。

如果:

$$W = \text{span}(\{\mathbf{v}_1, \dots, \mathbf{v}_k\}).$$

则构造已经完成，并且由 $\mathbf{v}_1, \dots, \mathbf{v}_k \in \mathcal{V}$ 可知：

$$\dim(\mathcal{W}) = k \leq n = \dim(\mathcal{V}).$$

否则，存在 $\mathbf{v}_{k+1} \in W \setminus \text{span}(\{\mathbf{v}_1, \dots, \mathbf{v}_k\})$ 使得：

$$\mathbf{v}_1, \dots, \mathbf{v}_k, \mathbf{v}_{k+1}$$

是线性无关的。并且注意到 $\dim(\mathcal{V}) = n$ ，从而由 Steinitz 交换引理：

$$k + 1 \leq n.$$

□

线性代数 (VI)

Lecturer: 杨启哲

Last modified: 2026 年 3 月 30 日

1 矩阵的列秩与行秩

回顾在第四个讲义中所提到的，给定一个 $m \times n$ 的矩阵 A ，其存在四个相关的线性空间：

1. A 的列空间 $C(A)$ ：

$$C(A) = \{Ax \mid x \in \mathbb{R}^n\}$$

即 $C(A)$ 是所有由 A 的列向量的线性组合而成的集合。

2. A 的零空间 $N(A)$ ：

$$N(A) = \{x \mid Ax = 0\}$$

即 $N(A)$ 是所有使得 $Ax = 0$ 的 x 的集合。

3. A 的行空间 $C(A^T)$ ：我们用 A^T 的列空间 来定义 A 的行空间

4. A 的左零空间 $N(A^T)$ ：我们用 A^T 的零空间 来定义 A 的左零空间。

我们展现这些空间与矩阵 A 和方程 $Ax = b$ 的关系。我们还将回答在介绍矩阵时遗留下的问题：

问题 1.1

给定 n 阶方阵 A ，如果方阵 B 满足 $AB = I$ 或者 $BA = I$ ， B 是否就是 A 的逆矩阵 A^{-1} ？

让我们首先来关注列空间与行空间的维数。

矩阵的列秩：注意到矩阵 A 的列空间 $C(A)$ 是 $\mathbb{R}^m$ 的子空间，所以自然有：

定理

$$\dim C(A) \leq m.$$

我们同样还有：

定理 1.2

$$\dim C(A) \leq n.$$

证明：令 A 的列向量为 $a_1, \dots, a_n$ ，则可以在其中选择一个子序列：

$$a_{i_1}, \dots, a_{i_k}$$

满足:

- $i_1 < i_2 < \dots < i_k$.
- $\mathbf{a}_{i_1}, \dots, \mathbf{a}_{i_k}$ 是线性无关的。
- k 是最大的。

则我们有:

$$\mathbf{C}(A) = \text{span}\{\mathbf{a}_{i_1}, \dots, \mathbf{a}_{i_k}\}$$

即:

$$\dim(\mathbf{C}(A)) = k \leq n$$

□

我们将其称为矩阵 A 的列秩, 记作 $\text{column-rank}(A)$ 。

定义 1.3 (列秩 (Column Rank))

给定一个 $m \times n$ 的矩阵 A , 其列秩 (Column Rank) 定义为:

$$\text{column-rank}(A) = \dim(\mathbf{C}(A)).$$

例 1.4

考虑矩阵:

$$A = \begin{bmatrix} 1 & 2 & 3 & 6 \\ 4 & 5 & 9 & 18 \\ 7 & 8 & 15 & 30 \end{bmatrix}$$

则注意到:

$$\begin{bmatrix} 3 \\ 9 \\ 15 \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \\ 7 \end{bmatrix} + 2 \begin{bmatrix} 2 \\ 5 \\ 8 \end{bmatrix}, \quad \begin{bmatrix} 6 \\ 18 \\ 30 \end{bmatrix} = 2 \begin{bmatrix} 1 \\ 4 \\ 7 \end{bmatrix} + 3 \begin{bmatrix} 2 \\ 5 \\ 8 \end{bmatrix}.$$

从而:

$$\mathbf{C}(A) = \text{span} \left\{ \begin{bmatrix} 1 \\ 4 \\ 7 \end{bmatrix}, \begin{bmatrix} 2 \\ 5 \\ 8 \end{bmatrix}, \begin{bmatrix} 3 \\ 9 \\ 15 \end{bmatrix}, \begin{bmatrix} 6 \\ 18 \\ 30 \end{bmatrix} \right\} = \text{span} \left\{ \begin{bmatrix} 1 \\ 4 \\ 7 \end{bmatrix}, \begin{bmatrix} 2 \\ 5 \\ 8 \end{bmatrix} \right\}.$$

因此 $\text{column-rank}(A) = \dim(\mathbf{C}(A)) = 2$.

上述两个列秩的界具有很直观的意义:

1. $\text{column-rank}(A) \leq m$: 这是因为 $\mathbf{C}(A)$ 是 $\mathbb{R}^m$ 的子空间, 所以其维数不会超过 m 。
2. $\text{column-rank}(A) \leq n$: 这是因为 $\mathbf{C}(A)$ 是由 A 的 n 个列向量生成的, 所以其维数不会超过 n 。

进一步, 我们还有如下的性质:

定理 1.5

给定一个 $m \times n$ 的矩阵 A , 则其列秩为 m 当且仅当存在一个 $n \times m$ 的矩阵 B 使得:

$$AB = I.$$

证明: 只需注意到:

$$\begin{aligned}\dim(\mathbf{C}(A)) = m &\iff \forall \mathbf{e}_i \in \mathbb{R}^m, \mathbf{e}_i \in \mathbf{C}(A) \\ &\iff \forall \mathbf{e}_i \in \mathbb{R}^m, \exists \mathbf{b}_i \in \mathbb{R}^n, A\mathbf{b}_i = \mathbf{e}_i \\ &\iff \exists B = \begin{bmatrix} \mathbf{b}_1 & \cdots & \mathbf{b}_m \end{bmatrix} \in \mathbb{R}^{n \times m}, AB = I.\end{aligned}$$

□

上述定理的一个自然推论是:

推论 1.6

如果 n 阶方阵 A 是可逆的, 则其列秩为 n 。

关于问题1.1的进一步思考 : 我们来考虑推论1.6的逆命题:

问题 1.7

如果 n 阶方阵 A 的列秩为 n , 则 A 是否一定是可逆的?

注意到对于一个 n 阶方阵 A , 由定理1.5我们还可以得到:

推论 1.8

如果 n 阶方阵 A 的列秩为 n , 则对任意的 $\mathbf{b} \in \mathbb{R}^n$, 方程 $A\mathbf{x} = \mathbf{b}$ 有唯一解。

证明: 由 A 的列向量线性无关即得。

□

因此, 问题1.7实际上问的是, $A\mathbf{x} = \mathbf{b}$ 的唯一解是否可以表示为:

$$\mathbf{x} = A^{-1}\mathbf{b}.$$

注意到我们已经知道如下的结论:

- 如果存在 n 阶方阵 B, C 使得 $AB = CA = I$, 则 A 是可逆的, 并且 $A^{-1} = B = C$ 。
- $\text{column-rank}(A) = n$ 当且仅当存在 n 阶方阵 B 使得 $AB = I$ 。

所以如果可以完成:

接下来的目标

$\text{column-rank}(A) = n$ 当且仅当存在 n 阶方阵 B 使得 $BA = I$ 。

那么我们便可以同时对问题1.1和问题1.7给出肯定的回答。

矩阵的行秩。 注意到：

$$AB = I \iff (AB)^T = I^T \iff B^T A^T = I.$$

我们可以尝试从行空间的角度找到左乘的矩阵 B 。

定义 1.9 (行秩 (Row Rank))

给定一个 $m \times n$ 的矩阵 A ，其行秩 (Row Rank) 定义为：

$$\text{row-rank}(A) = \dim(\mathbf{C}(A^T)).$$

例 1.10

依旧考虑矩阵：

$$A = \begin{bmatrix} 1 & 2 & 3 & 6 \\ 4 & 5 & 9 & 18 \\ 7 & 8 & 15 & 30 \end{bmatrix}$$

其转置矩阵为：

$$A^T = \begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 9 & 15 \\ 6 & 18 & 30 \end{bmatrix}$$

则注意到：

$$\begin{bmatrix} 7 \\ 8 \\ 15 \\ 30 \end{bmatrix} = (-1) \begin{bmatrix} 1 \\ 2 \\ 3 \\ 6 \end{bmatrix} + 2 \begin{bmatrix} 4 \\ 5 \\ 9 \\ 18 \end{bmatrix}.$$

从而：

$$\mathbf{C}(A) = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \\ 6 \end{bmatrix}, \begin{bmatrix} 4 \\ 5 \\ 9 \\ 18 \end{bmatrix}, \begin{bmatrix} 7 \\ 8 \\ 15 \\ 30 \end{bmatrix} \right\} = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ 3 \\ 6 \end{bmatrix}, \begin{bmatrix} 4 \\ 5 \\ 9 \\ 18 \end{bmatrix} \right\}.$$

因此 $\text{row-rank}(A) = \dim(\mathbf{C}(A^T)) = 2$.

由矩阵转置的性质和列空间、行空间的定义，自然有：

定理 1.11

给定一个 $m \times n$ 的矩阵 A ，则下述叙述是等价的：

1. $\text{row-rank}(A) = n$.

2. $\text{column-rank}(A^T) = n$.
3. 存在一个 $m \times n$ 的矩阵 B 使得 $A^T B = I$.
4. 存在一个 $n \times m$ 的矩阵 C 使得 $BA = I$.

所以如果进一步有：

$$\text{row-rank}(A) = \text{column-rank}(A)$$

则意味着：

$$\text{row-rank}(A) = \text{column-rank}(A) = n \iff \exists B, C \text{ 使得 } AB = I \text{ 且 } BA = I.$$

事实上，这件事是成立的：

定理 1.12

给定一个 $m \times n$ 的矩阵 A ，则 $\text{row-rank}(A) = \text{column-rank}(A)$.

我们将给出两个证明，一个基于解方程组的证明，而一个则更具有技巧性。在本节中，我们将首先关注于一个特殊情况，即 $m = n$ 并且 $\text{column-rank}(A) = n$ 的情况。注意到对于方程 $Ax = b$ ，我们有：

命题 1.13

令 A 是一个 $m \times n$ 的矩阵，并且将 A 表示成如下列向量的形式：

$$A = \begin{bmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_n \end{bmatrix}$$

其中 $\mathbf{a}_i \in \mathbb{R}^m$ ，则有：

1. 对任意的 $\mathbf{b} \in \mathbb{R}^m$,

$$Ax = \mathbf{b} \text{ 有解 } \iff \mathbf{b} \in C(A)$$

从而 $Ax = \mathbf{b}$ 对任意 $\mathbf{b} \in \mathbb{R}^m$ 都有解当且仅当 $C(A) = \mathbb{R}^m$ ，即 $\text{column-rank}(A) = m$.

2. 存在 $\mathbf{b} \in \mathbb{R}^m$ 使得 $Ax = \mathbf{b}$ 存在两个不同的解 $\mathbf{x}_1, \mathbf{x}_2$ 当且仅当 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 线性相关。
3. $Ax = \mathbf{b}$ 对任意 $\mathbf{b} \in \mathbb{R}^m$ 都有唯一解当且仅当：

$$\mathbf{a}_1, \dots, \mathbf{a}_n \text{ 是 } \mathbb{R}^m \text{ 的一组基}$$

特别的， $m = n$.

注意到，这也可以被认为是为什么只对方阵 A 才考虑逆矩阵的一个原因，因为如果能写成 $\mathbf{x} = A^{-1}\mathbf{b}$ 的唯一形式， $m = n$ 是必须的。

下面我们将通过解方程的方式进一步回答：

引理 1.14

令 A 是一个 $n \times n$ 的矩阵, 下面叙述是等价的:

1. A 是可逆的。
2. 方程 $Ax = b$ 对任意 $b \in \mathbb{R}^n$ 都有唯一解。
3. $\text{column-rank}(A) = \dim(C(A)) = n$.
4. $\text{row-rank}(A) = \dim(C(A^T)) = n$.
5. 存在矩阵 B 使得 $AB = I$ 。
6. 存在矩阵 C 使得 $CA = I$ 。
7. A 有 n 个首元。

并给出其逆矩阵 A^{-1} 的一个求法: 利用 Gauss-Jordan 消元法。

2 方程 $Ax = b$ 中 A 为方阵的 Gauss-Jordan 消元法

这一节我们讨论方程组个数和方程组变元相同的这一特殊的方程组的求解, 即从矩阵的角度来看, A 是一个方阵。我们首先回顾一下解方程的基本方法: **Gauss 消元法**。对于一个线性方程组的求解过程:

$$\begin{array}{rclcl} 2x_1 + 4x_2 - 2x_3 & = & 2 & & 2x_1 + 4x_2 - 2x_3 & = & 2 \\ 4x_1 + 9x_2 - 3x_3 & = & 8 & \implies & 1x_2 + x_3 & = & 4 \\ -2x_1 - 3x_2 + 7x_3 & = & 10 & & 4x_3 & = & 8 \end{array}$$

或者写成矩阵的形式:

$$\begin{bmatrix} 2 & 4 & -2 \\ 4 & 9 & -3 \\ 2 & -2 & 4 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 2 \\ 8 \\ 10 \end{bmatrix} \implies \begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ 0 & 0 & 4 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 2 \\ 4 \\ 8 \end{bmatrix} \quad (1)$$

$$Ax = b$$

$$Ux = c$$

(2)

我们称过程中用作第一个做其他行消去的非零元素为首元。在完成消去后, 首元在对角线上。

注 2.1 (首元的个数)

不难发现, 首元的个数至多为变量的个数和方程的个数中的较小者, 即 $\min\{m, n\}$, 在本节讨论的特殊情况, 即 $m = n$ 时, 首元的个数至多为 n 。

首元的个数会影响方程组的解的情况。

1. 首元的个数 = n 时, 方程组有唯一解, 如下所示:

$$\begin{array}{rclcl} x - 2y = 1 & & x - 2y = 1 & & x = 17 \\ 3x - 5y = 11 & \implies & y = 8 & \implies & y = 8 \end{array}$$

2. 首元的个数 $< n$ 时, 方程组有无穷多解或者无解:

$$\begin{array}{l} \bullet \\ \begin{array}{ccc} x - 2y = 1 & \Rightarrow & x - 2y = 1 \\ 3x - 6y = 11 & & 0y = 8 \end{array} \end{array} \quad \text{无解。}$$

$$\begin{array}{l} \bullet \\ \begin{array}{ccc} x - 2y = 1 & \Rightarrow & x - 2y = 1 \\ 3x - 6y = 3 & & 0y = 0 \end{array} \end{array} \quad \text{有无数解。}$$

等式1的过程 ($Ax = b \Rightarrow Ux = c$) 可以概括为:

1. 通过第一个方程上的第一个首元将所有后续方程对应位置上的系数全部变成 0。
2. 通过新的第二个方程上的第二个首元将所有后续方程对应位置上的系数全部变成 0。

3-n. 重复以上操作找到 n 个首元, 最终得到了一个上三角形的矩阵 U 。

我们还需注意如下的情况:

$$\begin{array}{l} -2y + z = 1 \\ 3x - 6y + z = 11 \\ 2x - y + z = 3 \end{array}$$

注意到第一个方程并没有 x 的项, 因此我们有的时候需要调换两个方程的位置 来确保这一方法可执行下去:

$$\begin{array}{ccc} -2y + z = 1 & & 3x - 6y + z = 11 \\ 3x - 6y + z = 11 & \Rightarrow & -2y + z = 1 \\ 2x - y + z = 3 & & 2x - y + z = 3 \end{array}$$

高斯消元法的矩阵形式. 在第一次介绍解方程时, 已经介绍并展示了一些消元矩阵(或者初等矩阵)。现在我们来重新思考一下将上述过程用矩阵的方式进行表述的过程。在上述的过程中, 可能存在如下的两个步骤:

1. 将第 j 行的 k 倍加到第 i 行上消去某个变元。
2. 将某两行方程互换位置。

我们可以用下列的矩阵 $E_{ij}(k)$ 来表示步骤1.:

$$E_{ij}(k) = \begin{bmatrix} 1 & \cdots & 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & \cdots & k & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & \cdots & 1 \end{bmatrix} \begin{bmatrix} a_1 \\ \vdots \\ a_i \\ \vdots \\ a_j \\ \vdots \\ a_n \end{bmatrix} = \begin{bmatrix} a_1 \\ \vdots \\ a_i + ka_j \\ \vdots \\ a_j \\ \vdots \\ a_n \end{bmatrix}$$

即 $E_{ij}(k)A$ 起到的效果是将第 j 行的 k 倍加到第 i 行上。特别的, 当我们不关心 k 的值的时候, 我们用 E_{ij} 来表示这一类矩阵。

步骤2. 可以用如下的矩阵表示:

$$P_{ij} = \begin{bmatrix} 1 & \cdots & 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & \cdots & 1 \end{bmatrix} \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_i \\ \vdots \\ \mathbf{a}_j \\ \vdots \\ \mathbf{a}_n \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_j \\ \vdots \\ \mathbf{a}_i \\ \vdots \\ \mathbf{a}_n \end{bmatrix}$$

即 $P_{ij}A$ 起到的效果是将第 i 行和第 j 行互换位置。

注 2.2

左乘和右乘有着截然不同的意义:

1. $AE_{ij}(k)$ 表示为将 A 的第 j 列的 k 倍加到第 i 列上, 即:

$$AE_{ij}(k) = [\mathbf{a}_1, \cdots, \mathbf{a}_i, \cdots, \mathbf{a}_j, \cdots, \mathbf{a}_n] E_{ij}(k) = [\mathbf{a}_1, \cdots, \mathbf{a}_i + k\mathbf{a}_j, \cdots, \mathbf{a}_j, \cdots, \mathbf{a}_n].$$

2. AP_{ij} 表示为将 A 的第 i 列和第 j 列互换位置, 即:

$$AP_{ij} = [\mathbf{a}_1, \cdots, \mathbf{a}_i, \cdots, \mathbf{a}_j, \cdots, \mathbf{a}_n] P_{ij} = [\mathbf{a}_1, \cdots, \mathbf{a}_j, \cdots, \mathbf{a}_i, \cdots, \mathbf{a}_n].$$

矩阵 $E_{ij}(k)$ 和 P_{ij} 的逆矩阵具有非常简单的形式:

引理 2.3

对于 $E_{ij}(k)$ 和 P_{ij} , 有:

1. $E_{ij}(k)^{-1} = E_{ij}(-k)$.
2. $P_{ij}^{-1} = P_{ij}$.

证明: [直观, 非严格证明] 我们给出两个直观来帮助理解:

1. 对于 $E_{ij}(k)$ 左乘的作用是将第 j 行的 k 倍加到第 i 行上, 而 $E_{ij}(-k)$ 的作用是将第 j 行的 k 倍加到第 j 行上, 因此 $E_{ij}(k)E_{ij}(-k) = I$ 。
2. 对于 P_{ij} 左乘的作用是将第 i 行和第 j 行互换位置, 因此再互换一次便变回原来的矩阵, 从而 $P_{ij}P_{ij} = I$ 。

□

回到我们最开始的方程组，其求解过程为：

$$\begin{array}{rclclcl} 2x_1 + 4x_2 - 2x_3 & = & 2 & 2x_1 + 4x_2 - 2x_3 & = & 2 & 2x_1 + 4x_2 - 2x_3 & = & 2 \\ 4x_1 + 9x_2 - 3x_3 & = & 8 & \Rightarrow & x_2 + x_3 & = & 8 & \Rightarrow & x_2 + x_3 & = & 4 \\ -2x_1 - 3x_2 + 7x_3 & = & 10 & & x_2 + 5x_3 & = & 10 & & 4x_3 & = & 8 \end{array}$$

即：

1. 将第一个方程的 -2 倍加到第二个方程上去。
2. 将第一个方程的 1 倍加到第三个方程上去。
3. 将第二个方程的 -1 倍加到第三个方程上去。

用矩阵的语言来表示，即：

$$E_{32}(-1)E_{31}(1)E_{21}(-2)A = U$$

即：

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 1 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 2 & 4 & -2 \\ 4 & 9 & -3 \\ 2 & -2 & 4 \end{bmatrix} = \begin{bmatrix} 2 & 4 & -2 \\ 0 & 1 & 1 \\ 0 & 0 & 4 \end{bmatrix}$$

注 2.4 (矩阵的 LU 分解)

我们也可以将上式写成如下的形式：

$$\begin{aligned} E_{21}(2)E_{31}(-1)E_{32}(1)E_{32}(-1)E_{31}(1)E_{21}(-2)A &= E_{21}(-2)E_{31}(-1)E_{32}(1)U \\ \Rightarrow A &= E_{21}(2)E_{31}(-1)E_{32}(1)U \end{aligned}$$

而：

$$E_{21}(2)E_{31}(-1)E_{32}(1) = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -1 & 1 & 1 \end{bmatrix}$$

是一个**下三角矩阵 L**，从而我们将 A 变成了**一个下三角矩阵 L** 和**一个上三角矩阵 U** 的乘积 ($A = LU$)，这就是**矩阵的 LU 分解**。

再次回顾上述这个过程，假设其没有行交换的情况下，消元的过程总可以表示成：

1. 用第一个方程依次消去后面的方程中的第一个变元。
2. 用第二个方程依次消去后面的方程中的第二个变元。
- 3-n. 重复以上操作，直到最后一个方程。

因此，对于一个 $n \times n$ 的矩阵 A ，如果**有 n 个首元**，并且**消元过程不需要进行行交换**，其对应的方程组 $Ax = b$ 对应的消元过程总可以表示为：

$$E_{n(n-1)}E_{n(n-2)}E_{(n-1)(n-2)} \cdots E_{31}E_{21}A = U$$

即:

$$A = E_{21}E_{31} \cdots E_{(n-1)(n-2)}E_{n(n-2)}E_{n(n-1)}U = LU$$

不难验证, 这里的 L 是一个下三角矩阵。

如果存在行变换怎么办? 直观上说, 我们总可以预先通过一些行变换使得在接下来的消元过程中不再需要行变换, 因此对于一般的有 n 个首元的 n 阶方阵 A 来说, 我们可以将其写成:

$$PA = LU$$

的形式, 其中 P 是一个置换矩阵。

上述例子中的消元过程是**不需要行交换的**, 但一般情况下在消元过程中可能存在行交换, 如下例所示:

$$\begin{array}{rcl} x - 2y - 6z & = & 1 \\ 2z & = & 4 \\ 3x + 2y & = & 11 \end{array} \implies \begin{array}{rcl} x - 2y - 6z & = & 1 \\ 2z & = & 4 \\ 8y + 18z & = & 8 \end{array} \implies \begin{array}{rcl} x - 2y - 6z & = & 1 \\ 8y + 18z & = & 8 \\ 2z & = & 4 \end{array} \quad (3)$$

也就是:

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -3 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & -2 & -6 \\ 0 & 0 & 2 \\ 3 & 2 & 0 \end{bmatrix} = \begin{bmatrix} 1 & -2 & -6 \\ 0 & 8 & 18 \\ 0 & 0 & 2 \end{bmatrix} \quad (4)$$

P_{23} E_{31} A U

注意到 P_{23}, E_{31} 对 b 也是同样起作用的, 即:

$$P_{23}E_{31} \begin{bmatrix} 1 \\ 4 \\ 11 \end{bmatrix} = \begin{bmatrix} 1 \\ 8 \\ 4 \end{bmatrix} \quad (5)$$

b c

我们也可以将 A, b 合起来写成如下的形式:

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -3 & 0 & 1 \end{bmatrix} [A \quad b] = [U \quad c] \quad (6)$$

我们将 $[A \quad b]$ 称为方程组 $Ax = b$ 的**增广矩阵**, 整个消元的过程也可以视作对该矩阵进行乘法。

现在我们继续回到解方程的过程, 我们还需要通过**回代**的方式来求解, 即对于如下的方程组:

$$\begin{array}{rcl} x - 2y - 6z & = & 1 \\ 8y + 18z & = & 8 \\ 2z & = & 4 \end{array}$$

我们还需要通过如下的方式来进一步的消元:

$$\begin{array}{rcl} x - 2y - 6z & = & 1 \\ 8y + 18z & = & 8 \\ 2z & = & 4 \end{array} \implies \begin{array}{rcl} x - 2y - 6z & = & 1 \\ 8y & = & -28 \\ 2z & = & 4 \end{array} \implies \begin{array}{rcl} x - 2y & = & 13 \\ 8y & = & -28 \\ 2z & = & 4 \end{array} \implies \begin{array}{rcl} x & = & 6 \\ 8y & = & -28 \\ 2z & = & 4 \end{array} \quad (7)$$

上述过程也可以用如下矩阵的形式表示：

$$\begin{array}{c} \begin{bmatrix} 1 & \frac{1}{4} & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 3 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & -9 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} \mathbf{u} & \mathbf{c} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 6 \\ 0 & 8 & 0 & -28 \\ 0 & 0 & 2 & 4 \end{bmatrix} \\ \textcolor{red}{E_{12}} \quad \quad \quad \textcolor{red}{E_{13}} \quad \quad \quad \textcolor{red}{E_{23}} \end{array} \quad (8)$$

最后我们只需要把每个变元的系数变回 1 即可：

$$\begin{array}{rcl} x & = & 6 \\ 8y & = & -28 \implies y = -3.5 \\ 2z & = & 4 \quad \quad z = 2 \end{array} \quad (9)$$

这一过程我们可以用一个简单的对角矩阵 $\mathbf{D} = \text{diag}(1, \frac{1}{8}, 2)$ 来进行刻画，即：

$$\begin{array}{c} \begin{bmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{8} & 0 \\ 0 & 0 & 2 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 6 \\ 0 & 8 & 0 & -28 \\ 0 & 0 & 2 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 6 \\ 0 & 1 & 0 & -3.5 \\ 0 & 0 & 1 & 2 \end{bmatrix} \\ \textcolor{red}{\mathbf{D}} \end{array} \quad (10)$$

上述整个求解方程组的过程3,7,9被称为高斯若尔当消元法 (Gauss-Jordan Elimination)，其中将其变为上三角形式的过程3被称为高斯消元法 (Gauss Elimination)，用矩阵的形式来表达，即如下的解方程过程4,8,10：

$$\begin{bmatrix} 1 & -2 & -6 \\ 0 & 0 & 2 \\ 3 & 2 & 0 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 1 \\ 4 \\ 11 \end{bmatrix} \implies \cdots \implies \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} 6 \\ -3.5 \\ 2 \end{bmatrix}$$

可以合起来表示为：

$$\textcolor{red}{\mathbf{D}E_{12}E_{13}E_{23}P_{23}E_{31}} \begin{bmatrix} \mathbf{A} & \mathbf{b} \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 & 6 \\ 0 & 1 & 0 & -3.5 \\ 0 & 0 & 1 & 2 \end{bmatrix} = \begin{bmatrix} \mathbf{I} & \mathbf{x}_0 \end{bmatrix}.$$

这里 $\mathbf{x}_0$ 就是求出的解。

方阵 A 的逆的计算。 注意到， $\textcolor{red}{\mathbf{D}E_{12}E_{13}E_{23}P_{23}E_{31}}$ 这一过程仅仅跟 A 有关，而与 b 无关，即对于任意的 $\mathbf{b}' \in \mathbb{R}^n$ ，都可以通过：

$$\textcolor{red}{\mathbf{D}E_{12}E_{13}E_{23}P_{23}E_{31}} \begin{bmatrix} \mathbf{A} & \mathbf{b}' \end{bmatrix} = \begin{bmatrix} \mathbf{I} & \mathbf{x}'_0 \end{bmatrix}.$$

来求解方程 $\mathbf{Ax} = \mathbf{b}'$ 的解 $\mathbf{x}'_0$ 。因此考虑三个特殊的单位向量所对应的方程组：

$$\mathbf{Ax} = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \mathbf{e}_1, \quad \mathbf{Ax} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} = \mathbf{e}_2, \quad \mathbf{Ax} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} = \mathbf{e}_3,$$

我们依旧可以用上述的方式来求得相应的解，即对于每个 $i \in [3]$ ，我们有：

$$\textcolor{red}{\mathbf{D}E_{12}E_{13}E_{23}P_{23}E_{31}} \begin{bmatrix} \mathbf{A} & \mathbf{e}_i \end{bmatrix} = \begin{bmatrix} \mathbf{I} & \mathbf{x}_i \end{bmatrix}$$

将上述的三个等式合起来写，便有：

$$DE_{12}E_{13}E_{23}P_{23}E_{31} \begin{bmatrix} A & \mathbf{e}_1 & \mathbf{e}_2 & \mathbf{e}_3 \end{bmatrix} = \begin{bmatrix} I & \mathbf{x}_1 & \mathbf{x}_2 & \mathbf{x}_3 \end{bmatrix}.$$

即：

$$\begin{aligned} DE_{12}E_{13}E_{23}P_{23}E_{31}A &= I \\ A \begin{bmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \mathbf{x}_3 \end{bmatrix} &= \begin{bmatrix} \mathbf{e}_1 & \mathbf{e}_2 & \mathbf{e}_3 \end{bmatrix} = I \end{aligned}$$

从而由逆矩阵的性质，我们有：

$$A^{-1} = DE_{12}E_{13}E_{23}P_{23}E_{31} = \begin{bmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \mathbf{x}_3 \end{bmatrix}.$$

这便是通过解方程组的形式来对矩阵 A^{-1} 的计算。我们对其再进行一个总结：

1. 考察一个矩阵 A ，其满足对于任意 $\mathbf{b} \in \mathbb{R}^3$ ，方程 $A\mathbf{x} = \mathbf{b}$ 都有解，从而我们通过高斯-若尔当消元法可以解出：

$$DE_{ij} \cdots P \cdots E_{ij} \begin{bmatrix} A & \mathbf{e}_1 & \mathbf{e}_2 & \mathbf{e}_3 \end{bmatrix} = \begin{bmatrix} I & \mathbf{x}_1 & \mathbf{x}_2 & \mathbf{x}_3 \end{bmatrix}$$

即存在 $B = \begin{bmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \mathbf{x}_3 \end{bmatrix}$ 使得 $AB = I$ ，这里 $DE_{ij} \cdots P \cdots E_{ij}$ 是一些消元矩阵的乘积。

2. 另一方面，如果令 $C = DE_{ij} \cdots P \cdots E_{ij}$ ，我们也有 $CA = I$ 。
3. 最终我们可以发现 A 是可逆的，并且：

$$A^{-1} = B = C = DE_{ij} \cdots P \cdots E_{ij}$$

例 2.5

我们以上面的例子进行参考，对于矩阵 A ：

$$A = \begin{bmatrix} 1 & -2 & -6 \\ 0 & 0 & 2 \\ 3 & 2 & 0 \end{bmatrix}$$

通过之前的消元法我们可知：

$$DE_{12}E_{13}E_{23}P_{23}E_{31}A = I$$

从而：

$$\begin{aligned} A^{-1} &= DE_{12}E_{13}E_{23}P_{23}E_{31} \\ &= \begin{bmatrix} 1 & 0 & 0 \\ 0 & \frac{1}{8} & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & \frac{1}{4} & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 3 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & -9 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -3 & 0 & 1 \end{bmatrix} \\ &= \begin{bmatrix} \frac{1}{4} & \frac{3}{4} & \frac{1}{4} \\ -\frac{3}{8} & -\frac{9}{8} & \frac{1}{8} \\ 0 & \frac{1}{2} & 0 \end{bmatrix} \end{aligned}$$

这一过程也可以伴随消元的过程逐步得到，即：

$$\begin{aligned}
 [A \quad I] &= \begin{bmatrix} 1 & -2 & -6 & 1 & 0 & 0 \\ 0 & 0 & 2 & 0 & 1 & 0 \\ 3 & 2 & 0 & 0 & 0 & 1 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & -2 & -6 & 1 & 0 & 0 \\ 0 & 0 & 2 & 0 & 1 & 0 \\ 0 & 8 & 18 & -3 & 0 & 1 \end{bmatrix} \\
 &\Rightarrow \begin{bmatrix} 1 & -2 & -6 & 1 & 0 & 0 \\ 0 & 8 & 18 & -3 & 0 & 1 \\ 0 & 0 & 2 & 0 & 1 & 0 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & -2 & -6 & 1 & 0 & 0 \\ 0 & 8 & 0 & -3 & -9 & 1 \\ 0 & 0 & 2 & 0 & 1 & 0 \end{bmatrix} \\
 &\Rightarrow \begin{bmatrix} 1 & -2 & 0 & 1 & 3 & 0 \\ 0 & 8 & 0 & -3 & -9 & 1 \\ 0 & 0 & 2 & 0 & 1 & 0 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 0 & 0 & \frac{1}{4} & \frac{3}{4} & \frac{1}{4} \\ 0 & 8 & 0 & -3 & -9 & 1 \\ 0 & 0 & 2 & 0 & 1 & 0 \end{bmatrix} \\
 &\Rightarrow \begin{bmatrix} 1 & 0 & 0 & \frac{1}{4} & \frac{3}{4} & \frac{1}{4} \\ 0 & 1 & 0 & -\frac{3}{8} & -\frac{9}{8} & \frac{1}{8} \\ 0 & 0 & 1 & 0 & \frac{1}{2} & 0 \end{bmatrix} \Rightarrow A^{-1} = \begin{bmatrix} \frac{1}{4} & \frac{3}{4} & \frac{1}{4} \\ -\frac{3}{8} & -\frac{9}{8} & \frac{1}{8} \\ 0 & \frac{1}{2} & 0 \end{bmatrix}.
 \end{aligned}$$

矩阵 A^{-1} 的存在性 . 在上述的过程中，我们展现了当存在 n 个首元的时候，通过高斯若尔当消元法求得 n 阶方阵 A 的逆矩阵 A^{-1} 的方法，下面我们将进一步证明，存在 n 个首元也是其逆矩阵存在的必要条件。

定理 2.6

令 A 是一个 $n \times n$ 的矩阵，则 A^{-1} 存在当且仅当 A 有 n 个首元。

证明： 假设 A 有 n 个首元：

- 通过高斯若尔当消元法，我们可以解出所有形如 $Ax = e_i$ 的方程，即：

$$D \cdots E_{ij} \cdots P \cdots E_{ij} [A \quad e_1 \quad \cdots \quad e_n] = [I \quad x_1 \quad \cdots \quad x_n]$$

也就是说，令 $B = [x_1 \quad \cdots \quad x_n]$ ，我们有 $AB = I$ 。

- 另一方面，令 $C = D \cdots E_{ij} \cdots P \cdots E_{ij}$ ，我们有 $CA = I$ 。
- 从而 A 是可逆的，并且

$$A^{-1} = B = C = D \cdots E_{ij} \cdots P \cdots E_{ij}.$$

另一方面，我们证明，如果存在一个 B 使得 $AB = I$ ，则 A 有 n 个首元。反设 A 没有 n 个首元，这意味着高斯消元法会得到某一行全 0 的情况，即：

$$E_{ij} \cdots P \cdots E_{ij} A = \begin{bmatrix} \vdots \\ 0 \\ \vdots \end{bmatrix}$$

令 $M = E_{ij} \cdots P \cdots E_{ij}$, 注意到 M 是可逆的, 但是:

$$M = MI = MAB = \begin{bmatrix} \vdots \\ 0 \\ \vdots \end{bmatrix} B$$

这意味着 M 存在一行全是 0, 与 M 是可逆的矛盾。 □

至此, 我们完成了如下引理1.14一个证明:

引理

令 A 是一个 $n \times n$ 的矩阵, 下面叙述是等价的:

1. A 是可逆的。
2. 方程 $Ax = b$ 对任意 $b \in \mathbb{R}^n$ 都有唯一解。
3. $\text{column-rank}(A) = \dim(\mathbf{C}(A)) = n$.
4. $\text{row-rank}(A) = \dim(\mathbf{C}(A^T)) = n$.
5. 存在矩阵 B 使得 $AB = I$ 。
6. 存在矩阵 C 使得 $CA = I$ 。
7. A 有 n 个首元。

也回答了如下的两个问题:

1. 对于 n 阶方阵 A 来说, 若存在 n 阶方阵 B 满足 $AB = I$ 或者 $BA = I$, 则 A 是可逆的, $B = A^{-1}$ 。
2. 如何求解一个 n 阶方阵 A 的逆矩阵 A^{-1} , 即通过高斯若尔当消元法。

以及定理1.12的一个特殊情况:

当方阵 A 是可逆的时候, $\text{row-rank}(A) = \text{column-rank}(A) = n$ 。

我们将在下一节中完整给出定理1.12的证明, 同时探讨清楚一般情况下方程组 $Ax = b$ 的解的情况。

线性代数 (VII)

Lecturer: 杨启哲

Last modified: 2026 年 4 月 20 日

在这一章，我们将首先给出上一章所遗留的定理的证明：

定理 0.1

给定一个 $m \times n$ 的矩阵 A ，则 $\text{row-rank}(A) = \text{column-rank}(A)$ 。

然后我们将给出一般情况下 $A\mathbf{x} = \mathbf{b}$ 的解的情况。

1 矩阵的秩

回顾之前的高斯消元法，其作用是将一个方阵 A 转换成了一个上三角矩阵 U ，如下所示：

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 9 \\ 7 & 8 & 16 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 2 & 3 \\ 0 & -3 & -3 \\ 7 & 8 & 16 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 2 & 3 \\ 0 & -3 & -3 \\ 0 & -6 & -5 \end{bmatrix} \Rightarrow U = \begin{bmatrix} 1 & 2 & 3 \\ 0 & -3 & -3 \\ 0 & 0 & 1 \end{bmatrix}$$

我们将通过解方程的方式来证明定理0.1，为此我们需要在一般情况下（方程个数和变元个数不一定相同）时进一步讨论高斯消元法。注意到对任意的矩阵，上述变元的消去过程可能如下所示：

$$\begin{bmatrix} 1 & 2 & 3 & 0 \\ 4 & 5 & 9 & 2 \\ 7 & 8 & 16 & 7 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 2 & 3 & 0 \\ 0 & -3 & -3 & 2 \\ 7 & 8 & 16 & 7 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 2 & 3 & 0 \\ 0 & -3 & -3 & 2 \\ 0 & -6 & -5 & 7 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 2 & 3 & 0 \\ 0 & -3 & -3 & 2 \\ 0 & 0 & 1 & 3 \end{bmatrix}$$

$$\begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 9 \\ 7 & 8 & 16 \\ 8 & 7 & 12 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 2 & 3 \\ 0 & -3 & -3 \\ 7 & 8 & 16 \\ 8 & 7 & 12 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 2 & 3 \\ 0 & -3 & -3 \\ 0 & -6 & -5 \\ 0 & -9 & -12 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 2 & 3 \\ 0 & -3 & -3 \\ 0 & 0 & 1 \\ 0 & 0 & 3 \end{bmatrix}$$

我们称这样最后形成的矩阵为行阶梯形矩阵：

定义 1.1 (行阶梯形矩阵)

对于一个 $m \times n$ 的矩阵 A ：

$$\begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \cdots & a_{mn} \end{bmatrix}$$

对于其中每个 $i \in [m]$, 我们定义:

$$j_i = \begin{cases} +\infty & \text{如果第 } i \text{ 行是零行} \\ \min\{j \in [n] : a_{ij} \neq 0\} & \text{o.w.} \end{cases}$$

即 a_{ji} 是第 j 行中**最左边的不为 0 的系数**。如果存在 $0 \leq r \leq m$ 使得:

$$j_1 < j_2 < \cdots < j_r, \quad j_{r+1} = \cdots = j_m = +\infty$$

则称 A 为**行阶梯形矩阵**。

如果 $Ax = b$ 的 A 是行阶梯形, 则我们称其是**行阶梯形的**。

一些例子。 上三角矩阵都是行阶梯形:

$$\begin{bmatrix} 1 & 2 & 3 \\ 0 & -3 & -3 \\ 0 & 0 & 1 \end{bmatrix}, \quad \begin{bmatrix} 1 & 2 & 3 \\ 0 & -3 & -3 \\ 0 & 0 & 0 \end{bmatrix}, \quad \begin{bmatrix} 1 & 2 & 3 \\ 0 & 0 & 1 \\ 0 & 0 & 0 \end{bmatrix}.$$

下列矩阵也是行阶梯形矩阵:

$$\begin{bmatrix} 4 & -13 & 0 & 2 \\ 0 & 11 & 0 & 1 \end{bmatrix}, \quad \begin{bmatrix} 4 & -13 & 0 & 2 \\ 0 & 11 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}.$$

命题 1.2

令方程组 $Ax = b$ 是行阶梯形的, 并且令 r 满足:

$$j_1 < j_2 < \cdots < j_r, \quad j_{r+1} = \cdots = j_m = +\infty$$

则方程组有 r 个首元。

证明: 由首元和行阶梯形的定义即得。 □

现在我们可以给出高斯消元法在一般方程组下的更为精确的描述:

高斯消元法的一般描述。 对于方程组 $Ax = b$, 我们维护一个值 $r \leq m$ 使得:

R1 第一行到第 r 行已经满足行阶梯形的形式 (Row Echelon Form), 即:

$$j_1 < j_2 < \cdots < j_r \leq n$$

R2 对于矩阵中第 $r+1$ 行到第 m 行第 1 列到第 j_r 列是一个全零矩阵, 即:

$$a_{ij} = 0, \quad \forall i \in [r+1, m], \forall j \in [1, j_r]$$

第一步: 初始 $r = 0$:

1. 选择最小的 $j \in [n]$ 使得第 j 列有非零的元素, 如果这样的 j 不存在, 意味着 $A = O$ 并且当 $r = 0$ 时 $R1, R2$ 已经满足, 算法结束。
2. 选择 $i \in [m]$ 满足 $a_{ij} = \max_{i \in [m]} a_{ij}$, 即选择这一列中最大的元素。
3. 将第 1 行与第 i 行进行交换, 交换后我们得到在新的第一行中 $a_{1j} \neq 0$, 并且对于所有的 $t \in [1, j-1]$ 都有 $a_{1t} = 0$, 此时我们有: $j_1 = j$.
4. 对每个 $i' > 1$, 我们将第 i' 行替换成:

$$(\text{row } i') - \frac{a_{i'j}}{a_{1j}}(\text{row } 1)$$

替换之后我们有对于所有的 $i' > 1$, $a_{i'j} = 0$ 。

显然此时对于 $r = 1$, $R1$ 和 $R2$ 都是满足的。

第 $i+1$ 步: 假设对于 $r = i$, $R1$ 和 $R2$ 都是满足的, 我们继续进行如下操作:

1. 选择最小的 $j \in [j_i + 1, n]$ 使得存在 $i' \in [i + 1, m]$ 使得 $a_{i'j} \neq 0$, 如果这样的 j 不存在, 算法结束。
2. 选择最大的 $i' \in [i + 1, m]$ 使得第 $a_{i'j} \neq 0$ 。
3. 将第 $i+1$ 行与第 i' 行进行交换, 交换后我们得到在新的第 $i+1$ 行中 $a_{(i+1)j} \neq 0$, 并且对于所有的 $t \in [1, j-1]$ 都有 $a_{(i+1)t} = 0$, 此时我们有: $j_{i+1} = j$.
4. 对每个 $i' > i+1$, 我们将第 i' 行替换成:

$$(\text{row } i') - \frac{a_{i'j}}{a_{(i+1)j}}(\text{row } (i+1))$$

替换之后我们有对于所有的 $i' > i+1$, $a_{i'j} = 0$ 。

显然此时对于 $r = i+1$, $R1$ 和 $R2$ 都是满足的。注意到 $r \leq m$, 每一步使得算法结束或者满足 $R1$ 和 $R2$ 的 r 增加 1, 因此算法一定会结束。因此:

引理 1.3

给定一个 $m \times n$ 的矩阵 A , 高斯消元法将 A 变成一个有 r 个首元的行阶梯形矩阵 U 。

注 1.4

上述过程中, 选择最大的是可以更改的, 如可以按最小的来选择的, 这一步主要是为了挑选一个用来进行消元的行。

我们再用一个例子来说明上述过程:

显然我们有如下结论：

引理 1.6

给定一个 $m \times n$ 的矩阵 A ，高斯消元法将 A 变成一个有 r 个首元的行阶梯形矩阵 U 。

现在我们用首元的个数来定义矩阵的秩：

定义 1.7 (矩阵的秩)

给定一个 $m \times n$ 的矩阵 A ，其秩 (rank) 定义为：

$$\text{rank}(A) = \text{矩阵 } A \text{ 的首元的个数} = r.$$

注 1.8 (关于矩阵的秩)

关于矩阵的秩，有很多定义方式，比如同济大学数学科学学院编制的教材《工程数学线性代数》第 7 版中给出的定义为矩阵 A 的最高阶非零子式，而梁鑫等人编著的《线性代数入门》则是直接定义为矩阵 A 的列秩。这些定义方式都是等价的，当然我会慢慢的证明，对于一个矩阵，这些定义下的秩都是一样的，从而在使用的时候可以进行混淆。

例 1.9 (可逆矩阵的逆)

顾上一节，注意到一个 n 阶可逆矩阵自然会有 n 个首元，从而：

给定一个 n 阶可逆矩阵 A ，则：

$$\text{rank}(A) = \text{column-rank}(A) = \text{row-rank}(A) = n.$$

现在我们来考察上述的行阶梯形矩阵，如：

$$A = \begin{bmatrix} 4 & -13 & 0 & 2 \\ 0 & 11 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

不难发现： $\text{rank}(A) = \text{row-rank}(A) = 2$ ，所以我们有：

命题 1.11

令 A 是一个 $m \times n$ 的行阶梯形矩阵，则 $\text{rank}(A) = \text{row-rank}(A)$ 。

事实上，我们可以证明不仅是针对行阶梯形矩阵，对于任意的矩阵 A ，其列秩、行秩和秩都是一致的：

定理 1.12

给定一个 $m \times n$ 的矩阵 A ，则

$$\text{rank}(A) = \text{row-rank}(A) = \text{column-rank}(A)$$

这也直接证明了上一章所遗留的定理0.1。证明的关键是考虑如下的一类矩阵 A ：

$$R = \begin{bmatrix} 1 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 3 & 0 \\ 0 & 0 & 1 & 4 & 0 \\ 0 & 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

其是一个行阶梯形矩阵，不仅如此其首元都是 1，并且首元的上方也都为 0，从而我们有：

$$\text{rank}(R) = \text{row-rank}(R) = \text{column-rank}(R) = 3$$

我们称这样的矩阵为行最简形：

定义 1.13

回顾一个 $m \times n$ 矩阵 A ，定义：

$$j_i = \begin{cases} +\infty & \text{如果第 } i \text{ 行是零行} \\ \min\{j \in [n] : a_{ij} \neq 0\} & \text{o.w.} \end{cases}$$

则称 A 是行最简形的 (Reduced Row Echelon Form)，如果：

1. 其是行阶梯形的，即存在 $0 \leq r \leq m$ 使得：

$$j_1 < j_2 < \cdots < j_r, \quad j_{r+1} = \cdots = j_m = +\infty$$

2. $a_{1j_1} = \cdots = a_{rj_r} = 1$ ，即所有的首元都是 1。
3. 对于所有的 $l \in [1, r], i \in [1, l-1] \cup [l+1, m]$ ，我们都有 $a_{ij_l} = 0$ ，即在首元的那一列中，除了首元之外的所有元素都是 0。

首先注意到，对于一个行最简形矩阵 R ，我们有：

命题 1.14

令 R 是一个 $m \times n$ 的行最简形矩阵，则 $\text{rank}(R) = \text{row-rank}(R) = \text{column-rank}(R)$ 。

其次对于一个行阶梯形矩阵 A ，我们只需要：

1. 选择最大的 j_r 满足 $j_r \neq \infty$ ，并且存在 $k < j_r$ 满足 $A(j_r, k) \neq 0$ ，如果这样的 j_r 不存在，算法结束。
2. 对每个 $k < j_r$ 满足 $A(j_r, k) \neq 0$ ，我们将第 k 行替换成：

$$(\text{row } k) - \frac{A(j_r, k)}{A(j_r, j_r)} (\text{row } j_r)$$

就能将 A 变成一个行最简形矩阵 R ，而这恰恰就是高斯-若尔当消元法：

引理 1.15

给定一个 $m \times n$ 的矩阵 A ，高斯-若尔当消元法将 A 变成一个行最简形矩阵 R ，并且有：

$$\text{rank}(A) = \text{rank}(R) = \text{column-rank}(R) = \text{row-rank}(R)$$

现在我们回到定理1.12，我们将证明如下引理：

引理 1.16

初等行变换不改变矩阵的行秩。

引理 1.17

初等行变换不改变矩阵的列秩。

在引理1.16和引理1.17的基础上，我们可以证明定理1.12：

证明： [定理1.12的证明]

1. 我们将 A 变成行阶梯形矩阵 U ，并且假设其有 r 个首元，则 $\text{rank}(A) = r$ 。
2. 进一步我们将 U 变换成行最简形，得到 R ，其还是有 r 个首元。
3. $\text{rank}(R) = \text{column-rank}(R) = \text{row-rank}(R) = \text{rank}(A)$ 。
4. 注意到我们只使用了初等行变换，从而：

$$\text{column-rank}(A) = \text{column-rank}(R), \quad \text{row-rank}(A) = \text{row-rank}(R)$$

即：

$$\text{rank}(A) = \text{row-rank}(A) = \text{column-rank}(A)$$

□

下面我们完成引理1.16和引理1.17的证明，注意到高斯若尔当消元法是基于如下的三种行变换来进行的：

1. 行加法：将一行的倍数加到另一行，矩阵如下所示：

$$E_{ij}(-k)A = \begin{bmatrix} 1 & \cdots & 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \\ 0 & \cdots & 1 & \cdots & -k & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \\ 0 & \cdots & 0 & \cdots & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \\ 0 & \cdots & 0 & \cdots & 0 & \cdots & 1 \end{bmatrix} \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_i \\ \vdots \\ \mathbf{a}_j \\ \vdots \\ \mathbf{a}_n \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_i - k\mathbf{a}_j \\ \vdots \\ \mathbf{a}_j \\ \vdots \\ \mathbf{a}_n \end{bmatrix}$$

2. 行交换：交换两行的位置，矩阵如下所示：

$$P_{ij}A = \begin{bmatrix} 1 & \cdots & 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & \cdots & 1 \end{bmatrix} \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_i \\ \vdots \\ \mathbf{a}_j \\ \vdots \\ \mathbf{a}_n \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_j \\ \vdots \\ \mathbf{a}_i \\ \vdots \\ \mathbf{a}_n \end{bmatrix}$$

3. 行乘法：将一行乘以一个非零常数，矩阵如下所示：

$$D_i(k)A = \begin{bmatrix} 1 & \cdots & 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & k & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & \cdots & 1 \end{bmatrix} \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_i \\ \vdots \\ \mathbf{a}_j \\ \vdots \\ \mathbf{a}_n \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ k\mathbf{a}_i \\ \vdots \\ \mathbf{a}_j \\ \vdots \\ \mathbf{a}_n \end{bmatrix}$$

所以我们只需要证明对于这三种初等行变换，其不改变矩阵的列秩和行秩即可：

证明：[引理1.16的证明] 令 $A = [\mathbf{a}_1^T \ \mathbf{a}_i^T \ \cdots \ \mathbf{a}_m^T]^T$ ，即令其写成行向量的形式，这里 $\mathbf{a}_i$ 是 $1 \times n$ 的行向量。则经过一次初等行变换后，矩阵会变成如下的形式：

$$A' = \begin{bmatrix} \mathbf{a}'_1 \\ \vdots \\ \mathbf{a}'_i \\ \vdots \\ \mathbf{a}'_m \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ k\mathbf{a}_i \\ \vdots \\ \mathbf{a}_m \end{bmatrix} \text{ 或者 } \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_i - k\mathbf{a}_j \\ \vdots \\ \mathbf{a}_m \end{bmatrix} \text{ 或者 } \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_j \\ \vdots \\ \mathbf{a}_i \\ \vdots \\ \mathbf{a}_m \end{bmatrix}$$

从而我们有：

$$\begin{aligned} C(A^T) &= \text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_i, \dots, \mathbf{a}_j, \dots, \mathbf{a}_m\}) \\ &= \text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_j, \dots, \mathbf{a}_i, \dots, \mathbf{a}_m\}) \\ &= \text{span}(\{\mathbf{a}_1, \dots, k\mathbf{a}_i, \dots, \mathbf{a}_j, \dots, \mathbf{a}_m\}) \\ &= \text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_i - k\mathbf{a}_j, \dots, \mathbf{a}_j, \dots, \mathbf{a}_m\}) \end{aligned}$$

即：

$$\text{row-rank}(A) = \dim(C(A^T)) = \dim(C(A'^T)) = \text{row-rank}(A')$$

□

列秩不改变的证明则略微麻烦一些。

证明：[引理1.17的证明] 我们这里仅考虑行交换的情形，其他两种情绪请同学们自行验证。令：

$$A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{i1} & \cdots & a_{in} \\ \vdots & \ddots & \vdots \\ a_{j1} & \cdots & a_{jn} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_i & \cdots & \mathbf{a}_j & \cdots & \mathbf{a}_n \end{bmatrix}$$

交换第 i 行和第 j 行后：

$$A' = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{j1} & \cdots & a_{jn} \\ \vdots & \ddots & \vdots \\ a_{i1} & \cdots & a_{in} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix} = \begin{bmatrix} \mathbf{a}'_1 & \cdots & \mathbf{a}'_i & \cdots & \mathbf{a}'_j & \cdots & \mathbf{a}'_n \end{bmatrix}$$

我们比较一下 $\mathbf{a}_k$ 和 $\mathbf{a}'_k$ ：

$$\begin{aligned} \mathbf{a}_k &= \begin{bmatrix} a_{1k} & \cdots & \mathbf{a}_{ik} & \cdots & \mathbf{a}_{jk} & \cdots & a_{nk} \end{bmatrix}^T \\ \mathbf{a}'_k &= \begin{bmatrix} a_{1k} & \cdots & \mathbf{a}_{jk} & \cdots & \mathbf{a}_{ik} & \cdots & a_{nk} \end{bmatrix}^T \end{aligned}$$

我们需要证明：

$$\dim(\text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_n\})) = \dim(\text{span}(\{\mathbf{a}'_1, \dots, \mathbf{a}'_n\})).$$

我们可以发现，对于任意的 $t \in [n]$, $1 \leq k_1 \leq k_2 \leq \cdots \leq k_t \leq n$ 和任意的 $c_1, \dots, c_t \in \mathbb{R}$ ，我们有：

$$\sum_{l \in [t]} c_l \mathbf{a}_{k_l} = \mathbf{0} \Leftrightarrow \sum_{l \in [t]} c_l \mathbf{a}'_{k_l} = \mathbf{0}$$

也就是说：

- $\mathbf{a}_{k_1}, \dots, \mathbf{a}_{k_t}$ 是线性相关的当且仅当 $\mathbf{a}'_{k_1}, \dots, \mathbf{a}'_{k_t}$ 是线性相关的。
- $\mathbf{a}_{k_1}, \dots, \mathbf{a}_{k_t}$ 是 $\text{span}(\mathbf{a}_1, \dots, \mathbf{a}_n)$ 的一组基当且仅当 $\mathbf{a}'_{k_1}, \dots, \mathbf{a}'_{k_t}$ 是 $\text{span}(\mathbf{a}'_1, \dots, \mathbf{a}'_n)$ 的一组基。

从而：

$$\dim(\mathbf{C}(A)) = \dim(\text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_n\})) = \dim(\text{span}(\{\mathbf{a}'_1, \dots, \mathbf{a}'_n\})) = \dim(\mathbf{C}(A')).$$

□

注 1.18

可以看到，对于初等行变换来说：

1. 其不会改变矩阵的行空间。
2. 其会改变矩阵的列空间，但是不会改变列空间的维数。

至此，我们完成了定理0.1的证明，

定理0.1的一个技巧性证明：我们再给出一个充满技巧性地简洁证明：

我们只需证明对任意的矩阵 A ，其有 $\text{row-rank}(A) \leq \text{column-rank}(A)$ 即可。

设 $\text{row-rank}(A) = r$, $\text{column-rank}(A) = c$ 。则存在 A 的 c 个列向量 $\mathbf{a}_{i_1}, \dots, \mathbf{a}_{i_c}$ 是线性无关的，并且对于 A 中的每个列向量 $\mathbf{a}_j (j \leq n)$ ，存在 $p_{j1}, \dots, p_{jc}$ 使得：

$$\mathbf{a}_j = p_{j1}\mathbf{a}_{i_1} + \dots + p_{jc}\mathbf{a}_{i_c}$$

从而我们有：

$$A = [\mathbf{a}_1 \ \dots \ \mathbf{a}_n] = [\mathbf{a}_{i_1} \ \dots \ \mathbf{a}_{i_c}] \begin{bmatrix} p_{11} & \dots & p_{1n} \\ \vdots & & \vdots \\ p_{c1} & \dots & p_{cn} \end{bmatrix}$$

记等式最右面的矩阵为 P , P 是一个 $c \times n$ 的矩阵，则有：

$$\text{row-rank}(A) \leq \text{row-rank}(P) \leq c = \text{column-rank}(A)$$

□

2 $A\mathbf{x} = \mathbf{0}$ 的解

这一节开始，我们来正式讨论方程组的解的情况。首先来关注 $A\mathbf{x} = \mathbf{0}$ ，回顾 A 的零空间 $\mathbf{N}(A)$ 的定义：

定义 (零空间 (Null Space))

给定一个 $m \times n$ 的矩阵 A ，定义其零空间 $\mathbf{N}(A)$ 为：

$$\mathbf{N}(A) = \{\mathbf{x} \mid A\mathbf{x} = \mathbf{0}\}$$

即 $\mathbf{N}(A)$ 是所有满足 $A\mathbf{x} = \mathbf{0}$ 的 $\mathbf{x}$ 的集合。

显然 $\mathbf{N}(A)$ 便是 $A\mathbf{x} = \mathbf{0}$ 的解的全体集合，注意到 $\mathbf{N}(A)$ 是 $\mathbb{R}^n$ 的一个子空间，所以 $A\mathbf{x} = \mathbf{0}$ 的求解实际上等价于求出 $\mathbf{N}(A)$ 的一组基。首先我们关注一个特殊情况：

引理 2.1

令 A 是一个 $m \times n$ 的矩阵，则 $\dim(\mathbf{C}(A)) = n$ 当且仅当 $\dim(\mathbf{N}(A)) = 0$ 。

注 2.2

事实上，这是线性代数基本定理的一个特殊情况：

$$\dim(\mathbf{C}(A)) + \dim(\mathbf{N}(A)) = n$$

我们在后续的内容中会详细讨论这个定理。

证明：令

$$A = [\mathbf{a}_1 \quad \cdots \quad \mathbf{a}_n]$$

则我们有：

$$\dim(\mathbf{C}(A)) = \dim(\text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_n\})) = n$$

$$\Leftrightarrow \mathbf{a}_1, \dots, \mathbf{a}_n \text{ 是 } \mathbf{C}(A) \text{ 的一组基}$$

$$\Leftrightarrow \mathbf{a}_1, \dots, \mathbf{a}_n \text{ 线性无关}$$

$$\Leftrightarrow \mathbf{N}(A) = \{\mathbf{0}\}$$

$$\Leftrightarrow \dim(\mathbf{N}(A)) = 0$$

□

引理2.1实际上描述了 $A\mathbf{x} = \mathbf{0}$ 的一种特殊情况，即当 $\mathbf{C}(A)$ 的维数等于 n 时， $\mathbf{N}(A)$ 的维数为 0，此时对任意的 $\mathbf{b} \in \mathbf{C}(A)$ ， $A\mathbf{x} = \mathbf{b}$ 都只有唯一解，自然 $A\mathbf{x} = \mathbf{0}$ 只有平凡解 $\mathbf{0}$ 。下面我们在看几个例子。

例 2.3 (第一个例子)

考察如下的方程组：

$$\begin{array}{l} x + 2y = 0 \\ 2x + 4y = 0 \end{array} \quad (\text{记作 } A \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}) \quad \Rightarrow \quad \begin{array}{l} x + 2y = 0 \\ 0 = 0 \end{array}$$

方程组只有一个首元，我们称剩下对应的变元是自由变量 (free variable)，这里 y 是自由变量，注意到任取一个 y 的值，我们都可以构造该方程组的一个解，特别的，我们令 $y = 1$ ，此时产生的解 $\mathbf{s}$ ：

$$\mathbf{s} = \begin{bmatrix} -2 \\ 1 \end{bmatrix}$$

称之为特解 (special solution)，不难验证：

$$\mathbf{N}(A) = \text{span}(\{\mathbf{s}\}).$$

例 2.4 (第二个例子)

再考虑如下的方程组：

$$x + 2y + 3z = 0, \quad \text{i.e.} \quad \begin{bmatrix} 1 & 2 & 3 \end{bmatrix} \text{ (记作 } A) \begin{bmatrix} x \\ y \\ z \end{bmatrix} = 0$$

这个方程组中， y, z 都是自由变量，分别令 $y = 1$ 和 $z = 1$ 可得两个特解 s_1, s_2 ：

$$s_1 = \begin{bmatrix} -2 \\ 1 \\ 0 \end{bmatrix}, \quad s_2 = \begin{bmatrix} -3 \\ 0 \\ 1 \end{bmatrix}$$

同样我们有：

$$N(A) = \text{span}(\{s_1, s_2\}).$$

上述例子给了我们求解 $Ax = 0$ 的思路，即：

1. 将 A 变成行阶梯形 U 或者行最简形 R 。
2. 找到 U 或者 R 中的自由变量，分别令其为 1 求得得到特解。
3. 将特解组合起来，得到 $N(A)$ 的一组基。

特别的，我们称：

1. 首元 (pivot) 所在的列为 **首元列 (pivot column)**，对应的变量 x_1, x_2 称为 **主变量 (pivot variables)**。
2. 剩余列则称为 **自由列 (free columns)**，对应的变量 x_3, x_4 称为 **自由变量 (free variables)**。

下面则是一个帮助理解的例子：

$$Cx = \begin{bmatrix} 1 & 2 & 2 & 4 \\ 3 & 8 & 6 & 16 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix} \implies \begin{bmatrix} 1 & 2 & 2 & 4 \\ 0 & 2 & 0 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

在其行阶梯形中，用红色来表示**首元列**，蓝色表示**自由列**：

$$\begin{bmatrix} 1 & 2 & 2 & 4 \\ 0 & 2 & 0 & 4 \end{bmatrix}$$

到此为止，似乎**行阶梯形**已经够我们处理 $Ax = 0$ 了，再让我们再来看下**行最简形**的好处。我们继续将上述的矩阵变成行最简形：

$$\begin{bmatrix} 1 & 2 & 2 & 4 \\ 0 & 2 & 0 & 4 \end{bmatrix} \implies \begin{bmatrix} 1 & 0 & 2 & 0 \\ 0 & 1 & 0 & 2 \end{bmatrix}$$

可以发现：

1. 所有的首元列构成了一个 $r \times r$ 的单位矩阵，这里 r 是首元的个数。
2. 每列自由列都表明了该方程组令该列对应的变元为 1 的一组特解，即：

$$\mathbf{s}_1 = \begin{bmatrix} -2 \\ 0 \\ 1 \\ 0 \end{bmatrix}, \mathbf{s}_2 = \begin{bmatrix} 0 \\ -2 \\ 0 \\ 1 \end{bmatrix}$$

我们再用一个例子来具体描述一下：令：

$$A = \begin{bmatrix} \textcolor{red}{p} & \textcolor{red}{p} & f & \textcolor{red}{p} & f \\ | & | & | & | & | \\ | & | & | & | & | \\ | & | & | & | & | \\ | & | & | & | & | \end{bmatrix} \Rightarrow R = \begin{bmatrix} 1 & 0 & a & 0 & c \\ 0 & 1 & b & 0 & d \\ 0 & 0 & 0 & 1 & e \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

3 个首元列 p $\text{rank}(R) = \text{rank}(A) = r = 3$
2 个自由列 f

从而 $A\mathbf{x} = \mathbf{0}$ 等价于：

$$\begin{bmatrix} 1 & 0 & \textcolor{red}{a} & 0 & \textcolor{blue}{c} \\ 0 & 1 & \textcolor{red}{b} & 0 & \textcolor{blue}{d} \\ 0 & 0 & \textcolor{red}{0} & 1 & \textcolor{blue}{e} \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \\ x_5 \end{bmatrix} = \mathbf{0}, \quad \text{i.e.} \quad \begin{aligned} x_1 + ax_3 + cx_5 &= 0 \\ x_2 + bx_3 + dx_5 &= 0 \\ x_4 + ex_5 &= 0 \end{aligned}$$

我们有：

首元	自由变量
x_1, x_2, x_4	x_3, x_5

也即， x_3, x_5 是可以任意选择的，而 x_1, x_2, x_4 则由 x_3, x_5 决定：

$$x_1 = -ax_3 - cx_5,$$

$$x_2 = -bx_3 - dx_5,$$

$$x_4 = -ex_5$$

特别的，分别令 x_3 和 x_5 为 1 我们可以得到如下两组特解：

$$\mathbf{s}_1 = \begin{bmatrix} -\textcolor{red}{a} \\ -\textcolor{red}{b} \\ 1 \\ \textcolor{red}{0} \\ 0 \end{bmatrix}, \quad \mathbf{s}_2 = \begin{bmatrix} -\textcolor{blue}{c} \\ -\textcolor{blue}{d} \\ 0 \\ -\textcolor{blue}{e} \\ 1 \end{bmatrix}$$

也就是说，行最简形上自由列的每一列其实都直接反映出了一个特解上首元的取值！ 同时我们有：

$$\mathbf{N}(A) = \mathbf{N}(R) = \text{span}(\{\mathbf{s}_1, \mathbf{s}_2\}).$$

$Ax = 0$ 的一般描述. 现在我们给出 $Ax = 0$ 的解的一般描述: 令 A 是 $m \times n$ 的矩阵, 我们考虑 $Ax = 0$ 的解。我们先使用高斯若尔当消元法将 A 转化成行最简形 R , 即:

$$Ax = 0 \iff \begin{bmatrix} 0 & \cdots & b_{1j_1} & \cdots & b_{1n} \\ 0 & \cdots & 0 & \cdots & b_{2n} \\ 0 & \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_{j_1} \\ \vdots \\ x_n \end{bmatrix} = 0$$

其 $\text{rank}(A) = r$ 意味着存在 r 个首元:

$$b_{1j_1} = b_{2j_2} = \cdots = b_{rj_r} = 1$$

也就是

首元	自由变量
$x_{j_1}, x_{j_2}, \cdots, x_{j_r}$	$x_1, \cdots, x_{j_1-1}, x_{j_1+1}, \cdots, x_{j_2-1}, \cdots, x_{j_r+1}, \cdots, x_n$

$Rx = 0$ 对应的方程组为:

$$\begin{aligned} x_{j_1} + b_{1,j_1+1}x_{j_1+1} + \cdots + b_{1,j_2-1}x_{j_2-1} + b_{1,j_2+1}x_{j_2+1} + \cdots + b_{1n}x_n &= 0 \\ x_{j_2} + b_{2,j_2+1}x_{j_2+1} + \cdots + b_{2n}x_n &= 0 \\ &\vdots \\ x_{j_r} + \cdots + b_{rn}x_n &= 0 \end{aligned}$$

从而我们可以构造出 $n - r$ 个特殊解:

$$s_1 = \begin{bmatrix} 1 \\ \vdots \\ 0 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \cdots, s_{j_1-1} = \begin{bmatrix} 0 \\ \vdots \\ 1 \\ 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, \cdots, s_{j_1+1} = \begin{bmatrix} 0 \\ \vdots \\ 0 \\ -b_{1,j_1+1} \\ 1 \\ \vdots \\ 0 \end{bmatrix}, \cdots,$$

这意味着:

$$N(A) = N(R) = \text{span}(\{s_1, \cdots, s_{j_1-1}, s_{j_1+1}, \cdots, s_{j_2-1}, \cdots, s_{j_r+1}, \cdots, s_n\}).$$

即:

$$\dim(N(A)) + \text{rank}(A) = n.$$

这就是线性代数基本定理的第一部分:

定理 2.5 (Fundamental Theorem of Linear Algebra, Part I)

令 A 是一个 $m \times n$ 的矩阵并且 $\text{rank}(A) = r$, 则:

1. $\dim(\mathbf{C}(A)) = \dim(\mathbf{C}(A^T)) = r$ 。
2. $\dim(\mathbf{N}(A)) = n - r$, $\dim(\mathbf{N}(A^T)) = m - r$ 。

3 $Ax = b$ 的解

最后我们来讨论对任意的 b , $Ax = b$ 的解的情况。我们需要搞清如下的三个问题:

1. 什么时候 $Ax = b$ 有解?
2. $Ax = b$ 的解的结构是怎么样的?
3. 如何计算 $Ax = b$ 的解?

事实上, 当我们搞清楚 $Ax = 0$ 的解的情况时, 上述问题都会有很清晰的解答。

第一个问题。 注意到 Ax 实际上是 A 的列向量的线性组合, 从而:

定理 3.1

$Ax = b$ 有解当且仅当 $b \in \mathbf{C}(A)$

上述定理也等价于下列的表述方式:

定理 3.2

$Ax = b$ 有解当且仅当

$$\text{rank}(A) = \text{rank}\begin{bmatrix} A & b \end{bmatrix}.$$

证明: 将 A 写成列向量的形式, 即:

$$A = \begin{bmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_n \end{bmatrix}$$

则我们有:

$Ax = b$ 有解

$$\begin{aligned}
&\iff b \in \mathbf{C}(A) = \text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_n\}) \\
&\iff \text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_n\}) = \text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_n, b\}) \\
&\iff \dim(\text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_n\})) = \dim(\text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_n, b\})) \\
&\iff \text{column-rank}(A) = \text{column-rank}\begin{bmatrix} A & b \end{bmatrix} \\
&\iff \text{rank}(A) = \text{rank}\begin{bmatrix} A & b \end{bmatrix}
\end{aligned}$$

□

第二个问题。假设 $\mathbf{x}_{p_1}, \mathbf{x}_{p_2}$ 是 $A\mathbf{x} = \mathbf{b}$ 的两个解，则：

$$A\mathbf{x}_{p_1} - A\mathbf{x}_{p_2} = \mathbf{0} \implies A(\mathbf{x}_{p_1} - \mathbf{x}_{p_2}) = \mathbf{0}$$

即： $\mathbf{x}_{p_1} - \mathbf{x}_{p_2}$ 是 $A\mathbf{x} = \mathbf{0}$ 的一个解。从而我们有：

定理 3.3

令 A 是一个 $m \times n$ 的矩阵， $\mathbf{x}_p \in \mathbb{R}^n$ 是方程 $A\mathbf{x} = \mathbf{b}$ 的一个解，则对任意的 $\mathbf{x} \in \mathbb{R}^n$ ：

$$A\mathbf{x} = \mathbf{b} \iff \mathbf{x} - \mathbf{x}_p \in \mathbf{N}(A).$$

定理3.3告诉我们， $A\mathbf{x} = \mathbf{b}$ 的解可以分解成如下的形式：

$$A\mathbf{x} = \mathbf{b} \text{ 的一个解 } \mathbf{x}_p + A\mathbf{x} = \mathbf{0} \text{ 的解 } \mathbf{x}$$

特别的，我们称 $\mathbf{x}_p$ 为 $A\mathbf{x} = \mathbf{b}$ 的一个特解。从而令

$$\mathbf{s}_1, \dots, \mathbf{s}_l$$

是 $A\mathbf{x} = \mathbf{0}$ 的一组特殊解，即其零空间 $\mathbf{N}(A)$ 的一组基，从而 $l = n - \text{rank}(A)$ 。则任何一个 $A\mathbf{x} = \mathbf{b}$ 的解都可以表示为：

$$\mathbf{x} = \mathbf{x}_p + c_1\mathbf{s}_1 + \dots + c_l\mathbf{s}_l.$$

注意到 A 的秩 r 应该满足：

$$r = \text{rank}(A) = \text{column-rank}(A) = \text{row-rank}(A) \leq \min\{m, n\}$$

从而我们有：

m	n	$\dim(\mathbf{N}(A))$	$A\mathbf{x} = \mathbf{b}$ 的解的个数
$= r$	$= r$	0	1
$= r$	$> r$	≥ 1	∞
$> r$	$= r$	0	0 or 1
$> r$	$> r$	≥ 1	0 or ∞

表 1 不同情况下 $A\mathbf{x} = \mathbf{b}$ 的解的情况

第三个问题。由前面的讨论可知，我们可以通过高斯若尔当消元法来求得 $A\mathbf{x} = \mathbf{b}$ 的解：

1. 对增广矩阵 $[A \ \mathbf{b}]$ 使用高斯若尔当消元法，将其变成行最简形 $[R \ \mathbf{c}]$ 。
2. 根据 $[R \ \mathbf{c}]$ 令所有的自由变量为 0，求得 $A\mathbf{x} = \mathbf{b}$ 的一组特解 $\mathbf{x}_p$ ，如果不存在特解，则 $A\mathbf{x} = \mathbf{b}$ 无解。
3. 根据 R 求得 $A\mathbf{x} = \mathbf{0}$ 的一组基 $\mathbf{s}_1, \dots, \mathbf{s}_l$ 。

4. 最后 $A\mathbf{x} = \mathbf{b}$ 的解可以表示为:

$$\mathbf{x} = \mathbf{x}_p + c_1 \mathbf{s}_1 + \cdots + c_l \mathbf{s}_l,$$

这里 $c_1, \dots, c_l \in \mathbb{R}$.

最后我们再通过一个例子来理解一下上述过程:

例 3.4

我们来求解下列的方程组 $A\mathbf{x} = \mathbf{b}$, 其中:

$$A = \begin{bmatrix} 1 & 2 & 3 & 5 \\ 2 & 4 & 8 & 12 \\ 3 & 6 & 7 & 13 \end{bmatrix}, \mathbf{b} = \begin{bmatrix} 0 \\ 6 \\ -6 \end{bmatrix} \quad \text{即:} \quad \begin{cases} x_1 + 2x_2 + 3x_3 + 5x_4 = 0 \\ 2x_1 + 4x_2 + 8x_3 + 12x_4 = 6 \\ 3x_1 + 6x_2 + 7x_3 + 13x_4 = -6 \end{cases}$$

解: 对 $[A \ \mathbf{b}]$ 使用高斯若尔当消元法变成行最简形得:

$$\begin{bmatrix} 1 & 2 & 3 & 5 & 0 \\ 2 & 4 & 8 & 12 & 6 \\ 3 & 6 & 7 & 13 & -6 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 2 & 0 & 2 & -9 \\ 0 & 0 & 1 & 1 & 3 \\ 0 & 0 & 0 & 0 & 0 \end{bmatrix} \quad (\text{记为 } [R \ \mathbf{c}])$$

1. x_1, x_3 是首元, 令自由变元 $x_2 = x_4 = 0$ 可求得 $R\mathbf{x} = \mathbf{c}$ (即 $A\mathbf{x} = \mathbf{b}$) 的一个解 $\mathbf{x}_p$:

$$\mathbf{x}_p = \begin{bmatrix} -9 \\ 0 \\ 3 \\ 0 \end{bmatrix}$$

2. 考察方程组 $R\mathbf{x} = \mathbf{0}$, 分别令 $x_2 = 1$ 和 $x_4 = 1$ 可以求得其解得一组基 $\mathbf{s}_1, \mathbf{s}_2$:

$$\mathbf{s}_1 = \begin{bmatrix} -2 \\ 1 \\ 0 \\ 0 \end{bmatrix}, \quad \mathbf{s}_2 = \begin{bmatrix} -2 \\ 0 \\ -1 \\ 1 \end{bmatrix}$$

3. 从而 $A\mathbf{x} = \mathbf{b}$ 的解可以表示为 $\mathbf{x}$:

$$\mathbf{x} = \mathbf{x}_p + c_1 \mathbf{s}_1 + c_2 \mathbf{s}_2 = \begin{bmatrix} -9 \\ 0 \\ 3 \\ 0 \end{bmatrix} + c_1 \begin{bmatrix} -2 \\ 1 \\ 0 \\ 0 \end{bmatrix} + c_2 \begin{bmatrix} -2 \\ 0 \\ -1 \\ 1 \end{bmatrix} = \begin{bmatrix} -9 - 2c_1 - 2c_2 \\ c_1 \\ 3 - c_2 \\ c_2 \end{bmatrix}$$

□

线性代数 (VIII)

Lecturer: 杨启哲

Last modified: 2026 年 4 月 19 日

1 正交性

我们首先从几何角度来考察一下 $Ax = 0$ 的解。记矩阵 A 的形式如下：

$$A = \begin{bmatrix} \mathbf{a}_1^T \\ \vdots \\ \mathbf{a}_m^T \end{bmatrix}$$

即每个 $\mathbf{a}_i$ 可以视作一个 $n \times 1$ 的矩阵：

$$\mathbf{a}_i = \begin{bmatrix} a_{i1} \\ \vdots \\ a_{in} \end{bmatrix}$$

则我们有对于任意 $\mathbf{x} \in \mathbb{R}^n$ ，如果 $\mathbf{x} \in \mathbf{N}(A)$ ，则对于任意的 $i \in [m]$ ，都有：

$$\mathbf{a}_i^T \mathbf{x} = \mathbf{a}_i \cdot \mathbf{x} = 0$$

这说明 $\mathbf{x}$ 与每个 $\mathbf{a}_i$ 都是垂直的，我们也称为正交 (orthogonal) 的。也就是每个满足 $Ax = 0$ 的解 $\mathbf{x}$ ，其与行空间 $\mathbf{C}(A^T)$ 都是垂直的。换句话说，A 的行空间 $\mathbf{C}(A^T)$ 与 A 的零空间 $\mathbf{N}(A)$ 是"垂直"的：

定理 1.1

给定一个矩阵 A ，其行空间 $\mathbf{C}(A^T)$ 和零空间 $\mathbf{N}(A)$ 是正交的 (orthogonal)，即对于任意的 $\mathbf{u} \in \mathbf{C}(A^T)$ 和 $\mathbf{v} \in \mathbf{N}(A)$ ，我们都有：

$$\mathbf{u} \cdot \mathbf{v} = \mathbf{u}^T \mathbf{v} = 0$$

特别的其逆命题也成立，即如果存在 $\mathbf{v} \in \mathbb{R}^n$ 满足 $\mathbf{v}$ 与 $\mathbf{C}(A^T)$ 中的任何一个 $\mathbf{u}$ 都是垂直的，则：

$$A\mathbf{v} = \mathbf{0}, \text{ 即: } \mathbf{v} \in \mathbf{N}(A).$$

证明：记 A 是之前的形式，则 $\mathbf{u} \in \mathbf{C}(A^T)$ 等价于存在 $\mathbf{C} = \begin{bmatrix} c_1 \\ \vdots \\ c_m \end{bmatrix} \in \mathbb{R}^m$ 使得：

$$\mathbf{u} = c_1 \mathbf{a}_1 + \cdots + c_m \mathbf{a}_m = A^T \mathbf{C}$$

从而对于任意 $\mathbf{v} \in \mathbf{N}(A)$ 有：

$$\mathbf{u} \cdot \mathbf{v} = \mathbf{u}^T \mathbf{v} = (A^T \mathbf{C})^T \mathbf{v} = \mathbf{C}^T A \mathbf{v} = \mathbf{C}^T \mathbf{0} = 0$$

□

正交的子空间： 我们在定理1.1中已经介绍了关于两个空间**正交**的概念，不难发现 $C(A^T), N(A)$ 都是 $\mathbb{R}^n$ 的子空间。下面我们考虑讨论一下两个**正交的子空间**。首先我们给出相应的定义：

定义 1.2

令 $n \geq 0$, V 和 W 是同一向量空间 (如: $\mathbb{R}^n$) 的两个子空间, 我们称 V 和 W 是**正交的 (orthogonal)**, 记作:

$$V \perp W$$

如果每个 V 中的向量 $\mathbf{v}$ 和 W 中的任何一个向量 $\mathbf{w}$ 的内积均为 0, 即:

$$\mathbf{v} \cdot \mathbf{w} = \mathbf{v}^T \mathbf{w} = 0$$

我们同样用 $\mathbf{v} \perp \mathbf{w}$ 来表示 $\mathbf{v} \cdot \mathbf{w} = 0$, 显然当我们讨论的是 $\mathbb{R}^n$ 时, $\mathbf{v} \cdot \mathbf{w} = 0$ 也意味着 $\mathbf{v}$ 和 $\mathbf{w}$ 是**垂直的 (perpendicular)**。

注 1.3 (关于垂直与正交)

垂直 (perpendicular) 与正交 (orthogonal) 是两个非常相似的概念, 但具体来说:

1. 垂直更是一个几何上的概念, 意味着两个对象的夹角为 90° 。
2. 正交则是一个更为一般性的抽象概念, 两个元素正交意味着其内积为 0, 而实际上, 只需要满足正定性、共轭对称性、线性性的函数关系便可以称为内积, 因此其适用范围可以更广。如我们可以对在区间 $[-1, 1]$ 上的实值连续函数构成的线性空间定义内积:

$$f \cdot g \stackrel{\text{def}}{=} \int_{-1}^1 f(x)g(x)dx$$

则我们有: $(\sqrt{\frac{1}{2}}) \cdot (\sqrt{\frac{3}{2}}x) = \int_{-1}^1 \frac{\sqrt{3}}{2}x dx = 0$, 即常值函数 $f(x) = \sqrt{\frac{1}{2}}$ 和 $g(x) = \sqrt{\frac{3}{2}}x$ 是正交的。

但在本课程大部分的时间内, 我们所讨论的内积还只是正常的向量上的内积定义。

注 1.4

出于我们的目的考虑, 为了让大家先建立一个几何直观, 我们后续的讨论和相关定义都是在 $\mathbb{R}^n$ 上进行的。但必须要注意的是, 本节所讨论是可以对任意的线性空间和内积上进行推广的。

例 1.5 (一些例子)

1. 考察 $\mathbb{R}^2$ 上如下两个子空间:

$$V_1 = \{(x, 0) \mid x \in \mathbb{R}\}$$

$$V_2 = \{(0, y) \mid y \in \mathbb{R}\}$$

则对任何 $(x_1, 0) \in V_1$ 和 $(0, y_2) \in V_2$, 都有:

$$(x_1, 0) \cdot (0, y_2) = x_1 \cdot 0 + 0 \cdot y_2 = 0$$

因此 $V_1 \perp V_2$, 即 V_1 和 V_2 是正交的。

2. 考察 $\mathbb{R}^3$ 上如下三个子空间:

$$V_3 = \{(x, 0, 0) \mid x \in \mathbb{R}\}$$

$$V_4 = \{(0, 0, z) \mid y, z \in \mathbb{R}\}$$

$$V_5 = \{(0, y, z) \mid y \in \mathbb{R}\}$$

则我们有:

$$V_3 \perp V_4, V_3 \perp V_5, \text{但 } V_4 \text{ 和 } V_5 \text{ 不正交。}$$

3. 考察任一线性空间 V 和其只包含 0 的子空间 Z , 显然 $V \perp Z$ 。

基与正交子空间的关系. 我们进一步来考察一下正交的子空间之间的关系。第一个要给出的是关于两个空间的基之间的关系:

定理 1.6

给定一个向量空间上的两个子空间 V 和 W , 令 $v_1, \dots, v_k$ 是 V 的一组基, $w_1, \dots, w_l$ 是 W 的一组基, 则 $V \perp W$ 当且仅当对任意的 $i \in [k], j \in [l]$ 我们有: $v_i \perp w_j$.

证明: 我们只需证明 $\Leftarrow$ 的方向, 另一边直接由定义可得。

假设对于任意的 v_i 和 w_j , 我们有: $v_i \perp w_j$, 则对于任意的 $v \in V$ 和 $w \in W$, 存在 $a \in \mathbb{R}^k$ 和 $b \in \mathbb{R}^l$ 满足:

$$v = \begin{bmatrix} v_1 & \cdots & v_k \end{bmatrix} a, \quad w = \begin{bmatrix} w_1 & \cdots & w_l \end{bmatrix} b$$

从而:

$$\begin{aligned} v \cdot w &= v^T w = a^T \begin{bmatrix} v_1^T \\ \vdots \\ v_k^T \end{bmatrix} \begin{bmatrix} w_1 & \cdots & w_l \end{bmatrix} b \\ &= a^T \begin{bmatrix} v_1^T w_1 & \cdots & v_1^T w_l \\ \vdots & \ddots & \vdots \\ v_k^T w_1 & \cdots & v_k^T w_l \end{bmatrix} b \\ &= a^T \begin{bmatrix} 0 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & 0 \end{bmatrix} b = 0 \end{aligned}$$

□

定理1.6说明了正交的子空间之间的基之间的关系，我们可以利用其给出定理1.1的一个直接的证明：

证明： [定理1.1的另一个证明] 记矩阵 A 的秩 $\text{rank}(A) = r$ ，令 $\mathbf{C}(A^T)$ 的一组基为 $\mathbf{a}_1, \dots, \mathbf{a}_r$ ， $\mathbf{N}(A)$ 的一组基为 $\mathbf{x}_1, \dots, \mathbf{x}_{n-r}$ ，则由定理1.6，对任意的 $i \in [r]$ 和 $j \in [n-r]$ ，都有：

$$\mathbf{a}_i \cdot \mathbf{x}_j = 0$$

则考虑任意的 $\mathbf{u} \in \mathbf{C}(A^T)$ 和 $\mathbf{v} \in \mathbf{N}(A)$ ，存在不全为 0 的系数 $c_1, \dots, c_r$ 和 $d_1, \dots, d_{n-r}$ 使得：

$$\mathbf{u} = \sum_{i=1}^r c_i \mathbf{a}_i, \quad \mathbf{v} = \sum_{j=1}^{n-r} d_j \mathbf{x}_j$$

从而：

$$\mathbf{u} \cdot \mathbf{v} = \left(\sum_{i=1}^r c_i \mathbf{a}_i \right) \cdot \left(\sum_{j=1}^{n-r} d_j \mathbf{x}_j \right) = \sum_{i=1}^r \sum_{j=1}^{n-r} c_i d_j (\mathbf{a}_i \cdot \mathbf{x}_j) = 0$$

□

正交补。 上述证明给的一个很重要的直观是， $\mathbf{C}(A^T)$ 和 $\mathbf{N}(A)$ 把 $\mathbb{R}^n$ 分解成了两个正交的子空间，我们将这个直观作更形式化的描述，首先给出正交补 (orthogonal complement) 的定义：

定义 1.7 (Orthogonal Complements)

令 V 是 $\mathbb{R}^n$ 的一个子空间，我们称 V 的正交补 (orthogonal complement) 为：

$$V^\perp \stackrel{\text{def}}{=} \{\mathbf{v} \in \mathbb{R}^n \mid \mathbf{v} \perp \mathbf{u}, \text{ 对于任意的 } \mathbf{u} \in V\}.$$

注 1.8

正交补也可以定义在任意的子集上。

一个子空间的正交补有如下的性质：

引理 1.9

令 V 是 $\mathbb{R}^n$ 的一个子空间，则：

1. $V^\perp$ 是一个子空间。
2. $V \perp V^\perp$ 。
3. 令 W 是 $\mathbb{R}^n$ 的子空间，如果 $W \perp V$ ，则 $W \subseteq V^\perp$ ，即 $V^\perp$ 是最大的与 V 正交的子空间。
4. $(V^\perp)^\perp = V$ 。

注 1.10

这里蕴含的是 $\mathbb{R}^n$ 是有限维的线性空间，当这一条件不满足时命题不一定成立。

证明：

1. 给定任意的 $\mathbf{v}_1, \mathbf{v}_2 \in V^\perp$ 和任意的 $\mathbf{c} \in \mathbb{R}$, 对任意的 $\mathbf{u} \in V$ 有:

$$(\mathbf{v}_1 + \mathbf{v}_2) \cdot \mathbf{u} = \mathbf{v}_1 \cdot \mathbf{u} + \mathbf{v}_2 \cdot \mathbf{u} = 0 \Rightarrow \mathbf{v}_1 + \mathbf{v}_2 \in V^\perp,$$

$$(c\mathbf{v}_1) \cdot \mathbf{u} = c(\mathbf{v}_1 \cdot \mathbf{u}) = 0 \Rightarrow c\mathbf{v}_1 \in V^\perp.$$

2. 由定义可得。

3. 由定义可得。

4. $V \subseteq (V^\perp)^\perp$ 是显然的, 下证 $(V^\perp)^\perp \subseteq V$. 令 $\mathbf{v} \in (V^\perp)^\perp$ 是一个非零向量, $\mathbf{u}_1, \dots, \mathbf{u}_k$ 是 V 的一组正交基。由定义 $\mathbf{v} \perp V^\perp$, 反设 $\mathbf{v} \notin V$, 构造线性空间:

$$V' = \text{span}\{\mathbf{v}, \mathbf{u}_1, \dots, \mathbf{u}_k\}$$

显然我们有: $V \subset V'$, 并且 $V' \perp V^\perp$, 由 3 可得: $V' \subseteq (V^\perp)^\perp$, 令 $\mathbf{w} = \mathbf{v} - \sum_{i=1}^k \langle \mathbf{v}, \mathbf{u}_i \rangle \mathbf{u}_i$, 显然 $\mathbf{w} \neq \mathbf{0}, \mathbf{w} \in V'$, 注意到:

$$\forall i \in [k] \quad \langle \mathbf{w}, \mathbf{u}_i \rangle = \langle \mathbf{v}, \mathbf{u}_i \rangle - \langle \mathbf{v}, \mathbf{u}_i \rangle = 0$$

从而

$$\mathbf{w} \in V^\perp \cap (V^\perp)^\perp \Rightarrow \mathbf{w} \cdot \mathbf{v} = 0, \text{ i.e. } \mathbf{w} = \mathbf{0}$$

与 $\mathbf{w}$ 非零矛盾。

□

注 1.11

这里利用了一些额外的结论, 即可以在 V 找到一组**正交基**, 关于这一部分我们会在后一个讲义中证明, 我们会先在这借用一下。

例 1.12 (一些例子)

1. 在例1.5中, 我们有:

$$V_1^\perp = V_2, \quad V_3^\perp = V_4.$$

2. 考察 $\mathbb{R}^3$ 中的子空间 $V = \{(x, y, z) \mid x + y + z = 0\}$, 其正交补为:

$$V^\perp = \text{span}\{(1, 1, 1)\}$$

也就是平面 V 的法向量所构成的子空间。

线性代数基本定理. 在真正刻画正交补的本质之前, 我们首先来叙述其的一个应用。正交补的一个重要引入是叙述完成线性代数基本定理, 我们首先回顾一下矩阵 A 的四个空间:

1. $\mathbf{C}(A)$: A 的列空间, 即所有的 $A\mathbf{x}$ 的集合。
2. $\mathbf{N}(A)$: A 的零空间, 即 $A\mathbf{x} = \mathbf{0}$ 的解的集合。

3. $\mathbf{C}(\mathbf{A}^T)$: $\mathbf{A}$ 的行空间, 即所有的 $\mathbf{A}^T \mathbf{y}$ 的集合。
4. $\mathbf{N}(\mathbf{A}^T)$: $\mathbf{A}$ 的左零空间, 即 $\mathbf{A}^T \mathbf{x} = \mathbf{0}$ 的解的集合。

在上一节内容中, 我们介绍了线性代数基本定理第一部分的内容, 即:

定理 1.13 (Fundamental Theorem of Linear Algebra, Part I)

令 $\mathbf{A}$ 是一个 $m \times n$ 的矩阵并且 $\text{rank}(\mathbf{A}) = r$, 则:

1. $\dim(\mathbf{C}(\mathbf{A})) = \dim(\mathbf{C}(\mathbf{A}^T)) = r$ 。
2. $\dim(\mathbf{N}(\mathbf{A})) = n - r$, $\dim(\mathbf{N}(\mathbf{A}^T)) = m - r$ 。

而定理1.1给出了线性代数基本定理第二部分的内容, 我们用正交补的概念来重新叙述:

定理 1.14 (Fundamental Theorem of Linear Algebra, Part II)

令 $\mathbf{A}$ 是一个 $m \times n$ 的矩阵, 则:

1. $\mathbf{N}(\mathbf{A}) = (\mathbf{C}(\mathbf{A}^T))^\perp$
2. $\mathbf{N}(\mathbf{A}^T) = (\mathbf{C}(\mathbf{A}))^\perp$

定理1.13和定理1.14给出矩阵 $\mathbf{A}$ 的四个空间之间的关系, 如图1所示: 最后让我们来考虑一下为什么

$m \times n$ 的矩阵 $\mathbf{A}$ 的四个空间




图 1 矩阵 $\mathbf{A}$ 的空间理解 (I)

会被称作“正交补”。考虑 $\mathbb{R}^2$ 的子集：

$$V = \{(x, 0) \mid x \in \mathbb{R}\}$$

其正交补为：

$$V^\perp = \{(0, y) \mid y \in \mathbb{R}\}$$

注意到： $\mathbb{R} \neq V \cup V^\perp$ ，但每个 $(x, y) \in \mathbb{R}^2$ 都可以表示为：

$$(x, y) = (x, 0) + (0, y).$$

也就是说， $\mathbb{R}^2$ 可以被表示成类似 $V + V^\perp$ 的形式，这一形式被称作**直和**，出于课程目的设计，我们并不准备引入直和这一运算，但是我们需要给出正交补的一个刻画，其将原本的线性空间分解成了两个子空间之和，即如下引理：

定理 1.15

令 V 是 $\mathbb{R}^n$ 的一个子空间，则对于任一 $x \in \mathbb{R}^n$ ，我们都存在**唯一的** $v \in V$ 和 $v^\perp \in V^\perp$ 使得：

$$x = v + v^\perp.$$

换句话说，

$$\mathbb{R}^n = V + V^\perp \stackrel{\text{def}}{=} \{u + v \mid u \in V \text{ and } v \in V^\perp\}.$$

我们将首先给出**唯一性**的证明，而存在性的证明需要用到**投影**的概念，因此我们将在稍后证明。

证明：[定理1.15的唯一性证明] 假设存在 $v_1, v_2 \in V$ 和 $v_1^\perp, v_2^\perp \in V^\perp$ 使得 $w = v_1 + v_1^\perp = v_2 + v_2^\perp$ ，则有：

$$v_1 - v_2 = v_2^\perp - v_1^\perp.$$

由于 $v_1 - v_2 \in V$ ， $v_2^\perp - v_1^\perp \in V^\perp$ ，从而：

$$v_1 - v_2 \in V \cap V^\perp = \{0\},$$

从而 $v_1 = v_2$ 。同理 $v_1^\perp = v_2^\perp$ 。 □

引理??则进一步给出了矩阵 A 的四个空间之间的关系，如图2所示：

2 投影

寻找向量到直线的最短距离 现在我们来介绍**投影**这一概念，我们从一条直线开始。假设一条线的方向是 $a = (a_1, \dots, a_m)$ 。考虑任一个向量 $b = (b_1, \dots, b_m)$ ，我们希望在这条直线上找到 p ，使得 p 到 b 的距离最小，也就是 $\|p - b\|$ 最小。特别的，我们称这个距离最小的 p 为 **b 在 a 上的投影**，而 $e \stackrel{\text{def}}{=} b - p$ 则称之为**误差**。

图3中给出了在 $\mathbb{R}^2$ 上的一个几何直观，不难发现，当 e 与 a 垂直时， e 的长度最小。事实上，这在任意的维度上都成立。我们首先来准确计算一下 e 与 a 垂直时 p 和 e 的值：

解：[e 与 a 垂直时 p 和 e 的值] 假设：

$$p = \hat{x}a$$

$m \times n$ 的矩阵 A 的四个空间




图 2 矩阵 A 的空间理解 (II)




图 3 投影在二维平面上的几何直观

则 $\mathbf{e} = \mathbf{b} - \mathbf{p}$, 注意到 $\mathbf{e} \perp \mathbf{a}$, 则我们有:

$$0 = \mathbf{a} \cdot \mathbf{e} = \mathbf{a}^T(\mathbf{b} - \mathbf{p}) = \mathbf{a}^T(\mathbf{b} - \hat{x}\mathbf{a}) = \mathbf{a}^T\mathbf{b} - \hat{x}\mathbf{a}^T\mathbf{a}$$

从而我们有:

$$\hat{x} = \frac{\mathbf{a}^T\mathbf{b}}{\mathbf{a}^T\mathbf{a}}$$

即我们所需要的投影 $\mathbf{p}$ 和相应的误差 $\mathbf{e}$ 为:

$$\mathbf{p} = \frac{\mathbf{a}^T\mathbf{b}}{\mathbf{a}^T\mathbf{a}}\mathbf{a}, \quad \mathbf{e} = \mathbf{b} - \mathbf{p} = \mathbf{b} - \frac{\mathbf{a}^T\mathbf{b}}{\mathbf{a}^T\mathbf{a}}\mathbf{a}.$$

□

注 2.1 (利用余弦来计算)

我们也可以通过余弦来计算 $\mathbf{p}$ 和 $\mathbf{e}$. 注意到: $\mathbf{p} = \frac{\|\mathbf{p}\|}{\|\mathbf{a}\|}\mathbf{a}$, $\|\mathbf{p}\| = \|\mathbf{b}\| \cos \theta$ 以及 $\cos \theta = \frac{\mathbf{a}^T\mathbf{b}}{\|\mathbf{a}\|\|\mathbf{b}\|}$, 我们有:

$$\hat{x} = \frac{\|\mathbf{b}\| \cos \theta}{\|\mathbf{a}\|} = \frac{\|\mathbf{b}\|}{\|\mathbf{a}\|} \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\|\|\mathbf{b}\|} = \frac{\mathbf{a} \cdot \mathbf{b}}{\|\mathbf{a}\|^2} = \frac{\mathbf{a}^T\mathbf{b}}{\mathbf{a}^T\mathbf{a}},$$

从而 $\mathbf{p} = \hat{x}\mathbf{a} = \frac{\mathbf{a}^T\mathbf{b}}{\mathbf{a}^T\mathbf{a}}\mathbf{a}$.

现在我们给出这一直观的确切证明, 即误差最小的时候恰好 $\mathbf{e}$ 与 $\mathbf{a}$ 垂直:

证明: [误差最小的情况] 沿用上面的记号, 考察 $\mathbf{a}$ 上任意一点 $x\mathbf{a}$, 则:

$$\begin{aligned} \|\mathbf{b} - x\mathbf{a}\|^2 &= \|\mathbf{b} - \mathbf{p} + \mathbf{p} - x\mathbf{a}\|^2 \\ &= \|\mathbf{b} - \mathbf{p}\|^2 + \|\mathbf{p} - x\mathbf{a}\|^2 + 2(\mathbf{b} - \mathbf{p}) \cdot (\mathbf{p} - x\mathbf{a}) \\ &= \|\mathbf{b} - \mathbf{p}\|^2 + \|\hat{x}\mathbf{a} - x\mathbf{a}\|^2 + 2(\mathbf{b} - \mathbf{p}) \cdot (\hat{x}\mathbf{a} - x\mathbf{a}) \\ &= \|\mathbf{b} - \mathbf{p}\|^2 + (\hat{x} - x)^2\|\mathbf{a}\|^2 + 2(\hat{x} - x)(\mathbf{b} - \mathbf{p}) \cdot \mathbf{a} \\ &= \|\mathbf{b} - \mathbf{p}\|^2 + (\hat{x} - x)^2\|\mathbf{a}\|^2 \\ &\geq \|\mathbf{b} - \mathbf{p}\|^2 \end{aligned}$$

最后一个不等式等号成立当且仅当 $x = \hat{x}$, 所以我们得到 $\mathbf{p}$ 是 $\mathbf{a}$ 方向这条线上唯一的一个点使得其与 $\mathbf{b}$ 的距离是最近的。 □

例 2.2 (一些例子)

1. 对于 $\mathbf{b} = \mathbf{a}_1 = \begin{bmatrix} 2 \\ 3 \end{bmatrix}$ 来说, 其投影 $\mathbf{p}$ 就是其本身 $\mathbf{p} = \begin{bmatrix} 2 \\ 3 \end{bmatrix}$, 误差 $\mathbf{e} = \mathbf{0}$.
2. 对于 $\mathbf{b} = \begin{bmatrix} 3 \\ -2 \end{bmatrix}$, $\mathbf{a}_1 = \begin{bmatrix} 2 \\ 3 \end{bmatrix}$ 来说, 其投影 $\mathbf{p} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$, 误差 $\mathbf{e} = \begin{bmatrix} 3 \\ -2 \end{bmatrix}$.

3. 对于 $\mathbf{b} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$ 和 $\mathbf{a}_2 = \begin{bmatrix} 1 \\ 2 \\ 2 \end{bmatrix}$ 来说, $\mathbf{a}_2^T \mathbf{b} = 5$, $\|\mathbf{a}_2\|^2 = 9$, 从而其投影 $\mathbf{p}$ 为:

$$\mathbf{p} = \hat{\mathbf{a}}_2 = \frac{\mathbf{a}_2^T \mathbf{b}}{\mathbf{a}_2^T \mathbf{a}_2} \mathbf{a}_2 = \frac{5}{9} \mathbf{a} = \begin{bmatrix} \frac{5}{9} \\ \frac{10}{9} \\ \frac{10}{9} \end{bmatrix},$$

$$\text{误差为 } \mathbf{e} = \mathbf{b} - \mathbf{p} = \begin{bmatrix} \frac{4}{9} \\ -\frac{1}{9} \\ -\frac{1}{9} \end{bmatrix}.$$

投影矩阵与误差投影矩阵 注意到:

$$\mathbf{p} = \frac{\mathbf{a}^T \mathbf{b}}{\mathbf{a}^T \mathbf{a}} \mathbf{a} = \frac{\mathbf{a}^T \mathbf{b} \mathbf{a}}{\mathbf{a}^T \mathbf{a}} = \frac{\mathbf{a} \mathbf{a}^T \mathbf{b}}{\mathbf{a}^T \mathbf{a}} = \frac{\mathbf{a} \mathbf{a}^T}{\mathbf{a}^T \mathbf{a}} \mathbf{b}$$

这里 $\frac{\mathbf{a} \mathbf{a}^T}{\mathbf{a}^T \mathbf{a}}$ 可以视作一个 $m \times m$ 的矩阵 $\mathbf{P}$, 更进一步的我们有对于任意的 $\mathbf{b}$, 都有:

$$\mathbf{p} = \mathbf{P} \mathbf{b}$$

时 $\mathbf{p}$ 到直线 $\mathbf{a}$ 的投影, 我们称 $\mathbf{P}$ 为**投影矩阵**, 并且注意到:

$$(\mathbf{I} - \mathbf{P}) \mathbf{b} = \mathbf{b} - \mathbf{p} = \mathbf{e}$$

因此矩阵

$$\mathbf{I} - \mathbf{P}$$

被称之为**误差投影矩阵**。

例 2.3

在例2.2中, 我们有:

1. $\mathbf{a}_1$ 的投影矩阵 $\mathbf{P}$ 和误差矩阵 $\mathbf{I} - \mathbf{P}$ 为:

$$\mathbf{P} = \begin{bmatrix} \frac{4}{13} & \frac{6}{13} \\ \frac{6}{13} & \frac{9}{13} \end{bmatrix}, \quad \mathbf{I} - \mathbf{P} = \begin{bmatrix} \frac{9}{13} & -\frac{6}{13} \\ -\frac{6}{13} & \frac{4}{13} \end{bmatrix}$$

2. $\mathbf{a}_2$ 的投影矩阵 $\mathbf{P}$ 和误差矩阵 $\mathbf{I} - \mathbf{P}$ 为:

$$\mathbf{P} = \begin{bmatrix} \frac{1}{9} & \frac{2}{9} & \frac{2}{9} \\ \frac{2}{9} & \frac{4}{9} & \frac{4}{9} \\ \frac{2}{9} & \frac{4}{9} & \frac{4}{9} \end{bmatrix}, \quad \mathbf{I} - \mathbf{P} = \begin{bmatrix} \frac{8}{9} & -\frac{2}{9} & -\frac{2}{9} \\ -\frac{2}{9} & \frac{5}{9} & -\frac{4}{9} \\ -\frac{2}{9} & -\frac{4}{9} & \frac{5}{9} \end{bmatrix}$$

投影到一个子空间 现在我们将投影的概念进一步扩充到任意的子空间 V 上。考察 $\mathbb{R}^m$ 上的任一子空间 V ，令 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 是 V 的一组基，即：

$$V = \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_n\} = \left\{ \sum_{i=1}^n c_i \mathbf{a}_i \mid c_i \in \mathbb{R} \right\}$$

与到一条线的投影相同， **$\mathbf{b}$ 到 V 的投影**应该是：

V 中离 $\mathbf{b}$ 最近的元素 (可能是唯一的?)

也就是说，我们需要寻找到 V 中的一个向量 $\mathbf{p}$ ：

$$\mathbf{p} = \hat{x}_1 \mathbf{a}_1 + \dots + \hat{x}_n \mathbf{a}_n = A\hat{\mathbf{x}}.$$

使得 $\|\mathbf{b} - \mathbf{p}\|$ 最小，这里我们令：

$$\hat{\mathbf{x}} = \begin{bmatrix} \hat{x}_1 \\ \vdots \\ \hat{x}_n \end{bmatrix}, \quad A = [\mathbf{a}_1 \quad \dots \quad \mathbf{a}_n].$$

令 $\mathbf{e} = \mathbf{b} - \mathbf{p}$ ，我们首先证明，依旧存在 $\mathbf{e} \perp V$ ：

引理 2.4

$\mathbf{e} \perp V$ 。

证明： 对于任意的 $\mathbf{v} \in V$ ，我们有：

$$\mathbf{v} = A\mathbf{y}$$

从而：

$$\begin{aligned} \|\mathbf{b} - \mathbf{v}\|^2 &= \|\mathbf{b} - A\mathbf{y}\|^2 \\ &= \|\mathbf{b} - A\hat{\mathbf{x}} + A\hat{\mathbf{x}} - A\mathbf{y}\|^2 \\ &= \|\mathbf{e}\|^2 + \|A(\hat{\mathbf{x}} - \mathbf{y})\|^2 + 2\mathbf{e} \cdot A(\hat{\mathbf{x}} - \mathbf{y}) \\ &= \|\mathbf{e}\|^2 + \|A(\hat{\mathbf{x}} - \mathbf{y})\|^2 \\ &\geq \|\mathbf{e}\|^2 \end{aligned}$$

□

由引理2.4，我们不难计算出 $\mathbf{p}$ 和 $\mathbf{e}$ 的值，注意到：

$$\mathbf{e} \perp V \implies \mathbf{e} \perp \mathbf{a}_i, \quad i = 1, \dots, n$$

从而：

$$\begin{cases} \mathbf{a}_1^T (\mathbf{b} - A\hat{\mathbf{x}}) = 0 \\ \vdots \\ \mathbf{a}_n^T (\mathbf{b} - A\hat{\mathbf{x}}) = 0 \end{cases}$$

即:

$$A^T(\mathbf{b} - A\hat{\mathbf{x}}) = \mathbf{0} \iff A^T A \hat{\mathbf{x}} = A^T \mathbf{b} \quad (1)$$

注意到 A 是一个 $m \times n$ 的矩阵:

$$A = [\mathbf{a}_1 \quad \cdots \quad \mathbf{a}_n]$$

并且其列向量是线性无关的, 则 $A^T A$ 是 $n \times n$ 的矩阵, 并且如果我们证明 $A^T A$ 是可逆的, 则我们有:

$$\hat{\mathbf{x}} = (A^T A)^{-1} A^T \mathbf{b}$$

并且我们可以得到 $\mathbf{b}$ 到 $V(= \text{span}\{\mathbf{a}_1, \dots, \mathbf{a}_n\})$ 的投影为:

$$\mathbf{p} = A\hat{\mathbf{x}} = A(A^T A)^{-1} A^T \mathbf{b}.$$

对应的投影矩阵为:

$$P = A(A^T A)^{-1} A^T.$$

现在我们来证明 $A^T A$ 是可逆的, 即定理2.5:

定理 2.5

令 A 是一个 $m \times n$ 的矩阵, 并且 $\text{rank}(A) = n$, 则 $A^T A$ 是可逆的。

证明: 我们证明: $\text{column-rank}(A^T A) = n$, 即等价的:

$$A^T A \mathbf{x} = \mathbf{0} \text{ 只有 } \mathbf{0} \text{ 一个解。}$$

事实上, 我们有:

$$\begin{aligned} A^T A \mathbf{x} = \mathbf{0} &\implies \mathbf{x}^T A^T A \mathbf{x} = 0 \\ &\iff (A\mathbf{x})^T A\mathbf{x} = 0 \\ &\iff A\mathbf{x} \cdot A\mathbf{x} = 0 \\ &\iff \|A\mathbf{x}\| = 0 \\ &\iff A\mathbf{x} = \mathbf{0} \\ &\iff \mathbf{x} = \mathbf{0} \quad (\text{这是因为 } \text{rank}(A) = n) \end{aligned}$$

□

例 2.6 (一个例子)

考虑 $\mathbb{R}^3$ 上的子空间 V :

$$V = \text{span} \left\{ \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \\ 2 \end{bmatrix} \right\}$$

我们来计算 $\mathbf{b} = \begin{bmatrix} 6 \\ 0 \\ 0 \end{bmatrix}$ 到该空间的投影和对应的投影矩阵。记矩阵 $\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \end{bmatrix}$, 则我们有:

$$1. \mathbf{A}^T \mathbf{A} = \begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix}, \mathbf{A}^T \mathbf{b} = \begin{bmatrix} 6 \\ 0 \end{bmatrix}$$

2. 解方程: $\mathbf{A}^T \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}^T \mathbf{b}$:

$$\begin{bmatrix} 3 & 3 \\ 3 & 5 \end{bmatrix} \begin{bmatrix} \hat{x}_1 \\ \hat{x}_2 \end{bmatrix} = \begin{bmatrix} 6 \\ 0 \end{bmatrix}$$

可得: $\hat{\mathbf{x}} = (\hat{x}_1, \hat{x}_2) = (5, -3)$

$$3. \text{ 其投影 } \mathbf{p} = \mathbf{A} \hat{\mathbf{x}} = \begin{bmatrix} 5 \\ 2 \\ -1 \end{bmatrix}, \text{ 误差为 } \mathbf{e} = \mathbf{b} - \mathbf{p} = \begin{bmatrix} 1 \\ -2 \\ 1 \end{bmatrix}, \text{ 投影矩阵 } \mathbf{P} = \frac{1}{6} \begin{bmatrix} 5 & 2 & -1 \\ 2 & 2 & 2 \\ -1 & 2 & 5 \end{bmatrix}$$

投影计算的一个总结。 我们现在对投影计算进行一个总结:

1. 我们的目标是计算 $\mathbf{b}$ 到下列空间:

$$\mathbb{V} = \text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_n\})$$

的投影 $\mathbf{p}$, 其中 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 是线性无关的, $\mathbf{p} \in \mathbb{V}$.

2. 我们令 $\mathbf{p} \in \mathbb{V}$ 是满足其误差 $\mathbf{e} = \mathbf{b} - \mathbf{p}$ 与 $\mathbb{V}$ 垂直的向量。我们证明了, 对于任意的 $\mathbf{v} \in \mathbb{V}$:

$$\|\mathbf{b} - \mathbf{v}\| = \min_{\mathbf{u} \in \mathbb{V}} \|\mathbf{b} - \mathbf{u}\| \iff \mathbf{v} = \mathbf{p}$$

3. 我们得到了相应的投影矩阵 $\mathbf{P} = \mathbf{A}(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T$, 即:

$$\mathbf{p} = \mathbf{A} \hat{\mathbf{x}} = \mathbf{A}(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{b}$$

并且我们证明了当 $\text{rank}(\mathbf{A}) = n$ 时 $(\mathbf{A}^T \mathbf{A})^{-1}$ 是存在的, 这也说明了 $\mathbf{p}$ 的**唯一性**。

定理1.15的完整证明。 在本节的最后, 我们回答上一节所遗留的问题。

证明: [定理1.15的完整证明] 唯一性的证明已经给出, 我们在这只给出**存在性**的证明。令 $\mathbf{a}_1, \dots, \mathbf{a}_k$ 表示 $\mathbb{V}$ 的一组基, 并且:

$$\mathbf{A} = \begin{bmatrix} \mathbf{a}_1 & \dots & \mathbf{a}_k \end{bmatrix}$$

则对于任意的 $\mathbf{x} \in \mathbb{R}^n$, 令 $\mathbf{u} = \mathbf{A}(\mathbf{A}^T \mathbf{A})^{-1} \mathbf{A}^T \mathbf{x}$, 则我们有:

$$\mathbf{x} = \mathbf{u} + (\mathbf{x} - \mathbf{u}), \quad \mathbf{u} \in \mathbb{V}, \mathbf{x} - \mathbf{u} \in \mathbb{V}^\perp.$$

□

线性代数 (IX)

Lecturer: 杨启哲

Last modified: 2026 年 5 月 7 日

1 最小二乘解

这一节我们首先还是聚焦于 $Ax = b$ 这一线性方程，我们在之前已经从理论上讨论了方程的解的情况，但在实际情况中，很多时候方程并不存在一个解。

我们以研究人群受全日制教育的年数与收入是否存在关系这一具体问题为例。通过调查，我们得到了 n 个人的数据 $(t_1, y_1), \dots, (t_n, y_n)$ 。这里 t_i 表示第 i 个人受全日制教育的年数， y_i 表示第 i 个人的年收入。

- 假设其满足线性关系，即 $y = f(t) = kt + b$ ，则需要求解下列方程：

$$\begin{cases} kt_1 + b = y_1 \\ \dots \\ kt_n + b = y_n \end{cases}, \quad \text{即} \quad \begin{bmatrix} t_1 & 1 \\ \vdots & \vdots \\ t_n & 1 \end{bmatrix} \begin{bmatrix} k \\ b \end{bmatrix} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$$

- 假设其满足二次关系，即 $y = f(t) = at^2 + bt + c$ ，则需要求解下列方程：

$$\begin{cases} at_1^2 + bt_1 + c = y_1 \\ \dots \\ at_n^2 + bt_n + c = y_n \end{cases}, \quad \text{即} \quad \begin{bmatrix} t_1^2 & t_1 & 1 \\ \vdots & \vdots & \vdots \\ t_n^2 & t_n & 1 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} y_1 \\ \vdots \\ y_n \end{bmatrix}$$

注意到，这类方程的特点是变元个数是固定的，但由于存在大量的数据，所以极有可能形成整个方程组无解的情况，如考虑 $(1, 2), (1, 3), (2, 4), (2, 5)$ ，则下述两个方程：

$$\begin{bmatrix} 1 & 1 \\ 1 & 1 \\ 2 & 1 \\ 2 & 1 \end{bmatrix} \begin{bmatrix} k \\ b \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \\ 4 \\ 5 \end{bmatrix}, \quad \begin{bmatrix} 1 & 1 & 1 \\ 1 & 1 & 1 \\ 4 & 2 & 1 \\ 4 & 2 & 1 \end{bmatrix} \begin{bmatrix} a \\ b \\ c \end{bmatrix} = \begin{bmatrix} 2 \\ 3 \\ 4 \\ 5 \end{bmatrix}$$

都没有解。

但对这类问题，我们也存在实际的需求。因此对这一类问题，求一个合适的近似解也是非常重要的。令 A 是一个 $m \times n$ 的矩阵，所谓近似解，其实就是寻找到一个解 x ，使得：

$$\min_{x \in \mathbb{R}^n} \|b - Ax\|$$

尽可能的小，而这恰恰是求 b 到矩阵 A 的列空间 $C(A)$ 的投影。

$\min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{b} - A\mathbf{x}\|$ 的计算尝试。我们先参照计算投影的方式，给出上述近似解的计算：

1. 我们知道如果 $\hat{\mathbf{x}} \in \mathbb{R}$ 满足：

$$A^T(A\hat{\mathbf{x}} - \mathbf{b}) = \mathbf{0} \quad \text{即} \quad A^T A \hat{\mathbf{x}} = A^T \mathbf{b}$$

则 $A\hat{\mathbf{x}} - \mathbf{b}$ 与 $C(A)$ 正交。

2. 我们可以得到 $\hat{\mathbf{x}}$ 的表达式：

$$\hat{\mathbf{x}} = (A^T A)^{-1} A^T \mathbf{b}$$

并且我们知道 $\hat{\mathbf{x}}$ 是唯一的。

我们称 $\hat{\mathbf{x}}$ 就是 最小二乘解 (least square solution)，因为其误差的长度 $\|\mathbf{e}\|$

$$\mathbf{e} = \mathbf{b} - A\hat{\mathbf{x}}$$

是所有 $\mathbf{b} - A\mathbf{x}$ 中最小的。

但上述计算方法存在一个问题，我们假定了 $\text{rank}(A) = n$ ，从而 $A^T A$ 是可逆的，但事实上这并不一定成立。令 $A = \begin{bmatrix} 1 & 1 \\ 1 & 1 \end{bmatrix}$ ，则 $A^T A = \begin{bmatrix} 2 & 2 \\ 2 & 2 \end{bmatrix}$ ，则 $\text{rank}(A) = \text{rank}(A^T A) = 1$ ， $A^T A$ 不可逆。

问题的解决方案在于上述求解过程实际上是求到 矩阵 A 的列空间 $C(A)$ 的投影，因此我们只需要找到一个矩阵 A' 满足：

$$C(A') = C(A) \quad \text{and} \quad (A')^T(A') \text{可逆}。$$

而这可以通过在矩阵 A 的列向量中选出一组 极大的线性无关向量 来实现，即 $C(A)$ 的一组基。

$\min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{b} - A\mathbf{x}\|$ 的计算。我们现在来严格叙述这一过程。

1. 选择 $C(A)$ 的一组基 $\{\mathbf{a}_{i_1}, \dots, \mathbf{a}_{i_r}\}$ ，其中 $r = \text{rank}(A)$ 。

2. 定义 $m \times r$ 的矩阵：

$$A' = [\mathbf{a}_{i_1} \quad \dots \quad \mathbf{a}_{i_r}]$$

显然我们有： $C(A) = C(A')$ ，并且当 $\text{rank}(A) = n$ 时， A 可以就是 A 本身。

3. $\text{rank}(A')$ 是列满秩的，所以我们可以利用前面的方法来找到 $A'\mathbf{x}' = \mathbf{b}$ 的最优近似解，即：

$$\hat{\mathbf{x}}' = (A'^T A')^{-1} A'^T \mathbf{b} \in \mathbb{R}^r$$

显然其误差 $\mathbf{e} = \mathbf{b} - A'\hat{\mathbf{x}}'$ 是所有 $\mathbf{b} - A\mathbf{x}$ 中长度最小的，即：

$$\|\mathbf{e}\| = \min_{\mathbf{x} \in \mathbb{R}^n} \|\mathbf{b} - A\mathbf{x}\| = \min\{\|\mathbf{b} - \mathbf{v}\| \mid \mathbf{v} \in C(A')\} = \min\{\|\mathbf{b} - \mathbf{v}\| \mid \mathbf{v} \in C(A)\}$$

4. 我们需要的 $\hat{\mathbf{x}} \in \mathbb{R}^n$ 只要满足：

$$A\hat{\mathbf{x}} = A'\hat{\mathbf{x}}'。$$

例 1.1 (一个例子)

考察如下的方程组 $A\mathbf{x} = \mathbf{b}$:

$$\begin{bmatrix} 0 & 1 & 1 \\ 8 & 1 & 9 \\ 8 & 1 & 9 \\ 20 & 1 & 21 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 3 \\ 4 \end{bmatrix}$$

注意到 $\text{rank}(A) = 2 < 3$, $A^T A$ 不可逆。我们可以选择 $\mathbf{C}(A)$ 的一组基为 $\{\mathbf{a}_1 = \begin{bmatrix} 0 \\ 8 \\ 8 \\ 20 \end{bmatrix}, \mathbf{a}_2 = \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix}\}$,

定义 A' :

$$A' = \begin{bmatrix} 0 & 1 \\ 8 & 1 \\ 8 & 1 \\ 20 & 1 \end{bmatrix}$$

则我们有:

$$\hat{\mathbf{x}}' = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = (A'^T A')^{-1} A'^T \mathbf{b} = \begin{bmatrix} \frac{10}{51} \\ \frac{12}{51} \end{bmatrix}$$

我们可以定义:

$$\hat{\mathbf{x}} = \begin{bmatrix} \frac{10}{51} \\ \frac{12}{51} \\ 0 \end{bmatrix}$$

则 $A\hat{\mathbf{x}} = A\hat{\mathbf{x}}'$, 且 $\hat{\mathbf{x}}$ 是 $\mathbf{b}$ 的最小二乘解。

最小二乘解的简化。 在这一部分的讨论中, 我们不妨先假设 A 是可逆的, 注意到此时最小二乘解 $\hat{\mathbf{x}}$ 满足:

$$\hat{\mathbf{x}} = (A^T A)^{-1} A^T \mathbf{b}$$

如果 $A^T A = I$, 则解可以进一步简化为:

$$\hat{\mathbf{x}} = A^T \mathbf{b}$$

定理1.2给出了满足这一条件的矩阵条件:

定理 1.2

令 $A = [\mathbf{a}_1, \dots, \mathbf{a}_n]$ 是一个 $m \times n$ 的矩阵, 则 $A^T A = I$ 当且仅当下列的两个条件满足:

1. 对于任意的 $i \neq j$ 有 $\mathbf{a}_i \perp \mathbf{a}_j$ 。
2. 对于任意的 $i \in [n]$, $\mathbf{a}_i$ 是单位向量, 即 $\|\mathbf{a}_i\| = 1$ 。

证明：只要注意到：

$$A^T A = \begin{bmatrix} \mathbf{a}_1^T \\ \vdots \\ \mathbf{a}_n^T \end{bmatrix} \begin{bmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_n \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1^T \mathbf{a}_1 & \cdots & \mathbf{a}_1^T \mathbf{a}_n \\ \vdots & \ddots & \vdots \\ \mathbf{a}_n^T \mathbf{a}_1 & \cdots & \mathbf{a}_n^T \mathbf{a}_n \end{bmatrix}$$

从而：

$$A^T A = I \iff \mathbf{a}_i^T \mathbf{a}_j = \begin{cases} 1 & \text{当 } i = j \\ 0 & \text{当 } i \neq j \end{cases}$$

□

我们进一步讨论下该条件下的矩阵 A 的意义。注意到此时 A 中每个列向量 $\mathbf{a}_i$ 都满足 $\|\mathbf{a}_i\| = 1$ ，从而对于所有的 $i \in [n]$ ，我们有：

$$\hat{x}_i = \mathbf{a}_i^T \mathbf{b} = \mathbf{a}_i \cdot \mathbf{b} = \frac{\mathbf{a}_i \cdot \mathbf{b}}{\|\mathbf{a}_i\| \|\mathbf{b}\|} \|\mathbf{b}\| = \|\mathbf{b}\| \cos \theta_i$$

这里 θ_i 是 $\mathbf{b}$ 和 $\mathbf{a}_i$ 的夹角。从而 $\mathbf{b}$ 到 $C(A)$ 的投影 $\mathbf{p}$ 可以表示为：

$$\mathbf{p} = \sum_{i=1}^n \hat{x}_i \mathbf{a}_i = \sum_{i=1}^n (\|\mathbf{b}\| \cos \theta_i) \mathbf{a}_i = \sum_{i=1}^n (\mathbf{b} \cdot \mathbf{a}_i) \mathbf{a}_i$$

也就是： $\mathbf{p}$ 是 $\mathbf{b}$ 分别到每条线 $\text{span}(\{\mathbf{a}_i\})$ 上的投影的和。

例 1.3 (例子1.1的延续)

我们沿着例子1.1，考虑如下矩阵：

$$Q = \begin{bmatrix} 0 & \frac{11}{\sqrt{187}} \\ \frac{2}{\sqrt{33}} & \frac{5}{\sqrt{187}} \\ \frac{2}{\sqrt{33}} & \frac{5}{\sqrt{187}} \\ \frac{5}{\sqrt{33}} & -\frac{4}{\sqrt{187}} \end{bmatrix}$$

记其列向量为 $\mathbf{q}_1, \mathbf{q}_2$ ，注意到：

$$\begin{aligned} \mathbf{q}_1 &= 4\sqrt{33}\mathbf{a}_1 \\ \frac{\sqrt{187}}{11}\mathbf{q}_2 &= \mathbf{a}_1 - \frac{3}{44}\mathbf{a}_2 \end{aligned}$$

从而我们有 $C(Q) = C(A)$ ，且 $Q^T Q = I$ 。通过 Q 我们计算对应的最小二乘解为：

$$\begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = (\mathbf{b} \cdot \mathbf{q}_1) \mathbf{q}_1 + (\mathbf{b} \cdot \mathbf{q}_2) \mathbf{q}_2 = \begin{bmatrix} \frac{10}{51} \\ \frac{12}{51} \end{bmatrix}.$$

注意到这不是对任意矩阵 A 都成立，回顾定理1.2，实际上 A 满足：

1. 对于任意的 $i \neq j$ 有 $\mathbf{a}_i \perp \mathbf{a}_j$ 。
2. 对于任意的 $i \in [n]$ ， $\mathbf{a}_i$ 是单位向量，即 $\|\mathbf{a}_i\| = 1$ 。

这恰恰是一组 $C(A)$ 上一组特殊的基，我们称之为标准正交基 (standard orthogonal basis)，在这组基之下，我们可以将 $\mathbf{b}$ 在 $C(A)$ 上的投影表示为：

$$\mathbf{p} = \sum_{i=1}^n (\mathbf{b} \cdot \mathbf{a}_i) \mathbf{a}_i$$

我们会在下一部分进一步讨论这一概念。

2 标准正交基和 Gram-Schmidt 正交化

正交矩阵。 我们首先给出标准正交 的概念。

定义 2.1 (正交向量, Orthonormal Vectors)

$\mathbf{q}_1, \dots, \mathbf{q}_n \in \mathbb{R}^m$ 是标准正交的 (orthonormal), 如果：

$$\mathbf{q}_i^T \mathbf{q}_j = \begin{cases} 0 & \text{当 } i \neq j, \text{ 即 } \mathbf{q}_i \text{ 和 } \mathbf{q}_j \text{ 是正交的} \\ 1 & \text{当 } i = j, \text{ 即 } \mathbf{q}_i \text{ 是单位向量} \end{cases}$$

我们将列向量是标准正交的 矩阵记为 Q ，显然我们有：

$$Q^T Q = I$$

但 $Q Q^T$ 则不一定为单位矩阵，比如考虑 $Q = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ 0 & 0 \end{bmatrix}$ ，我们有： $Q Q^T = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$ 。而我们关注的是满足标准正交的方阵，我们称之为正交矩阵：

定义 2.2 (正交矩阵, Orthogonal Matrix)

称一个 $n \times n$ 的矩阵 Q 是正交矩阵 (Orthogonal Matrix)，如果：

$$Q^T Q = I$$

或者等价的说，其列向量 $\mathbf{q}_1, \dots, \mathbf{q}_n \in \mathbb{R}^n$ 也是标准正交的。

我们先来通过几个例子来理解下正交矩阵的概念：

1. **旋转矩阵。** 第一个例子是 $\mathbb{R}^2$ 上的旋转矩阵 Q_1 ：

$$Q_1 = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}, \quad Q_1^{-1} = Q_1^T = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix}$$

Q_1 如图1所示，其也可以推广到高维的情况，相应的旋转被称作Givens 变换。




图 1 $\mathbb{R}^2$ 上的旋转矩阵

2. **转置矩阵。**第二个例子是 $\mathbb{R}^3$ 上的置换矩阵 Q_2 :

$$Q_2 = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}, \quad Q_2^{-1} = Q_2^T = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}$$

不难验证，其是一个正交矩阵。事实上，对于任意 $n \times n$ 上的置换矩阵 P ，其都是正交矩阵。

3. **反射矩阵。**第三个例子是 $\mathbb{R}^n$ 上的反射矩阵，令 $\mathbf{u} \in \mathbb{R}^n$ 是一个单位向量，定义矩阵 Q_3 :

$$Q_3 = 2\mathbf{u}\mathbf{u}^T - I$$

则我们有:

$$Q_3^T Q_3 = (2\mathbf{u}\mathbf{u}^T - I)^T (2\mathbf{u}\mathbf{u}^T - I) = 4\mathbf{u}\mathbf{u}^T - 4\mathbf{u}\mathbf{u}^T + I = I, \quad \text{即 } Q_3^{-1} = Q_3^T = Q_3$$

Q_3 如图2所示，其也可以推广到高维的情况。




图 2 $\mathbb{R}^2$ 上的反射矩阵

正交矩阵的性质。 我们可以很容易的得到正交矩阵的一些性质:

定理 2.3

令 Q 是一个 $n \times n$ 的矩阵, 则:

1. Q 是正交矩阵 $\iff Q$ 是可逆的并且 $Q^{-1} = Q^T$.
2. 若 Q 是一个正交矩阵, 则其行向量也是标准正交的。

证明: 由正交矩阵的定义可直接得到。 □

正交矩阵另一重要的性质体现在几何直观上, 即其不会改变向量的长度和夹角:

定理 2.4

令 Q 是一个 $n \times n$ 的正交矩阵, 则对于任意的 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^n$, 我们有:

1. $\|Q\mathbf{x}\| = \|\mathbf{x}\|$
2. $Q\mathbf{x} \cdot Q\mathbf{y} = \mathbf{x} \cdot \mathbf{y}$

证明:

1. $\|Q\mathbf{x}\|^2 = Q\mathbf{x} \cdot Q\mathbf{x} = \mathbf{x}^T Q^T Q\mathbf{x} = \mathbf{x}^T \mathbf{x} = \|\mathbf{x}\|^2$.
2. $Q\mathbf{x} \cdot Q\mathbf{y} = \mathbf{x}^T Q^T Q\mathbf{y} = \mathbf{x}^T \mathbf{y} = \mathbf{x} \cdot \mathbf{y}$

□

利用正交矩阵投影。 现在我们考虑到一个正交矩阵 Q 的列空间的投影。令 $\mathbf{q}_1, \dots, \mathbf{q}_n \in \mathbb{R}^m$ 是标准正交的, 并且:

$$Q = [\mathbf{q}_1 \ \cdots \ \mathbf{q}_n]$$

显然 $\text{rank}(Q) = n$ 。从而 $Q\mathbf{x} = \mathbf{b}$ 的最小二乘解为: $\hat{\mathbf{x}} = Q^T \mathbf{b}$, 对应的投影矩阵为 QQ^T , 从而 $\mathbf{b}$ 到 $C(Q)$ 的投影 $\mathbf{p}$ 为:

$$\mathbf{p} = Q\hat{\mathbf{x}} = QQ^T \mathbf{b} = \begin{bmatrix} \mathbf{q}_1 & \cdots & \mathbf{q}_n \end{bmatrix} \begin{bmatrix} \mathbf{q}_1^T \mathbf{b} \\ \vdots \\ \mathbf{q}_n^T \mathbf{b} \end{bmatrix} = \mathbf{q}_1 \mathbf{q}_1^T \mathbf{b} + \cdots + \mathbf{q}_n \mathbf{q}_n^T \mathbf{b}$$

也就是: $\mathbf{p}$ 是 $\mathbf{b}$ 分别到每条线 $\text{span}(\{\mathbf{q}_i\})$ 上的投影的和。

我们在前一节中提到了当 $A^T A = I$ 时, $\mathbf{b}$ 到 $C(A)$ 的投影可被认为是到每个 $\text{span}\{\mathbf{a}_i\}$ 上的投影之和。

注 2.5

我们再讨论一个简化的情况, 即 $A^T A \neq I$ 但 A 的列向量是两两正交的, 即假设其列向量 $\mathbf{a}_1, \dots, \mathbf{a}_n \in$

$\mathbb{R}^m \setminus \{0\}$ 只是两两正交的, 则:

$$\frac{\mathbf{a}_1}{\|\mathbf{a}_1\|}, \dots, \frac{\mathbf{a}_n}{\|\mathbf{a}_n\|}$$

是标准正交的, 并且:

$$\text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_n\}) = \text{span}(\{\frac{\mathbf{a}_1}{\|\mathbf{a}_1\|}, \dots, \frac{\mathbf{a}_n}{\|\mathbf{a}_n\|}\})$$

从而 $\mathbf{b}$ 到 $C(A)$ 上的投影 $\mathbf{p}$ 可以表示为:

$$\begin{aligned} \mathbf{p} &= \frac{\mathbf{a}_1}{\|\mathbf{a}_1\|} \left(\frac{\mathbf{a}_1}{\|\mathbf{a}_1\|} \right)^T \mathbf{b} + \dots + \frac{\mathbf{a}_n}{\|\mathbf{a}_n\|} \left(\frac{\mathbf{a}_n}{\|\mathbf{a}_n\|} \right)^T \mathbf{b} \\ &= \sum_{i \in [n]} \frac{\mathbf{a}_i \mathbf{a}_i^T}{\mathbf{a}_i^T \mathbf{a}_i} \mathbf{b} = \sum_{i \in [n]} \frac{\mathbf{a}_i^T \mathbf{b}}{\mathbf{a}_i^T \mathbf{a}_i} \mathbf{a}_i = \sum_{i \in [n]} \frac{\|\mathbf{b}\| \cos \theta_i}{\|\mathbf{a}_i\|} \mathbf{a}_i = \sum_{i \in [n]} \frac{\mathbf{b} \cdot \mathbf{a}_i}{\|\mathbf{a}_i\|^2} \mathbf{a}_i \end{aligned}$$

这里 θ_i 是 $\mathbf{b}$ 和 $\mathbf{a}_i$ 的夹角。此时投影依旧是到每个 $\text{span}\{\mathbf{a}_i\}$ 上的投影之和。**这说明这一结论的成立条件是对应向量两两正交。**

Gram-Schmidt 正交化 在上述求投影的过程中, 当 A 不是正交矩阵, 即 $A^T A \neq I$ 时, 如果可以找到一个正交矩阵 Q , 使得 $C(Q) = C(A)$, 那么计算投影的方式也会化成简单的形式, 这一问题本质上是问的, 能否从任意一组基内转化出一组标准正交基?

我们先来看一下两个的情况: 假设 $\mathbf{x}, \mathbf{y} \in \mathbb{R}^m \setminus \{0\}$, 则 $\mathbf{x}$ 到 $\text{span}(\{\mathbf{y}\})$ 上的投影为:

$$\mathbf{p} = \frac{\mathbf{y}^T \mathbf{x}}{\mathbf{y}^T \mathbf{y}} \mathbf{y}$$

其误差 $\mathbf{e} = \mathbf{x} - \mathbf{p}$ 满足 $\mathbf{e} \perp \mathbf{y}$ 。从而我们有:

$$\text{span}(\{\mathbf{x}, \mathbf{y}\}) = \text{span}(\{\mathbf{e}, \mathbf{y}\})$$

上述方法也可以推广到更多的情况, 而这就是 Gram-Schmidt 正交化方法:

定理 2.6

令 $\mathbf{a}_1, \dots, \mathbf{a}_n \in \mathbb{R}^m$ 是线性无关的。则存在一组向量 $\mathbf{q}_1, \dots, \mathbf{q}_n \in \mathbb{R}^m$, 满足:

1. 对于任意的 $i \neq j \in [n]$, $\mathbf{q}_i \perp \mathbf{q}_j$ 。
2. $\text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_n\}) = \text{span}(\{\mathbf{q}_1, \dots, \mathbf{q}_n\})$

由定理2.6, 并将得到这组两两正交的向量 $\mathbf{q}_1, \dots, \mathbf{q}_n$ 单位化, 即可得到一组标准正交基:

推论 2.7

一组 $\text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_n\})$ 的标准正交基为:

$$\frac{\mathbf{q}_1}{\|\mathbf{q}_1\|}, \dots, \frac{\mathbf{q}_n}{\|\mathbf{q}_n\|}.$$

证明: [定理2.6的证明] 我们通过归纳的方式来获取 $\mathbf{q}_1, \dots, \mathbf{q}_n$ 。令 $\mathbf{q}_1 = \mathbf{a}_1$ ，假设对于 $k < n$ ，我们已经找到了 $\mathbf{q}_1, \dots, \mathbf{q}_k$ ，满足：

R1. 对于任意的 $i \neq j \in [k]$ ， $\mathbf{q}_i \perp \mathbf{q}_j$ 。

R2. $\text{span}(\{\mathbf{a}_1, \dots, \mathbf{a}_k\}) = \text{span}(\{\mathbf{q}_1, \dots, \mathbf{q}_k\})$ 。

由于 $\mathbf{a}_1, \dots, \mathbf{a}_k$ 是线性无关的，从而 $\mathbf{q}_1, \dots, \mathbf{q}_k$ 也是线性无关的，并且 $\mathbf{q}_i \neq \mathbf{0}$ 。我们定义：

$$\mathbf{q}_{k+1} = \mathbf{a}_{k+1} - \sum_{i=1}^k \frac{\mathbf{q}_i^T \mathbf{a}_{k+1}}{\mathbf{q}_i^T \mathbf{q}_i} \mathbf{q}_i$$

注意到，事实上 $\sum_{i=1}^k \frac{\mathbf{q}_i^T \mathbf{a}_{k+1}}{\mathbf{q}_i^T \mathbf{q}_i} \mathbf{q}_i$ 就是 $\mathbf{a}_{k+1}$ 到 $\text{span}(\{\mathbf{q}_1, \dots, \mathbf{q}_k\})$ 的投影 $\mathbf{p}$ ：

$$\mathbf{p} = \sum_{i=1}^k \frac{\mathbf{q}_i^T \mathbf{q}_i^T}{\mathbf{q}_i^T \mathbf{q}_i} \mathbf{a}_{k+1} = \sum_{i=1}^k \frac{\mathbf{q}_i^T \mathbf{a}_{k+1}}{\mathbf{q}_i^T \mathbf{q}_i} \mathbf{q}_i = \sum_{i \in [k]} \frac{\|\mathbf{a}_{k+1}\| \cos \theta_i}{\|\mathbf{q}_i\|} \mathbf{q}_i$$

这里 θ_i 是 $\mathbf{a}_{k+1}$ 与 $\mathbf{q}_i$ 的夹角。从而：

1. $\mathbf{q}_{k+1} = \mathbf{a}_{k+1} - \mathbf{p}$ 与每个向量 $\mathbf{q}_i (i \in [k])$ 正交。
2. $\text{span}(\{\mathbf{q}_1, \dots, \mathbf{q}_k, \mathbf{a}_{k+1}\}) = \text{span}(\{\mathbf{q}_1, \dots, \mathbf{q}_k, \mathbf{a}_{k+1} - \mathbf{p}\}) = \text{span}(\{\mathbf{q}_1, \dots, \mathbf{q}_k, \mathbf{q}_{k+1}\})$

□

例 2.8 (一个例子)

考察如下三个 $\mathbb{R}^3$ 中的向量：

$$\mathbf{a} = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}, \mathbf{b} = \begin{bmatrix} 2 \\ 0 \\ -2 \end{bmatrix}, \mathbf{c} = \begin{bmatrix} 3 \\ -3 \\ 3 \end{bmatrix}$$

我们可以通过 Gram-Schmidt 正交化来找到一组正交的向量组：

$$1. \mathbf{q}_1 = \mathbf{a} = \begin{bmatrix} 1 \\ -1 \\ 0 \end{bmatrix}$$

$$2. \mathbf{q}_2 = \mathbf{b} - \frac{\mathbf{q}_1^T \mathbf{b}}{\mathbf{q}_1^T \mathbf{q}_1} \mathbf{q}_1 = \begin{bmatrix} 1 \\ 1 \\ -2 \end{bmatrix}$$

$$3. \mathbf{q}_3 = \mathbf{c} - \frac{\mathbf{q}_1^T \mathbf{c}}{\mathbf{q}_1^T \mathbf{q}_1} \mathbf{q}_1 - \frac{\mathbf{q}_2^T \mathbf{c}}{\mathbf{q}_2^T \mathbf{q}_2} \mathbf{q}_2 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

单位化后即可得到一组标准正交基： $\{\frac{1}{\sqrt{2}} \mathbf{q}_1, \frac{1}{\sqrt{6}} \mathbf{q}_2, \frac{1}{\sqrt{3}} \mathbf{q}_3\}$ 。

可逆矩阵的 QR 分解。 我们再来回顾一下 Gram-Schmidt 正交化的过程。令 $\mathbf{a}_1, \dots, \mathbf{a}_n \in \mathbb{R}^m$ 是线性无关的一组向量，我们利用 Gram-Schmidt 正交化得到一组正交的向量组 $\mathbf{q}_1, \dots, \mathbf{q}_n$ ：

$$\begin{aligned}\mathbf{q}_1 &= \mathbf{a}_1 \\ \mathbf{q}_2 &= \mathbf{a}_2 - \frac{\mathbf{q}_1^T \mathbf{a}_2}{\mathbf{q}_1^T \mathbf{q}_1} \mathbf{q}_1 \\ \mathbf{q}_3 &= \mathbf{a}_3 - \frac{\mathbf{q}_1^T \mathbf{a}_3}{\mathbf{q}_1^T \mathbf{q}_1} \mathbf{q}_1 - \frac{\mathbf{q}_2^T \mathbf{a}_3}{\mathbf{q}_2^T \mathbf{q}_2} \mathbf{q}_2 \\ &\vdots \\ \mathbf{q}_n &= \mathbf{a}_n - \frac{\mathbf{q}_1^T \mathbf{a}_n}{\mathbf{q}_1^T \mathbf{q}_1} \mathbf{q}_1 - \frac{\mathbf{q}_2^T \mathbf{a}_n}{\mathbf{q}_2^T \mathbf{q}_2} \mathbf{q}_2 - \dots - \frac{\mathbf{q}_{n-1}^T \mathbf{a}_n}{\mathbf{q}_{n-1}^T \mathbf{q}_{n-1}} \mathbf{q}_{n-1}\end{aligned}$$

从而定义下列矩阵：

$$A = [\mathbf{a}_1, \dots, \mathbf{a}_n], \quad \hat{Q} = [\mathbf{q}_1, \dots, \mathbf{q}_n], \quad Q = \left[\frac{\mathbf{q}_1}{\|\mathbf{q}_1\|}, \dots, \frac{\mathbf{q}_n}{\|\mathbf{q}_n\|} \right]$$

则我们有：

$$\begin{aligned}A &= \hat{Q}R = [\mathbf{q}_1 \quad \dots \quad \mathbf{q}_n] \begin{bmatrix} 1 & \frac{\mathbf{q}_1^T \mathbf{a}_2}{\mathbf{q}_1^T \mathbf{q}_1} & \dots & \frac{\mathbf{q}_1^T \mathbf{a}_n}{\mathbf{q}_1^T \mathbf{q}_1} \\ 0 & 1 & \dots & \frac{\mathbf{q}_2^T \mathbf{a}_n}{\mathbf{q}_2^T \mathbf{q}_2} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 1 \end{bmatrix} \\ A &= QR = \left[\frac{\mathbf{q}_1}{\|\mathbf{q}_1\|} \quad \dots \quad \frac{\mathbf{q}_n}{\|\mathbf{q}_n\|} \right] \begin{bmatrix} \|\mathbf{q}_1\| & \frac{\mathbf{q}_1^T \mathbf{a}_2}{\|\mathbf{q}_1\|} & \dots & \frac{\mathbf{q}_1^T \mathbf{a}_n}{\|\mathbf{q}_1\|} \\ 0 & \|\mathbf{q}_2\| & \dots & \frac{\mathbf{q}_2^T \mathbf{a}_n}{\|\mathbf{q}_2\|} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \|\mathbf{q}_n\| \end{bmatrix}\end{aligned}$$

这意味着任何一个可逆矩阵 A 都可以分解为一个正交矩阵 Q 和一个主对角线上是正数的上三角矩阵 R 的乘积，即 QR 分解。

定理 2.9

令 A 是一个 $n \times n$ 的可逆矩阵，则存在一个正交矩阵 Q 和一个主对角线上是正数的上三角矩阵 R ，使得

$$A = QR.$$

特别的，该分解是唯一的。

证明： 存在性的证明已有上述过程给出，我们下给出唯一性的证明。反设其中存在两个 QR 分解 $A = Q_1 R_1 = Q_2 R_2$ ，其中 Q_1, Q_2 是正交矩阵， R_1, R_2 是上三角矩阵，我们有：

$$Q_2^{-1} Q_1 = R_2 R_1^{-1}.$$

这意味着 $R' = R_2 R_1^{-1}$ 是一个正交矩阵并且是一个上三角矩阵。下用数学归纳法证明 R' 的第 i 列是 $\mathbf{e}_i$ ，即只有第 i 个元素是 1，其余元素都是 0 的向量。

- 当 $i = 1$ 时, 由上三角矩阵的定义及 R 的每一列都是单位向量可得 R' 的第一列是 $\mathbf{e}_1$, 显然成立。
- 假设当 $i = k$ 时成立, 即 R' 的第 k 列是 $\mathbf{e}_k$, 则考虑 R' 的第 $k+1$ 列 $\mathbf{r}_{k+1}$, 则我们有:
 1. 对于 $i > k+1$, $\mathbf{r}_{k+1}(i) = 0$.
 2. 对于 $i < k+1$, 注意到 R' 是正交矩阵, 从而第 $k+1$ 列和第 i 列是正交的, 从而 $\mathbf{r}_{k+1}(i) = 0$.
 3. 对于 $i = k+1$, 注意到 R' 是一个正对角的元的上三角矩阵, 从而 $\mathbf{r}_{k+1}(k+1) = 1$.

□

例 2.10 (一个例子)

考察矩阵:

$$A = \begin{bmatrix} 1 & 2 & 4 \\ 0 & 0 & 5 \\ 0 & 3 & 6 \end{bmatrix}$$

其 $\text{rank}(A) = 3$, 将其列向量进行 Gram-Schmidt 正交化, 得到:

$$1. \mathbf{q}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}.$$

$$2. \mathbf{q}_2 = \begin{bmatrix} 2 \\ 0 \\ 3 \end{bmatrix} - \frac{(1,0,0) \cdot (2,0,3)}{(1,0,0) \cdot (1,0,0)} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix}$$

$$3. \mathbf{q}_3 = \begin{bmatrix} 4 \\ 5 \\ 6 \end{bmatrix} - \frac{(1,0,0) \cdot (4,5,6)}{(1,0,0) \cdot (1,0,0)} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} - \frac{(0,0,3) \cdot (4,5,6)}{(0,0,3) \cdot (0,0,3)} \begin{bmatrix} 0 \\ 0 \\ 3 \end{bmatrix} = \begin{bmatrix} 0 \\ 5 \\ 0 \end{bmatrix}$$

从而我们有:

$$A = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 5 \\ 0 & 3 & 0 \end{bmatrix} \begin{bmatrix} 1 & 2 & 4 \\ 0 & 1 & 2 \\ 0 & 0 & 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} 1 & 2 & 4 \\ 0 & 3 & 6 \\ 0 & 0 & 5 \end{bmatrix} (= QR).$$

我们再利用矩阵的 QR 分解来观察一下投影的计算。注意到:

$$A^T A = R^T Q^T Q R = R^T R$$

从而:

$$A^T A \hat{\mathbf{x}} = A^T \mathbf{b} \implies R^T R A \hat{\mathbf{x}} = R^T Q^T \mathbf{b} \implies R A \hat{\mathbf{x}} = Q^T \mathbf{b}$$

这意味着:

$$\hat{\mathbf{x}} = R^{-1} Q^T \mathbf{b}.$$

这里 R^{-1} 是一个上三角矩阵, 从而 $\hat{\mathbf{x}}$ 可以通过回代法求解。

最小二乘解的进一步讨论。 最后我们想再展现一下"求最小距离"的一个理解。事实上, 我们上述所讨论的, 是与**内积定义**无关的性质, 这意味着, 我们可以在别的内积空间中进行类似的讨论, 如之前我们提到, 我们可以定义在 $[\pi, \pi]$ 上的实值函数所构成的线性空间 F 上的内积:

$$f \cdot g \stackrel{\text{def}}{=} \int_{-\pi}^{\pi} f(x)g(x)dx$$

考察 F 上的一个子空间 V , 其由在 $[\pi, \pi]$ 上不超过 5 次的实系数多项式构成, 显然 V 是 F 上的一个子空间。现在考虑如下一个问题, 我们希望求一个 $f = \sin x$ 在 V 上的投影 g , 即:

$$\min_{g \in V} \|f - g\| = \min_{g \in V} \sqrt{\int_{-\pi}^{\pi} (\sin x - g(x))^2 dx}$$

注意到: $1, x, x^2, x^3, x^4, x^5$ 实际上是 V 的一组基, 我们可以通过 Gram-Schmidt 正交化将其转化为一组正交基 $\hat{e}_1, \dots, \hat{e}_6$:

$$\hat{e}_1 = 1$$

$$\hat{e}_2 = x - \frac{\int_{-\pi}^{\pi} x dx}{\int_{-\pi}^{\pi} dx} = x$$

$$\hat{e}_3 = x^2 - \frac{\int_{-\pi}^{\pi} x^2 dx}{\int_{-\pi}^{\pi} dx} - \frac{\int_{-\pi}^{\pi} x^3 dx}{\int_{-\pi}^{\pi} x^2 dx} x = x^2 - \frac{1}{3}\pi^2$$

$$\hat{e}_4 = x^3 - \frac{\int_{-\pi}^{\pi} x^3 dx}{\int_{-\pi}^{\pi} dx} - \frac{\int_{-\pi}^{\pi} x^4 dx}{\int_{-\pi}^{\pi} x^2 dx} x^2 - \frac{\int_{-\pi}^{\pi} x^3(x^2 - \frac{1}{3}\pi^2) dx}{\int_{-\pi}^{\pi} (x^2 - \frac{1}{3}\pi^2)^2 dx} (x^2 - \frac{1}{3}\pi^2) = x^3 - \frac{3}{5}\pi^2 x$$

$$\begin{aligned} \hat{e}_5 &= x^4 - \frac{\int_{-\pi}^{\pi} x^4 dx}{\int_{-\pi}^{\pi} dx} - \frac{\int_{-\pi}^{\pi} x^5 dx}{\int_{-\pi}^{\pi} x^2 dx} - \frac{\int_{-\pi}^{\pi} x^4(x^2 - \frac{1}{3}\pi^2) dx}{\int_{-\pi}^{\pi} (x^2 - \frac{1}{3}\pi^2)^2 dx} (x^2 - \frac{1}{3}\pi^2) - \frac{\int_{-\pi}^{\pi} x^4(x^3 - \frac{3}{5}\pi^2 x) dx}{\int_{-\pi}^{\pi} (x^3 - \frac{3}{5}\pi^2 x)^2 dx} (x^3 - \frac{3}{5}\pi^2 x) \\ &= x^4 - \frac{3}{5}\pi^2 x^2 + \frac{3}{35}\pi^4 \end{aligned}$$

$$\begin{aligned} \hat{e}_6 &= x^5 - \frac{\int_{-\pi}^{\pi} x^5 dx}{\int_{-\pi}^{\pi} dx} - \frac{\int_{-\pi}^{\pi} x^6 dx}{\int_{-\pi}^{\pi} x^2 dx} - \frac{\int_{-\pi}^{\pi} x^5(x^2 - \frac{1}{3}\pi^2) dx}{\int_{-\pi}^{\pi} (x^2 - \frac{1}{3}\pi^2)^2 dx} (x^2 - \frac{1}{3}\pi^2) - \frac{\int_{-\pi}^{\pi} x^5(x^3 - \frac{3}{5}\pi^2 x) dx}{\int_{-\pi}^{\pi} (x^3 - \frac{3}{5}\pi^2 x)^2 dx} (x^3 - \frac{3}{5}\pi^2 x) \\ &\quad - \frac{\int_{-\pi}^{\pi} x^5(x^4 - \frac{3}{5}\pi^2 x^2 + \frac{3}{35}\pi^4) dx}{\int_{-\pi}^{\pi} (x^4 - \frac{3}{5}\pi^2 x^2 + \frac{3}{35}\pi^4)^2 dx} (x^4 - \frac{3}{5}\pi^2 x^2 + \frac{3}{35}\pi^4) \\ &= x^5 - \frac{5}{2}\pi^2 x^3 + \frac{15}{14}\pi^4 x \end{aligned}$$

单位化后便可得到一组标准正交基 $e_1, \dots, e_6$, 计算 $\sin x$ 到对应元素的投影可得:

$$(e_1 \cdot \sin x)e_1 = \frac{1}{\int_{-\pi}^{\pi} dx} \int_{-\pi}^{\pi} \sin x dx = 0$$

$$(e_2 \cdot \sin x)e_2 = \left(\frac{1}{\int_{-\pi}^{\pi} x^2 dx} \int_{-\pi}^{\pi} x \sin x dx \right) x = \left(\frac{3}{2\pi^3} \int_{-\pi}^{\pi} x \sin x dx \right) x = \frac{3}{\pi^2} x$$

$$(e_3 \cdot \sin x)e_3 = \left(\frac{1}{\int_{-\pi}^{\pi} (x^2 - \frac{1}{3}\pi^2)^2 dx} \int_{-\pi}^{\pi} (x^2 - \frac{1}{3}\pi^2) \sin x dx \right) (x^2 - \frac{1}{3}\pi^2) = 0$$

$$(e_4 \cdot \sin x)e_4 = \left(\frac{1}{\int_{-\pi}^{\pi} (x^3 - \frac{3}{5}\pi^2 x)^2 dx} \int_{-\pi}^{\pi} (x^3 - \frac{3}{5}\pi^2 x) \sin x dx \right) (x^3 - \frac{3}{5}\pi^2 x) = \left(\frac{35}{2\pi^4} - \frac{525}{2\pi^6} \right) (x^3 - \frac{3}{5}\pi^2 x)$$




图 3 $\sin x$ 和由上述两个五次多项式的比较，上图为 $\sin x$ 和由泰勒多项式展开得到的多项式的比较，下图为 $\sin x$ 和由 Gram-Schmidt 正交化得到的多项式的比较，图中蓝色曲线表示的是 $\sin x$ 。

$$\begin{aligned}
 (\mathbf{e}_5 \cdot \sin x) \mathbf{e}_5 &= \left(\frac{1}{\int_{-\pi}^{\pi} (x^4 - \frac{3}{5}\pi^2 x^2 + \frac{3}{35}\pi^4)^2 dx} \int_{-\pi}^{\pi} (x^4 - \frac{3}{5}\pi^2 x^2 + \frac{3}{35}\pi^4) \sin x dx \right) (x^4 - \frac{3}{5}\pi^2 x^2 + \frac{3}{35}\pi^4) = 0 \\
 (\mathbf{e}_6 \cdot \sin x) \mathbf{e}_6 &= \left(\frac{1}{\int_{-\pi}^{\pi} (x^5 - \frac{5}{2}\pi^2 x^3 + \frac{15}{14}\pi^4 x)^2 dx} \int_{-\pi}^{\pi} (x^5 - \frac{5}{2}\pi^2 x^3 + \frac{15}{14}\pi^4 x) \sin x dx \right) (x^5 - \frac{5}{2}\pi^2 x^3 + \frac{15}{14}\pi^4 x) \\
 &= -\frac{1386}{937\pi^{10}} (3\pi^4 + 35\pi^2 - 840) (x^5 - \frac{5}{2}\pi^2 x^3 + \frac{15}{14}\pi^4 x)
 \end{aligned}$$

从而，我们可以计算 g :

$$g(x) = \sum_{i=1}^6 ((\sin x) \cdot \mathbf{e}_i) \mathbf{e}_i \approx 0.987862x - 0.155271x^3 + 0.00564312x^5.$$

而这恰恰是比由泰勒多项式展开的五次多项式逼近:

$$x - \frac{x^3}{6} + \frac{x^5}{120}$$

更接近 $\sin x$ 的多项式，见图3所示。

注 2.11

该例与图3来源于《Linear Algebra Done Right》的第3版，作者是 Sheldon Axler。其中的计算则由笔者完成，如有错误，欢迎指正。

行列式 (Determinants)

Lecturer: 杨启哲

Last modified: 2026 年 5 月 25 日

这是一个关于行列式的讲义，主要分为两部分：行列式的一个快速学习 [1] 和 行列式的正式介绍 [2]，以应对同学们的不同需求。如果只是想快速知道如何计算行列式的值，可以看 [1]，但如果想对行列式进行一个系统的学习，请阅读 [2]。

1 行列式的一个快速学习

1.1 行列式和矩阵的联系和区别

1. 从形式上来说，行列式是 $n \times n$ 的形式，而矩阵的行和列是可以不相等的。特别的，我们会用 $\begin{vmatrix} * \end{vmatrix}$ 表示行列式，而用 $\begin{bmatrix} * \end{bmatrix}$ 表示矩阵：

$$\begin{vmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix}, \quad \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{m1} & \cdots & a_{mn} \end{bmatrix}$$

上式左边是一个行列式，而右边则表示矩阵。

2. 从值上来说，行列式是一个具体的值，而矩阵是由 $m \times n$ 个元素组成的一张表。
3. 对于一个方阵 A ，我们将以其形式的行列式的值记为 $\det(A)$ 或者 $|A|$ ，称为矩阵 A 的行列式。如：

$$\begin{vmatrix} 1 & 2 \\ 3 & 4 \end{vmatrix} = -2, \quad A = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

我们称 $\det(A) = -2$ 。

4. 对于方阵 A 来说， $\det(A)$ 是否等于 0 决定了矩阵 A 是否可逆。

1.2 行列式的计算

行列式的一些性质 我们将首先列举出一些行列式的性质，这些性质能帮助我们进行对行列式的计算。然后我们将给出一些行列式的具体公式。请注意，尤其是二阶和三阶的行列式，其只是恰好具有下列的形式，并不具备往高阶推广的方式。

- 将行列式的某些列的线性组合加到另一列上 (其他列不改变)，行列式的值保持不变。
- 将行列式的某些行的线性组合加到另一行上 (其他行不改变)，行列式的值保持不变。
- 交换行列式的两列，行列式的值变号。

- 交换行列式的两行，行列式的值变号。
- 行列式的某一列乘以一个系数 k ，行列式的值变为原来的 k 倍。
- 行列式的某一行乘以一个系数 k ，行列式的值变为原来的 k 倍。
- 三角矩阵 (上三角 or 下三角) 的行列式的值等于主对角线上 (即左上向右下) 元素的乘积。

二阶行列式的计算： 对于一个 2×2 的矩阵：

$$A = \begin{bmatrix} x_1 & x_2 \\ y_1 & y_2 \end{bmatrix}$$

$$\det(A) = \begin{vmatrix} x_1 & x_2 \\ y_1 & y_2 \end{vmatrix} = x_1 y_2 - x_2 y_1$$


三阶行列式的计算： 对于一个 3×3 的矩阵：

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

我们有：

$$\det(A) = \begin{vmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{vmatrix} = a_{11}a_{22}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} - a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33} - a_{13}a_{22}a_{31}$$

这也就是书本中常见的三阶行列式计算的记忆方式：



n 阶行列式的计算： 我们一共提供三种方法来计算 n 阶行列式，请注意这三种方式对二阶和三阶也是成立的，更确切地说是基于这三种方式我们可以发现二阶行列式和三阶行列式计算的一个简单形式。

1. 对矩阵 (行列式) 进行初等列变换 (行变换)，将其转换成一个三角矩阵，然后计算三角矩阵的行列式的值，再根据上述行列式的性质反推回原来的行列式的值。我们这里用一个例子进行说明：

例 1.1

考察 4×4 的矩阵:

$$\begin{bmatrix} 2 & 1 & 4 & 1 \\ 3 & -1 & 2 & 1 \\ 1 & 2 & 3 & 2 \\ 5 & 0 & 6 & 2 \end{bmatrix}$$

我们有:

$$\begin{bmatrix} 2 & 1 & 4 & 1 \\ 3 & -1 & 2 & 1 \\ 1 & 2 & 3 & 2 \\ 5 & 0 & 6 & 2 \end{bmatrix} \Rightarrow \begin{bmatrix} 2 & 0 & 0 & 0 \\ 3 & -\frac{5}{2} & -4 & -\frac{1}{2} \\ 1 & \frac{3}{2} & 1 & \frac{3}{2} \\ 5 & -\frac{5}{2} & -4 & -\frac{1}{2} \end{bmatrix} \Rightarrow \begin{bmatrix} 2 & 0 & 0 & 0 \\ 3 & -\frac{5}{2} & 0 & 0 \\ 1 & \frac{3}{2} & -\frac{7}{5} & -\frac{9}{10} \\ 5 & -\frac{5}{2} & 0 & 0 \end{bmatrix} \Rightarrow \begin{bmatrix} 2 & 0 & 0 & 0 \\ 3 & -\frac{5}{2} & 0 & 0 \\ 1 & \frac{3}{2} & -\frac{7}{5} & 0 \\ 5 & -\frac{5}{2} & 0 & 0 \end{bmatrix}$$

从而:

$$\det \begin{bmatrix} 2 & 1 & 4 & 1 \\ 3 & -1 & 2 & 1 \\ 1 & 2 & 3 & 2 \\ 5 & 0 & 6 & 2 \end{bmatrix} = \begin{vmatrix} 2 & 1 & 4 & 1 \\ 3 & -1 & 2 & 1 \\ 1 & 2 & 3 & 2 \\ 5 & 0 & 6 & 2 \end{vmatrix} = \begin{vmatrix} 2 & 0 & 0 & 0 \\ 3 & -\frac{5}{2} & 0 & 0 \\ 1 & \frac{3}{2} & -\frac{7}{5} & 0 \\ 5 & -\frac{5}{2} & 0 & 0 \end{vmatrix} = 2 \cdot \left(-\frac{5}{2}\right) \cdot \left(-\frac{7}{5}\right) \cdot 0 = 0$$

2. 行列式的展开。我们可以将 n 阶行列式展开成若干个更小的行列式的和。具体来说, 令 A 是一个 $n \times n$ 的矩阵, 并且 $n \geq 2$ 。对于任意的 $i, j \in [n]$, 我们定义:

$A_{-i,-j}$ 是将 A 第 i 行第 j 列的元素删去后得到的 $(n-1) \times (n-1)$ 的矩阵。

下列数:

$$A_{ij} = (-1)^{i+j} \det(A_{-i,-j})$$

称之为代数余子式 (Cofactor)。则我们可以将 n 阶行列式展开为:

- 按第 i 行展开: $\det(A) = a_{i1}A_{i1} + \cdots + a_{in}A_{in}$ 。
- 按第 j 列展开: $\det(A) = a_{1j}A_{1j} + \cdots + a_{nj}A_{nj}$ 。

我们也用一个例子进行展示。

例 1.2

考察行列式:

$$\begin{vmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 0 & 0 \\ 1 & 0 & 3 & 0 \\ 1 & 0 & 0 & 4 \end{vmatrix}$$

我们根据其**第一列**展开进行计算：

$$\begin{vmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 0 & 0 \\ 1 & 0 & 3 & 0 \\ 1 & 0 & 0 & 4 \end{vmatrix} = 1 \begin{vmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 4 \end{vmatrix} - 1 \begin{vmatrix} 1 & 1 & 1 \\ 0 & 3 & 0 \\ 0 & 0 & 4 \end{vmatrix} + 1 \begin{vmatrix} 1 & 1 & 1 \\ 2 & 0 & 0 \\ 0 & 0 & 4 \end{vmatrix} - 1 \begin{vmatrix} 1 & 1 & 1 \\ 2 & 0 & 0 \\ 0 & 3 & 0 \end{vmatrix}$$

$$= 24 - 12 - 8 - 6 = -2$$

我们也可以按**第二列**进行展开进行计算：

$$\begin{vmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 0 & 0 \\ 1 & 0 & 3 & 0 \\ 1 & 0 & 0 & 4 \end{vmatrix} = (-1)^{2+1} 1 \begin{vmatrix} 1 & 0 & 0 \\ 1 & 3 & 0 \\ 1 & 0 & 4 \end{vmatrix} + (-1)^{2+2} 2 \begin{vmatrix} 1 & 1 & 1 \\ 1 & 3 & 0 \\ 1 & 0 & 4 \end{vmatrix} = -12 + 2 * 5 = -2$$

也可以选择按**第二行**展开进行计算：

$$\begin{vmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 0 & 0 \\ 1 & 0 & 3 & 0 \\ 1 & 0 & 0 & 4 \end{vmatrix} = (-1)^{1+2} 1 \begin{vmatrix} 1 & 1 & 1 \\ 0 & 3 & 0 \\ 0 & 0 & 4 \end{vmatrix} + (-1)^{2+2} 2 \begin{vmatrix} 1 & 1 & 1 \\ 1 & 3 & 0 \\ 1 & 0 & 4 \end{vmatrix} = -12 + 2 * 5 = -2$$

3. 行列式的计算公式，即行列式的定义。令 A 是一个 $n \times n$ 的矩阵，则

$$\det(A) = \sum_{\sigma \in \text{Perm}(n)} (-1)^{\tau(\sigma)} a_{\sigma(1)1} a_{\sigma(2)2} \cdots a_{\sigma(n)n}$$

这里 $\text{Perm}(n)$ 指的是 $[n]$ 上的所有置换 (全排列)，而 $\tau(\sigma)$ 指的是置换对应排列的逆序数。我们用三阶的例子来进行展示：

例 1.3

对于 3×3 的矩阵：

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

其一共有 123, 132, 213, 231, 312, 321 六种不同的置换，并且：

$$\tau(123) = 0, \tau(132) = 1, \tau(213) = 1, \tau(231) = 2, \tau(312) = 2, \tau(321) = 3$$

从而我们有：

$$\begin{aligned} \det(A) &= (-1)^{\tau(123)} a_{11} a_{22} a_{33} + (-1)^{\tau(132)} a_{11} a_{23} a_{32} + (-1)^{\tau(213)} a_{12} a_{21} a_{33} \\ &\quad + (-1)^{\tau(231)} a_{12} a_{23} a_{31} + (-1)^{\tau(312)} a_{13} a_{21} a_{32} + (-1)^{\tau(321)} a_{13} a_{22} a_{31} \\ &= a_{11} a_{22} a_{33} + a_{12} a_{23} a_{31} + a_{13} a_{21} a_{32} - a_{11} a_{23} a_{32} - a_{12} a_{23} a_{31} - a_{13} a_{22} a_{31} \end{aligned}$$

需要注意的是，当考虑 n 时一共有 $n!$ 种不同的置换，因此此时共有 $n!$ 项。

Cramer 法则： 最后我们简单介绍下 Cramer 法则，其可以用来求解方程组和计算矩阵的逆矩阵。考察下列的方程组：

$$\begin{aligned} a_{11}x_1 + \cdots + a_{1n}x_n &= b_1 \\ &\vdots \\ a_{n1}x_1 + \cdots + a_{nn}x_n &= b_n \end{aligned} \quad \text{即} \quad \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_n \end{bmatrix} \quad (\text{记作 } A\mathbf{x} = \mathbf{b})$$

对于任意的 $i \in [n]$ ，令 A_i 是将 A 的第 i 列替换成 $\mathbf{b}$ 后的矩阵，则方程组 $A\mathbf{x} = \mathbf{b}$ 的解可以表示为：

$$\mathbf{x} = \begin{bmatrix} \frac{\det(A_1)}{\det(A)} \\ \vdots \\ \frac{\det(A_n)}{\det(A)} \end{bmatrix}$$

当然此时若 $\det(A) = 0$ ，则该方程组无解或者有无穷多解。运用 Cramer 法则，我们也可以求解矩阵的逆矩阵，即对于一个 $n \times n$ 的矩阵 A ，其逆矩阵 A^{-1} 可以表示为：

$$A^{-1} = \frac{1}{\det(A)} \begin{bmatrix} A_{11} & \cdots & A_{n1} \\ \vdots & \ddots & \vdots \\ A_{1n} & \cdots & A_{nn} \end{bmatrix}$$

再次强调，这里的 A_{ij} 是对应的代数余子式。特别的，我们将 $\begin{bmatrix} A_{11} & \cdots & A_{n1} \\ \vdots & \ddots & \vdots \\ A_{1n} & \cdots & A_{nn} \end{bmatrix}$ 称为 A 的伴随矩阵，记作 A^* 。

2 行列式的正式介绍

2.1 行列式究竟求的是什么？

为了考虑为何要引入行列式这个概念，让我们能从二阶的例子开始。我们直接给出二阶行列式的严格定义：

$$\begin{vmatrix} x_1 & x_2 \\ y_1 & y_2 \end{vmatrix} = x_1y_2 - x_2y_1$$

两个不共线（线性无关）的二维平面上的向量可以在平面上围出一个平行四边形。上述定义实际上是计算了在二维平面上由向量 (x_1, y_1) 和 (x_2, y_2) 围成的平行四边形的有向面积。这里的正方向指的是逆时针方向，即从 (x_1, y_1) 到 (x_2, y_2) 的方向如果是逆时针方向，则面积为正，否则为负。如图??所示。

同样的想法，我们可以扩展到三维的情况。三个不共面（线性无关）的三维向量可以在三维空间中围成一个有向体积。这里其体积的方向，我们可以通过右手系来确定。需要说明的是，我们也可以使用左手系，




图 1 上图中，左图由向量 (x_1, y_1) 和 (x_2, y_2) 围成的平行四边形的有向面积是正的；而右图由向量 (x_1, y_1) 和 (x_2, y_2) 围成的平行四边形的有向面积则是负的。

两者正好是相反的，如图??所示。当三个向量 $\mathbf{x}, \mathbf{y}, \mathbf{z}$ 确定的时候，其围成的平行六面体的有向体积也已经确定，我们将其按用列的方式表示：

$$\begin{vmatrix} \mathbf{x} & \mathbf{y} & \mathbf{z} \end{vmatrix} = \begin{vmatrix} x_1 & y_1 & z_1 \\ x_2 & y_2 & z_2 \\ x_3 & y_3 & z_3 \end{vmatrix}$$

这其实就是三阶行列式。




图 2 我们以右手系为例进行介绍。对于三个向量 $\mathbf{x}, \mathbf{y}, \mathbf{z}$ 来说，将大拇指指向第一个向量 $\mathbf{x}$ ，食指指向第二个向量 $\mathbf{y}$ ，则中指的方向表示为正方向，即如果第三个向量 $\mathbf{z}$ 和中指同向，则该有向体积是正的；否则则是负的。左手系的情况恰好相反。

我们进一步推广到 n 维的情况。 n 个不共面 (线性无关) 的 n 维向量 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 可以在 n 维空间中围

成一个平行六面体，我们的目标依旧是求其**有向体积**。我们记这个函数为 $\mathcal{D}$ ，即 $\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_n)$ 表示 n 个向量 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 围成的有向体积。当然，我们可以将其表示为行列式的形式：

$$\begin{vmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_n \end{vmatrix} = \begin{vmatrix} \mathbf{a}_1[1] & \cdots & \mathbf{a}_1[n] \\ \vdots & \ddots & \vdots \\ \mathbf{a}_n[1] & \cdots & \mathbf{a}_n[n] \end{vmatrix}$$

当然，这就是 n 阶行列式。我们明确一下， **n 阶行列式** 实际上在求 n 维空间中 n 个向量围成的有向体积。所以这也解释了为什么行列式只有类似方阵这样的形式，而不存在 $m \times n$ 的样子。

我们现在给了行列式的一个几何直观和基于几何上的定义，但是我们还有一些问题没有解决：

1. 这个定义是良定义的么？即是否可能有不同的值，抑或是不存在具体的值？
2. 这个有向体积该如何计算？大小？符号？

我们将在下节给出介绍。在这，为了后面的叙述方便，我们介绍一些后面会用到的符号，对于这 n 个 n 维向量 $\mathbf{a}_1, \dots, \mathbf{a}_n$ ，我们将其写成矩阵的形式：

$$A := \begin{bmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_n \end{bmatrix}$$

则 $\det(A)$, $|A|$, $\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_n)$ 以及 $\begin{vmatrix} \mathbf{a}_1 & \cdots & \mathbf{a}_n \end{vmatrix}$ 均表示为该对应的 n 阶行列式。特别的，我们也称 $\det(A)$ 为**方阵 A 的行列式**。

2.2 行列式的基本性质

有向体积应当会有如下基本的性质：

1. **单位体积**：我们定义一个具体的单位，即由 n 个单位向量 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 围成的有向体积为 1：

$$\mathcal{D}(\mathbf{e}_1, \dots, \mathbf{e}_n) = 1$$

这也就是**单位矩阵 I 的行列式**为 $\det(I) = 1$ 。

2. **反对称性**：这是关于符号的一个基本性质，假设我们交换了两个向量的位置，从 2 维和 3 维的情况来比较，这相当于体积反向，从而两者的有向体积会差一个负号，即：

$$\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_i, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n) = -\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_j, \dots, \mathbf{a}_i, \dots, \mathbf{a}_n)$$

这也就是**交换两列会改变行列式的符号**。

3. **线性性**：这是关于体积计算的一个性质。考虑向量加法的几何意义，即两个向量的和是一个平行四边形的对角线，其有向体积等于两个向量的有向体积之和，图??是一个二维上的解释。因此有向体积对于每个向量都应该是**线性的**，即对任意的 $i \in [n]$ ，我们都有：

$$\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_i + \mathbf{y}, \dots, \mathbf{a}_n) = \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_i, \dots, \mathbf{a}_n) + \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{y}, \dots, \mathbf{a}_n)$$

$$\mathcal{D}(\mathbf{a}_1, \dots, \lambda \mathbf{a}_i, \dots, \mathbf{a}_n) = \lambda \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_i, \dots, \mathbf{a}_n)$$

我们也可以加这两条合起来写，即对于任意的 $i \in [n]$ 和 $\lambda, \mu \in \mathbb{R}$ ，我们都有：

$$\mathcal{D}(\mathbf{a}_1, \dots, \lambda \mathbf{a}_i + \mu \mathbf{y}, \dots, \mathbf{a}_n) = \lambda \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_i, \dots, \mathbf{a}_n) + \mu \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{y}, \dots, \mathbf{a}_n)$$




图 3 有向体积关于每个向量是线性的在二维的一个解释。记 S_1 是 $\mathbf{a}, \mathbf{a}_1$ 张成的平行四边形的有向面积, S_2 是 $k\mathbf{a}, \mathbf{a}_1$ 张成的平行四边形的有向面积, S_3 是 $\mathbf{a}', \mathbf{a}_1$ 张成的平行四边形的有向面积, S_4 是 $\mathbf{a} + \mathbf{a}', \mathbf{a}_1$ 张成的平行四边形的有向面积, 则: $S_2 = kS_1, S_4 = S_1 + S_3$

因此,为了求得 n 个 n 维向量 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 围成的有向体积 $\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_n)$, 函数 $\mathcal{D}$ 应当满足上述三个性质, 而我们将说明, **满足这三个性质的函数 $\mathcal{D}$ 是存在且唯一的**, 从而其就是我们想要的行列式的良定义。

行列式的衍生性质 我们先观察一些行列式的衍生性质。在接下来的内容中, 我们将分不加区分的 n 个对应的向量 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 和对应 $n \times n$ 的矩阵 $A = \begin{bmatrix} \mathbf{a}_1 & \dots & \mathbf{a}_n \end{bmatrix}$ 。

定理 2.1

- 如果 A 存在一个列向量是 $\mathbf{0}$, 则 $\det(A) = 0$ 。
- 如果 A 存在两个列向量相同, 则 $\det(A) = 0$ 。
- 如果 A 存在一列是其他列的倍数, 则 $\det(A) = 0$ 。

证明:

1. 不妨假设 A 的第一列是 $\mathbf{a}_1 = \mathbf{0}$, 则我们有:

$$\mathcal{D}(\mathbf{a}'_1, \dots, \mathbf{a}_n) = \mathcal{D}(\mathbf{a}_1 + \mathbf{a}'_1, \dots, \mathbf{a}_n) = \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_n) + \mathcal{D}(\mathbf{a}'_1, \dots, \mathbf{a}_n)$$

从而:

$$\det(A) = \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_n) = \mathcal{D}(\mathbf{0}, \dots, \mathbf{a}_n) = 0$$

2. 如果 A 存在两列向量相同, 不妨记为 $\mathbf{a}_i = \mathbf{a}_j$, 则我们有:

$$\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_i, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n) = -\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_j, \dots, \mathbf{a}_i, \dots, \mathbf{a}_n) = -\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_i, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n)$$

从而:

$$\det(A) = \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_n) = 0$$

3. 如果 A 存在一列是其他列的倍数, 不妨记为 $\mathbf{a}_i = c\mathbf{a}_j$, 则我们有:

$$\det(A) = \mathcal{D}(\mathbf{a}_1, \dots, c\mathbf{a}_j, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n) = c\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_j, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n) = 0$$

□

定理 2.2

如果 $\text{rank}(A) < n$, 则 $\det(A) = 0$ 。

证明: 由 $\text{rank}(A) < n$ 可知 $\mathbf{a}_1, \dots, \mathbf{a}_n$ 是线性相关的, 即存在 $1 \leq i_0 < i_1 < \dots < i_k \leq n$ 和 $c_1, \dots, c_k$ 使得:

$$\mathbf{a}_{i_0} = c_1 \mathbf{a}_{i_1} + \dots + c_k \mathbf{a}_{i_k}$$

从而我们有:

$$\begin{aligned} \det(A) &= \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_{i_0}, \dots, \mathbf{a}_n) \\ &= \mathcal{D}(\mathbf{a}_1, \dots, c_1 \mathbf{a}_{i_1} + \dots + c_k \mathbf{a}_{i_k}, \dots, \mathbf{a}_n) \\ &= \sum_{j=1}^k c_j \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_{i_j}, \dots, \mathbf{a}_{i_j}, \dots, \mathbf{a}_n) \\ &= 0 \end{aligned}$$

□

定理 2.3

将矩阵的某些列的线性组合加到另一列上 (其他列不改变), 行列式的值保持不变。

证明: 利用:

$$\bullet \mathcal{D}(\mathbf{a}_1, \dots, c\mathbf{a}_j, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n) = c\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_j, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n) = 0$$

可知:

$$\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_i + \sum_{j=1}^n c_j \mathbf{a}_j, \dots, \mathbf{a}_n) = \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_n)$$

□

行列式的计算 有了上述的性质以后, 我们已经可以对行列式进行计算了。首先我们来考虑两个特殊的形式, 即式对角矩阵 和 三角矩阵 的情况。

定理 2.4 (对角矩阵的行列式值)

令 A 是一个 $n \times n$ 的对角矩阵:

$$A = \begin{bmatrix} a_1 & 0 & \cdots & 0 \\ 0 & a_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_n \end{bmatrix}$$

则我们有:

$$\det(A) = a_1 a_2 \cdots a_n$$

证明： 利用行列式的线性性和单位体积可得：

$$\det(A) = \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_n) = \mathbf{a}_1 \mathbf{a}_2 \cdots \mathbf{a}_n \mathcal{D}(\mathbf{e}_1, \dots, \mathbf{e}_n) = \mathbf{a}_1 \mathbf{a}_2 \cdots \mathbf{a}_n \det(I) = \mathbf{a}_1 \mathbf{a}_2 \cdots \mathbf{a}_n$$

□

定理 2.5 (三角矩阵的行列式值)

令 A 是一个 $n \times n$ 的三角矩阵 (triangular matrix):

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ 0 & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{bmatrix} \quad \text{或者} \quad A = \begin{bmatrix} a_{11} & 0 & \cdots & 0 \\ a_{21} & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

则我们有：

$$\det(A) = a_{11} a_{22} \cdots a_{nn}$$

证明： 令 $i, j \in [n]$ ，注意到由线性性和定理2.3，对矩阵进行初等列变换会对行列式产生如下的变化：

1. **列加法：** 将第 j 列的 l 倍加到第 i 列上，我们有：

$$A' = \begin{bmatrix} a_{11} & \cdots & a_{1i} + la_{1j} & \cdots & a_{1j} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{ni} + la_{nj} & \cdots & a_{nj} & \cdots & a_{nn} \end{bmatrix}$$

则我们有：

$$\det(A') = \det(A)$$

2. **列交换：** 将第 j 列和第 i 列互换，我们有：

$$A' = \left\{ \begin{bmatrix} a_{11} & \cdots & a_{1j} & \cdots & a_{1i} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nj} & \cdots & a_{ni} & \cdots & a_{nn} \end{bmatrix} \right\}$$

则我们有：

$$\det(A') = -\det(A)$$

3. **列乘法：** 令 $l \in \mathbb{R}$ ，将第 i 列乘以 l 倍，我们有：

$$A' = \left\{ \begin{bmatrix} a_{11} & \cdots & la_{1i} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots & \ddots & \vdots \\ a_{n1} & \cdots & la_{ni} & \cdots & a_{nn} \end{bmatrix} \right\}$$

则我们有：

$$\det(A') = l \det(A)$$

从而通过矩阵的初等列变换，我们可以得到：

$$\det(A) = \det \begin{bmatrix} a_{11} & 0 & \cdots & 0 \\ 0 & a_{22} & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & a_{nn} \end{bmatrix} = a_{11}a_{22} \cdots a_{nn}$$

□

定理2.5的证明过程实际上也给求一般 n 阶行列式的方法，即：

1. 我们对 A 进行初等列变换，或者等价地说，对 A^T 进行初等行变换。最终我们可以得到一个 A^T 的行阶梯形 R 。从而 R^T 是一个下三角矩阵。令其对角线的元素为 $d_1, \dots, d_n$ ，则我们有：

$$\det(R^T) = d_1 \cdots d_n$$

2. 我们根据 A 变成 R^T 的过程，注意到这个过程中得每一步都是列变换，从而根据前面得结论一步步反推得到 $\det(A)$ 的值。

下面我们通过一些例子来进一步说明。

例 2.6

考察 2×2 的矩阵：

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix}$$

我们有：

$$\begin{bmatrix} a & b \\ c & d \end{bmatrix} \Rightarrow \begin{bmatrix} a & 0 \\ c & d - \frac{cb}{a} \end{bmatrix}$$

从而：

$$\det(A) = \begin{vmatrix} a & b \\ c & d \end{vmatrix} = \begin{vmatrix} a & 0 \\ c & d - \frac{cb}{a} \end{vmatrix} = a \cdot (d - \frac{cb}{a}) = ad - bc$$

例 2.7

考察 3×3 的矩阵：

$$\begin{bmatrix} 2 & 0 & 1 \\ 1 & -4 & -1 \\ -1 & 8 & 3 \end{bmatrix}$$

我们有:

$$\begin{aligned} \begin{bmatrix} 2 & 0 & 1 \\ 1 & -4 & -1 \\ -1 & 8 & 3 \end{bmatrix} &\Rightarrow \begin{bmatrix} 1 & 0 & 1 \\ \frac{1}{2} & -4 & -1 \\ -\frac{1}{2} & 8 & 3 \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 0 & 0 \\ \frac{1}{2} & -4 & -\frac{3}{2} \\ -\frac{1}{2} & 8 & \frac{7}{2} \end{bmatrix} \\ &\Rightarrow \begin{bmatrix} 1 & 0 & 0 \\ \frac{1}{2} & 1 & -\frac{3}{2} \\ -\frac{1}{2} & -2 & \frac{7}{2} \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 0 & 0 \\ \frac{1}{2} & 1 & 0 \\ -\frac{1}{2} & -2 & \frac{1}{2} \end{bmatrix} \end{aligned}$$

从而:

$$\det\left(\begin{bmatrix} 2 & 0 & 1 \\ 1 & -4 & -1 \\ -1 & 8 & 3 \end{bmatrix}\right) = \begin{vmatrix} 2 & 0 & 1 \\ 1 & -4 & -1 \\ -1 & 8 & 3 \end{vmatrix} = 2 \cdot (-4) \cdot \begin{vmatrix} 1 & 0 & 0 \\ \frac{1}{2} & 1 & 0 \\ -\frac{1}{2} & -2 & \frac{1}{2} \end{vmatrix} = 2 \cdot (-4) \cdot \frac{1}{2} = -4$$

对于更高阶的矩阵情况也是一样的:

例 2.8

1. 考察 4×4 的矩阵:

$$\begin{bmatrix} 2 & 1 & 4 & 1 \\ 3 & -1 & 2 & 1 \\ 1 & 2 & 3 & 2 \\ 5 & 0 & 6 & 2 \end{bmatrix}$$

我们有:

$$\begin{aligned} \begin{bmatrix} 2 & 1 & 4 & 1 \\ 3 & -1 & 2 & 1 \\ 1 & 2 & 3 & 2 \\ 5 & 0 & 6 & 2 \end{bmatrix} &\Rightarrow \begin{bmatrix} 2 & 0 & 0 & 0 \\ 3 & -\frac{5}{2} & -4 & -\frac{1}{2} \\ 1 & \frac{3}{2} & 1 & \frac{3}{2} \\ 5 & -\frac{5}{2} & -4 & -\frac{1}{2} \end{bmatrix} \Rightarrow \begin{bmatrix} 2 & 0 & 0 & 0 \\ 3 & -\frac{5}{2} & 0 & 0 \\ 1 & \frac{3}{2} & -\frac{7}{5} & -\frac{9}{10} \\ 5 & -\frac{5}{2} & 0 & 0 \end{bmatrix} \Rightarrow \begin{bmatrix} 2 & 0 & 0 & 0 \\ 3 & -\frac{5}{2} & 0 & 0 \\ 1 & \frac{3}{2} & -\frac{7}{5} & 0 \\ 5 & -\frac{5}{2} & 0 & 0 \end{bmatrix} \end{aligned}$$

从而:

$$\det\left(\begin{bmatrix} 2 & 1 & 4 & 1 \\ 3 & -1 & 2 & 1 \\ 1 & 2 & 3 & 2 \\ 5 & 0 & 6 & 2 \end{bmatrix}\right) = \begin{vmatrix} 2 & 1 & 4 & 1 \\ 3 & -1 & 2 & 1 \\ 1 & 2 & 3 & 2 \\ 5 & 0 & 6 & 2 \end{vmatrix} = \begin{vmatrix} 2 & 0 & 0 & 0 \\ 3 & -\frac{5}{2} & 0 & 0 \\ 1 & \frac{3}{2} & -\frac{7}{5} & 0 \\ 5 & -\frac{5}{2} & 0 & 0 \end{vmatrix} = 2 \cdot \left(-\frac{5}{2}\right) \cdot \left(-\frac{7}{5}\right) \cdot 0 = 0$$

2. 考察 $n \times n$ 的矩阵:

$$\begin{bmatrix} a & 0 & \cdots & 1 \\ 0 & a & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & \cdots & a \end{bmatrix}$$

我们有：

$$\begin{bmatrix} a & 0 & \cdots & 1 \\ 0 & a & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & \cdots & a \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 0 & \cdots & 1 \\ 0 & a & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{a} & 0 & \cdots & a \end{bmatrix} \Rightarrow \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & a & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{a} & 0 & \cdots & a - \frac{1}{a} \end{bmatrix}$$

从而：

$$\det \begin{bmatrix} a & 0 & \cdots & 1 \\ 0 & a & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & \cdots & a \end{bmatrix} = \det \begin{bmatrix} a & 0 & \cdots & 1 \\ 0 & a & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 1 & 0 & \cdots & a \end{bmatrix} = a \det \begin{bmatrix} 1 & 0 & \cdots & 0 \\ 0 & a & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ \frac{1}{a} & 0 & \cdots & a - \frac{1}{a} \end{bmatrix} = a^{n-1} \left(a - \frac{1}{a} \right) = a^n - a^{n-2}$$

至此，我们已经可以计算出任何 n 阶行列式的值了。简单回顾一下对 $\det(A)$ 的计算：

1. 根据我们的理解， $\det(A)$ 如果存在，一定要满足三条基本性质。
2. 我们推得了关于 $\det(A)$ 的一些其他性质。
3. 通过上述的讨论，我们知道了初等列变换对 $\det(A)$ 的影响。
4. 而通过初等列变换，我们可以将 A 转变成一个下三角矩阵 L 。
5. 我们知道 $\det(L)$ 是多少，从而根据 3 和 4，我们可以从 $\det(L)$ 得到 $\det(A)$ 的值。

这解决了我们前面提到的一个问题，即 $\det(A)$ ，或者说函数 $\mathcal{D}$ 是存在的！

行列式的行变换？ 在之前的讨论中，受有向体积的启发，我们一直在讨论初等列变换对行列式的影响，而这一部分我们将讨论初等行变换对行列式的影响。我们会发现，初等行变换对行列式的影响和初等列变换是完全的。具体来说，我们将证明如下的两个定理：

定理 2.9

令 A 是一个 $n \times n$ 的矩阵，我们有：

$$\det(A) = \det(A^T)$$

定理 2.10

令 A 是一个 $n \times n$ 的矩阵， B 是一个 $n \times n$ 的矩阵，我们有：

$$\det(AB) = \det(A) \det(B)$$

上述定理有一个很有意思的推论，即：

推论 2.11

给定一个正交矩阵 Q ，我们有：

$$\det(Q) = \pm 1$$

这说明，在 $\mathbb{R}^n$ 中由 n 个标准正交 (orthonormal) 基向量构成的平行六面体的体积是 1。

证明：注意到：

$$Q^T Q = I$$

从而我们有：

$$1 = \det(I) = \det(Q) \det(Q^T) = \det(Q) \det(Q) = (\det(Q))^2 \implies \det(Q) = \pm 1$$

□

为了证明定理2.9和定理2.10，我们先来考虑其特殊情况，即矩阵 B 是初等矩阵的情形。

引理 2.12

令 A 是一个 $n \times n$ 的矩阵， P 是一个 $n \times n$ 的初等矩阵，则我们有：

$$\det(AP) = \det(A) \det(P)$$

证明：注意到 P 是下列三种矩阵的一种：

$$\begin{bmatrix} 1 & \cdots & 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & \cdots & k & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & \cdots & 1 \end{bmatrix}, \begin{bmatrix} 1 & \cdots & 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 1 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & \cdots & 1 \end{bmatrix}, \begin{bmatrix} 1 & \cdots & 0 & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & k & \cdots & 0 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 1 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & \cdots & 0 & \cdots & 1 \end{bmatrix}$$

$E(ij(k)) \qquad E(i, j) \qquad E(i(k))$

由于 AP 是对 A 进行相应的列变换操作，所以我们只需要检查每种初等矩阵是否满足 $\det(AP) = \det(A) \det(P)$ 即可。令 $A = [\mathbf{a}_1, \dots, \mathbf{a}_n]$ ，我们下面分三种情况讨论：

1. $P = E(ij(k))$ 。注意到：

$$AE(ij(k)) = [\mathbf{a}_1, \dots, \mathbf{a}_i + k\mathbf{a}_j, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n]$$

从而我们有：

$$\begin{aligned} \det(E(ij(k))) &= \det(I) = 1 \\ \det(AE(ij(k))) &= \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_i + k\mathbf{a}_j, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n) \\ &= \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_i, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n) + k\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_j, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n) \\ &= \det(A) = \det(A) \det(E(ij(k))) \end{aligned}$$

2. $P = E(i, j)$ 。注意到：

$$AE(i, j) = [\mathbf{a}_1, \dots, \mathbf{a}_j, \dots, \mathbf{a}_i, \dots, \mathbf{a}_n]$$

从而我们有：

$$\begin{aligned} \det(E(i, j)) &= -\det(I) = -1 \\ \det(AE(i, j)) &= \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_j, \dots, \mathbf{a}_i, \dots, \mathbf{a}_n) \\ &= -\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_i, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n) \\ &= -\det(A) = \det(A) \det(E(i, j)) \end{aligned}$$

3. $P = E(i(k))$ 。注意到：

$$AE(i(k)) = [\mathbf{a}_1, \dots, k\mathbf{a}_i, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n]$$

从而我们有：

$$\begin{aligned} \det(E(i(k))) &= k \det(I) = k \\ \det(AE(i(k))) &= \mathcal{D}(\mathbf{a}_1, \dots, k\mathbf{a}_i, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n) \\ &= k \mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_i, \dots, \mathbf{a}_j, \dots, \mathbf{a}_n) \\ &= k \det(A) = \det(A) \det(E(i(k))) \end{aligned}$$

□

其有一个自然的推论：

推论 2.13

令 A 是一个 $n \times n$ 的矩阵， $P_1, \dots, P_k$ 是 $n \times n$ 的初等矩阵，则我们有：

$$\det(AP_1 \cdots P_k) = \det(A) \det(P_1) \cdots \det(P_k)$$

特别的：

$$\det(P_1 P_2 \cdots P_k) = \det(P_1) \det(P_2) \cdots \det(P_k)$$

回顾 Gauss—Jordan 消元法：

$$E(i(k)) \cdots E(ij(k)) \cdots E(ij) \cdots E(ij(k)) [A \quad I] = [I \quad A^{-1}]$$

我们有：

定理 2.14

每个可逆矩阵都可以由一系列的初等矩阵的乘积得到。

结合推论2.13，我们可以完成定理2.9和定理2.10的证明。

证明： [定理2.9的证明]

1. 对于初等矩阵 P ，我们有 $\det(P) = \det(P^T)$ 。

2. 如果 A 不是可逆的, 则 $\text{rank}(A) = \text{rank}(A^T) < n$, 从而

$$\det(A) = \det(A^T) = 0$$

3. 如果 A 是可逆的, 则存在一系列的初等矩阵 $P_1, \dots, P_k$ 使得:

$$A = P_1 \cdots P_k$$

从而 $A^T = P_1^T \cdots P_k^T$, 因此:

$$\begin{aligned} \det(A) &= \det(P_1) \cdots \det(P_k) \\ &= \det(P_1^T) \cdots \det(P_k^T) = \det(P_k^T) \cdots \det(P_1^T) = \det(P_k^T \cdots P_1^T) = \det(A^T) \end{aligned}$$

□

证明: [定理2.10的证明] 如果 B 是可逆的, 则存在一系列的初等矩阵 $P_1, \dots, P_k$ 使得:

$$B = P_1 \cdots P_k$$

从而:

$$\begin{aligned} \det(AB) &= \det(AP_1 \cdots P_k) = \det(A) \det(P_1) \cdots \det(P_k) \\ &= \det(A) \det(P_1 \cdots P_k) = \det(A) \det(B) \end{aligned}$$

如果 B 不是可逆的, 则 AB 也不可逆, 否则:

$$I = (AB)^{-1}AB = ((AB)^{-1}A)B$$

所以此时我们有:

$$\det(AB) = \det(A) \det(B) = 0$$

□

例 2.15 ($\det(AB) = \det(A) \det(B)$ 一个运用-Cramer 法则 (I))

我们来展示 $\det(AB) = \det(A) \det(B)$ 的一个运用。考察下列的方程组:

$$\begin{aligned} a_{11}x_1 + \cdots + a_{1n}x_n &= b_1 \\ &\vdots \\ a_{n1}x_1 + \cdots + a_{nn}x_n &= b_n \end{aligned} \quad \text{即} \quad \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} b_1 \\ \vdots \\ b_n \end{bmatrix} \quad (\text{记作 } Ax = b)$$

注意到:

$$A \begin{bmatrix} x_1 & 0 & 0 & \cdots & 0 \\ x_2 & 1 & 0 & \cdots & 0 \\ x_3 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ x_n & 0 & 0 & \cdots & 1 \end{bmatrix} = [Ax \quad Ae_2 \quad Ae_3 \quad \cdots \quad Ae_n] = \begin{bmatrix} b_1 & a_{12} & \cdots & a_{1n} \\ b_2 & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ b_n & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

记下列矩阵为 A_1 :

$$\begin{bmatrix} \mathbf{b}_1 & a_{12} & \cdots & a_{1n} \\ \mathbf{b}_2 & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{b}_n & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

注意到:

$$\begin{vmatrix} x_1 & 0 & 0 & \cdots & 0 \\ x_2 & 1 & 0 & \cdots & 0 \\ x_3 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ x_n & 0 & 0 & \cdots & 1 \end{vmatrix} = \begin{vmatrix} x_1 & 0 & 0 & \cdots & 0 \\ 0 & 1 & 0 & \cdots & 0 \\ 0 & 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & 1 \end{vmatrix} = x_1$$

则我们有:

$$\det(A)x_1 = \det(A_1), \quad \text{即: } x_1 = \frac{\det(A_1)}{\det(A)}$$

一般的, 对于任意的 $i \in [n]$, 令 A_i 是将 A 的第 i 列替换成 $\mathbf{b}$ 后的矩阵, 则我们有:

$$A \begin{bmatrix} 1 & \cdots & x_1 & \cdots & 0 \\ 0 & \cdots & x_2 & \cdots & 0 \\ \vdots & \ddots & \vdots & \ddots & 0 \\ 0 & \cdots & x_n & \cdots & 1 \end{bmatrix} = [A\mathbf{e}_1 \cdots A\mathbf{x} \cdots A\mathbf{e}_n] = A_i \implies \det(A)x_i = \det(A_i)$$

从而方程组 $A\mathbf{x} = \mathbf{b}$ 的解可以表示为:

$$\mathbf{x} = \begin{bmatrix} \frac{\det(A_1)}{\det(A)} \\ \vdots \\ \frac{\det(A_n)}{\det(A)} \end{bmatrix}$$

这就是**克拉默法则 (Cramer's Rule)**。

行列式的值跟首元的关系。 我们再来看下其跟矩阵 A 的首元的关系。令可逆矩阵 A 的首元为 $p_1, \dots, p_n$, 通过 Gauss 消元法我们可以将矩阵 A 变为如下的行阶梯形矩阵:

$$U = \begin{bmatrix} p_1 & * & \cdots & * \\ 0 & p_2 & \cdots & * \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & p_n \end{bmatrix}$$

由于上述过程只使用了行加法和行交换操作 (列加法或者列交换), 从而我们有:

$$\det(A) = \det(U) = p_1 p_2 \cdots p_n \quad \text{或者} \quad \det(A) = -\det(U) = -p_1 p_2 \cdots p_n$$

即:

$$|\det(A)| = |p_1 p_2 \cdots p_n|.$$

这也被称作是行列式的主元式 (Pivot Formula)。

2.3 行列式的正式定义

在这一部分中，我们将给出行列式的正式定义，最终我们将回答还剩下的遗留的问题： $\det(A)$ ，或者说函数 $\mathcal{D}$ 是**唯一的**。

考虑一个 $n \times n$ 的矩阵：

$$A = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix}$$

注意到其每个列向量：

$$\mathbf{a}_j = \begin{bmatrix} a_{1j} \\ \vdots \\ a_{nj} \end{bmatrix} = a_{1j} \begin{bmatrix} 1 \\ \vdots \\ 0 \end{bmatrix} + \cdots + a_{nj} \begin{bmatrix} 0 \\ \vdots \\ 1 \end{bmatrix} = \sum_{i=1}^n a_{ij} \mathbf{e}_i$$

从而由行列式的线性性，我们有：

$$\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_n) = \mathcal{D}\left(\sum_{i=1}^n a_{ij} \mathbf{e}_i, \dots, \mathbf{a}_n\right) = \sum_{i=1}^n a_{i1} \mathcal{D}(\mathbf{e}_i, \dots, \mathbf{a}_n)$$

将其每一列都表示成 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 的线性组合，并展开则有：

$$\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_n) = \sum_{i_1=1}^n \sum_{i_2=1}^n \cdots \sum_{i_n=1}^n a_{i_1,1} a_{i_2,2} \cdots a_{i_n,n} \mathcal{D}(\mathbf{e}_{i_1}, \mathbf{e}_{i_2}, \dots, \mathbf{e}_{i_n})$$

上述等式一共有 n^n 项。由行列式的性质，如果存在 $i_k = i_j$ ，则我们有：

$$\mathcal{D}(\mathbf{e}_{i_1}, \mathbf{e}_{i_2}, \dots, \mathbf{e}_{i_k}, \dots, \mathbf{e}_{i_j}, \dots, \mathbf{e}_{i_n}) = 0$$

从而上述等式可以转化为：

$$\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_n) = \sum_{\substack{i_1 \in [n] \\ i_2 \neq i_1}} \sum_{\substack{i_2 \in [n] \\ i_2 \neq i_1}} \cdots \sum_{\substack{i_n \in [n] \\ i_n \neq i_1, \dots, i_n \neq i_{n-1}}} a_{i_1,1} a_{i_2,2} \cdots a_{i_n,n} \mathcal{D}(\mathbf{e}_{i_1}, \mathbf{e}_{i_2}, \dots, \mathbf{e}_{i_n}) \quad (1)$$

我们来观察一下等式1右边的每一项：

1. $\mathcal{D}(\mathbf{e}_{i_1}, \mathbf{e}_{i_2}, \dots, \mathbf{e}_{i_n})$ 实际上对应的矩阵是个**置换矩阵**，从而其行列式值为 1 或者 -1。
2. $a_{i_1,1} a_{i_2,2} \cdots a_{i_n,n}$ 中 $i_1, \dots, i_n$ 实际上是对 $1, \dots, n$ 的一个**重排列**。

为了进一步讨论清楚每一项的值，我们引入一个新的概念：**置换 (Permutation)**。

置换 (Permutation) 一个置换实际上就是一个从 $1, \dots, n$ 到 $1, \dots, n$ 的一个重排列。下面我们给出其正式的定义：

定义 2.16 (置换)

固定一个 $n \in \mathbb{N}$, 一个 $[n]$ 的置换 (Permutation) 是一个 $[n] \rightarrow [n]$ 的**双射函数 (bijective function)** σ , 并且我们定义:

$$\text{Perm}(n) = \{\sigma \mid \sigma \text{ 是 } [n] \text{ 的一个置换.}\}$$

例 2.17

- 1, 3, 2, 4 是 1, 2, 3, 4 的一个置换 σ , 即 $\sigma(1) = 1, \sigma(2) = 3, \sigma(3) = 2, \sigma(4) = 4$ 。
- $\sigma(i) = n + 1 - i$ 是 $[n]$ 上的一个置换, 其将 $1, 2, \dots, n$ 重排列成 $n, n-1, \dots, 1$ 。

一个 $[n]$ 上的置换实际上对应了一个 $[n]$ 上的排列。为了方便, 很多时候我们将一个置换 $\sigma \in \text{Perm}(n)$ 表示成一个序列的形式, 即 $\sigma := \sigma(1) \dots \sigma(n)$ 。不难发现, $\text{Perm}(n)$ 的所有元素组成了 $[n]$ 上的一个全排列, 因此其个数是 $n!$, 即:

定理 2.18

$\text{Perm}(n)$ 的元素个数是 $n!$ 。

从而我们可以将等式1重写成:

$$\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_n) = \sum_{\sigma \in \text{Perm}(n)} \mathbf{a}_{\sigma(1)1} \mathbf{a}_{\sigma(2)2} \cdots \mathbf{a}_{\sigma(n)n} \mathcal{D}(\mathbf{e}_{\sigma(1)}, \dots, \mathbf{e}_{\sigma(n)}) \quad (2)$$

我们需要进一步确认 $\mathcal{D}(\mathbf{e}_{\sigma(1)}, \dots, \mathbf{e}_{\sigma(n)})$ 的大小, 其对应的矩阵 $P = [\mathbf{e}_{\sigma(1)}, \dots, \mathbf{e}_{\sigma(n)}]$ 是一个**置换矩阵**:

1. P 通过若干次列交换操作变成单位矩阵 I 。
2. 每次列交换操作改变其行列式的符号。
3. $\det(P) = (-1)^{k_\sigma}$, 这里 k_σ 是列交换的次数。

因此, 等式2可以进一步写成:

$$\mathcal{D}(\mathbf{a}_1, \dots, \mathbf{a}_n) = \sum_{\sigma \in \text{Perm}(n)} (-1)^{k_\sigma} \mathbf{a}_{\sigma(1)1} \mathbf{a}_{\sigma(2)2} \cdots \mathbf{a}_{\sigma(n)n}. \quad (3)$$

等式3似乎可以作为行列式的**正式定义**, 但其还面临一个问题: k_σ 不一定唯一。考虑如下定义在 $[3]$ 上的置换 σ : $\sigma(1) = 2, \sigma(2) = 3, \sigma(3) = 1$, 其对应的置换矩阵为:

$$P = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

我们可以通过交换 $1 \leftrightarrow 2$ 和 $1 \leftrightarrow 3$ 两次列交换操作将其变成单位矩阵 I , 也可以通过交换 $1 \leftrightarrow 2, 2 \leftrightarrow 3, 3 \leftrightarrow 1, 1 \rightarrow 2$ 四次列交换操作将其变成单位矩阵 I 。因此, 用列交换操作次数变成单位矩阵 E 的方式 定义 k_σ 并不好, 我们要进一步探索 k_σ 的性质。

逆序数 (Inverse Number) 考虑 [4] 上的一个置换 σ_0 :

$$\sigma_0(1) = 4, \sigma_0(2) = 2, \sigma_0(3) = 1, \sigma_0(4) = 3$$

注意到在对应的排列中, 第一个位置是 4, 第二个位置是 2; **第一个位置更靠前, 但数字更大**, 更严谨的说, 这与正常大小顺序不同; 我们称满足这样的性质的对 (i, j) 为一个**逆序对**。一个置换 σ 的逆序数则是其逆序对的个数, 下面是其正式的定义。

定义 2.19 (逆序数 (Inversion number))

给定一个置换 $\sigma = \sigma(1)\sigma(2)\cdots\sigma(n)$, 其对应排列的**逆序数** $\tau(\sigma)$ 定义为:

$$\tau(\sigma) = |\{(p, q) \mid 1 \leq p < q \leq n \text{ 并且 } \sigma(p) > \sigma(q)\}|$$

特别的, 逆序数为**奇数**的排列称为**奇排列**, 逆序数为**偶数**的排列称为**偶排列**。

例 2.20

1. 在上述的置换 σ_0 中, 注意到 $(1, 2), (1, 3), (1, 4), (2, 3)$ 都是逆序对, 因此 $\tau(\sigma_0) = 4$ 。
2. 在置换 $\sigma_1 = 1324$ 里, 只有 $(2, 3)$ 是逆序对, 因此 $\tau(\sigma_1) = 1$ 。

对于一个排列, 我们将其两个位置上的数进行交换称为一次对换。 比如:

$$1324 \rightarrow 1234$$

就是一次对换。

逆序数的重要性质 观察如下的排列:

$$\tau(4213) = 4 \implies 4213 \rightarrow 2413 \rightarrow 2143 \rightarrow 2134 \rightarrow 1234$$

$$\tau(1324) = 1 \implies 1324 \rightarrow 1234$$

$$\tau(3241) = 4 \implies 3241 \rightarrow 3214 \rightarrow 2314 \rightarrow 2134 \rightarrow 1234$$

逆序数恰好可以作为一个将置换 $\sigma = \sigma(1)\sigma(2)\cdots\sigma(n)$ 变回 $123\cdots n$ 的个数!

定理 2.21

给定置换矩阵

$$P = [\mathbf{e}_{\sigma(1)}, \cdots, \mathbf{e}_{\sigma(n)}]$$

我们可以通过 $\tau(\sigma)$ 次列交换将其变回单位矩阵 I 。

证明: 注意到对于一个置换 σ , 我们有:

$$\tau(\sigma) = \sum_{i=1}^n |\{t \mid t > i \text{ 并且 } \sigma(i) > \sigma(t)\}|$$

从而对于置换矩阵我们可以定义如下的列交换操作, 初始令 $k = n$:

- 不妨令 $k = \sigma(t)$, 令 $t_1 < t_2 < \dots < t_j$ 是满足 $k > \sigma(t_i)$ 的位置。依次将第 k 列与第 t_i 列进行交换, 共交换 j 次。
- 令 $k = k - 1$, 重复上述过程。

注意到上述列交换的总数恰好是置换 σ 的逆序数 (为什么?), 从而定理得证。 $\square$

行列式的正式定义。 定理2.21说明, 可以用 $\tau(\sigma)$ 来定义 $k_\sigma!$

定义 2.22

令 A 是一个 $n \times n$ 的矩阵, 我们定义:

$$\det(A) = \sum_{\sigma \in \text{Perm}(n)} (-1)^{\tau(\sigma)} a_{\sigma(1)1} a_{\sigma(2)2} \cdots a_{\sigma(n)n}$$

上述式子也被称为行列式的基础公式 (Big Formula)。不难验证, 上述定义满足如下的性质:

定理 2.23

$\det(A)$ 满足下列性质:

- $\det([e_1, \dots, e_n]) = 1$
- $\det([a_1, \dots, a_i, \dots, a_j, \dots, a_n]) = -\det([a_1, \dots, a_j, \dots, a_i, \dots, a_n])$
- $\det([a_1, \dots, ca_i + da'_i, \dots, a_n]) = c \det([a_1, \dots, a_i, \dots, a_n]) + d \det([a_1, \dots, a'_i, \dots, a_n])$

例 2.24 (定义2.22下的二维的例子)

对于一个 2×2 的矩阵:

$$A = \begin{bmatrix} x_1 & x_2 \\ y_1 & y_2 \end{bmatrix}$$

一共有 12, 21 两种不同的置换, 从而我们有:

$$\det(A) = (-1)^{\tau(12)} x_1 y_2 + (-1)^{\tau(21)} x_2 y_1 = x_1 y_2 - x_2 y_1$$

例 2.25 (定义2.22下的三维的例子)

对于一个 3×3 的矩阵:

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$


其一共有 123, 132, 213, 231, 312, 321 六种不同的置换, 并且:

$$\tau(123) = 0, \tau(132) = 1, \tau(213) = 1, \tau(231) = 2, \tau(312) = 2, \tau(321) = 3$$

从而我们有：

$$\begin{aligned}\det(A) &= (-1)^{\tau(123)} a_{11} a_{22} a_{33} + (-1)^{\tau(132)} a_{11} a_{23} a_{32} + (-1)^{\tau(213)} a_{12} a_{21} a_{33} \\ &\quad + (-1)^{\tau(231)} a_{12} a_{23} a_{31} + (-1)^{\tau(312)} a_{13} a_{21} a_{32} + (-1)^{\tau(321)} a_{13} a_{22} a_{31} \\ &= a_{11} a_{22} a_{33} + a_{12} a_{23} a_{31} + a_{13} a_{21} a_{32} - a_{11} a_{23} a_{32} - a_{12} a_{21} a_{33} - a_{13} a_{22} a_{31}\end{aligned}$$

这也就是书本中常见的三阶行列式计算的记忆方式：



现在我们可以完成**唯一性 (Uniqueness)**的证明。

定理 2.26 (Uniqueness)

$\det(A)$ 是**唯一**一个 $\underbrace{\mathbb{R}^n \times \cdots \times \mathbb{R}^n}_{n \uparrow} \rightarrow \mathbb{R}$ 的函数 $\mathcal{D}$ 满足下述三个性质：

- $\mathcal{D}(\mathbf{e}_1, \cdots, \mathbf{e}_n) = 1$
- $\mathcal{D}(\mathbf{a}_1, \cdots, \mathbf{a}_i, \cdots, \mathbf{a}_j, \cdots, \mathbf{a}_n) = -\mathcal{D}(\mathbf{a}_1, \cdots, \mathbf{a}_j, \cdots, \mathbf{a}_i, \cdots, \mathbf{a}_n)$
- $\mathcal{D}(\mathbf{a}_1, \cdots, c\mathbf{a}_i + d\mathbf{a}'_i, \cdots, \mathbf{a}_n) = c\mathcal{D}(\mathbf{a}_1, \cdots, \mathbf{a}_i, \cdots, \mathbf{a}_n) + d\mathcal{D}(\mathbf{a}_1, \cdots, \mathbf{a}'_i, \cdots, \mathbf{a}_n)$

证明： 我们前面已经证明，满足这三个性质的函数具备如下的性质：

$$\mathcal{D}(\mathbf{a}_1, \cdots, \mathbf{a}_n) = \sum_{\sigma \in \text{Perm}(n)} (-1)^{k_\sigma} a_{\sigma(1)1} a_{\sigma(2)2} \cdots a_{\sigma(n)n}$$

根据前面的讨论， k_σ 可以用 $\tau(\sigma)$ 来替代，从而：

$$\mathcal{D}(\mathbf{a}_1, \cdots, \mathbf{a}_n) = \sum_{\sigma \in \text{Perm}(n)} (-1)^{\tau(\sigma)} a_{\sigma(1)1} a_{\sigma(2)2} \cdots a_{\sigma(n)n} = \det(A)$$

这就完成了唯一性的证明。

□

2.4 行列式的展开

回顾 2×2 的矩阵 $A = \begin{bmatrix} x_1 & x_2 \\ y_1 & y_2 \end{bmatrix}$, 我们有:

$$\det(A) = (-1)^{\tau(12)}x_1y_2 + (-1)^{\tau(21)}x_2y_1 = x_1 \det\left(\begin{bmatrix} y_2 \end{bmatrix}\right) - x_2 \det\left(\begin{bmatrix} y_1 \end{bmatrix}\right)$$

类似的, 对于 3×3 的矩阵:

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

我们也可以写成如下的形式:

$$\begin{aligned} \det(A) &= (-1)^{\tau(123)}a_{11}a_{22}a_{33} + (-1)^{\tau(132)}a_{11}a_{23}a_{32} + (-1)^{\tau(213)}a_{12}a_{21}a_{33} \\ &\quad + (-1)^{\tau(231)}a_{12}a_{23}a_{31} + (-1)^{\tau(312)}a_{13}a_{21}a_{32} + (-1)^{\tau(321)}a_{13}a_{22}a_{31} \\ &= (-1)^{\tau(123)}a_{11}(a_{22}a_{33} - a_{23}a_{32}) + (-1)^{\tau(132)}a_{11}(a_{21}a_{33} - a_{23}a_{31}) + (-1)^{\tau(213)}a_{12}(a_{21}a_{32} - a_{22}a_{31}) \\ &= a_{11} \det\left(\begin{bmatrix} a_{22} & a_{23} \\ a_{32} & a_{33} \end{bmatrix}\right) - a_{12} \det\left(\begin{bmatrix} a_{21} & a_{23} \\ a_{31} & a_{33} \end{bmatrix}\right) + a_{13} \det\left(\begin{bmatrix} a_{21} & a_{22} \\ a_{31} & a_{32} \end{bmatrix}\right) \end{aligned}$$

这两个例子表明, 我们可以将行列式展开成某些更小的行列式的线性组合, 更具体地说, 可以按照某一行或者某一列进行展开。为了描述清楚这个过程, 我们首先介绍**代数余子式 (Cofactor)**的概念。

定义 2.27 (余子式与代数余子式)

令 A 是一个 $n \times n$ 的矩阵, 并且 $n \geq 2$ 。对于任意的 $i, j \in [n]$, 我们定义:

$A_{-i,-j}$ 是将 A 第 i 行第 j 列的元素删去后得到的 $(n-1) \times (n-1)$ 的矩阵。

下列数:

$$A_{ij} = (-1)^{i+j} \det(A_{-i,-j})$$

称之为**代数余子式 (Cofactor)**, 特别的 $M_{ij} := \det(A_{-i,-j})$ 称之为**余子式**。

我们将首先证明, 行列式可以按照**第一列**进行展开。我们先证明如下的引理:

定理 2.28

1. $\det\left(\begin{bmatrix} a \end{bmatrix}\right) = a$.
2. 对于任意的 $n \geq 2$, 并且 A 是一个 $n \times n$ 的矩阵:

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix}$$

我们有:

$$\det(A) = a_{11}A_{11} + \cdots + a_{1n}A_{1n}$$

证明: 我们对其第一列展开:

$$\begin{vmatrix} a_{11} & \cdots & a_{1n} \\ a_{21} & \cdots & a_{2n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix} = \begin{vmatrix} a_{11} & \cdots & a_{1n} \\ 0 & \cdots & a_{2n} \\ \vdots & \ddots & \vdots \\ 0 & \cdots & a_{nn} \end{vmatrix} + \begin{vmatrix} 0 & \cdots & a_{1n} \\ a_{12} & \cdots & a_{2n} \\ \vdots & \ddots & \vdots \\ 0 & \cdots & a_{nn} \end{vmatrix} + \cdots + \begin{vmatrix} 0 & \cdots & a_{1n} \\ 0 & \cdots & a_{2n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{vmatrix}$$

所以我们只需要证明, 对任意的 $i \in [n]$ 有:

$$\begin{vmatrix} 0 & a_{12} & \cdots & a_{1n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{i1} & a_{i2} & \cdots & a_{in} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{n2} & \cdots & a_{nn} \end{vmatrix} = a_{i1}A_{i1} = (-1)^{i+1}a_{i1} \det(A_{-i,-1}) = (-1)^{i-1}a_{i1} \det(A_{-i,-1})$$

对其第 i 行向上交换 $i-1$ 次可得:

$$\begin{vmatrix} 0 & a_{12} & \cdots & a_{1n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{i-1,2} & \cdots & a_{i-1,n} \\ a_{i1} & a_{i2} & \cdots & a_{in} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{n2} & \cdots & a_{nn} \end{vmatrix} = (-1) \begin{vmatrix} 0 & a_{12} & \cdots & a_{1n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{i1} & a_{i2} & \cdots & a_{in} \\ 0 & a_{i-1,2} & \cdots & a_{i-1,n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{n2} & \cdots & a_{nn} \end{vmatrix} \cdots = (-1)^{i-1} \begin{vmatrix} a_{i1} & a_{i2} & \cdots & a_{in} \\ 0 & a_{12} & \cdots & a_{1n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{i-1,2} & \cdots & a_{i-1,n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{n2} & \cdots & a_{nn} \end{vmatrix}$$

所以我们只要证明:

$$\begin{vmatrix} a_{i1} & a_{i2} & \cdots & a_{in} \\ 0 & a_{12} & \cdots & a_{1n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{i-1,2} & \cdots & a_{i-1,n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{n2} & \cdots & a_{nn} \end{vmatrix} = a_{i1} \det(A_{-i,1})$$

通过行列式的性质, 我们注意到:

$$\begin{vmatrix} a_{i1} & a_{i2} & \cdots & a_{in} \\ 0 & a_{12} & \cdots & a_{1n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{i-1,2} & \cdots & a_{i-1,n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{n2} & \cdots & a_{nn} \end{vmatrix} = \begin{vmatrix} a_{i1} & 0 & \cdots & 0 \\ 0 & a_{12} & \cdots & a_{1n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{i-1,2} & \cdots & a_{i-1,n} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & a_{n2} & \cdots & a_{nn} \end{vmatrix} = \begin{vmatrix} a_{i1} & O_{1 \times (n-1)} \\ O_{(n-1) \times 1} & A_{-i,-1} \end{vmatrix}$$

也就是要证明:

$$\begin{vmatrix} \mathbf{a}_{i1} & \mathbf{O}_{1 \times (n-1)} \\ \mathbf{O}_{(n-1) \times 1} & \mathbf{A}_{-i,-1} \end{vmatrix} = \mathbf{a} \det(\mathbf{A}_{-i,-1})$$

事实上, 我们有如下的引理:

引理 2.29

令 $\mathbf{A}$ 是 n 阶方阵, $\mathbf{B}$ 是 $n-1$ 阶方阵, 则我们有:

$$\det(\mathbf{A}) = \begin{vmatrix} \mathbf{a} & \mathbf{O} \\ \mathbf{O} & \mathbf{B} \end{vmatrix} = \mathbf{a} \det(\mathbf{B}).$$

证明:

$$\begin{aligned} \det(\mathbf{A}) &= \begin{vmatrix} \mathbf{a} & \mathbf{O} \\ \mathbf{O} & \mathbf{B} \end{vmatrix} = \sum_{\sigma \in \text{Perm}(n)} (-1)^{\tau(\sigma)} \mathbf{a}_{\sigma(1)1} \cdots \mathbf{a}_{\sigma(n)n} \\ &= \sum_{\substack{\sigma \in \text{Perm}(n) \\ \sigma(1)=1}} (-1)^{\tau(\sigma)} \mathbf{a} \mathbf{a}_{\sigma(2)2} \cdots \mathbf{a}_{\sigma(n)n} \\ &= \mathbf{a} \sum_{\substack{\sigma \in \text{Perm}(n) \\ \sigma(1)=1}} (-1)^{\tau(\sigma)} \mathbf{b}_{\sigma(2)-1,1} \cdots \mathbf{b}_{\sigma(n)-1,n} \\ &= \mathbf{a} \sum_{\delta \in \text{Perm}(n-1)} (-1)^{\tau(\delta)} \mathbf{b}_{\delta(1),1} \cdots \mathbf{b}_{\delta(n-1),n-1} = \mathbf{a} \det(\mathbf{B}). \end{aligned}$$

□

从而定理2.28得证。

□

注意到对于其他列的情况, 我们可以通过 $j-1$ 次列交换将第 j 列交换到第 1 列, 从而可以得到:

定理 2.30

对于任意的 $n \geq 2$, 并且 $\mathbf{A}$ 是一个 $n \times n$ 的矩阵:

$$\begin{bmatrix} \mathbf{a}_{11} & \cdots & \mathbf{a}_{1i} & \cdots & \mathbf{a}_{1n} \\ \vdots & \cdots & \vdots & \ddots & \vdots \\ \mathbf{a}_{n1} & \cdots & \mathbf{a}_{ni} & \cdots & \mathbf{a}_{nn} \end{bmatrix}$$

我们有:

$$\det(\mathbf{A}) = \mathbf{a}_{1i} \mathbf{A}_{1i} + \cdots + \mathbf{a}_{1i} \mathbf{A}_{1i}$$

证明: 通过 $j-1$ 次列交换, 我们可以将第 j 列逐步换到第 1 列, 即:

$$\begin{bmatrix} a_{1,1} & \cdots & a_{1,j-1} & \mathbf{a_{1,j}} & \cdots & a_{1,n} \\ a_{2,1} & \cdots & a_{2,j-1} & \mathbf{a_{2,j}} & \cdots & a_{2,n} \\ \vdots & \cdots & \vdots & \vdots & \vdots & \vdots \\ a_{n,1} & \cdots & a_{n,j-1} & \mathbf{a_{n,j}} & \cdots & a_{n,n} \end{bmatrix} \rightarrow \begin{bmatrix} a_{1,1} & \cdots & \mathbf{a_{1,j}} & a_{1,j-1} & \cdots & a_{1,n} \\ a_{2,1} & \cdots & \mathbf{a_{2,j}} & a_{2,j-1} & \cdots & a_{2,n} \\ \vdots & \cdots & \vdots & \vdots & \vdots & \vdots \\ a_{n,1} & \cdots & \mathbf{a_{n,j}} & a_{n,j-1} & \cdots & a_{n,n} \end{bmatrix} \\
\cdots \rightarrow \begin{bmatrix} \mathbf{a_{1,j}} & a_{1,1} & \cdots & \cdots & \cdots & a_{1,n} \\ \mathbf{a_{2,j}} & a_{2,1} & \cdots & \cdots & \cdots & a_{2,n} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \mathbf{a_{n,j}} & a_{n,1} & \cdots & \cdots & \cdots & a_{n,n} \end{bmatrix}$$

从而：

$$\begin{aligned}
\det(A) &= (-1)^{j-1} \begin{vmatrix} \mathbf{a_{1,j}} & a_{1,1} & \cdots & \cdots & \cdots & a_{1,n} \\ \mathbf{a_{2,j}} & a_{2,1} & \cdots & \cdots & \cdots & a_{2,n} \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ \mathbf{a_{n,j}} & a_{n,1} & \cdots & \cdots & \cdots & a_{n,n} \end{vmatrix} \\
&= (-1)^{j-1} (a_{1,j}A'_{11} + a_{2,j}A'_{12} + \cdots + a_{n,j}A'_{1n}) \\
&= (-1)^{j-1} (a_{1,j}(-1)^{1+1} \det(A_{-1,-j}) + a_{2,j}(-1)^{2+1} \det(A_{-2,-j}) + \cdots + a_{n,j}(-1)^{n+1} \det(A_{-n,-j})) \\
&= (-1)^{1+j} a_{1,j} \det(A_{-1,-j}) + (-1)^{2+j} a_{2,j} \det(A_{-2,-j}) + \cdots + (-1)^{n+j} a_{n,j} \det(A_{-n,-j}) \\
&= a_{1j}A_{1j} + \cdots + a_{nj}A_{nj}
\end{aligned}$$

□

由定理2.9可知， A 的行列式等于 A^T 的行列式，从而我们可以得到关于行列式按行展开的方式：

定理 2.31

对于任意的 $n \geq 2$ ，并且 A 是一个 $n \times n$ 的矩阵：

$$\begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ \mathbf{a_{i1}} & \cdots & \mathbf{a_{in}} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix}$$

我们有：

$$\det(A) = a_{i1}A_{i1} + \cdots + a_{in}A_{in}$$

上述这些展开式被称为行列式的代数余子式展开 (Cofactor Expansion)。

一些例子。 我们再通过一些例子观察行列式的展开。

例 2.32

考察行列式：

$$\begin{vmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 0 & 0 \\ 1 & 0 & 3 & 0 \\ 1 & 0 & 0 & 4 \end{vmatrix}$$

我们根据其**第一列**展开进行计算：

$$\begin{vmatrix} \color{red}{1} & 1 & 1 & 1 \\ \color{red}{1} & 2 & 0 & 0 \\ \color{red}{1} & 0 & 3 & 0 \\ \color{red}{1} & 0 & 0 & 4 \end{vmatrix} = \color{red}{1} \begin{vmatrix} 2 & 0 & 0 \\ 0 & 3 & 0 \\ 0 & 0 & 4 \end{vmatrix} - \color{red}{1} \begin{vmatrix} 1 & 1 & 1 \\ 0 & 3 & 0 \\ 0 & 0 & 4 \end{vmatrix} + \color{red}{1} \begin{vmatrix} 1 & 1 & 1 \\ 2 & 0 & 0 \\ 0 & 0 & 4 \end{vmatrix} - \color{red}{1} \begin{vmatrix} 1 & 1 & 1 \\ 2 & 0 & 0 \\ 0 & 3 & 0 \end{vmatrix}$$

$$= 24 - 12 - 8 - 6 = -2$$

我们也可以按**第二列**进行展开进行计算：

$$\begin{vmatrix} 1 & \color{red}{1} & 1 & 1 \\ 1 & \color{red}{2} & 0 & 0 \\ 1 & \color{red}{0} & 3 & 0 \\ 1 & \color{red}{0} & 0 & 4 \end{vmatrix} = (-1)^{2+1} \color{red}{1} \begin{vmatrix} 1 & 0 & 0 \\ 1 & 3 & 0 \\ 1 & 0 & 4 \end{vmatrix} + (-1)^{2+2} \color{red}{2} \begin{vmatrix} 1 & 1 & 1 \\ 1 & 3 & 0 \\ 1 & 0 & 4 \end{vmatrix} = -12 + 2 * 5 = -2$$

也可以选择按**第二行**展开进行计算：

$$\begin{vmatrix} 1 & 1 & 1 & 1 \\ \color{red}{1} & \color{red}{2} & \color{red}{0} & \color{red}{0} \\ 1 & 0 & 3 & 0 \\ 1 & 0 & 0 & 4 \end{vmatrix} = (-1)^{1+2} \color{red}{1} \begin{vmatrix} 1 & 1 & 1 \\ 0 & 3 & 0 \\ 0 & 0 & 4 \end{vmatrix} + (-1)^{2+2} \color{red}{2} \begin{vmatrix} 1 & 1 & 1 \\ 1 & 3 & 0 \\ 1 & 0 & 4 \end{vmatrix} = -12 + 2 * 5 = -2$$

例 2.33

记下列的矩阵为 D_n ：

$$D_n = \begin{bmatrix} 2 & -1 & 0 & 0 & \cdots & 0 \\ -1 & 2 & -1 & 0 & \cdots & 0 \\ 0 & -1 & 2 & -1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & \cdots & 0 & -1 & 2 & -1 \\ 0 & \cdots & 0 & 0 & -1 & 2 \end{bmatrix}$$

我们来计算其行列式 $\det(D_n)$ ，将其按第一行展开可得：

$$\begin{aligned} \det(D_n) &= 2 \begin{vmatrix} 2 & -1 & 0 & \cdots & 0 \\ -1 & 2 & -1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \cdots & 0 & -1 & 2 & -1 \\ \cdots & 0 & 0 & -1 & 2 \end{vmatrix} + (-1)^{1+2}(-1) \begin{vmatrix} -1 & -1 & 0 & \cdots & 0 & 0 & 0 \\ 0 & 2 & -1 & \cdots & 0 & 0 & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & 0 & \cdots & -1 & 2 & -1 \\ 0 & 0 & 0 & \cdots & 0 & -1 & 2 \end{vmatrix} \\ &= 2 \begin{vmatrix} 2 & -1 & 0 & \cdots & 0 \\ -1 & 2 & -1 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \cdots & 0 & -1 & 2 & -1 \\ \cdots & 0 & 0 & -1 & 2 \end{vmatrix} + (-1)^{1+2}(-1)(-1) \begin{vmatrix} 2 & -1 & \cdots & 0 & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 0 & 0 & \cdots & -1 & 2 & -1 \\ 0 & 0 & \cdots & 0 & -1 & 2 \end{vmatrix} \\ &= 2 \det(D_{n-1}) - \det(D_{n-2}) \end{aligned}$$

我们有：

$$\det(D_n) = 2 \det(D_{n-1}) - \det(D_{n-2})$$

注意到：

$$\det(D_1) = \begin{vmatrix} 2 \end{vmatrix} = 2, \quad \det(D_2) = \begin{vmatrix} 2 & -1 \\ -1 & 2 \end{vmatrix} = 4 - 1 = 3$$

我们可以根据上述递推式得到：

$$\det(D_n) = n + 1$$

范德蒙德矩阵 (Vandermonde Matrix)。我们下面介绍一个非常著名的矩阵的行列式计算问题，即**范德蒙德矩阵**。考察如下的 $n \times n$ 的矩阵 V_n ：

$$V_n = \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \\ x_1^2 & x_2^2 & \cdots & x_n^2 \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{n-1} & x_2^{n-1} & \cdots & x_n^{n-1} \end{bmatrix}$$

我们将说明，其行列式的值为：

$$\det(V_n) = \prod_{1 \leq j < i \leq n} (x_j - x_i).$$

解：事实上，我们可以通过归纳法进行计算：

1. $n = 2$ 时，我们有：

$$\det(V_2) = \begin{vmatrix} 1 & 1 \\ x_1 & x_2 \end{vmatrix} = x_2 - x_1.$$

2. 考虑 n 的时候，我们的策略是先用行变换将第一列除了第一个元素全部变为 0，再将行列式按第

一列展开，即：

$$\begin{aligned}
 \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{n-2} & x_2^{n-2} & \cdots & x_n^{n-2} \\ x_1^{n-1} & x_2^{n-1} & \cdots & x_n^{n-1} \end{bmatrix} &\rightarrow \begin{bmatrix} 1 & 1 & \cdots & 1 \\ x_1 & x_2 & \cdots & x_n \\ \vdots & \vdots & \ddots & \vdots \\ x_1^{n-2} & x_2^{n-2} & \cdots & x_n^{n-2} \\ 0 & x_2^{n-2}(x_2 - x_1) & \cdots & x_2^{n-2}(x_n - x_1) \end{bmatrix} \\
 &\rightarrow \cdots \rightarrow \begin{bmatrix} 1 & 1 & \cdots & 1 \\ 0 & x_2 - x_1 & \cdots & x_n - x_1 \\ 0 & x_2(x_2 - x_1) & \cdots & x_n(x_n - x_1) \\ 0 & \vdots & \ddots & \vdots \\ 0 & x_2^{n-2}(x_2 - x_1) & \cdots & x_2^{n-2}(x_n - x_1) \end{bmatrix}
 \end{aligned}$$

从而我们有：

$$\det(V_n) = \begin{vmatrix} x_2 - x_1 & \cdots & x_n - x_1 \\ x_2(x_2 - x_1) & \cdots & x_n(x_n - x_1) \\ \vdots & \ddots & \vdots \\ x_2^{n-2}(x_2 - x_1) & \cdots & x_2^{n-2}(x_n - x_1) \end{vmatrix} = (x_2 - x_1) \cdots (x_n - x_1) \begin{vmatrix} 1 & \cdots & 1 \\ x_2 & \cdots & x_n \\ \vdots & \ddots & \vdots \\ x_2^{n-2} & \cdots & x_n^{n-2} \end{vmatrix}$$

由归纳假设我们有：

$$\begin{vmatrix} 1 & \cdots & 1 \\ x_2 & \cdots & x_n \\ \vdots & \ddots & \vdots \\ x_2^{n-2} & \cdots & x_n^{n-2} \end{vmatrix} = \prod_{2 \leq j \leq i \leq n} (x_j - x_i)$$

从而我们有：

$$\det(V_n) = (x_2 - x_1) \cdots (x_n - x_1) \prod_{2 \leq j \leq i \leq n} (x_j - x_i) = \prod_{1 \leq j \leq i \leq n} (x_j - x_i)$$

□

再次讨论 Cramer 法则。 我们在定理2.10中的应用中已经展示了 Cramer 法则，即：方程组 $Ax = b$ 的解可以表示为：

$$x = \begin{bmatrix} \frac{\det(A_1)}{\det(A)} \\ \vdots \\ \frac{\det(A_n)}{\det(A)} \end{bmatrix}$$

现在我们进一步展示其在求逆矩阵上的作用。考察可逆矩阵 A ，则其逆矩阵 A^{-1} 存在，不妨令其列向量为 $x_1, \cdots, x_n$ ，即： $A^{-1} = [x_1 \cdots x_n]$ 。注意到由矩阵的运算，这等价于如下的 n 个方程组：

$$Ax_1 = e_1, Ax_2 = e_2, \cdots, Ax_n = e_n$$

我们先考虑 $\mathbf{x}_1$ 的情形，即：

$$A\mathbf{x}_1 = A \begin{bmatrix} x_{11} \\ \vdots \\ x_{n1} \end{bmatrix} = \begin{bmatrix} 1 \\ \vdots \\ 0 \end{bmatrix}$$

由 Cramer 法则，我们有对任意的 $i \in [n]$ ：

$$x_{i1} = \frac{1}{\det(A)} \begin{vmatrix} a_{1,1} & \cdots & a_{1,i-1} & 1 & a_{1,i+1} & \cdots & a_{1,n} \\ a_{2,1} & \cdots & a_{2,i-1} & 0 & a_{2,i+1} & \cdots & a_{2,n} \\ \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n,1} & \cdots & a_{n,i-1} & 0 & a_{n,i+1} & \cdots & a_{n,n} \end{vmatrix} = \frac{A_{1i}}{\det(A)}$$

更一般的来说，对于 $j \in [n]$

$$A\mathbf{x}_j = A \begin{bmatrix} x_{1j} \\ \vdots \\ x_{nj} \end{bmatrix} = \begin{bmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix}$$

同样通过 Cramer 法则我们有对任意的 $i \in [n]$ ：

$$x_{ij} = \frac{1}{\det(A)} \begin{vmatrix} a_{1,1} & \cdots & a_{1,i-1} & 0 & a_{1,i+1} & \cdots & a_{1,n} \\ \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{j,1} & \cdots & a_{j,i-1} & 1 & a_{j,i+1} & \cdots & a_{j,n} \\ \vdots & \ddots & \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n,1} & \cdots & a_{n,i-1} & 0 & a_{n,i+1} & \cdots & a_{n,n} \end{vmatrix} = \frac{A_{ji}}{\det(A)}$$

从而我们可以计算出 A^{-1} ：

$$A^{-1} = \frac{1}{\det(A)} \begin{bmatrix} A_{11} & \cdots & A_{n1} \\ \vdots & \ddots & \vdots \\ A_{1n} & \cdots & A_{nn} \end{bmatrix}$$

我们也称上述不带分数的矩阵为 A 的伴随矩阵 (Adjugate matrix)：

定义 2.34 (伴随矩阵)

称下列矩阵：

$$A^* = \begin{bmatrix} A_{11} & \cdots & A_{n1} \\ \vdots & \ddots & \vdots \\ A_{1n} & \cdots & A_{nn} \end{bmatrix}$$

为 A 的伴随矩阵 (Adjugate Matrix)。

由上述的讨论：

定理 2.35

$$AA^* = \det(A)I$$

这也是同济教材上，包括很多国内教材引入计算逆矩阵的方式。

线性代数 (XII)

Lecturer: 杨启哲

Last modified: 2026 年 5 月 29 日

1 特征值介绍

这一章我们从斐波那契数列开始，斐波那契数列 $0, 1, 1, 2, 3, 5, 8, 13, 21, \dots$ ，是一个递归数列，定义为

$$F_n = \begin{cases} 0 & n = 0 \\ 1 & n = 1 \\ F_{n-1} + F_{n-2} & n \geq 2 \end{cases}$$

如果我们将递推过程写成矩阵的形式，即：

$$\begin{bmatrix} F_{n+1} \\ F_n \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} F_n \\ F_{n-1} \end{bmatrix}$$

我们将这个矩阵记为 $A = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$ ，则斐波那契数列可以如下计算：

$$\begin{bmatrix} F_{n+1} \\ F_n \end{bmatrix} = A^n \begin{bmatrix} F_1 \\ F_0 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}^n \begin{bmatrix} 1 \\ 0 \end{bmatrix} \quad (1)$$

另一方面，由递推公式的求法（求 a, c 满足 $F_{k+2} + aF_{k+1} = c(F_{k+1} + aF_k)$ ）我们可以得到：

$$\begin{aligned} F_{k+1} + \frac{-1+\sqrt{5}}{2}F_k &= \frac{1+\sqrt{5}}{2}(F_k + \frac{-1+\sqrt{5}}{2}F_{k-1}) \\ F_{k+1} + \frac{-1-\sqrt{5}}{2}F_k &= \frac{1-\sqrt{5}}{2}(F_k + \frac{-1-\sqrt{5}}{2}F_{k-1}) \end{aligned}$$

将上述式子写成矩阵的形式有：

$$\begin{bmatrix} F_{k+1} + \frac{-1+\sqrt{5}}{2}F_k \\ F_{k+1} + \frac{-1-\sqrt{5}}{2}F_k \end{bmatrix} = \begin{bmatrix} \frac{1+\sqrt{5}}{2} & 0 \\ 0 & \frac{1-\sqrt{5}}{2} \end{bmatrix} \begin{bmatrix} F_k + \frac{-1+\sqrt{5}}{2}F_{k-1} \\ F_k + \frac{-1-\sqrt{5}}{2}F_{k-1} \end{bmatrix}$$

从而通过类似的讨论可以得到：

$$\begin{aligned} \begin{bmatrix} F_{k+1} + \frac{-1+\sqrt{5}}{2}F_k \\ F_{k+1} + \frac{-1-\sqrt{5}}{2}F_k \end{bmatrix} &= \left(\begin{bmatrix} \frac{1+\sqrt{5}}{2} & 0 \\ 0 & \frac{1-\sqrt{5}}{2} \end{bmatrix} \right)^k \begin{bmatrix} F_1 + \frac{-1+\sqrt{5}}{2}F_0 \\ F_1 + \frac{-1-\sqrt{5}}{2}F_0 \end{bmatrix} \\ &= \begin{bmatrix} \left(\frac{1+\sqrt{5}}{2} \right)^k & 0 \\ 0 & \left(\frac{1-\sqrt{5}}{2} \right)^k \end{bmatrix} \begin{bmatrix} F_1 + \frac{-1+\sqrt{5}}{2}F_0 \\ F_1 + \frac{-1-\sqrt{5}}{2}F_0 \end{bmatrix} \end{aligned} \quad (2)$$

注意到：

$$\begin{bmatrix} F_1 + \frac{-1+\sqrt{5}}{2}F_0 \\ F_1 + \frac{-1-\sqrt{5}}{2}F_0 \end{bmatrix} = \begin{bmatrix} 1 & \frac{-1+\sqrt{5}}{2} \\ 1 & \frac{-1-\sqrt{5}}{2} \end{bmatrix} \begin{bmatrix} F_1 \\ F_0 \end{bmatrix}, \quad \begin{bmatrix} F_{k+1} + \frac{-1+\sqrt{5}}{2}F_k \\ F_{k+1} + \frac{-1-\sqrt{5}}{2}F_k \end{bmatrix} = \begin{bmatrix} 1 & \frac{-1+\sqrt{5}}{2} \\ 1 & \frac{-1-\sqrt{5}}{2} \end{bmatrix} \begin{bmatrix} F_{k+1} \\ F_k \end{bmatrix}$$

从而有：

$$\begin{aligned} \begin{bmatrix} F_{k+1} + \frac{-1+\sqrt{5}}{2}F_k \\ F_{k+1} + \frac{-1-\sqrt{5}}{2}F_k \end{bmatrix} &= \begin{bmatrix} 1 & \frac{-1+\sqrt{5}}{2} \\ 1 & \frac{-1-\sqrt{5}}{2} \end{bmatrix} \begin{bmatrix} F_{k+1} \\ F_k \end{bmatrix} = \begin{bmatrix} 1 & \frac{-1+\sqrt{5}}{2} \\ 1 & \frac{-1-\sqrt{5}}{2} \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} F_k \\ F_{k-1} \end{bmatrix} \\ \begin{bmatrix} F_{k+1} + \frac{-1+\sqrt{5}}{2}F_k \\ F_{k+1} + \frac{-1-\sqrt{5}}{2}F_k \end{bmatrix} &= \begin{bmatrix} \frac{1+\sqrt{5}}{2} & 0 \\ 0 & \frac{1-\sqrt{5}}{2} \end{bmatrix} \begin{bmatrix} F_k + \frac{-1+\sqrt{5}}{2}F_{k-1} \\ F_k + \frac{-1-\sqrt{5}}{2}F_{k-1} \end{bmatrix} = \begin{bmatrix} \frac{1+\sqrt{5}}{2} & 0 \\ 0 & \frac{1-\sqrt{5}}{2} \end{bmatrix} \begin{bmatrix} 1 & \frac{-1+\sqrt{5}}{2} \\ 1 & \frac{-1-\sqrt{5}}{2} \end{bmatrix} \begin{bmatrix} F_k \\ F_{k-1} \end{bmatrix} \end{aligned}$$

因此我们得到了：

$$\begin{bmatrix} 1 & \frac{-1+\sqrt{5}}{2} \\ 1 & \frac{-1-\sqrt{5}}{2} \end{bmatrix} \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} \frac{1+\sqrt{5}}{2} & 0 \\ 0 & \frac{1-\sqrt{5}}{2} \end{bmatrix} \begin{bmatrix} 1 & \frac{-1+\sqrt{5}}{2} \\ 1 & \frac{-1-\sqrt{5}}{2} \end{bmatrix}$$

令： $X = \begin{bmatrix} 1 & \frac{-1+\sqrt{5}}{2} \\ 1 & \frac{-1-\sqrt{5}}{2} \end{bmatrix}$, $\Lambda = \begin{bmatrix} \frac{1+\sqrt{5}}{2} & 0 \\ 0 & \frac{1-\sqrt{5}}{2} \end{bmatrix} = \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix}$ 。则上述式子可改写为：

$$XA = \Lambda X, \quad \text{即：} A = X^{-1}\Lambda X.$$

注意到此时：

$$X^{-1} = \begin{bmatrix} \frac{5+\sqrt{5}}{10} & \frac{5-\sqrt{5}}{10} \\ \frac{\sqrt{5}}{5} & -\frac{\sqrt{5}}{5} \end{bmatrix}$$

回到等式(1)和等式(2)，注意到：

$$\begin{aligned} \begin{bmatrix} F_{k+1} \\ F_k \end{bmatrix} &= \left(\begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \right)^k \begin{bmatrix} F_1 \\ F_0 \end{bmatrix} \\ &= \left(X^{-1} \begin{bmatrix} \frac{1+\sqrt{5}}{2} & 0 \\ 0 & \frac{1-\sqrt{5}}{2} \end{bmatrix} X \right)^k \begin{bmatrix} F_1 \\ F_0 \end{bmatrix} \\ &= \left(X^{-1} \begin{bmatrix} \left(\frac{1+\sqrt{5}}{2}\right)^k & 0 \\ 0 & \left(\frac{1-\sqrt{5}}{2}\right)^k \end{bmatrix} X \right) \begin{bmatrix} F_1 \\ F_0 \end{bmatrix} \end{aligned}$$

这也说明等式(1)和等式(2)是一致的，同时 $A = X^{-1}\Lambda X$ 的分解也给出了一个简单的计算 A^n 的方式。

特征值和特征向量 令 X^{-1} 的列向量是 $\mathbf{x}_1, \mathbf{x}_2$ 。我们有：

$$AX^{-1} = [A\mathbf{x}_1 \quad A\mathbf{x}_2] = X^{-1} \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} = [\mathbf{x}_1 \quad \mathbf{x}_2] \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} = [\lambda_1\mathbf{x}_1 \quad \lambda_2\mathbf{x}_2]$$

也就是：

$$A\mathbf{x}_1 = \lambda_1\mathbf{x}_1, \quad A\mathbf{x}_2 = \lambda_2\mathbf{x}_2$$

我们称 λ_1, λ_2 是 A 的**特征值 (Eigenvalue)**，而 $\mathbf{x}_1, \mathbf{x}_2$ 是相应的**特征向量 (Eigenvector)**。下面首先尝试给出如下的定义：

定义 1.1 (特征值和特征向量, 尝试定义)

令 A 是一个 $n \times n$ 的矩阵, λ 是一个实数, $\mathbf{x} \in \mathbb{R}^n$ 是一个非零的 n 维向量。如果:

$$A\mathbf{x} = \lambda\mathbf{x}.$$

则称 λ 是 A 的特征值 (Eigenvalue), $\mathbf{x}$ 是 λ 对应的特征向量 (Eigenvector)。

一些例子 下面通过一些例子来理解上述概念。

例 1.2 (斐波那契矩阵的特征值和特征向量)

先回顾前面斐波那契上的例子:

$$A = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$$

由前面讨论:

$$\begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} \frac{5+\sqrt{5}}{10} \\ \frac{\sqrt{5}}{5} \end{bmatrix} = \frac{1+\sqrt{5}}{2} \begin{bmatrix} \frac{5+\sqrt{5}}{10} \\ \frac{\sqrt{5}}{5} \end{bmatrix}, \quad \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} \frac{5-\sqrt{5}}{10} \\ -\frac{\sqrt{5}}{5} \end{bmatrix} = \frac{1-\sqrt{5}}{2} \begin{bmatrix} \frac{5-\sqrt{5}}{10} \\ -\frac{\sqrt{5}}{5} \end{bmatrix}$$

从而对于矩阵 A :

1. 其有两个特征值: $\lambda_1 = \frac{1+\sqrt{5}}{2}$, $\lambda_2 = \frac{1-\sqrt{5}}{2}$, 对应的特征向量为: $\mathbf{x}_1 = \begin{bmatrix} \frac{5+\sqrt{5}}{10} \\ \frac{\sqrt{5}}{5} \end{bmatrix}$, $\mathbf{x}_2 = \begin{bmatrix} \frac{5-\sqrt{5}}{10} \\ -\frac{\sqrt{5}}{5} \end{bmatrix}$.
2. 回顾之前的计算:

$$AX^{-1} = A \begin{bmatrix} \mathbf{x}_1 & \mathbf{x}_2 \end{bmatrix} = \begin{bmatrix} \mathbf{x}_1 & \mathbf{x}_2 \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} = X^{-1}\Lambda$$

例 1.3 (对角矩阵的特征值和特征向量)

考察对角矩阵:

$$\Lambda = \begin{bmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_n \end{bmatrix}$$

显然我们有:

$$A\mathbf{e}_i = \lambda_i\mathbf{e}_i, \quad \text{这里 } \mathbf{e}_i = \begin{bmatrix} 0 \\ \vdots \\ 1 \\ \vdots \\ 0 \end{bmatrix}$$

从而 Λ 的特征值为 $\lambda_1, \dots, \lambda_n$, 每个 λ_i 对应的特征向量为 $\mathbf{e}_i$ 。

例 1.4 (投影矩阵的特征值和特征向量)

现在来考察投影矩阵, 令 A 是一个 $m \times n$ 且 $\text{rank}(A) = n$ 的矩阵, 则投影至 $C(A)$ 的投影矩阵 P 可以表示为:

$$P = A(A^T A)^{-1} A^T$$

注意到 Px 是 x 到 $C(A)$ 上的投影, 所以 $Px = \lambda x$ 只有两种情况:

1. $x \in C(A)$, 此时 $Px = 1x = x$
2. $x \in C(A)^\perp$ 即 $x \in N(A^T)$, 此时 $Px = 0x = 0$

特征值为 0 的情况 假设 $n \times n$ 的矩阵 A 存在特征值 0, 即存在一个非零的 $x \in \mathbb{R}^n \setminus \{0\}$ 满足:

$$Ax = 0x = 0$$

这说明 $Ax = 0$ 有非零解, 即 $\dim(N(A)) \geq 1$, 进一步有:

引理 1.5

下述是等价的:

1. A 具有特征值 0。
2. $N(A) \neq \{0\}$ 。
3. $\text{rank}(A) < n$ 。
4. $\det(A) = 0$ 。

特征值和特征向量的几何解释 下面从几何的角度来理解一下特征值的意义。令 A 是一个 $n \times n$ 的矩阵, 将其看作一个函数 $f_A: \mathbb{R}^n \rightarrow \mathbb{R}^n$, 即:

$$f_A(x) = Ax$$

则当 x 是 A 的特征向量, 即 $Ax = \lambda x$ 时我们有:

$$f_A(x) = \lambda x$$

这意味着 f_A 不改变 x 的方向!

另一方面, 考察矩阵: $A = \begin{bmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{bmatrix}$, 有:

$$A \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix} = \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix}, \quad A \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \frac{1}{2} \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

从而 $1, \frac{1}{2}$ 是其两个特征值, $\begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix}, \begin{bmatrix} 1 \\ -1 \end{bmatrix}$ 是相应的特征向量, 注意到这两个向量是线性无关的, 意味

着任何一个向量都可以表示成其线性组合，比如：

$$\begin{bmatrix} 0.8 \\ 0.2 \end{bmatrix} = \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix} + 0.2 \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

从而：

$$A^{100} \begin{bmatrix} 0.8 \\ 0.2 \end{bmatrix} = (1)^{100} \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix} + 0.2 \left(\frac{1}{2}\right)^{100} \begin{bmatrix} 1 \\ -1 \end{bmatrix} \approx \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix}$$

这也给出了 $A^n \mathbf{x}$ 的一种估计方式。

特征值的计算 进一步回顾上述例子中特征值的计算，实际是就是：

$$A\mathbf{x} = \lambda\mathbf{x} \implies (\lambda I - A)\mathbf{x} = \mathbf{0} \text{ 有非零解}$$

因此有下列定理：

定理 1.6

令 A 是 $n \times n$ 的矩阵， λ 是 A 的特征值当且仅当：

$$\det(\lambda I - A) = 0$$

证明：

$$\begin{aligned} \lambda \text{ 是 } A \text{ 的特征值} &\iff A\mathbf{x} = \lambda\mathbf{x} \text{ 有非零解} \\ &\iff (\lambda I - A)\mathbf{x} = \mathbf{0} \text{ 有非零解} \\ &\iff \text{rank}(\lambda I - A) < n \\ &\iff \det(\lambda I - A) = 0 \end{aligned}$$

□

将 λ 看成一个变量，则对于 $n \times n$ 的矩阵 A ：

$$f(\lambda) = \det(\lambda I - A)$$

是一个关于 λ 的 n 次多项式，我们将其称为矩阵 A 的特征多项式：

定义 1.7 (特征多项式 (Characteristic Polynomial))

令 A 是 $n \times n$ 的矩阵，则称 $f(\lambda) = \det(\lambda I - A)$ 是 A 的特征多项式 (Characteristic Polynomial)。

不难有如下结论：

陈述 1.8

令 A 是 $n \times n$ 的矩阵，则其特征多项式 $f(\lambda)$ 的零点即为 A 的特征值。

我们依旧通过一些例子来理解特征多项式：

1. 对于矩阵 $A = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix}$, 其特征多项式为:

$$\det(\lambda I - A) = \begin{vmatrix} \lambda - 1 & -1 \\ -1 & \lambda \end{vmatrix} = \lambda^2 - \lambda - 1$$

该多项式的两个零点为:

$$\lambda_1 = \frac{1 + \sqrt{5}}{2}, \quad \lambda_2 = \frac{1 - \sqrt{5}}{2}$$

2. 对角矩阵: $A = \begin{bmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_n \end{bmatrix}$ 的特征多项式为:

$$(\lambda - \lambda_1)(\lambda - \lambda_2) \cdots (\lambda - \lambda_n)$$

其对应的零点为:

$$\lambda_1, \dots, \lambda_n (\text{可能重复})$$

消元法会改变特征值! 高斯-若尔当消元法是课程中一个重要的工具, 但下面的例子表明, 该过程会改变矩阵的特征值:

$$A = \begin{bmatrix} 1 & 3 \\ 2 & 6 \end{bmatrix} \implies U = \begin{bmatrix} 1 & 3 \\ 0 & 0 \end{bmatrix}$$

我们有:

$$1. f_A(\lambda) = (1 - \lambda)(6 - \lambda) - 6 = \lambda(\lambda - 7) \implies \lambda_1 = 0, \lambda_2 = 7.$$

$$2. f_U(\lambda) = (1 - \lambda)(0 - \lambda) - 0 = \lambda(\lambda - 1) \implies \lambda_1 = 0, \lambda_2 = 1.$$

旋转矩阵的特征值和特征向量 现在来关注一个特殊的例子: 旋转矩阵。考察如下的矩阵:

$$Q = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix} = \begin{bmatrix} \cos \frac{\pi}{2} & -\sin \frac{\pi}{2} \\ \sin \frac{\pi}{2} & \cos \frac{\pi}{2} \end{bmatrix}$$

其特征多项式为:

$$\det(\lambda I - A) = \begin{vmatrix} \lambda & 1 \\ -1 & \lambda \end{vmatrix} = \lambda^2 + 1$$

其两个零点为:

$$\lambda_1 = i, \lambda_2 = -i$$

从而 Q 有两个复数特征值, 其对应的特征向量为:

$$Q \begin{bmatrix} 1 \\ i \end{bmatrix} = -i \begin{bmatrix} 1 \\ i \end{bmatrix}$$

$$Q \begin{bmatrix} i \\ 1 \end{bmatrix} = i \begin{bmatrix} i \\ 1 \end{bmatrix}$$

也是在 $\mathbb{C}^2$ 上的向量!

上述例子说明了定义1.1的不足之处, 即使考虑的是实数矩阵 A , 其特征值和特征向量也可能是复数的。我们需要对定义1.1进行修正:

定义 1.9 (特征值和特征向量)

令 A 是一个 $n \times n$ 的矩阵, $\lambda \in \mathbb{C}$, $\mathbf{x} \in \mathbb{C}^n \setminus \{\mathbf{0}\}$ 。如果:

$$A\mathbf{x} = \lambda\mathbf{x}$$

则称 λ 是 A 的**特征值 (Eigenvalue)**, $\mathbf{x}$ 是 λ 对应的**特征向量 (Eigenvector)**。

不难验证, 上述的所有讨论在定义1.9下依旧成立, 因此并不需要花费篇幅修改之前的内容。现在可以总结如下计算特征值和特征向量的方法:

1. 计算 A 的特征多项式, 即 $\lambda I - A$ 的行列式 $\det(\lambda I - A)$.
2. 计算 $\det(\lambda I - A)$ 的根, 我们一共会得到 n 个特征值 (可能重复)。这使得 $\lambda I - A$ 变成一个奇异矩阵 ($\text{rank}(A) < n$).
3. 对每个 λ , 通过解方程 $(\lambda I - A)\mathbf{x} = \mathbf{0}$ 来获取 λ 对应的特征向量 $\mathbf{x}$.

注 1.10

在一般意义下:

1. 矩阵可以有复数。
2. 向量空间是可以通过复数扩充的, 即数乘允许 $c \in \mathbb{C}$ 进行运算。
3. 甚至复数域的结论会更加优美。

但在本课程中:

1. 出于课程的面向对象和内容, 我们只考虑实数的矩阵。
2. 但是我们依旧会讨论到复数的特征值和特征向量。

特征值的数目 本节的最后, 我们来讨论一下特征值的数目。由陈述1.8, 我们知道特征值的数目和特征多项式的零点数目是相同的。注意到**代数基本定理**:

定理 1.11 (Fundamental Theorem of Algebra)

对于任一的 $a_1, \dots, a_n \in \mathbb{C}$, 我们有

$$x^n + a_1 x^{n-1} + \dots + a_{n-1} x + a_n = (x - b_1)(x - b_2) \cdots (x - b_n)$$

这里 $b_1, \dots, b_n \in \mathbb{C}$, 即任一单变元的 n 次复系数多项式恰好有 n 个复数根 (可重复)。

得益于定义1.7, 不难得出:

推论 1.12

令 A 是一个 $n \times n$ 的矩阵, 则在计算重根的意义下, A 恰好有 n 个 $\mathbb{C}$ 中的特征值。

例 1.13

考察矩阵

$$\begin{bmatrix} 0 & -1 & 0 & 0 \\ 1 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

其特征多项式为 $f(\lambda) = \lambda^2(\lambda^2 + 1)$, 注意到 $f(\lambda) = 0$ 一共有 4 个解:

$$\lambda_1 = \lambda_2 = 0, \lambda_3 = i, \lambda_4 = -i$$

这里 0 是一个重根, 在计算重复次数以后可以得到其一共有 4 个特征值。

2 对角化矩阵

回顾上节斐波那契数列中提到的等式1和等式2:

$$\begin{aligned} \begin{bmatrix} F_{k+1} \\ F_k \end{bmatrix} &= \left(\begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \right)^k \begin{bmatrix} F_1 \\ F_0 \end{bmatrix} \\ &= \left(\mathbf{X}' \begin{bmatrix} \frac{1+\sqrt{5}}{2} & 0 \\ 0 & \frac{1-\sqrt{5}}{2} \end{bmatrix} (\mathbf{X}')^{-1} \right)^k \begin{bmatrix} F_1 \\ F_0 \end{bmatrix} \\ &= \left(\mathbf{X}' \begin{bmatrix} \left(\frac{1+\sqrt{5}}{2}\right)^k & 0 \\ 0 & \left(\frac{1-\sqrt{5}}{2}\right)^k \end{bmatrix} (\mathbf{X}')^{-1} \right) \begin{bmatrix} F_1 \\ F_0 \end{bmatrix} \end{aligned}$$

中间的对角矩阵 Λ 极大的简化了我们对 $\left(\begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \right)^k$ 的计算, 我们把这过程称为**对角化 (Diagonalization)**, 下面给出正式的定义:

定义 2.1 (Diagonalization)

一个方阵 A 是可对角化的 (Diagonalizable), 如果其存在一个可逆矩阵 X 和对角矩阵 Λ 使得:

$$A = X\Lambda X^{-1}, \text{ 或者等价的 } \Lambda = X^{-1}AX$$

推论 2.2

若 $A = X\Lambda X^{-1}$, 其中 $X = \text{diag}(\lambda_1, \dots, \lambda_n)$, 则对于任意的 $k \geq 1$ 我们有:

$$A^k = X\Lambda^k X^{-1} = X \begin{bmatrix} \lambda_1^k & & \\ & \lambda_2^k & \\ & & \ddots \\ & & & \lambda_n^k \end{bmatrix} X^{-1}$$

我们也称这是矩阵的谱分解。

例 2.3

考察矩阵 $A = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix}$, 我们有:

$$A = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} \end{bmatrix}$$

其中 $\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$ 是可逆矩阵, 并且:

$$\left(\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \right)^{-1} = \begin{bmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} \end{bmatrix}$$

$A = X\Lambda X^{-1}$ 可以理解成 $AX = X\Lambda$, 从而 A 可以对角化说明的是:

1. X 的每一列都应该是 A 的特征向量。
2. X 是可逆的, 所以 A 需要有 n 个线性无关的特征向量。

也即下述定理:

定理 2.4

$n \times n$ 的矩阵可对角化当且仅当 A 有 n 个线性无关的特征向量。

证明: 假设 A 有 n 个特征值 $\lambda_1, \dots, \lambda_n$ (可以重复), 对应的特征向量 $\mathbf{x}_1, \dots, \mathbf{x}_n$ 是线性无关的:

$$A\mathbf{x}_1 = \lambda_1\mathbf{x}_1, \dots, A\mathbf{x}_n = \lambda_n\mathbf{x}_n$$

定义下列矩阵:

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n) = \begin{bmatrix} \lambda_1^k & & \\ & \lambda_2^k & \\ & & \ddots \\ & & & \lambda_n^k \end{bmatrix}, \quad X = [\mathbf{x}_1, \dots, \mathbf{x}_n]$$

则有:

1. $AX = A \begin{bmatrix} \mathbf{x}_1, \dots, \mathbf{x}_n \end{bmatrix} = \begin{bmatrix} A\mathbf{x}_1, \dots, A\mathbf{x}_n \end{bmatrix} = \begin{bmatrix} \lambda_1 \mathbf{x}_1, \dots, \lambda_n \mathbf{x}_n \end{bmatrix} = \begin{bmatrix} \mathbf{x}_1, \dots, \mathbf{x}_n \end{bmatrix} \Lambda = X\Lambda$.
2. $\text{rank}(X) = n$, 从而 X 可逆, 即: $A = X\Lambda X^{-1}$ 。

另一方面, 定义下列矩阵:

$$\Lambda = \text{diag}(\lambda_1, \dots, \lambda_n) = \begin{bmatrix} \lambda_1^k & & \\ & \lambda_2^k & \\ & & \ddots \\ & & & \lambda_n^k \end{bmatrix}, \quad X = \begin{bmatrix} \mathbf{x}_1, \dots, \mathbf{x}_n \end{bmatrix}$$

容易验证:

1. 对于每个 $\mathbf{x}_i$, 有 $A\mathbf{x}_i = \lambda_i \mathbf{x}_i$ 。
2. $\mathbf{x}_1, \dots, \mathbf{x}_n$ 是线性无关的。

□

一些例子 还是通过一些例子来进行理解。

1. 回顾之前提到的矩阵:

$$A = \begin{bmatrix} 2 & -1 \\ -1 & 2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} \frac{1}{2} & \frac{1}{2} \\ \frac{1}{2} & -\frac{1}{2} \end{bmatrix}$$

其特征多项式为 $f_A(\lambda) = \lambda^2 - 4\lambda + 3 = (\lambda - 1)(\lambda - 3)$, 分别计算其对应的特征向量为:

- (1) $\lambda = 1$ 时解方程 $(A - I)\mathbf{x} = \mathbf{0}$ 得一个其特征向量为 $\begin{bmatrix} 1 \\ 1 \end{bmatrix}$ 。
- (2) $\lambda = 3$ 时解方程 $(A - 3I)\mathbf{x} = \mathbf{0}$ 得一个其特征向量为 $\begin{bmatrix} 1 \\ -1 \end{bmatrix}$ 。

2. 下列矩阵:

$$A = \begin{bmatrix} 1 & -1 \\ 1 & -1 \end{bmatrix}, \quad B = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, \quad C = \begin{bmatrix} 1 & 1 \\ 0 & 1 \end{bmatrix}$$

不可对角化。

- A 的特征值为 $\lambda_1 = \lambda_2 = 0$, 只有一个特征向量。
- B 的特征值为 $\lambda_1 = \lambda_2 = 0$, 只有一个特征向量。
- C 的特征值为 $\lambda_1 = \lambda_2 = 1$, 只有一个特征向量。

注 2.5

注意到矩阵 C 是可逆的，因此可逆和可对角化并没有直接的关系。

- (1) 矩阵是否可逆取决于是否有零特征值 ($\lambda = 0$)。
- (2) 矩阵是否可对角化取决于是否有 n 个特征向量。

下述定理给出了 n 个线性无关的特征向量的一个充分条件：

定理 2.6

令 $\mathbf{x}_1, \dots, \mathbf{x}_k$ 是 A 的 k 个特征向量，并且其对应的特征值两两不相同。则 $\mathbf{x}_1, \dots, \mathbf{x}_k$ 是线性无关的。

从而 n 个不同的特征值蕴含了可对角化的结论：

推论 2.7

如果 $n \times n$ 的矩阵 A 有 n 个不同的特征值，则 A 是可对角化的。

下面开始对定理2.6进行证明，其直观理解是，当 λ 互不相等的时候，下属两个等式不可能相等：

$$A\mathbf{x} = \lambda\mathbf{x} = c_1\lambda\mathbf{x}_1 + \dots + c_k\lambda\mathbf{x}_k$$

$$A(c_1\mathbf{x}_1 + \dots + c_k\mathbf{x}_k) = c_1\lambda_1\mathbf{x}_1 + \dots + c_k\lambda_k\mathbf{x}_k$$

证明：[定理2.6的证明.] 对 k 做归纳法， $k = 1$ 的时候是显然的。

假设 $k \geq 2$ ，并且：

$$c_1\mathbf{x}_1 + \dots + c_k\mathbf{x}_k = \mathbf{0}$$

下面证明 $c_1 = c_2 = \dots = c_k = 0$ ，反设结论不成立，即存在 $c_i \neq 0$ ，即：

$$\mathbf{x}_i = \sum_{j \in [k] \setminus \{i\}} -\frac{c_j}{c_i} \mathbf{x}_j$$

从而有：

$$\lambda_i \mathbf{x}_i = A\mathbf{x}_i = \sum_{j \in [k] \setminus \{i\}} -\frac{c_j}{c_i} A\mathbf{x}_j = \sum_{j \in [k] \setminus \{i\}} -\frac{c_j}{c_i} \lambda_j \mathbf{x}_j$$

注意到，由归纳假设：

$$\mathbf{x}_1, \dots, \mathbf{x}_{i-1}, \mathbf{x}_{i+1}, \dots, \mathbf{x}_k \text{ 是线性无关的}$$

从而：

1. 如果 $\lambda_i = 0$ ，则有 $\frac{c_j}{c_i} \lambda_j = 0$ ，从而 $\frac{c_j}{c_i} = 0$ ， $\mathbf{x}_i = \mathbf{0}$ ，矛盾。
2. 如果 $\lambda_i \neq 0$ ，则有：

$$\mathbf{x}_i = \sum_{j \in [k] \setminus \{i\}} -\frac{c_j}{c_i} \mathbf{x}_j \text{ 和 } \mathbf{x}_i = \sum_{j \in [k] \setminus \{i\}} -\frac{c_j \lambda_j}{c_i \lambda_i} \mathbf{x}_j$$

注意到 $\lambda_j \neq \lambda_i$, 所以存在不全为 0 的 $d_1, \dots, d_{i-1}, d_{i+1}, \dots, d_k$ 满足:

$$d_1 \mathbf{x}_1 + \dots + d_{i-1} \mathbf{x}_{i-1} + d_{i+1} \mathbf{x}_{i+1} + \dots + d_k \mathbf{x}_k = \mathbf{0}$$

与 $\mathbf{x}_1, \dots, \mathbf{x}_{i-1}, \mathbf{x}_{i+1}, \dots, \mathbf{x}_k$ 是线性无关的矛盾。

□

相似矩阵 再来考虑一下对角化的形式:

$$A = X \Lambda X^{-1}$$

当特征向量组成的矩阵 X 改变的时候, 我们得到了无数个不同的矩阵。

- 但这些矩阵的特征值都是相同的。

更一般的, 对于

$$A = B C B^{-1}$$

其中 B 是可逆矩阵, 即使 C 不可以对角化, 我们也可以得到跟 C 具有相同特征值的一大类矩阵。我们称这样一个关系叫相似 (similar):

定义 2.8 (相似矩阵 (Similar Matrix))

给定矩阵 A, B , 如果存在可逆矩阵 P , 使得:

$$A = P B P^{-1}$$

则称矩阵 A 和 B 是相似的。

引理 2.9

相似矩阵 A 和 B 的特征值相同。

证明: 假设 $B\mathbf{x} = \lambda\mathbf{x}$, 则我们有:

$$A(P\mathbf{x}) = P B P^{-1}(P\mathbf{x}) = P B \mathbf{x} = \lambda P \mathbf{x}$$

□

引理 2.10

相似关系是一个等价关系。

证明:

1. 自反性: $A = P A P^{-1}$, 其中 $P = I$.
2. 对称性: $A = P B P^{-1} \implies B = P^{-1} A P$.
3. 传递性: $A = P B P^{-1}, B = Q C Q^{-1} \implies A = P Q C Q^{-1} P^{-1}$.

□

相似矩阵的直观理解 我们先补充一些线性变换上的概念。这一部分的定理具体证明都会在正式介绍线性变换的时候完成，现在只是为了帮助大家建立起一个概念。假设一个线性空间 V 的两组基为 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 和 $\mathbf{f}_1, \dots, \mathbf{f}_n$ ，则存在 $c_{ij} \in \mathbb{R}$, $i, j \in [n]$ 满足：

$$\begin{aligned}\mathbf{f}_1 &= c_{11}\mathbf{e}_1 + c_{21}\mathbf{e}_2 + \dots + c_{n1}\mathbf{e}_n \\ \mathbf{f}_2 &= c_{12}\mathbf{e}_1 + c_{22}\mathbf{e}_2 + \dots + c_{n2}\mathbf{e}_n \\ &\dots \\ \mathbf{f}_n &= c_{1n}\mathbf{e}_1 + c_{2n}\mathbf{e}_2 + \dots + c_{nn}\mathbf{e}_n\end{aligned}$$

记：

$$\begin{pmatrix} \mathbf{f}_1 & \mathbf{f}_2 & \dots & \mathbf{f}_n \end{pmatrix} = \begin{pmatrix} \mathbf{e}_1 & \mathbf{e}_2 & \dots & \mathbf{e}_n \end{pmatrix} \begin{bmatrix} c_{11} & c_{12} & \dots & c_{1n} \\ c_{21} & c_{22} & \dots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{n1} & c_{n2} & \dots & c_{nn} \end{bmatrix} \quad (3)$$

则上式右边的矩阵被称作基 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 到 $\mathbf{f}_1, \dots, \mathbf{f}_n$ 的过渡矩阵。当 $V = \mathbb{R}^n$ 时等式3可以转换成矩阵的形式：

$$\begin{bmatrix} \mathbf{f}_1 & \mathbf{f}_2 & \dots & \mathbf{f}_n \end{bmatrix} = \begin{bmatrix} \mathbf{e}_1 & \mathbf{e}_2 & \dots & \mathbf{e}_n \end{bmatrix} \begin{bmatrix} c_{11} & c_{12} & \dots & c_{1n} \\ c_{21} & c_{22} & \dots & c_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ c_{n1} & c_{n2} & \dots & c_{nn} \end{bmatrix}$$

而对于 V 上的一个元素 $\mathbf{u}$ ，假设存在 $c_1, \dots, c_n$ 满足：

$$\mathbf{u} = c_1\mathbf{e}_1 + c_2\mathbf{e}_2 + \dots + c_n\mathbf{e}_n$$

则称 $\mathbf{u}$ 在基 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 下的坐标为 $(c_1, \dots, c_n)$ ，也用列向量 $(c_1, \dots, c_n)^T$ 表示。我们有如下的定理：

定理 2.11

令一个线性空间 V 的两组基为 $\bar{\mathbf{e}} = \{\mathbf{e}_1, \dots, \mathbf{e}_n\}$ 和 $\bar{\mathbf{f}} = \{\mathbf{f}_1, \dots, \mathbf{f}_n\}$ ， M 是 $\bar{\mathbf{e}}$ 到 $\bar{\mathbf{f}}$ 的过渡矩阵。则对于任意的 $\mathbf{u} \in V$ ，令其在 $\bar{\mathbf{e}}$ 下的坐标为 $(c_1, \dots, c_n)^T$ ，在 $\bar{\mathbf{f}}$ 下的坐标为 $(d_1, \dots, d_n)^T$ ，则有：

$$\begin{bmatrix} d_1 \\ d_2 \\ \vdots \\ d_n \end{bmatrix} = M \begin{bmatrix} c_1 \\ c_2 \\ \vdots \\ c_n \end{bmatrix}.$$

为了叙述清楚相似矩阵的本质，我们还需要引入线性变换在不同基下的表示。设 V 是一个线性空间， $T: V \rightarrow W$ 是一个线性变换， $\bar{\mathbf{e}} = \{\mathbf{e}_1, \dots, \mathbf{e}_n\}$ 和 $\bar{\mathbf{f}} = \{\mathbf{f}_1, \dots, \mathbf{f}_m\}$ 是 V 和 W 上的一组基。则意味着

对于 $i \in [n]$, $j \in [m]$, 存在 $a_{ij} \in \mathbb{R}$ 使得:

$$T(\mathbf{v}_1) = a_{11}\mathbf{w}_1 + \cdots + a_{1m}\mathbf{w}_m$$

$$T(\mathbf{v}_2) = a_{21}\mathbf{w}_1 + \cdots + a_{2m}\mathbf{w}_m$$

$$\vdots$$

$$T(\mathbf{v}_n) = a_{n1}\mathbf{w}_1 + \cdots + a_{nm}\mathbf{w}_m$$

则称下列矩阵:

$$A_T = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1m} \\ a_{21} & a_{22} & \cdots & a_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nm} \end{bmatrix}$$

为线性变换 T 在基 $\bar{\mathbf{e}}$ 和 $\bar{\mathbf{f}}$ 下的矩阵。特别的, 当 $V = W$ 时并且 $\bar{\mathbf{e}} = \bar{\mathbf{f}}$ 时, 称 A_T 是基 $\bar{\mathbf{e}}$ 下线性变换 T 对应的矩阵。

下列定理给出了线性变换在不同基下的矩阵与相应坐标之间的联系:

定理 2.12

令 $\mathbf{v} \in V$ 和 $\mathbf{w} \in W$ 。若 $\mathbf{x} \in \mathbb{R}^n$ 是 $\mathbf{v}$ 在基 $\bar{\mathbf{v}}$ 下的坐标, $\mathbf{y} \in \mathbb{R}^m$ 是 $T(\mathbf{v})$ 在基 $\bar{\mathbf{w}}$ 下的坐标, 则我们有:

$$T(\mathbf{v}) = \mathbf{w} \iff \mathbf{y} = A_T \mathbf{x}$$

例 2.13

我们这里通过一个 $\mathbb{R}^2$ 上的例子来简单介绍一下, 考虑如下的两组基:

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \text{ 和 } \mathbf{f}_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}, \mathbf{f}_2 = \begin{bmatrix} 0 \\ 3 \end{bmatrix}$$

我们分别用 $\bar{\mathbf{e}}$ 和 $\bar{\mathbf{f}}$ 来表示这两组基, 则 $\bar{\mathbf{e}}$ 到 $\bar{\mathbf{f}}$ 的过渡矩阵 M 满足:

$$\begin{bmatrix} \mathbf{f}_1 & \mathbf{f}_2 \end{bmatrix} = \begin{bmatrix} \mathbf{e}_1 & \mathbf{e}_2 \end{bmatrix} M \implies \begin{bmatrix} 1 & 0 \\ -1 & 3 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} M$$

从而该过渡矩阵 M 为:

$$M = \left(\begin{bmatrix} 1 & 0 \\ 1 & 1 \end{bmatrix} \right)^{-1} \begin{bmatrix} 1 & 0 \\ -1 & 3 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ -2 & 3 \end{bmatrix}$$

注意到对于 $\begin{bmatrix} 5 \\ 6 \end{bmatrix}$ 有:

$$\begin{bmatrix} 5 \\ 6 \end{bmatrix} = 5\mathbf{e}_1 + \mathbf{e}_2 = 5\mathbf{f}_1 + \frac{11}{3}\mathbf{f}_2$$

即其在基 $\bar{\mathbf{e}}$ 下的坐标为 $(5, 1)$ ，在基 $\bar{\mathbf{f}}$ 下的坐标为 $(5, \frac{11}{3})$ ，并且有：

$$\begin{bmatrix} 5 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ -2 & 3 \end{bmatrix} \begin{bmatrix} 5 \\ \frac{11}{3} \end{bmatrix}$$

再考虑如下 $\mathbb{R}^2$ 上的线性变换 T ：

$$T\mathbf{e}_1 = 2\mathbf{e}_1, T\mathbf{e}_2 = 3\mathbf{e}_2$$

则 T 在 $\bar{\mathbf{e}}$ 上对应的矩阵为：

$$A_T = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$$

另一方面，注意到：

$$T\mathbf{f}_1 = T(\mathbf{e}_1 - 2\mathbf{e}_2) = T\mathbf{e}_1 - 2T\mathbf{e}_2 = 2\mathbf{e}_1 - 6\mathbf{e}_2 = \begin{bmatrix} 2 \\ -4 \end{bmatrix} = 2\mathbf{f}_1 - \frac{2}{3}\mathbf{f}_2$$

$$T\mathbf{f}_2 = T(3\mathbf{e}_2) = 3T\mathbf{e}_2 = 9\mathbf{e}_2 = \begin{bmatrix} 0 \\ 9 \end{bmatrix} = 3\mathbf{f}_2$$

从而 T 在 $\bar{\mathbf{f}}$ 上对应的矩阵为：

$$A'_T = \begin{bmatrix} 2 & 0 \\ -\frac{2}{3} & 3 \end{bmatrix}$$

现在回到相似矩阵，考察如下两个矩阵：

$$Q = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}, Q' = \begin{bmatrix} 1 & 1 \\ 1 & 0 \end{bmatrix} \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 0 & 1 \\ 1 & -1 \end{bmatrix} = \begin{bmatrix} 3 & -1 \\ 0 & 2 \end{bmatrix}$$

由定义 Q 和 Q' 是相似的，考虑如下两组基：

$$\mathbf{e}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \mathbf{e}_2 = \begin{bmatrix} 0 \\ 1 \end{bmatrix} \text{ 和 } \mathbf{f}_1 = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \mathbf{f}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

给定 $\mathbf{u} = (5, 4) = 5\mathbf{e}_1 + 4\mathbf{e}_2 = 9\mathbf{f}_1 + 5\mathbf{f}_2$ ，则有：

$$Q \begin{bmatrix} 5 \\ 4 \end{bmatrix} = \begin{bmatrix} 10 \\ 12 \end{bmatrix}, Q' \begin{bmatrix} 9 \\ 5 \end{bmatrix} = \begin{bmatrix} 22 \\ 10 \end{bmatrix}$$

从而我们有：

$$\begin{bmatrix} \mathbf{e}_1 & \mathbf{e}_2 \end{bmatrix} \begin{bmatrix} 10 \\ 12 \end{bmatrix} = 10\mathbf{e}_1 + 12\mathbf{e}_2 = \begin{bmatrix} 10 \\ 12 \end{bmatrix} = 22\mathbf{f}_1 + 10\mathbf{f}_2 = \begin{bmatrix} \mathbf{f}_1 & \mathbf{f}_2 \end{bmatrix} \begin{bmatrix} 22 \\ 10 \end{bmatrix}$$

这说明，当 Q 和 Q' 分别代表了在 $\mathbf{e}_1, \mathbf{e}_2$ 和 $\mathbf{f}_1, \mathbf{f}_2$ 这两组基下的线性变换的时候，其实表示的是同一个线性变换，即：两个相似矩阵本质上是在不同基下的相同线性变换！我们将其表述为如下的定理：

定理 2.14

令 V 是一个 n 维的向量空间, $\bar{v}$ 和 $\bar{v}'$ 是 V 的两组基。考虑 $V \rightarrow V$ 的一个线性变换 T , 令:

- M 是 $\bar{v}$ 到 $\bar{v}'$ 的过渡矩阵。
- A 是在基 $\bar{v}$ 下 T 对应的矩阵。
- B 是在基 $\bar{v}'$ 下 T 对应的矩阵。

则有:

$$B = M^{-1}AM.$$

即同一个线性变换在不同基下表示的矩阵是相似的。

例 2.15

在例2.13中, 我们有:

$$\begin{bmatrix} 2 & 0 \\ -\frac{2}{3} & 3 \end{bmatrix} = \left(\begin{bmatrix} 1 & 0 \\ -2 & 3 \end{bmatrix} \right)^{-1} \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix} \begin{bmatrix} 1 & 0 \\ -2 & 3 \end{bmatrix},$$

即: $A'_T = M^{-1}A_TM$ 。

3 特征空间、代数重数以及几何重数

定理2.4 告诉我们:

矩阵 A 可对角化当且仅当存在 n 个线性无关的特征向量。

定理1.6 则给出了计算特征值的一个方式, 通过求解特征多项式的根。直观上来讲, 这两种理解思路其实是分别从几何和代数的角度来看的:

1. n 个线性无关的特征向量是一个几何的视角。
2. 特征多项式的根则是代数的视角。

这一节我们尝试从这两个视角进一步讨论对角化的充分必要条件。

几何视角: 让我们回到特征向量。事实上, 给定一个 $n \times n$ 的矩阵 A 和其一个特征值 $\lambda \in \mathbb{C}$, 若 x_1, x_2 是其特征向量, 则我们有:

$$A(x_1 + x_2) = Ax_1 + Ax_2 = \lambda x_1 + \lambda x_2 = \lambda(x_1 + x_2)$$

$$A(cx_1) = cAx_1 = c\lambda x_1 = \lambda(cx_1)$$

即其特征向量组成的空间是一个向量空间, 我们称为**特征空间**。

定义 3.1 (特征空间 (Eigenspace))

给定一个 $n \times n$ 的矩阵 A 和其一个特征值 $\lambda \in \mathbb{C}$, 定义:

$$V_\lambda = \{\mathbf{x} \in \mathbb{C}^n \mid A\mathbf{x} = \lambda\mathbf{x}\}$$

为 A 的特征值 λ 对应的特征空间。

引理 3.2

V_λ 是 $\mathbb{C}^n$ 的一个子空间, 并且 $\dim(V_\lambda) \geq 1$ 。

例 3.3

考察旋转矩阵:

$$A = \begin{bmatrix} 0 & -1 \\ 1 & 0 \end{bmatrix}$$

我们有:

$$\det(A - \lambda I) = \lambda^2 + 1 \implies \lambda = \pm i$$

从而我们有:

$$\lambda = i \implies V_i = \{\mathbf{x} \in \mathbb{C}^n \mid A\mathbf{x} = i\mathbf{x}\} = \text{span} \left\{ \begin{bmatrix} 1 \\ i \end{bmatrix} \right\}$$

$$\lambda = -i \implies V_{-i} = \{\mathbf{x} \in \mathbb{C}^n \mid A\mathbf{x} = -i\mathbf{x}\} = \text{span} \left\{ \begin{bmatrix} 1 \\ -i \end{bmatrix} \right\}$$

从而, 我们将特征空间的维度定义成该特征值的几何特征, 称为 colored 几何重数:

定义 3.4 (几何重数 (Geometric Multiplicity))

给定一个 $n \times n$ 的矩阵 A 和其一个特征值 $\lambda \in \mathbb{C}$, λ 的几何重数是其特征空间 V_λ 的维数, 即:

$$\begin{aligned} \dim(V_\lambda) &= \dim(\{\mathbf{x} \in \mathbb{C}^n \mid A\mathbf{x} = \lambda\mathbf{x}\}) \\ &= \dim(\{\mathbf{x} \in \mathbb{C}^n \mid (A - \lambda I)\mathbf{x} = \mathbf{0}\}) \\ &= \dim(\text{null}(A - \lambda I)) = n - \text{rank}(A - \lambda I) \end{aligned}$$

例 3.5

在例子3.3中, 我们有 $\dim(V_i) = \dim(V_{-i}) = 1$, 即 i 和 $-i$ 的几何重数为 1。

代数视角: 代数视角考虑的则是特征多项式的重根数量。考虑 A 的特征多项式:

$$f_A(\lambda) = \det(A - \lambda I) = \prod_{i=1}^n (\lambda - \lambda_i) = \prod_{i=1}^k (\lambda - \lambda_i)^{m_i} (m_1 + m_2 + \cdots + m_k = n)$$

我们将 m_i 称为 λ_i 的代数重数:

定义 3.6 (代数重数 (Algebraic Multiplicity))

给定一个 $n \times n$ 的矩阵 A 和其一个特征值 $\lambda \in \mathbb{C}$, λ 的代数重数是其特征多项式中 $(\lambda - \lambda_i)$ 的幂次 m_i , 即:

$$m_i = \max\{m \mid (\lambda - \lambda_i)^m \text{ 是 } f_A(\lambda) \text{ 的因子}\}$$

例 3.7

在例子3.3中, 我们有 $f_A(\lambda) = (\lambda + i)(\lambda - i)$, 即 i 和 $-i$ 的代数重数为 1。

可以见到, 在例子3.3 中, 代数重数和几何重数是相等的, 但事实上这并不一定成立。考察如下矩阵:

$$A = \begin{bmatrix} -1 & 1 & 0 \\ -4 & 3 & 0 \\ 1 & 0 & 2 \end{bmatrix}$$

1. 其特征多项式为:

$$\begin{aligned} \det(A - \lambda I) &= \begin{vmatrix} -1-\lambda & 1 & 0 \\ -4 & 3-\lambda & 0 \\ 1 & 0 & 2-\lambda \end{vmatrix} \\ &= (-1-\lambda) \begin{vmatrix} 3-\lambda & 0 \\ 0 & 2-\lambda \end{vmatrix} - 1 \begin{vmatrix} -4 & 0 \\ 1 & 2-\lambda \end{vmatrix} \\ &= (-1-\lambda)(3-\lambda)(2-\lambda) + 4(2-\lambda) \\ &= (1-\lambda)^2(2-\lambda) \end{aligned}$$

从而其特征值为 $\lambda = 1, 2$, 代数重数分别为 2, 1。

2. 现在来考察对应的特征空间:

$\lambda = 2$: 考察 $A - 2I$:

$$A - 2I = \begin{bmatrix} -3 & 1 & 0 \\ -4 & 1 & 0 \\ 1 & 0 & 0 \end{bmatrix}$$

不难验证 $\text{rank}(A - 2I) = 2$, 从而 $\dim(V_2) = n - \text{rank}(A - 2I) = 1$, 即 2 的几何重数为 1, 更精确的说:

$$V_2 = \{\mathbf{x} \in \mathbb{C}^n \mid A\mathbf{x} = 2\mathbf{x}\} = \left\{ c \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \mid c \in \mathbb{C} \right\} = \text{span} \left\{ \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \right\}$$

$\lambda = 1$: 考察 $A - I$:

$$A - I = \begin{bmatrix} -2 & 1 & 0 \\ -4 & 2 & 0 \\ 1 & 0 & 1 \end{bmatrix}$$

不难验证 $\text{rank}(A - I) = 2$, 从而 $\dim(V_1) = n - \text{rank}(A - I) = 1$, 即 1 的几何重数为 1, 更精确的说:

$$V_1 = \{\mathbf{x} \in \mathbb{C}^n \mid A\mathbf{x} = \mathbf{x}\} = \left\{ c \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \mid c \in \mathbb{C} \right\} = \text{span} \left\{ \begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix} \right\}$$

很显然, 其几何重数 $\neq$ 代数重数。事实上, 我们有:

定理 3.8

特征值的代数重数大于等于其几何重数。

在正式开始证明定理 3.8 之前, 我们先叙述一下证明定理的直观; 如果 $\dim(V_\lambda) = i$, 意味着可以从 V_λ 中找出 i 个线性无关的特征向量 $\mathbf{x}_1, \dots, \mathbf{x}_i$, 使得:

$$A \begin{bmatrix} \mathbf{x}_1 & \dots & \mathbf{x}_i \end{bmatrix} = \begin{bmatrix} \lambda \mathbf{x}_1 & \dots & \lambda \mathbf{x}_i \end{bmatrix} = \begin{bmatrix} \mathbf{x}_1 & \dots & \mathbf{x}_i \end{bmatrix} \begin{bmatrix} \lambda & & \\ & \ddots & \\ & & \lambda \end{bmatrix}$$

从而我们可以将 A 转化成如下的形式:

$$A = P \begin{bmatrix} \lambda I_i & B \\ O & C \end{bmatrix} P^{-1}.$$

而矩阵 $\begin{bmatrix} \lambda I_i & B \\ O & C \end{bmatrix}$ 的关于 λ 的代数重数一定是大于等于 i 的。为了完成全部的证明, 我们还需要如下的引理, 即相似矩阵的特征值不仅相同, 其代数重数也是相等的:

引理 3.9

令 A 和 B 是相似矩阵, 即存在可逆矩阵 P 使得 $B = P^{-1}AP$, 则我们有:

$$\det(A - \lambda I) = \det(B - \lambda I).$$

即两个相似矩阵不仅有相同的特征值, 而且其代数重数也相等。

证明: 由于 $B = P^{-1}AP$, 我们有:

$$\begin{aligned} \det(B - \lambda I) &= \det(A - \lambda I) \\ &= \det(P^{-1}AP - P^{-1}(\lambda I)P) \\ &= \det(P^{-1}(A - \lambda I)P) \\ &= \det(P^{-1}) \det(A - \lambda I) \det(P) \\ &= \det(A - \lambda I) \end{aligned}$$

现在可以进行定理3.8的证明了。

证明: [定理3.8的证明] 令 A 是一个 $n \times n$ 的矩阵, λ_0 是其一个特征值, 考虑其特征空间:

$$V_{\lambda_0} = \{x \in \mathbb{C}^n \mid Ax = \lambda_0 x\}$$

令其的一组基为 $v_1, \dots, v_m$, 则 m 就是 λ_0 的几何重数。特别的, 我们有:

$$\begin{aligned} A \begin{bmatrix} v_1 & \cdots & v_m \end{bmatrix} &= \begin{bmatrix} \lambda_0 v_1 & \cdots & \lambda_0 v_m \end{bmatrix} \\ &= \begin{bmatrix} v_1 & \cdots & v_m \end{bmatrix} \begin{bmatrix} \lambda_0 & & \\ & \ddots & \\ & & \lambda_0 \end{bmatrix}. \end{aligned}$$

这里 $\begin{bmatrix} \lambda_0 & & \\ & \ddots & \\ & & \lambda_0 \end{bmatrix} = \lambda_0 I_m$ 是一个 $m \times m$ 的矩阵。将 $v_1, \dots, v_m$ 扩展成 $\mathbb{C}^n$ 的一组基, 即:

$$v_1, \dots, v_m, v_{m+1}, \dots, v_n.$$

从而我们有:

$$\begin{aligned} A \begin{bmatrix} v_1 & \cdots & v_m & v_{m+1} & \cdots & v_n \end{bmatrix} &= \begin{bmatrix} \lambda_0 v_1 & \cdots & \lambda_0 v_m & Av_{m+1} & \cdots & Av_n \end{bmatrix} \\ &= \begin{bmatrix} v_1 & \cdots & v_m & v_{m+1} & \cdots & v_n \end{bmatrix} \begin{bmatrix} \lambda_0 I_m & B \\ O & C \end{bmatrix}. \end{aligned}$$

这里 B 是一个 $m \times (n-m)$ 的矩阵, C 是一个 $(n-m) \times (n-m)$ 的矩阵。令 $P = \begin{bmatrix} v_1 & \cdots & v_m & v_{m+1} & \cdots & v_n \end{bmatrix}$, 则 P 是可逆矩阵, 从而我们有:

$$A = P \begin{bmatrix} \lambda_0 I_m & B \\ O & C \end{bmatrix} P^{-1}.$$

从而我们有

$$\det(A - \lambda I) = \det \left(\begin{bmatrix} \lambda_0 I_m & B \\ O & C \end{bmatrix} - \lambda I \right) = \begin{vmatrix} (\lambda_0 - \lambda) I_m & B \\ O & C - \lambda I_{n-m} \end{vmatrix}.$$

不难验证:

$$\det(A - \lambda I) = (\lambda_0 - \lambda)^m g(\lambda).$$

这里 $g(\lambda)$ 是一个 $n - m$ 次的多项式, 从而 λ_0 的代数重数至少为 m , 即:

$$\lambda_0 \text{ 的代数重数} \geq \lambda_0 \text{ 的几何重数}.$$

注意到, 特征值的几何重数实际上对应了线性无关向量的个数, 从而我们有:

定理 3.10

$n \times n$ 的矩阵可对角化当且仅当其每个特征值的代数重数等于几何重数。

这也是可对角化的另一充要条件描述。

线性代数 (XIII)

Lecturer: 杨启哲

Last modified: 2026 年 5 月 22 日

1 对称矩阵

一个方阵是**对称 (Symmetric)**的, 如果其满足:

$$A = A^T$$

下列矩阵很显然都是对称的:

$$\begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix}, \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix},$$

考虑将其对角化, 我们有:

$$\begin{aligned} \begin{bmatrix} 1 & 2 \\ 2 & 4 \end{bmatrix} &= X_1 \Lambda_1 X_1^{-1} = \begin{bmatrix} -\frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 0 & 5 \end{bmatrix} \begin{bmatrix} -\frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} \\ \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{5}} \end{bmatrix} \\ \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix} &= X_2 \Lambda_2 X_2^{-1} = \begin{bmatrix} \frac{1}{\sqrt{6}} & -\frac{2}{\sqrt{5}} & \frac{1}{\sqrt{30}} \\ \frac{2}{\sqrt{6}} & \frac{1}{\sqrt{5}} & \frac{2}{\sqrt{30}} \\ \frac{1}{\sqrt{6}} & 0 & -\frac{5}{\sqrt{30}} \end{bmatrix} \begin{bmatrix} 6 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{2}{\sqrt{6}} & \frac{1}{\sqrt{6}} \\ -\frac{2}{\sqrt{5}} & \frac{1}{\sqrt{5}} & 0 \\ \frac{1}{\sqrt{30}} & \frac{2}{\sqrt{30}} & -\frac{5}{\sqrt{30}} \end{bmatrix} \end{aligned}$$

仔细观察可以发现, 其对应的特征矩阵 X 是正交的, 即:

$$X_i^{-1} = X_i^T \quad (i = 1, 2)$$

在本节中我们将证明, 这并不是巧合, 而是对称矩阵的一个重要性质。事实上我们将说明:

1. 实对称矩阵的特征值都是实数。
2. 实对称矩阵不同特征值的特征向量是正交的, 且其一定可以对角化。

实对称矩阵的特征值 我们将证明如下定理:

定理 1.1

实对称矩阵 S 的特征值是实数, 特别的, 其每个特征值都有一个对应的实特征向量。

为了完成这个定理的证明, 我们需要使用一些复数上的知识: 令 $x \in \mathbb{C}$, 则我们有存在 $a, b \in \mathbb{R}$, 使得:

$$x = a + bi$$

我们定义 x 的共轭复数 (complex conjugate) 为:

$$\bar{x} = a - bi$$

共轭复数有如下的性质:

引理 1.2

给定复数 $x, y \in \mathbb{C}$, 我们有:

1. 如果 $\bar{x}x = 0$, 则 $x = 0$.
2. $\overline{\bar{x} + \bar{y}} = x + y$.
3. $\overline{xy} = \bar{x}\bar{y}$.

由共轭复数可以定义在复矩阵中的共轭矩阵:

定义 1.3 (共轭矩阵 (Conjugate Matrix))

对于一个矩阵 A , 我们定义其共轭矩阵 $\bar{A}$ 为:

$$\bar{A}(i, j) = \overline{A(i, j)}.$$

为了证明定理1.1, 还需要共轭矩阵上的如下性质:

引理 1.4

令 $A \in \mathbb{C}^{m \times n}$ 是一个 $m \times n$ 的复矩阵, $x \in \mathbb{C}^n$ 是任一复向量, 则:

1. 如果 $\bar{x}^T x = 0$, 则 $x = 0$.
2. 对任意的 $\lambda \in \mathbb{C}$, 我们有: $\overline{\lambda A} = \bar{\lambda} \bar{A}$.
3. $\overline{\bar{A}x} = A\bar{x}$.

现在可以给出定理1.1的证明了。

证明: [定理1.1的证明] 令 S 是 $n \times n$ 的实对称矩阵, $\lambda \in \mathbb{C}$ 是 S 的特征值, $x \in \mathbb{C}^n \setminus \{0\}$ 是 λ 对应的特征向量, 则:

$$\begin{aligned} Sx &= \lambda x \\ \implies \bar{S}x &= \bar{\lambda}x \\ \implies \bar{x}^T \bar{S}^T &= \bar{\lambda}x^T \\ \implies \bar{x}^T S &= \bar{\lambda}x^T \quad (S \text{ 是实对称的, 从而 } \bar{S}^T = S) \\ \implies \bar{x}^T Sx &= \bar{\lambda}x^T x \\ \implies \lambda \bar{x}^T x &= \bar{\lambda}x^T x \\ \implies (\lambda - \bar{\lambda})\bar{x}^T x &= 0 \end{aligned}$$

显然由于 $x \neq 0$, 从而 $\bar{x}^T x \neq 0$, 因此 $\lambda - \bar{\lambda} = 0$, 即 λ 是实数。

下证每个特征值都有一个对应的实特征向量。假设 $\mathbf{x}_j = \mathbf{a}_j + \mathbf{b}_j \mathbf{i}$ ，即：

$$\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1 + \mathbf{b}_1 \mathbf{i} \\ \vdots \\ \mathbf{a}_n + \mathbf{b}_n \mathbf{i} \end{bmatrix} = \begin{bmatrix} \mathbf{a}_1 \\ \vdots \\ \mathbf{a}_n \end{bmatrix} + \mathbf{i} \begin{bmatrix} \mathbf{b}_1 \\ \vdots \\ \mathbf{b}_n \end{bmatrix} = \mathbf{a} + \mathbf{i} \mathbf{b}$$

由于 $S\mathbf{x} = \lambda\mathbf{x}$ ，我们有：

$$S\mathbf{x} = S(\mathbf{a} + \mathbf{i} \mathbf{b}) = \lambda(\mathbf{a} + \mathbf{i} \mathbf{b})$$

由于 S 是实对称矩阵， λ 是实数，我们有：

$$S\mathbf{a} = \lambda\mathbf{a}, S\mathbf{b} = \lambda\mathbf{b}$$

由于 $\mathbf{x} \neq \mathbf{0}$ ， $\mathbf{a}$ 和 $\mathbf{b}$ 至少有一个是 S 的特征向量。 □

实对称矩阵的对角化 现在来考察其特征向量，下述定理阐明了不同特征值对应的特征向量不仅是线性无关的，更是正交的：

定理 1.5

对于一个实对称矩阵 S ，如果 λ_1 和 λ_2 是 S 的两个不同的特征值， $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 是 λ_1 和 λ_2 对应的特征向量，则 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 是正交的。

证明：由假设有：

$$S\mathbf{x}_1 = \lambda_1\mathbf{x}_1, S\mathbf{x}_2 = \lambda_2\mathbf{x}_2$$

从而：

$$\begin{aligned} \lambda_1(\mathbf{x}_1 \cdot \mathbf{x}_2) &= (\lambda_1\mathbf{x}_1) \cdot \mathbf{x}_2 = (S\mathbf{x}_1) \cdot \mathbf{x}_2 = (S\mathbf{x}_1)^T \mathbf{x}_2 = \mathbf{x}_1^T S^T \mathbf{x}_2 \\ &= \mathbf{x}_1^T S \mathbf{x}_2 = \mathbf{x}_1^T (S\mathbf{x}_2) = \mathbf{x}_1^T (\lambda_2\mathbf{x}_2) = \mathbf{x}_1 \cdot (\lambda_2\mathbf{x}_2) = \lambda_2(\mathbf{x}_1 \cdot \mathbf{x}_2) \end{aligned}$$

由于 $\lambda_1 \neq \lambda_2$ ，从而 $\mathbf{x}_1 \cdot \mathbf{x}_2 = 0$ ，即 $\mathbf{x}_1$ 和 $\mathbf{x}_2$ 是正交的。 □

定理1.5可以直接推出如下结论：

推论 1.6

令 S 是一个 $n \times n$ 的实对称矩阵，如果 S 存在 n 个两两不同的特征值，则 S 可以对角化。更精确的说，存在一个正交矩阵 Q 和对角矩阵 Λ 使得：

$$\Lambda = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{bmatrix} = Q^T S Q$$

这里 $\lambda_1, \dots, \lambda_n$ 都是 S 的特征值。

证明：令 S 的特征值为 $\lambda_1, \dots, \lambda_n$ ，由定理1.1和定理1.5， S 存在如下的 n 个特征向量 $\mathbf{q}_1, \dots, \mathbf{q}_n$ ，满足：

1. 对每个 $i = 1, \dots, n$, $Sq_i = \lambda_i q_i$.
2. 对于任意的 $i \neq j$, q_i 和 q_j 是正交的, 即 $q_i \cdot q_j = 0$.
3. q_i 的模长为 1, 即 $\|q_i\| = 1$.

令 $Q = [q_1 \ q_2 \ \dots \ q_n]$, 则 Q 是一个正交矩阵, 从而:

$$Q^T S Q = Q^T S [q_1 \ q_2 \ \dots \ q_n] = \begin{bmatrix} q_1^T \\ q_2^T \\ \vdots \\ q_n^T \end{bmatrix} \begin{bmatrix} \lambda_1 q_1 & \lambda_2 q_2 & \dots & \lambda_n q_n \end{bmatrix} = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{bmatrix}.$$

□

事实上, 我们并不需要“ n 个两两不同的特征值”这个条件。

定理 1.7

令 S 是一个 $n \times n$ 的实矩阵, 则 S 是对称的当且仅当存在一个正交矩阵 Q 和对角矩阵 Λ 使得:

$$\Lambda = \begin{bmatrix} \lambda_1 & & & \\ & \lambda_2 & & \\ & & \ddots & \\ & & & \lambda_n \end{bmatrix} = Q^T S Q$$

这里 $\lambda_1, \dots, \lambda_n$ 都是 S 的特征值。

证明: ($\Leftarrow$) 的方向是显然的, 注意到:

$$S^T = (Q \Lambda Q^T)^T = Q \Lambda Q^T = S$$

下证 ($\Rightarrow$) 方向。令 S 是一个 $n \times n$ 的实对称矩阵, 我们对 n 作归纳。

BASE: $n = 1$ 时是显然的。

INDUCTION: 现在令 $n \geq 2$ 。令 S 的一个特征值为 $\lambda_1 \in \mathbb{R}$, 其对应的一个特征向量为 $x_1 \in \mathbb{R}^n \setminus \{0\}$ 。我们不妨可以假设 $\|x_1\| = 1$, 否则我们可以令:

$$x_1 \leftarrow \frac{x_1}{\|x_1\|}$$

通过 Gram-Schmidt 正交化, 我们可以从 x_1 扩展出一组标准正交基:

$$x_1, x_2, \dots, x_n$$

满足:

$$x_i \cdot x_j = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

定义矩阵 P :

$$P = \begin{bmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_n \end{bmatrix}$$

不难验证 P 是正交矩阵, 即 $P^T P = I$ 。并且我们有:

$$p^T \mathbf{x}_i = \mathbf{e}_i$$

从而:

$$\begin{aligned} P^T S P &= P^T S \begin{bmatrix} \mathbf{x}_1 & \mathbf{x}_2 & \cdots & \mathbf{x}_n \end{bmatrix} \\ &= \begin{bmatrix} P^T S \mathbf{x}_1 & P^T S \mathbf{x}_2 & \cdots & P^T S \mathbf{x}_n \end{bmatrix} \\ &= \begin{bmatrix} P^T \lambda_1 \mathbf{x}_1 & P^T S \mathbf{x}_2 & \cdots & P^T S \mathbf{x}_n \end{bmatrix} \\ &= \begin{bmatrix} \lambda_1 P^T \mathbf{x}_1 & P^T S \mathbf{x}_2 & \cdots & P^T S \mathbf{x}_n \end{bmatrix} \\ &= \begin{bmatrix} \lambda_1 \mathbf{e}_1 & P^T S \mathbf{x}_2 & \cdots & P^T S \mathbf{x}_n \end{bmatrix} = \begin{bmatrix} \lambda_1 & \mathbf{a}^T \\ \mathbf{0} & B \end{bmatrix} \end{aligned}$$

这里 $\mathbf{a} \in \mathbb{R}^{n-1}$ 是一个列向量, B 是一个 $(n-1) \times (n-1)$ 的矩阵。注意到:

$$\begin{bmatrix} \lambda_1 & \mathbf{0}^T \\ \mathbf{a} & B^T \end{bmatrix} = \left(\begin{bmatrix} \lambda_1 & \mathbf{a}^T \\ \mathbf{0} & B \end{bmatrix} \right)^T = (P^T S P)^T = P^T S^T P = P^T S P = \begin{bmatrix} \lambda_1 & \mathbf{a}^T \\ \mathbf{0} & B \end{bmatrix}$$

从而我们有 $\mathbf{a} = \mathbf{0}$, 并且 $B = B^T$ 。从而 B 是一个 $(n-1) \times (n-1)$ 实对称矩阵。由归纳假设, 我们可以对 B 进行对角化, 即存在 $(n-1) \times (n-1)$ 的正交矩阵 P' 和对角矩阵 Λ' 使得:

$$\Lambda' = (P')^T B P'$$

从而我们有:

$$P^T S P = \begin{bmatrix} \lambda_1 & \mathbf{0}^T \\ \mathbf{0} & B \end{bmatrix} = \begin{bmatrix} \lambda_1 & \mathbf{0}^T \\ \mathbf{0} & (P')^T B P' \end{bmatrix} = \begin{bmatrix} 1 & \mathbf{0}^T \\ \mathbf{0} & P' \end{bmatrix} \begin{bmatrix} \lambda_1 & \mathbf{0}^T \\ \mathbf{0} & \Lambda' \end{bmatrix} \begin{bmatrix} 1 & \mathbf{0} \\ \mathbf{0} & (P')^T \end{bmatrix}$$

令

$$M = \begin{bmatrix} 1 & \mathbf{0}^T \\ \mathbf{0} & P' \end{bmatrix}$$

显然 M 是一个正交矩阵, 并且我们有:

$$(PM)^T S PM = M^T P^T S PM = \begin{bmatrix} \lambda_1 & \mathbf{0}^T \\ \mathbf{0} & \Lambda' \end{bmatrix}$$

从而令 $Q = PM, \Lambda = \begin{bmatrix} \lambda_1 & \mathbf{0}^T \\ \mathbf{0} & \Lambda' \end{bmatrix}$, 我们有:

$$\Lambda = Q^T S Q$$

并且有归纳假设, Λ 上对角线的元素都是 S 的特征值。 □

实对称矩阵的谱分解 这一节的最后再进一步思考下实对称矩阵 S 的对角化，由定理1.7存在正交矩阵 Q 和对角矩阵 Λ 使得：

$$S = Q\Lambda Q^T$$

令 $Q = [\mathbf{q}_1 \quad \mathbf{q}_2 \quad \cdots \quad \mathbf{q}_n]$, $\Lambda = \begin{bmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_n \end{bmatrix}$, 我们有：

$$S = [\mathbf{q}_1 \quad \mathbf{q}_2 \quad \cdots \quad \mathbf{q}_n] \begin{bmatrix} \lambda_1 & & \\ & \lambda_2 & \\ & & \ddots \\ & & & \lambda_n \end{bmatrix} \begin{bmatrix} \mathbf{q}_1^T \\ \mathbf{q}_2^T \\ \vdots \\ \mathbf{q}_n^T \end{bmatrix} = \lambda_1 \mathbf{q}_1 \mathbf{q}_1^T + \lambda_2 \mathbf{q}_2 \mathbf{q}_2^T + \cdots + \lambda_n \mathbf{q}_n \mathbf{q}_n^T$$

即：实对称矩阵的**谱分解 (Spectral Decomposition)**将其分解成了 n 个秩为 1 的矩阵之和。

例 1.8

考察矩阵 $S = \begin{bmatrix} 1 & 2 & 1 \\ 2 & 4 & 2 \\ 1 & 2 & 1 \end{bmatrix}$, 其特征多项式为：

$$f(\lambda) = \begin{vmatrix} \lambda - 1 & -2 & -1 \\ -2 & \lambda - 4 & -2 \\ -1 & -2 & \lambda - 1 \end{vmatrix} = \lambda^2(\lambda - 6)$$

从而 S 的特征值为 $\lambda_1 = 6, \lambda_2 = 0, \lambda_3 = 0$, 对应的单位特征向量为：

$$\mathbf{q}_1 = \begin{bmatrix} \frac{1}{\sqrt{6}} \\ \frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} \end{bmatrix}, \mathbf{q}_2 = \begin{bmatrix} -\frac{1}{\sqrt{2}} \\ 0 \\ \frac{1}{\sqrt{2}} \end{bmatrix}, \mathbf{q}_3 = \begin{bmatrix} 0 \\ -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{bmatrix}$$

由定理1.7, 我们有：

$$S = \lambda_1 \mathbf{q}_1 \mathbf{q}_1^T + \lambda_2 \mathbf{q}_2 \mathbf{q}_2^T + \lambda_3 \mathbf{q}_3 \mathbf{q}_3^T = 6 \begin{bmatrix} \frac{1}{\sqrt{6}} \\ \frac{2}{\sqrt{6}} \\ \frac{1}{\sqrt{6}} \end{bmatrix} \begin{bmatrix} \frac{1}{\sqrt{6}} & \frac{2}{\sqrt{6}} & \frac{1}{\sqrt{6}} \end{bmatrix}$$

这意味着一个 $n \times n$ 的实对称矩阵可以用 n 个特征值和对应的 n 个正交的特征向量来表示。这也是**奇异值分解 (SVD)** 的一个特例。

2 正定矩阵

这一节讨论的是所有特征值都大于 0 的矩阵。我们给出如下的定义：

定义 2.1 (Positive Definite Matrix)

一个对称矩阵 S 被称为是正定矩阵, 如果其所有的特征值 λ 都满足 $\lambda > 0$ 。

如下的矩阵:

$$A = \begin{bmatrix} 1 & 0 \\ 0 & 4 \end{bmatrix}, B = \begin{bmatrix} 4 & 3 \\ 3 & 4 \end{bmatrix}, C = \begin{bmatrix} 4 & 3 & 0 \\ 3 & 4 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

1. A 的特征值为 $\lambda_1 = 1, \lambda_2 = 4$.
2. B 的特征值为 $\lambda_1 = 7, \lambda_2 = 1$.
3. C 的特征值为 $\lambda_1 = 7, \lambda_2 = 1, \lambda_3 = 2$.

从而 A, B, C 都是正定矩阵。

下述定理给出了正定矩阵的另一个重要刻画:

定理 2.2

令 S 是一个实对称矩阵, 则 S 是正定的, 当且仅当对于所有的 $\mathbf{x} \in \mathbb{R}^n \setminus \{0\}$, 都有:

$$\mathbf{x}^T S \mathbf{x} > 0.$$

二次型 在证明定理2.2之前, 我们先搞清楚 $\mathbf{x}^T S \mathbf{x}$ 是什么。令 $\mathbf{x} = (x_1, \dots, x_n)$, $S = \begin{bmatrix} s_{11} & \cdots & s_{1n} \\ \vdots & \ddots & \vdots \\ s_{n1} & \cdots & s_{nn} \end{bmatrix}$,

则我们有:

$$\mathbf{x}^T S \mathbf{x} = s_{11}x_1^2 + \cdots + s_{nn}x_n^2 + 2 \sum_{1 \leq i < j \leq n} s_{ij}x_i x_j,$$

即 $\mathbf{x}^T A \mathbf{x}$ 是关于 $x_1, \dots, x_n$ 的一个二次齐次函数, 我们称其为**二次型 (Quadratic Forms)**:

定义 2.3 (Quadratic Forms)

含有 n 个变量 $x_1, \dots, x_n$ 的二次齐次函数

$$f(x_1, \dots, x_n) = s_{11}x_1^2 + \cdots + s_{nn}x_n^2 + \sum_{1 \leq i < j \leq n} a_{ij}x_i x_j$$

被称作二次型 (Quadratic Forms), 特别的, 令 $a_{ij} = 2s_{ij} = 2s_{ji}$, 则上述式子中的每一项 $a_{ij}x_i x_j$ 可以被改写为:

$$a_{ij}x_i x_j = s_{ij}x_i x_j + s_{ji}x_i x_j$$

再令 $S = \begin{bmatrix} s_{11} & \cdots & s_{1n} \\ \vdots & \ddots & \vdots \\ s_{n1} & \cdots & s_{nn} \end{bmatrix}$, $\mathbf{x} = \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix}$, 从而 f 可以有如下的矩阵表示:

$$f(x_1, \dots, x_n) = \mathbf{x}^T S \mathbf{x}$$

对称矩阵 S 的表达是唯一的，所以称 S 就是 f 的二次型矩阵 (Quadratic Forms Matrix)。

注 2.4

由上述定义可知， $n \times n$ 的对称矩阵和 n 个变量的二次型形成了一一对应的关系，所以我们经常回混用这两个概念，如我们称一个二次型 f 的秩表示的其对应的矩阵 S 的秩。

证明：[定理2.2的证明] 先证 $(\Rightarrow)$ 方向。由于 S 是一个实对称矩阵，从而存在一个正交矩阵 Q 满足：

$$\begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix} = Q^T S Q$$

这里 $\lambda_1, \dots, \lambda_n$ 是 S 的特征值，并且由假设： $\lambda_i > 0$ 。

定义：

$$\mathbf{x} = Q^T \mathbf{y}, \text{ 即: } \mathbf{y} = Q \mathbf{x}$$

从而：

$$\mathbf{x}^T S \mathbf{x} = (Q \mathbf{y})^T S (Q \mathbf{y}) = \mathbf{y}^T Q^T S Q \mathbf{y} = \lambda_1 y_1^2 + \cdots + \lambda_n y_n^2$$

注意到 Q 是可逆的，从而对于任意 $\mathbf{x} \neq \mathbf{0}$ ，我们有 $\mathbf{y} = Q \mathbf{x} \neq \mathbf{0}$ ，即：

$$\mathbf{x}^T S \mathbf{x} = \lambda_1 y_1^2 + \cdots + \lambda_n y_n^2 > 0$$

另一方面，反设存在 $\lambda_i \leq 0$ ，注意到：

$$\mathbf{x}^T S \mathbf{x} = \lambda_1 y_1^2 + \cdots + \lambda_n y_n^2 = \lambda_i y_i^2 + \sum_{j \neq i} \lambda_j y_j^2$$

从而令 $y_i = 1, y_j = 0 (j \neq i)$ ，由矩阵的可逆性我们有 $\mathbf{x} = Q \mathbf{y} \neq \mathbf{0}$ ，即：

$$\mathbf{x}^T S \mathbf{x} = \lambda_i y_i^2 + \sum_{j \neq i} \lambda_j y_j^2 = \lambda_i \leq 0$$

与假设矛盾。 □

定理2.2给出了正定矩阵的一个刻画，对应的二次型恒大于 0，自然也可以将其推广到任意的实矩阵上：

定义 2.5

给定一个 $n \times n$ 的实矩阵 A ，如果对任意向量 $\mathbf{x} \in \mathbb{R}^n \setminus \{\mathbf{0}\}$ ：

1. $\mathbf{x}^T A \mathbf{x} > 0$ ，则称 A 是正定的。
2. $\mathbf{x}^T A \mathbf{x} \geq 0$ ，则称 A 是半正定的。
3. $\mathbf{x}^T A \mathbf{x} < 0$ ，则称 A 是负定的。

4. $\mathbf{x}^T \mathbf{A} \mathbf{x} \leq 0$, 则称 $\mathbf{A}$ 是半负定的。

5. 若不满足以上任何一种条件, 则称矩阵 $\mathbf{A}$ 是不定的。

注 2.6

定义2.5给出了正定矩阵在实矩阵上的一个定义, 但在本课程中, 后续讨论的还是实对称矩阵的正定性, 其原因有二:

1. 如果不加对称这一条件, 矩阵和二次型便没有了一一对应的关系。
2. 对于非对称矩阵来说, 即使其所有的特征值大于 0, 它也不一定是正定的。考虑下列的例子:

$$\begin{bmatrix} 1 & 100 \\ 0 & 2 \end{bmatrix}.$$

不难验证, 其特征值为 1, 2。但是我们有:

$$\begin{bmatrix} -1 & 1 \end{bmatrix} \begin{bmatrix} 1 & 100 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} -1 \\ 1 \end{bmatrix} = 1 + 2 - 100 = -97 < 0.$$

下述定理给出了正定矩阵的一个充分性条件:

定理 2.7

令 $\mathbf{A}$ 是 $m \times n$ 的矩阵, 并且 $\text{rank}(\mathbf{A}) = n$. 则 $\mathbf{S} = \mathbf{A}^T \mathbf{A}$ 是对称且正定的。

证明: 令 $\mathbf{x} \in \mathbb{R}^n$, 则我们有:

$$\mathbf{x}^T \mathbf{S} \mathbf{x} = \mathbf{x}^T \mathbf{A}^T \mathbf{A} \mathbf{x} = (\mathbf{A} \mathbf{x})^T (\mathbf{A} \mathbf{x}) = \mathbf{A} \mathbf{x} \cdot \mathbf{A} \mathbf{x} = \|\mathbf{A} \mathbf{x}\|^2$$

从而我们有: $\mathbf{x}^T \mathbf{S} \mathbf{x} \geq 0$ 并且:

$$\mathbf{x}^T \mathbf{S} \mathbf{x} = 0 \iff \|\mathbf{A} \mathbf{x}\| = 0 \implies \mathbf{A} \mathbf{x} = \mathbf{0}$$

由于 $\text{rank}(\mathbf{A}) = n$, 从而:

$$\mathbf{x}^T \mathbf{S} \mathbf{x} = 0 \implies \mathbf{A} \mathbf{x} = \mathbf{0} \iff \mathbf{x} = \mathbf{0}$$

□

二次型的转化 在定理 2.2 的证明中可以看到, 通过对参数做可逆的线性变换, 可以简化对应的二次型, 比如在定理证明中:

1. 对应的二次型为: $\mathbf{x}^T \mathbf{S} \mathbf{x} = s_{11}x_1^2 + \cdots + s_{nn}x_n^2 + 2 \sum_{1 \leq i < j \leq n} s_{ij}x_i x_j$ 。
2. 如果令 $\mathbf{x} = \mathbf{Q}^T \mathbf{y}$, 则二次型可表示为:

$$\mathbf{x}^T \mathbf{S} \mathbf{x} = \lambda_1 y_1^2 + \cdots + \lambda_n y_n^2.$$

正式的说，称一个二次型 f :

1. **标准二次型**，如果其只包含平方项，即:

$$f = s_{11}x_1^2 + \cdots + s_{nn}x_n^2.$$

2. **规范二次型**，如果其只包含系数为 1 或 -1 的平方项，即:

$$f = x_1^2 + \cdots + x_p^2 - x_{p+1}^2 - \cdots - x_r^2.$$

一般的，通过一个可逆的线性变换可以将一个二次型进行转换，即，令

$$f = \mathbf{x}^T \mathbf{A} \mathbf{x}$$

则可以通过一个可逆矩阵 $\mathbf{C}$, 使得 $\mathbf{x} = \mathbf{C} \mathbf{y}$, 并且:

$$f = \mathbf{y}^T \mathbf{C}^T \mathbf{A} \mathbf{C} \mathbf{y} = \mathbf{y}^T \mathbf{B} \mathbf{y}$$

我们称满足这样一个关系的矩阵 $\mathbf{A}, \mathbf{B}$ 是合同的。

定义 2.8

令 $\mathbf{A}, \mathbf{B}$ 是 $n \times n$ 的矩阵，若存在可逆矩阵 $\mathbf{C}$ 使得:

$$\mathbf{B} = \mathbf{C}^T \mathbf{A} \mathbf{C}$$

则称 $\mathbf{A}$ 和 $\mathbf{B}$ 是合同的。

注意到无论是规范二次型还是标准二次型，其对应的矩阵 $\mathbf{A}$ 都是一个对角矩阵，从而由定理1.7，寻找一个二次型的标准型或规范型的问题其实就是计算实对称矩阵的谱分解，总结如下:

1. 计算实对称矩阵 $\mathbf{S}$ 的谱分解，即寻找一个正交矩阵 $\mathbf{Q}$ 和对角矩阵 $\mathbf{\Lambda}$ 使得:

$$\mathbf{S} = \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T.$$

2. 令 $\mathbf{y} = \mathbf{Q}^T \mathbf{x}$, 则:

$$\mathbf{x}^T \mathbf{S} \mathbf{x} = \mathbf{x}^T \mathbf{Q} \mathbf{\Lambda} \mathbf{Q}^T \mathbf{x} = (\mathbf{Q}^T \mathbf{x})^T \mathbf{\Lambda} (\mathbf{Q}^T \mathbf{x}) = \mathbf{y}^T \mathbf{\Lambda} \mathbf{y}.$$

得到了对应的标准型。

3. 再将 $\mathbf{y}$ 作归一化，即可将标准型进一步转化成规范型。

下面通过一个例子来进行说明。以下列二次函数为例:

$$f(x_1, x_2, x_3) = -2x_1x_2 + 2x_1x_3 + 2x_2x_3$$

其对应的对称矩阵为:

$$\mathbf{S} = \begin{bmatrix} 0 & -1 & 1 \\ -1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix}$$

将其进行谱分解，则存在正交矩阵 P 和对角矩阵 Λ 使得

$$\begin{bmatrix} -2 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} = \Lambda = P^T S P = \begin{bmatrix} -\frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{3}} & \frac{1}{\sqrt{3}} \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{6}} & \frac{2}{\sqrt{6}} \end{bmatrix} \begin{bmatrix} 0 & -1 & 1 \\ -1 & 0 & 1 \\ 1 & 1 & 0 \end{bmatrix} \begin{bmatrix} -\frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} \\ -\frac{1}{\sqrt{3}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{3}} & 0 & \frac{2}{\sqrt{6}} \end{bmatrix}$$

从而令：

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} -\frac{1}{\sqrt{3}} & -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} \\ -\frac{1}{\sqrt{3}} & \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} \\ \frac{1}{\sqrt{3}} & 0 & \frac{2}{\sqrt{6}} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$$

我们有：

$$f = -2y_1^2 + y_2^2 + y_3^2$$

如果要进一步变成规范型，我们只需要在令：

$$\begin{cases} y_1 = \frac{1}{\sqrt{2}}z_1 \\ y_2 = z_2 \\ y_3 = z_3 \end{cases}$$

即有：

$$f = -z_1^2 + z_2^2 + z_3^2.$$

另一个二次型的转化方法-配方法 我们再介绍另一个方法，配方法。它不依赖于矩阵的运算。比如考虑：

$$f = x_1^2 + 2x_1x_2 + 5x_1x_3 + 2x_1x_2 + 2x_1x_3 + 6x_2x_3$$

我们考虑先将所有 x_1 的项集中起来：

$$x_1^2 + 2x_1x_2 + 2x_1x_3$$

对其配方可得：

$$x_1^2 + 2x_1x_2 + 2x_1x_3 = (x_1 + x_2 + x_3)^2 - x_2^2 - x_3^2 - 2x_2x_3$$

从而：

$$f = (x_1 + x_2 + x_3)^2 + x_2^2 + 4x_3^2 + 4x_2x_3 = (x_1 + x_2 + x_3)^2 + (x_2 + x_3)^2$$

$$f = (x_1 + x_2 + x_3)^2 + x_2^2 + 4x_3^2 + 4x_2x_3 = (x_1 + x_2 + x_3)^2 + (x_2 + 2x_3)^2$$

我们令

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 1 \\ 0 & 1 & 2 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}, \text{即: } \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 & -1 & 1 \\ 0 & 1 & -2 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$$

则我们有：

$$f = \mathbf{x}^T \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \\ 1 & 3 & 5 \end{bmatrix} \mathbf{x} = \mathbf{y}^T \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 1 & -2 & 1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \\ 1 & 2 & 3 \\ 1 & 3 & 5 \end{bmatrix} \begin{bmatrix} 1 & -1 & 1 \\ 0 & 1 & -2 \\ 0 & 0 & 1 \end{bmatrix} \mathbf{y} = \mathbf{y}^T \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix} \mathbf{y}$$

需要注意的是，该方法并不一定满足系数矩阵是正交的。

如果只有类似 x_1x_2 的项，比如：

$$f = 2x_1x_2 + 2x_1x_3 - 6x_1x_3$$

我们也是可以用配方法的，只要注意到：

$$4x_1x_2 = (x_1 + x_2)^2 - (x_1 - x_2)^2$$

从而进行

$$\begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} 1 & 1 & 0 \\ 1 & -1 & 0 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix}$$

代入再按之前配方的思路化简即可。

正定性与行列式的关系 这一节的最后，我们再给出正定性的另一个刻画，即用行列式来描述，下述定理给出了一个必要的条件：

定理 2.9

如果 S 是正定矩阵，则 $\det(S) > 0$ 。

证明：由 S 是实对称的，从而存在正交矩阵 Q 使得：

$$\begin{bmatrix} \lambda_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \lambda_n \end{bmatrix} = Q^T S Q$$

这里 $\lambda_1, \dots, \lambda_n$ 是 S 的特征值。从而：

$$\begin{vmatrix} \lambda_1 & \cdots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \cdots & \lambda_n \end{vmatrix} = \det(Q^T) \det(S) \det(Q)$$

即：

$$\det(S) = \det(Q^T) \det(S) \det(Q) = \lambda_1 \cdots \lambda_n > 0$$

□

定理2.9的逆命题并不一定正确。考察下列矩阵：

$$\begin{bmatrix} -1 & 0 & 0 \\ 0 & 0 & 2 \\ 0 & 2 & -1 \end{bmatrix}$$

其行列式 $= 4 > 0$ ，但是我们有：

$$\begin{bmatrix} 1 & 0 & 0 \end{bmatrix} \begin{bmatrix} -1 & 0 & 0 \\ 0 & 0 & 2 \\ 0 & 2 & -1 \end{bmatrix} \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} = -1 < 0$$

事实上，为了充分的利用行列式来刻画正定性，我们需要引入一系列新的行列式，称之为**顺序主子式 (Leading Principal Minor)**：

定义 2.10 (顺序主子式 (Leading Principal Minors))

给定一个 $n \times n$ 的矩阵：

$$A = \begin{bmatrix} a_{11} & a_{12} & \cdots & a_{1n} \\ a_{21} & a_{22} & \cdots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \cdots & a_{nn} \end{bmatrix}$$

则对任意的 $k \in [n]$ 。定义下列行列式：

$$\Delta_k = \begin{vmatrix} a_{11} & a_{12} & \cdots & a_{1k} \\ a_{21} & a_{22} & \cdots & a_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ a_{k1} & a_{k2} & \cdots & a_{kk} \end{vmatrix}$$

是 A 的一个 k 阶顺序主子式 (Leading Principal Minors)。

例 2.11

令 $A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \\ 7 & 8 & 9 \end{bmatrix}$ ，则：

$$\Delta_1 = 1, \Delta_2 = \begin{vmatrix} 1 & 2 \\ 4 & 5 \end{vmatrix} = 1 \cdot 5 - 2 \cdot 4 = -3, \Delta_3 = \det(A) = 0.$$

直观来讲，当顺序主子式都 > 0 时，其对应的特征值满足：

$$\lambda_k = \frac{\Delta_k}{\Delta_{k-1}}$$

这里可以不妨假设 $\Delta_0 = 1$ ，从而蕴含了所有特征值都 > 0 的条件，即对应的矩阵是正定的，下面对其进行严格的证明：

定理 2.12

给定一个 $n \times n$ 的对称矩阵 S ， S 是正定的当且仅当所有的顺序主子式 $\Delta_k > 0$ 。

证明： 令

$$S_k = \begin{bmatrix} s_{11} & \cdots & s_{1k} \\ \vdots & \ddots & \vdots \\ s_{k1} & \cdots & s_{kk} \end{bmatrix}$$

则我们有: $\Delta_k = \det(S_k)$. 我们先证 ($\Leftarrow$) 方向, 即说明每个 S_k 都是正定的。令 $\mathbf{x} = (x_1, \dots, x_k) \in \mathbb{R}^k \setminus \{0\}$, 注意到:

$$\begin{bmatrix} x_1 & \cdots & x_k \end{bmatrix} S_k \begin{bmatrix} x_1 \\ \vdots \\ x_k \end{bmatrix} = \begin{bmatrix} x_1 & \cdots & x_k & 0 & \cdots & 0 \end{bmatrix} S \begin{bmatrix} x_1 \\ \vdots \\ x_k \\ 0 \\ \vdots \\ 0 \end{bmatrix} > 0$$

从而 S_k 正定, 因此 $\Delta_k = \det(S_k) > 0$.

另一个方向我们使用归纳法。

BASE: $n = 1$ 时是显然的。

INDUCTION: 现在考虑 $n \geq 2$ 的时候, 我们有对于任意的 $k \in [n]$:

$$\Delta_k = \begin{vmatrix} s_{11} & s_{12} & \cdots & s_{1k} \\ s_{21} & s_{22} & \cdots & s_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ s_{k1} & s_{k2} & \cdots & s_{kk} \end{vmatrix} = \begin{vmatrix} s_{11} & s_{12} & \cdots & s_{1k} \\ 0 & s_{22} - \frac{s_{12}s_{21}}{s_{11}} & \cdots & s_{2k} - \frac{s_{1k}s_{21}}{s_{11}} \\ 0 & \vdots & \ddots & \vdots \\ 0 & s_{k2} - \frac{s_{1k}s_{12}}{s_{11}} & \cdots & s_{kk} - \frac{s_{1k}s_{k1}}{s_{11}} \end{vmatrix}$$

对任意的 $2 \leq i, j \leq k$ 定义:

$$t_{ij} = s_{ij} - \frac{s_{1i}s_{1j}}{s_{11}} (= s_{ij} - \frac{s_{1i}s_{j1}}{s_{11}})$$

从而我们有:

$$\Delta_k = \begin{vmatrix} s_{11} & s_{12} & \cdots & s_{1k} \\ 0 & t_{22} & \cdots & t_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ 0 & t_{k2} & \cdots & t_{kk} \end{vmatrix} = s_{11} \begin{vmatrix} t_{22} & \cdots & t_{2k} \\ \vdots & \ddots & \vdots \\ t_{k2} & \cdots & t_{kk} \end{vmatrix}$$

注意到 $s_{11} = \Delta_1 > 0$, $\Delta_k > 0$, 从而我们有:

$$\begin{vmatrix} t_{22} & \cdots & t_{2k} \\ \vdots & \ddots & \vdots \\ t_{k2} & \cdots & t_{kk} \end{vmatrix} > 0$$

对任意的 $2 \leq k \leq n$ 是成立的。定义 $(n-1) \times (n-1)$ 的矩阵 T :

$$T = \begin{bmatrix} t_{22} & \cdots & t_{2k} \\ \vdots & \ddots & \vdots \\ t_{k2} & \cdots & t_{kk} \end{bmatrix}$$

显然 T 是一个实对称矩阵, 并且其所有的顺序主子式都是大于 0 的, 从而有归纳假设 T 是正定的。从

而:

$$\begin{aligned}
 \mathbf{x}^T \mathbf{S} \mathbf{x} &= \sum_{i \in [n]} \sum_{j \in [n]} s_{ij} x_i x_j \\
 &= \frac{(s_{11}x_1 + \cdots + s_{1n}x_n)^2}{s_{11}} + \sum_{i=2}^n \sum_{j=2}^n t_{ij} x_i x_j \\
 &= \frac{(s_{11}x_1 + \cdots + s_{1n}x_n)^2}{s_{11}} + \begin{bmatrix} x_2 & \cdots & x_n \end{bmatrix}^T \begin{bmatrix} x_2 \\ \vdots \\ x_n \end{bmatrix}
 \end{aligned}$$

最后我们分两种情况讨论:

1. $\begin{bmatrix} x_2 & \cdots & x_n \end{bmatrix}^T \neq \mathbf{0}$, 则由 $\mathbf{T}$ 是正定的, 我们有:

$$\mathbf{x}^T \mathbf{S} \mathbf{x} \geq \begin{bmatrix} x_2 & \cdots & x_n \end{bmatrix}^T \begin{bmatrix} x_2 \\ \vdots \\ x_n \end{bmatrix} > 0$$

2. $\begin{bmatrix} x_2 & \cdots & x_n \end{bmatrix}^T = \mathbf{0}$, 这意味着 $x_1 \neq 0$, 注意到 $s_{11} > 0$, 我们有:

$$\mathbf{x}^T \mathbf{S} \mathbf{x} = \frac{(s_{11}x_1)^2}{s_{11}} = s_{11}x_1^2 > 0$$

□

定理2.12还有相应的判断矩阵是否负定的版本:

定理 2.13

令 $\mathbf{S}$ 是 $n \times n$ 的对称矩阵, 则 $\mathbf{S}$ 是负定的当且仅当所有的奇数阶顺序主子式 < 0 , 偶数阶顺序主子式 > 0 .

线性代数 (XIV)

Lecturer: 杨启哲

Last modified: 2026 年 6 月 1 日

1 线性变换的概念

回顾最开始关于“线性的介绍”。我们考察了如下的函数：

$$y = 3x$$

这是一个线性函数 $f: \mathbb{R} \rightarrow \mathbb{R}$.

- 几何上来讲，其定义了 $\mathbb{R}^2$ 上或者说是一个二维平面上的一条线。
- 代数上来讲，对任意的 $x, y, c \in \mathbb{R}$ 其满足：

$$f(x + y) = 3(x + y) = 3x + 3y = f(x) + f(y)$$

$$f(cx) = 3cx = cf(x)$$

现在让我们将关注点放到线性空间的映射。一个 $V \rightarrow W$ 的映射，可视为：

$$T: \mathbf{v} \rightarrow \mathbf{w}.$$

即 T 将一个 V 中的元素映射到 W 中的元素。这可以视作是两个空间元素的变换。而“线性变换”就是类似满足上述性质的那些映射，我们给出如下的正式定义：

定义 1.1 (Linear Transformation)

令 V 和 W 是两个线性空间。一个映射 $T: V \rightarrow W$ 被称作是一个**线性变换**，如果其满足对任意的 $\mathbf{v}, \mathbf{w} \in V$ 和实数 $c \in \mathbb{R}$ ：

$$T(\mathbf{v} + \mathbf{w}) = T(\mathbf{v}) + T(\mathbf{w}), T(c\mathbf{v}) = cT(\mathbf{v})$$

注 1.2

- 在很多资料当中，会将 $V \neq W$ 的情况称为**线性映射**，而只有 $V = W$ 的情况下称为**线性变换**。我们的课件则不作这类区分，但当 $V \neq W$ 时，我们会经常显示的表达出 V 和 W 。
- $V = W$ 的情况下我们也会称： T 是 V 上的线性变换。

很显然关于线性变换 T ，我们有如下的基本性质：

引理 1.3

1. $T(\mathbf{0}) = \mathbf{0}$.
2. $T(c\mathbf{v} + d\mathbf{w}) = cT(\mathbf{v}) + dT(\mathbf{w})$.
3. $T(c_1\mathbf{v}_1 + \cdots + c_n\mathbf{v}_n) = c_1T(\mathbf{v}_1) + \cdots + c_nT(\mathbf{v}_n)$

证明: 只需说明第一个, 注意到:

$$T(\mathbf{0}_V) = T(\mathbf{0}_V + \mathbf{0}_V) = T(\mathbf{0}_V) + T(\mathbf{0}_V) = 2T(\mathbf{0}_V).$$

从而 $T(\mathbf{0}_V) = \mathbf{0}_W$. □

我们再考察一些例子:

例 1.4

1. **内积 (Inner Product):** 固定一个向量 $\mathbf{a} = (1, 2, 3) \in \mathbb{R}^3$, 定义 $T_{\mathbf{a}}(\mathbf{v}) = \mathbf{a} \cdot \mathbf{v}$. 则 $T_{\mathbf{a}}$ 是 $\mathbb{R}^3 \rightarrow \mathbb{R}$ 上的线性变换。
2. **长度 (Length):** 定义 $T(\mathbf{v}) = \|\mathbf{v}\|$, 则 T **不是** $\mathbb{R}^n \rightarrow \mathbb{R}$ 上的线性变换。
3. **旋转 (Rotation):** 定义 V 上的映射:

$$T(\mathbf{v}) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \mathbf{v}$$

则 T 是一个 V 上的线性变换。

之前我们提到过描述线性空间最核心的是要选取一组该空间的基, 我们下面要首先说明的是, 在给定的基下, 线性变换是唯一确定的:

引理 1.5

令 V 和 W 是两个线性空间, 并且 $\dim(V) = \dim(W) = n$. 令 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 是 V 的一组基, 则:

1. 令 $T_1, T_2: V \rightarrow W$ 是两个其上的线性变换, 满足对任意的 $i \in [n]$ 都有:

$$T_1(\mathbf{v}_i) = T_2(\mathbf{v}_i)$$

则 $T_1 = T_2$ 。

2. 令 $\mathbf{w}_1, \dots, \mathbf{w}_n$ 是 W 中的一组基, 则存在**唯一**的线性变换 $T: V \rightarrow W$ 使得对任意的 $i \in [n]$ 都有:

$$T(\mathbf{v}_i) = \mathbf{w}_i$$

证明: 令 $\mathbf{v} \in V$. 由于 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 是 V 的一组基, 从而存在 $c_1, \dots, c_n$ 使得:

$$\mathbf{v} = c_1\mathbf{v}_1 + \cdots + c_n\mathbf{v}_n = \sum_{i \in [n]} c_i \mathbf{v}_i.$$

从而我们有：

$$\begin{aligned} T_1(\mathbf{v}) &= T_1\left(\sum_{i \in [n]} c_i \mathbf{v}_i\right) = \sum_{i \in [n]} c_i T_1(\mathbf{v}_i) \\ &= \sum_{i \in [n]} c_i T_2(\mathbf{v}_i) = T_2\left(\sum_{i \in [n]} c_i \mathbf{v}_i\right) = T_2(\mathbf{v}). \end{aligned}$$

另一方面，注意到 $c_1, \dots, c_n$ 是唯一的，从而我们有：

$$T(\mathbf{v}) = \sum_{i \in [n]} c_i \mathbf{w}_i.$$

即 T 满足对任意的 $i \in [n]$ ，有 $T(\mathbf{v}_i) = \mathbf{w}_i$ 。 □

令 V 是一个 n 维的向量空间， $\mathbf{v}_1, \dots, \mathbf{v}_n$ 是 V 的一组基，我们记作： $\bar{\mathbf{v}} = \mathbf{v}_1, \dots, \mathbf{v}_n$ 。注意到，对于任意的 $\mathbf{v} \in V$ ，存在唯一的 $c_1, \dots, c_n \in \mathbb{R}$ 使得：

$$\mathbf{v} = c_1 \mathbf{v}_1 + \dots + c_n \mathbf{v}_n$$

从而可以定义其系数构成的向量 (coordinate vector) 为：

$$(c_1, \dots, c_n) \in \mathbb{R}^n$$

其被称作是在基 $\bar{\mathbf{v}}$ 下的坐标。

例 1.6

回顾我们之前提过的一个很奇怪的向量空间：

$$\mathbf{v} = \mathbb{R}^+ = \{x \in \mathbb{R} \mid x > 0\}.$$

我们定义了其上的加法 $\oplus$ 和数乘 $\otimes$ ：

$$x \oplus x' = x \times x', \quad c \otimes x = x^c.$$

由于 $\dim(\mathbf{v}) = 1$ ，我们可以选取如下的一组基：

$$\mathbf{v}_1 = 2.$$

则对于任意的 $x \in \mathbf{v}$ ，我们有唯一的 $c \in \mathbb{R}$ 使得：

$$x = c \otimes \mathbf{v}_1 = 2^c.$$

即： $c = \log_2 x$ 是 x 在基 $\mathbf{v}_1$ 下的坐标。

可以看到，上述坐标的表示其实也是一种线性变换，下列映射：

$$x \mapsto \log_2 x.$$

是 $\mathbb{R}^+$ 到 $\mathbb{R}$ 上的一一对应的线性变换。事实上，我们有：

定理 1.7

令 n 维空间 V 的一组基为 $\bar{\mathbf{v}}$, 定义 $T_{\bar{\mathbf{v}}}: V \rightarrow \mathbb{R}^n$:

$$T_{\bar{\mathbf{v}}}(\mathbf{v}) = (c_1, \dots, c_n)$$

这里 $(c_1, \dots, c_n)$ 是 $\mathbf{v}$ 在基 $\bar{\mathbf{v}}$ 下的坐标。则 $T_{\bar{\mathbf{v}}}$ 是一个 V 到 $\mathbb{R}^n$ 上的线性变换, 并且 $T_{\bar{\mathbf{v}}}$ 是**一一对应的 (bijective)**。

证明: 注意到:

1. 对任意的 $\mathbf{v}, \mathbf{v}' \in V$, 令 $\mathbf{v} = \sum_{i \in [n]} c_i \mathbf{v}_i$, $\mathbf{v}' = \sum_{i \in [n]} c'_i \mathbf{v}_i$, 则我们有:

$$\begin{aligned} T_{\bar{\mathbf{v}}}(\mathbf{v} + \mathbf{v}') &= T_{\bar{\mathbf{v}}} \left(\sum_{i \in [n]} c_i \mathbf{v}_i + \sum_{i \in [n]} c'_i \mathbf{v}_i \right) \\ &= T_{\bar{\mathbf{v}}} \left(\sum_{i \in [n]} (c_i + c'_i) \mathbf{v}_i \right) \\ &= (c_1 + c'_1, \dots, c_n + c'_n) \\ &= (c_1, \dots, c_n) + (c'_1, \dots, c'_n) \\ &= T_{\bar{\mathbf{v}}} \left(\sum_{i \in [n]} c_i \mathbf{v}_i \right) + T_{\bar{\mathbf{v}}} \left(\sum_{i \in [n]} c'_i \mathbf{v}_i \right) = T_{\bar{\mathbf{v}}}(\mathbf{v}) + T_{\bar{\mathbf{v}}}(\mathbf{v}'). \end{aligned}$$

2. 令 $\mathbf{v} = \sum_{i \in [n]} c_i \mathbf{v}_i$ 和 $c \in \mathbb{R}$, 则我们有:

$$\begin{aligned} T_{\bar{\mathbf{v}}}(\mathbf{cv}) &= T_{\bar{\mathbf{v}}}(c \sum_{i \in [n]} c_i \mathbf{v}_i) \\ &= T_{\bar{\mathbf{v}}} \left(\sum_{i \in [n]} (cc_i) \mathbf{v}_i \right) \\ &= (cc_1, \dots, cc_n) \\ &= c(c_1, \dots, c_n) \\ &= c T_{\bar{\mathbf{v}}} \left(\sum_{i \in [n]} c_i \mathbf{v}_i \right) = c T_{\bar{\mathbf{v}}}(\mathbf{v}). \end{aligned}$$

3. $T_{\bar{\mathbf{v}}}$ 是一个双射:

• 令 $\mathbf{v}, \mathbf{v}' \in V$ 满足: $T_{\bar{\mathbf{v}}}(\mathbf{v}) = T_{\bar{\mathbf{v}}}(\mathbf{v}') = (c_1, \dots, c_n)$, 则我们有:

$$\mathbf{v} = \sum_{i \in [n]} c_i \mathbf{v}_i = \mathbf{v}'.$$

即 $\mathbf{v} = \mathbf{v}'$ 。

- 令 $(c_1, \dots, c_n) \in \mathbb{R}^n$, 则定义:

$$\mathbf{u} = c_1 \mathbf{v}_1 + \dots + c_n \mathbf{v}_n = \sum_{i \in [n]} c_i \mathbf{v}_i \in V.$$

从而我们有: $T_{\bar{\mathbf{v}}}(\mathbf{u}) = (c_1, \dots, c_n)$.

□

可以看到由 $\mathbf{v} \in V$ 决定的线性变换 $T_{\bar{\mathbf{v}}}$ 依赖于基 $\bar{\mathbf{v}}$ 的选择, 那么不同的基的选择会产生怎样的影响?

例 1.8

考察 $\mathbb{R}^2$, 我们选取两组基:

$$\bar{\mathbf{v}}_1 = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \bar{\mathbf{v}}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix},$$

则对于 $\begin{bmatrix} 2 \\ 3 \end{bmatrix}$ 来说, 我们有:

$$T_{\bar{\mathbf{v}}_1}\left(\begin{bmatrix} 2 \\ 3 \end{bmatrix}\right) = \begin{bmatrix} 2 \\ 3 \end{bmatrix}, \quad T_{\bar{\mathbf{v}}_2}\left(\begin{bmatrix} 2 \\ 3 \end{bmatrix}\right) = \begin{bmatrix} 2.5 \\ -0.5 \end{bmatrix}.$$

而对于 $\begin{bmatrix} 1 \\ 2 \end{bmatrix}$ 来说, 我们有:

$$T_{\bar{\mathbf{v}}_1}\left(\begin{bmatrix} 1 \\ 2 \end{bmatrix}\right) = \begin{bmatrix} 1 \\ 2 \end{bmatrix}, \quad T_{\bar{\mathbf{v}}_2}\left(\begin{bmatrix} 1 \\ 2 \end{bmatrix}\right) = \begin{bmatrix} -0.5 \\ 1.5 \end{bmatrix}.$$

我们可以看到, 在这两组例子里均有:

$$\begin{bmatrix} 2 \\ 3 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} 2.5 \\ -0.5 \end{bmatrix}, \quad \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 & 1 \\ -1 & 1 \end{bmatrix} \begin{bmatrix} -0.5 \\ 1.5 \end{bmatrix}$$

例子1.8启发我们, 对同一个向量 $\mathbf{v}$ 在不同基诱导出的线性变换 $T_{\bar{\mathbf{v}}}$ 可能只差一个矩阵。事实上, 令 $\mathbf{v}_1, \dots, \mathbf{v}_n \in V$, A 是一个 $n \times m$ 的矩阵。则我们定义:

$$\begin{bmatrix} \mathbf{u}_1 & \dots & \mathbf{u}_n \end{bmatrix} = \begin{bmatrix} \mathbf{v}_1 & \dots & \mathbf{v}_n \end{bmatrix} A$$

为满足:

$$\mathbf{u}_i = \sum_{k \in [n]} A(k, i) \mathbf{v}_k$$

的 m 个 V 中的元素 $\mathbf{u}_1, \dots, \mathbf{u}_m \in V$ 。从而令 $\bar{\mathbf{v}} = \mathbf{v}_1, \dots, \mathbf{v}_n$ 是 V 的一组基, 则对于 $\mathbf{v} \in V$ 我们有:

$$\mathbf{v} = \begin{bmatrix} \mathbf{v}_1 & \dots & \mathbf{v}_n \end{bmatrix} T_{\bar{\mathbf{v}}}(\mathbf{v}).$$

从而我们可以用一个矩阵来联系两组基之间的关系:

引理 1.9

令 $\bar{\mathbf{v}} = \mathbf{v}_1, \dots, \mathbf{v}_n$ 和 $\bar{\mathbf{v}}' = \mathbf{v}'_1, \dots, \mathbf{v}'_n$ 是 V 的两组基, 则存在一个唯一的 $n \times n$ 矩阵 M 满足:

$$\begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} = \begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} M$$

证明: 由于 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 是 V 的一组基, 从而对于任意的 $\mathbf{v}'_i$, 存在唯一的 $a_{i1}, \dots, a_{in}$ 使得:

$$\mathbf{v}'_i = a_{i1}\mathbf{v}_1 + \cdots + a_{in}\mathbf{v}_n = \sum_{k \in [n]} a_{ik}\mathbf{v}_k$$

即 $(a_{i1}, \dots, a_{in}) \in \mathbb{R}^n$ 是 $\mathbf{v}'_i$ 在基 $\bar{\mathbf{v}}$ 下的坐标。

定义下列矩阵:

$$M = \begin{bmatrix} a_{11} & \cdots & a_{1n} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nn} \end{bmatrix}$$

则我们有:

$$\begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} = \begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} M$$

M 的唯一性由 $\mathbf{v}'_i = \sum_{k \in [n]} a_{ik}\mathbf{v}_k$ 保证。 □

我们将引理1.9 中所定义的矩阵 M 称为过度矩阵。

定义 1.10 (Change of Basis)

引理1.9 中 M 被称作基 $\bar{\mathbf{v}}$ 到 $\bar{\mathbf{v}}'$ 的过渡矩阵。

注意到, 上述利用矩阵定义的基之间的关系同样满足矩阵乘法的性质, 即:

引理 1.11

令 $\mathbf{v}_1, \dots, \mathbf{v}_n \in V$, A 是 $n \times m$ 的矩阵, B 是 $m \times l$ 的矩阵, 则我们有:

$$\begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} (AB) = (\begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} A) B$$

证明: 定义:

$$\begin{bmatrix} \mathbf{u}_1 & \cdots & \mathbf{u}_m \end{bmatrix} = \begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} A, \quad \begin{bmatrix} \mathbf{w}_1 & \cdots & \mathbf{w}_l \end{bmatrix} = (\begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} A) B$$

则对于任意的 $i \in [l]$, 我们有:

$$\mathbf{w}_i = \sum_{k \in [m]} B(k, i) \mathbf{u}_k = \sum_{k \in [m]} B(k, i) \left(\sum_{j \in [n]} A(j, k) \mathbf{v}_j \right) = \sum_{j \in [n]} \left(\sum_{k \in [m]} A(j, k) B(k, i) \right) \mathbf{v}_j$$

即:

$$(\begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} A) B = \begin{bmatrix} \mathbf{w}_1 & \cdots & \mathbf{w}_l \end{bmatrix} = \begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} (AB).$$

□

从而过渡矩阵是可逆的:

定理 1.12

M 是可逆的。

证明: 由引理 1.9, 存在唯一的 $n \times n$ 的矩阵 M' 满足:

$$\begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} = \begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} M'.$$

从而:

$$\begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} = \begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} M = \left(\begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} M' \right) M = \begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} (M'M).$$

另一方面, 我们有: $\begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} = \begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} I$, 即 I 也是 $\bar{\mathbf{v}}'$ 到 $\bar{\mathbf{v}}$ 的过渡矩阵。根据过渡矩阵的唯一性, 我们有:

$$M'M = I.$$

□

因此例子1.8的直观可以衍生出如下的基变换公式:

定理 1.13

令 $\bar{\mathbf{v}}$ 和 $\bar{\mathbf{v}}'$ 是 V 的两组基, 则对于任意的 $\mathbf{u} \in V$, 我们有:

$$T_{\bar{\mathbf{v}}}(\mathbf{u}) = M T_{\bar{\mathbf{v}}'}(\mathbf{u})$$

证明: 注意到:

$$\begin{aligned} \begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} T_{\bar{\mathbf{v}}}(\mathbf{u}) &= \mathbf{u} = \begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} T_{\bar{\mathbf{v}}'}(\mathbf{u}) \\ &= \left(\begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} M \right) T_{\bar{\mathbf{v}}'}(\mathbf{u}) \\ &= \begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} (M T_{\bar{\mathbf{v}}'}(\mathbf{u})). \end{aligned}$$

从而由 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 是线性无关的, 我们有:

$$T_{\bar{\mathbf{v}}}(\mathbf{u}) = M T_{\bar{\mathbf{v}}'}(\mathbf{u}).$$

□

定理1.13实际给出了不同基下的坐标变换公式,事实上,给定 $\mathbf{v} \in V$, 若其在基 $\bar{\mathbf{v}}$ 下的坐标为: $(x_1, \dots, x_n)$; 在基 $\bar{\mathbf{v}}'$ 下的坐标为: $(x'_1, \dots, x'_n)$, 则由定理1.13 有:

$$\begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = M \begin{bmatrix} x'_1 \\ \vdots \\ x'_n \end{bmatrix}.$$

从而在一个线性空间的元素在不同基的坐标只差一个可逆矩阵, 这是我们第一部分要理解的一个信息。

2 线性变换的矩阵形式

这一节我们继续探讨矩阵在线性变换中表达的形式。注意到线性空间的一个元素实际上就是一组基的线性组合，所以我们可以用该形式来描述一个线性变换。具体来说，令 V 和 W 是两个线性空间，并且 $\dim(V) = n$, $\dim(W) = m$ 。特别的：

$$\bar{\mathbf{v}} = \mathbf{v}_1, \dots, \mathbf{v}_n \text{ 和 } \bar{\mathbf{w}} = \mathbf{w}_1, \dots, \mathbf{w}_m.$$

分别是 V 和 W 的一组基。

定义 $T: V \rightarrow W$ 是一个线性变换，这意味着对于 $i \in [n]$, $j \in [m]$ ，存在 $a_{ij} \in \mathbb{R}$ 使得：

$$T(\mathbf{v}_1) = a_{11}\mathbf{w}_1 + \dots + a_{1m}\mathbf{w}_m$$

$$T(\mathbf{v}_2) = a_{21}\mathbf{w}_1 + \dots + a_{2m}\mathbf{w}_m$$

$$\vdots$$

$$T(\mathbf{v}_n) = a_{n1}\mathbf{w}_1 + \dots + a_{nm}\mathbf{w}_m.$$

给定 $\mathbf{v} \in V$ ，则存在 $c_1, \dots, c_n \in \mathbb{R}$ ：

$$\mathbf{v} = c_1\mathbf{v}_1 + \dots + c_n\mathbf{v}_n.$$

从而：

$$\begin{aligned} T(\mathbf{v}) &= T(c_1\mathbf{v}_1 + \dots + c_n\mathbf{v}_n) \\ &= c_1T(\mathbf{v}_1) + \dots + c_nT(\mathbf{v}_n) \\ &= c_1(a_{11}\mathbf{w}_1 + \dots + a_{1m}\mathbf{w}_m) + \dots + c_n(a_{n1}\mathbf{w}_1 + \dots + a_{nm}\mathbf{w}_m) \\ &= (a_{11}c_1 + \dots + a_{n1}c_n)\mathbf{w}_1 + \dots + (a_{1m}c_1 + \dots + a_{nm}c_n)\mathbf{w}_m \\ &= \sum_{j \in [m]} \left(\sum_{i \in [n]} c_i a_{ij} \right) \mathbf{w}_j. \end{aligned}$$

即 $T(\mathbf{v})$ 在基 $\bar{\mathbf{w}}$ 下的坐标为：

$$(\mathbf{w}_1, \dots, \mathbf{w}_m) := \left(\sum_{i \in [n]} c_i a_{i1}, \dots, \sum_{i \in [n]} c_i a_{im} \right).$$

从而 $\mathbf{v}$ 在 $\bar{\mathbf{v}}$ 下的坐标与 $T(\mathbf{v})$ 在基 $\bar{\mathbf{w}}$ 下的坐标有如下的关系：

$$\begin{bmatrix} \mathbf{w}_1 \\ \vdots \\ \mathbf{w}_m \end{bmatrix} = \begin{bmatrix} a_{11} & \dots & a_{n1} \\ \vdots & \ddots & \vdots \\ a_{1m} & \dots & a_{nm} \end{bmatrix} \begin{bmatrix} c_1 \\ \vdots \\ c_n \end{bmatrix}.$$

记上述标红的矩阵为 A_T ，其被视作在这两组基下线性变换 T 的矩阵表示：

定义 2.1

A_T 被称作线性变换 T 在基 $\bar{\mathbf{v}}$ 和 $\bar{\mathbf{w}}$ 下的矩阵。

A_T 显然具备如下的性质：

引理 2.2

1. 对任意的 $\mathbf{v} \in V$, 令 $(v_1, \dots, v_n)$ 表示其在基 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 下的坐标, 则;

$$\begin{bmatrix} T(\mathbf{v}_1) & \cdots & T(\mathbf{v}_n) \end{bmatrix} = \begin{bmatrix} \mathbf{w}_1 & \cdots & \mathbf{w}_m \end{bmatrix} A_T$$

2. A_T 是唯一的, 即如果存在 $m \times n$ 的矩阵 B 使得:

$$\begin{bmatrix} T(\mathbf{v}_1) & \cdots & T(\mathbf{v}_n) \end{bmatrix} = \begin{bmatrix} \mathbf{w}_1 & \cdots & \mathbf{w}_m \end{bmatrix} B$$

则我们有 $B = A_T$ 。

证明:

1. 由 A_T 的定义可直接得到。
2. 由 $T(\mathbf{v}_j) = \sum_{i \in [n]} a_{ji} \mathbf{w}_i$ 的唯一性可以得到。

□

下面的定理说明, 事实上在给定的基下, 任何一个线性变换都可用一个确定的矩阵来进行表示:

定理 2.3

令 $\mathbf{v} \in V$ 和 $\mathbf{w} \in W$ 。若 $\mathbf{x} \in \mathbb{R}^n$ 是 $\mathbf{v}$ 在基 $\bar{\mathbf{v}}$ 下的坐标, $\mathbf{y} \in \mathbb{R}^m$ 是 $T(\mathbf{v})$ 在基 $\bar{\mathbf{w}}$ 下的坐标, 则我们有:

$$T(\mathbf{v}) = \mathbf{w} \iff \mathbf{y} = A_T \mathbf{x}.$$

证明: 不妨令 $\mathbf{x} = (x_1, \dots, x_n)$, $\mathbf{y} = (y_1, \dots, y_m)$, 从而:

$$\mathbf{v} = \sum_{i \in [n]} x_i \mathbf{v}_i, \quad \mathbf{w} = \sum_{j \in [m]} y_j \mathbf{w}_j.$$

若 $T(\mathbf{v}) = \mathbf{w}$, 则我们有:

$$\begin{aligned} T(\mathbf{v}) &= T\left(\sum_{i \in [n]} x_i \mathbf{v}_i\right) = \sum_{i \in [n]} x_i T(\mathbf{v}_i) \\ &= \begin{bmatrix} T(\mathbf{v}_1) & \cdots & T(\mathbf{v}_n) \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} T(\mathbf{v}_1) & \cdots & T(\mathbf{v}_n) \end{bmatrix} \mathbf{x} \\ &= \begin{bmatrix} \mathbf{w}_1 & \cdots & \mathbf{w}_m \end{bmatrix} A_T \mathbf{x} = \begin{bmatrix} \mathbf{w}_1 & \cdots & \mathbf{w}_m \end{bmatrix} (A_T \mathbf{x}). \end{aligned}$$

另一方面, 注意到 $\mathbf{w}_1, \dots, \mathbf{w}_m$ 是线性无关的:

$$\mathbf{w} = \sum_{j \in [m]} y_j \mathbf{w}_j = \begin{bmatrix} \mathbf{w}_1 & \cdots & \mathbf{w}_m \end{bmatrix} \mathbf{y} = \begin{bmatrix} \mathbf{w}_1 & \cdots & \mathbf{w}_m \end{bmatrix} A_T \mathbf{x} = \begin{bmatrix} T(\mathbf{v}_1) & \cdots & T(\mathbf{v}_n) \end{bmatrix} \mathbf{x}$$

$$= T\left(\sum_{i \in [n]} x_i \mathbf{v}_i\right) = T(\mathbf{v}).$$

□

我们现在来考察一下两个线性变换的复合，我们通过一个具体的例子来进行说明。考察 $\mathbb{R}^2$ 上的旋转变换：

$$T: \mathbb{R}^2 \longrightarrow \mathbb{R}^2$$

其将向量逆时针旋转 θ 角度，从而我们有：

$$T(\mathbf{v}) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \mathbf{v}$$

我们使用如下的标准基：

$$\bar{\mathbf{e}} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \begin{bmatrix} 0 \\ 1 \end{bmatrix}.$$

则：

$$A_T = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}.$$

现在考察 $\mathbb{R}^2$ 上的两个旋转变换（即令 $U = V = W = \mathbb{R}^2$ ），令 S 将向量逆时针旋转 θ 角度， T 将向量逆时针旋转 δ 角度，即：

$$S(\mathbf{v}) = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \mathbf{v}, \quad T(\mathbf{v}) = \begin{bmatrix} \cos \delta & -\sin \delta \\ \sin \delta & \cos \delta \end{bmatrix} \mathbf{v}.$$

。从而：

$$\begin{aligned} TS(\mathbf{v}) &= T(S(\mathbf{v})) = \begin{bmatrix} \cos \delta & -\sin \delta \\ \sin \delta & \cos \delta \end{bmatrix} \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} \mathbf{v} \\ &= \begin{bmatrix} \cos(\theta + \delta) & -\sin(\theta + \delta) \\ \sin(\theta + \delta) & \cos(\theta + \delta) \end{bmatrix} \mathbf{v}. \end{aligned}$$

而在标准基 $\bar{\mathbf{e}}$ 下我们有：

$$A_{TS} = \begin{bmatrix} \cos(\theta + \delta) & -\sin(\theta + \delta) \\ \sin(\theta + \delta) & \cos(\theta + \delta) \end{bmatrix} = \begin{bmatrix} \cos \delta & -\sin \delta \\ \sin \delta & \cos \delta \end{bmatrix} \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix} = A_T A_S.$$

上述例子说明，两个线性变换的复合，在确定了基的情况下，可以表示成其对应的矩阵的乘积，即如下的引理：

引理 2.4

令 U, V, W 是三个线性空间，其基分别为 $\bar{\mathbf{u}}, \bar{\mathbf{v}}, \bar{\mathbf{w}}$ ， $S: U \longrightarrow V$ 和 $T: V \longrightarrow W$ 是两个线性变换。

- 定义 $TS: U \longrightarrow W$ 为：

$$TS(\mathbf{u}) = T(S(\mathbf{u})).$$

则 TS 是一个线性变换。

- 若 A_S 和 A_T 分别是 S 和 T 在基 $\bar{\mathbf{u}}, \bar{\mathbf{v}}$ 和 $\bar{\mathbf{v}}, \bar{\mathbf{w}}$ 下的矩阵, 则 A_{TS} 是 TS 在基 $\bar{\mathbf{u}}, \bar{\mathbf{w}}$ 下的矩阵, 则:

$$A_{TS} = A_TA_S$$

即 A_TA_S 是 TS 在基 $\bar{\mathbf{u}}, \bar{\mathbf{w}}$ 下的矩阵。

证明: 我们先证明 TS 是一个线性变换。给定 $\mathbf{u}, \mathbf{u}' \in U$ 和 $c \in \mathbb{R}$:

$$TS(\mathbf{u} + \mathbf{u}') = T(S(\mathbf{u} + \mathbf{u}')) = T(S(\mathbf{u}) + S(\mathbf{u}')) = T(S(\mathbf{u})) + T(S(\mathbf{u}')) = TS(\mathbf{u}) + TS(\mathbf{u}')$$

$$TS(c\mathbf{u}) = T(S(c\mathbf{u})) = T(cS(\mathbf{u})) = cT(S(\mathbf{u})) = cTS(\mathbf{u}).$$

从而 TS 是一个线性变换。

另一方面, 令 $TS(\mathbf{u})$ 在 $\bar{\mathbf{w}}$ 下的坐标为 $\mathbf{z}$, $S(\mathbf{u})$ 在 $\bar{\mathbf{v}}$ 下的坐标为 $\mathbf{y}$, $\mathbf{u}$ 在 $\bar{\mathbf{u}}$ 下的坐标为 $\mathbf{x}$, 则我们有:

$$TS(\mathbf{u}) = T(S(\mathbf{u})) \implies \mathbf{z} = A_T\mathbf{y}$$

$$S(\mathbf{u}) = S(\mathbf{u}) \implies \mathbf{y} = A_S\mathbf{x}.$$

从而我们有:

$$\mathbf{z} = A_TA_S\mathbf{x}.$$

即: $A_{TS} = A_TA_S$. □

注 2.5

事实上, 这也是部分教材引入矩阵乘法的方式, 也是笔者认为引入乘法的最佳方案。因为从线性变换的角度来讲, 解方程组其实也就是在一组给定的基下确定某个线性变换的具体表示。从而通过方程的复合引入的矩阵乘法, 本质上就是通过线性变换的复合引入矩阵乘法。

现在我们考察一下目前为止线性变换与矩阵的认知。给定线性空间 V, W 和其一组对应的基下:

- 我们定义了线性变换, 特别的, V 到 W 上所有的线性变换为如下的集合:

$$T(V, W) := \{T \mid T: V \rightarrow W \text{ 是一个线性变换.}\}$$

通过合适的加法运算和数乘运算, $T(V, W)$ 是一个线性空间, 并且从函数的角度理解, 其应该是一个 $m \times n$ 维的线性空间。

- 考虑所有的 $m \times n$ 的实矩阵:

$$\mathbb{M}_{m \times n}(\mathbb{R}) = \{A \mid A \text{ 是一个 } m \times n \text{ 的实矩阵.}\}$$

- 令 $T \in T(V, W)$, $A_T \in \mathbb{M}_{m \times n}(\mathbb{R})$ 存在且唯一, 满足:

$$T(\mathbf{v}) = \mathbf{w} \iff \mathbf{y} = A_T\mathbf{x}.$$

这其实说明了, 在给定的基下, 线性变换和矩阵是一一对应的!

定理 2.6

下述映射：

$$T \mapsto A_T.$$

是 $T(V, W)$ 到 $M_{m \times n}(\mathbb{R})$ 的一一映射。

证明： 令 $T_1, T_2 \in T(V, W)$ ，并且假设：

$$A_{T_1} = \begin{bmatrix} a_{11} & \cdots & a_{1m} \\ \vdots & \ddots & \vdots \\ a_{n1} & \cdots & a_{nm} \end{bmatrix}, \quad A_{T_2} = \begin{bmatrix} b_{11} & \cdots & b_{1m} \\ \vdots & \ddots & \vdots \\ b_{n1} & \cdots & b_{nm} \end{bmatrix}.$$

即：

$$\begin{aligned} T_1(\mathbf{v}_1) &= a_{11}\mathbf{w}_1 + \cdots + a_{1m}\mathbf{w}_m & T_2(\mathbf{v}_1) &= b_{11}\mathbf{w}_1 + \cdots + b_{1m}\mathbf{w}_m \\ \vdots & & \vdots & \\ T_1(\mathbf{v}_n) &= a_{n1}\mathbf{w}_1 + \cdots + a_{nm}\mathbf{w}_m & T_2(\mathbf{v}_n) &= b_{n1}\mathbf{w}_1 + \cdots + b_{nm}\mathbf{w}_m \end{aligned}$$

若 $T_1 \neq T_2$ ，则存在 $i \in [n]$ 使得

$$T_1(\mathbf{v}_i) \neq T_2(\mathbf{v}_i)$$

从而 $(a_{i1}, \dots, a_{im}) \neq (b_{i1}, \dots, b_{im})$ ，即 $A_{T_1} \neq A_{T_2}$ 。从而映射 $T \mapsto A_T$ 是单射。

另一方面，给定 $A \in M_{m \times n}(\mathbb{R})$ ，定义：

$$\begin{aligned} \mathbf{u}_i &= a_{i1}\mathbf{w}_1 + \cdots + a_{im}\mathbf{w}_m \\ \vdots & \\ \mathbf{u}_n &= a_{n1}\mathbf{w}_1 + \cdots + a_{nm}\mathbf{w}_m \end{aligned}$$

定义 $T: V \rightarrow W$ 满足对任意的 $i \in [n]$ 有 $T(\mathbf{v}_i) = \mathbf{u}_i$ 。则 $T \in T(V, W)$ 且 $A_T = A$ 。即映射 $T \mapsto A_T$ 是满射。 $\square$

定理2.6 充分说明了一件事，线性变换就是矩阵！但在之前的讨论中，我们都假定了基是确定的，那么一个很自然的问题就是，如果选择不同的基会发生什么？正如之前相似矩阵的介绍提到，不同的基决定的矩阵存在相似关系！我们有如下定理：

定理 2.7

令 V 是一个 n 维的线性空间， $\bar{\mathbf{v}}$ 和 $\bar{\mathbf{v}}'$ 是 V 的两组基。考虑 $V \rightarrow V$ 的一个线性变换 T ，令：

- M 是 $\bar{\mathbf{v}}$ 到 $\bar{\mathbf{v}}'$ 的过渡矩阵。
- A 是在基 $\bar{\mathbf{v}}$ 下 T 对应的矩阵。
- B 是在基 $\bar{\mathbf{v}}'$ 下 T 对应的矩阵。

则我们有:

$$B = M^{-1}AM.$$

证明: 令 M 是 $\bar{\mathbf{v}}$ 到 $\bar{\mathbf{v}}'$ 的过渡矩阵, 从而:

$$\begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} = \begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} M.$$

M 是可逆的, 因此:

$$\begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} = \begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} M^{-1}.$$

由 A, B 的定义我们有:

$$\begin{aligned} \begin{bmatrix} T(\mathbf{v}_1) & \cdots & T(\mathbf{v}_n) \end{bmatrix} &= \begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} A \\ \begin{bmatrix} T(\mathbf{v}'_1) & \cdots & T(\mathbf{v}'_n) \end{bmatrix} &= \begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} B \end{aligned}$$

我们下面证明:

$$\begin{bmatrix} T(\mathbf{v}'_1) & \cdots & T(\mathbf{v}'_n) \end{bmatrix} = \begin{bmatrix} T(\mathbf{v}_1) & \cdots & T(\mathbf{v}_n) \end{bmatrix} M.$$

令:

$$M = \begin{bmatrix} m_{11} & \cdots & m_{n1} \\ \vdots & \ddots & \vdots \\ m_{1n} & \cdots & m_{nn} \end{bmatrix}.$$

从而对任意的 $i \in [n]$, 我们有:

$$\mathbf{v}'_i = \sum_{j \in [n]} m_{ij} \mathbf{v}_j.$$

从而:

$$T(\mathbf{v}'_i) = T\left(\sum_{j \in [n]} m_{ij} \mathbf{v}_j\right) = \sum_{j \in [n]} m_{ij} T(\mathbf{v}_j).$$

即:

$$\begin{bmatrix} T(\mathbf{v}'_1) & \cdots & T(\mathbf{v}'_n) \end{bmatrix} = \begin{bmatrix} T(\mathbf{v}_1) & \cdots & T(\mathbf{v}_n) \end{bmatrix} \begin{bmatrix} m_{11} & \cdots & m_{n1} \\ \vdots & \ddots & \vdots \\ m_{1n} & \cdots & m_{nn} \end{bmatrix} = \begin{bmatrix} T(\mathbf{v}_1) & \cdots & T(\mathbf{v}_n) \end{bmatrix} M.$$

从而我们有:

$$\begin{aligned} \begin{bmatrix} T(\mathbf{v}'_1) & \cdots & T(\mathbf{v}'_n) \end{bmatrix} &= \begin{bmatrix} T(\mathbf{v}_1) & \cdots & T(\mathbf{v}_n) \end{bmatrix} M \\ &= \begin{bmatrix} \mathbf{v}_1 & \cdots & \mathbf{v}_n \end{bmatrix} AM \\ &= \begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} M^{-1}AM \\ &= \begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} (M^{-1}AM). \end{aligned}$$

注意到:

$$\begin{bmatrix} T(\mathbf{v}'_1) & \cdots & T(\mathbf{v}'_n) \end{bmatrix} = \begin{bmatrix} \mathbf{v}'_1 & \cdots & \mathbf{v}'_n \end{bmatrix} B.$$

从而由线性变换矩阵的唯一性可知: $B = M^{-1}AM$. □

我们再次强调，上述定理说明了，在同一个线性空间上不同基下的线性变换对应的矩阵是相似的。注意到基的选择会影响一个线性变换对应的矩阵。考察 n 维空间 V 上的一个线性变换，令其一组基为 $\bar{v} = v_1, \dots, v_n$ 。若对于每一个 $i \in [n]$ ，都存在 $\lambda_i \in \mathbb{R}$ 使得：

$$T(v_i) = \lambda_i v_i$$

则我们有：

$$A_T = \begin{bmatrix} \lambda_1 & 0 & \cdots & 0 \\ 0 & \lambda_2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_n \end{bmatrix}$$

与矩阵相类似，我们也称满足 $T(v_i) = \lambda_i v_i$ 的 λ_i 和 v_i 为 T 上的特征值和特征向量。但特别的是，可以看到这就是用来描述这个线性变换最简单的矩阵！

注 2.8

事实上，我们知道不是所有矩阵都可以对角化。同样的，对于线性变换，我们也不是所有的线性变换都可以找到一组特征向量作为基。但我们可以寻找尽可能接近对角化的形式，这就是若尔当标准型 (Jordan Form)，但我们在这里不多叙述。

3 线性变换的像与核




图 1 线性变换的像与核

这节我们从函数的角度来理解一下线性变换，很多概念都是相同的。我们固定两个线性空间 V 和 W ，并且考虑 V 到 W 上的一个线性变换 T 。

定义 3.1 (像 (Image))

T 的像 (Image) 是：

$$\text{Im}(T) := \{T(v) \mid v \in V\}$$

定义 3.2 (核 (Kernel))

T 的核 (Kernel) 是:

$$\text{Ker}(T) := \{\mathbf{v} \in V \mid T(\mathbf{v}) = \mathbf{0}\}$$

图1给出了线性变换的像与核的示意图。我们再看利用矩阵进行描述。考虑一个 $m \times n$ 的矩阵 A :

$$T_A(\mathbf{x}) = A\mathbf{x}$$

是一个 $\mathbb{R}^n$ 到 $\mathbb{R}^m$ 上的线性变换。我们有:

$$\text{Im}(T_A) = \{T_A(\mathbf{x}) \mid \mathbf{x} \in \mathbb{R}^n\} = \{A\mathbf{x} \mid \mathbf{x} \in \mathbb{R}^n\} = \mathbf{C}(A),$$

$$\text{Ker}(T_A) = \{\mathbf{x} \mid T_A(\mathbf{x}) = \mathbf{0}\} = \{\mathbf{x} \in \mathbb{R}^n \mid A\mathbf{x} = \mathbf{0}\} = \mathbf{N}(A).$$

注意到由定理2.3, 任何一个线性变换在一组给定的基下都可用矩阵来进行表示, 从而有如下推论:

推论 3.3

1. 线性变换 T 是单射当且仅当:

$$\text{Ker}(T) = \{\mathbf{0}\}.$$

2. 假设 W 是有限维的, 线性变换 T 是满射当且仅当:

$$\dim(\text{Im}(T)) = \dim(W).$$

下面我们将介绍线性变换中最核心的定理: Rank-Nullity 定理, 虽然我们早就已经见识过了。

定理 3.4 (Rank-Nullity 定理)

令 V 和 W 是两个有限维的线性空间, $T: V \rightarrow W$ 是一个线性变换。则:

$$\dim(V) = \dim(\text{Im}(T)) + \dim(\text{Ker}(T)).$$

图1 给出了定理3.4的示意图。




图 2 Rank-Nullity 定理

在正式证明该定理之前，我们来考察其矩阵的情形，考虑一个 $m \times n$ 的矩阵 A ，则我们有：

$$\text{Im}(A) = \mathbf{C}(A), \quad \text{Ker}(A) = \mathbf{N}(A).$$

从而我们有：

推论 3.5

令 A 是 $m \times n$ 的矩阵，则：

$$n = \dim(\mathbf{C}(A)) + \dim(\mathbf{N}(A)) = \text{rank}(A) + \dim(\mathbf{N}(A))$$

而这恰恰就是之前所介绍的线性代数基本定理！所以换个角度来理解，我们之前就已经通过矩阵的形式了解了这个定理了！现在我们从线性变换的角度给出证明：**证明：**[定理3.4的证明] 假设 V 存在一组基 $\bar{\mathbf{v}} = \mathbf{v}_1, \dots, \mathbf{v}_n$ ，特别的 $\dim(V) = n$ 。注意到：

$$\text{Im}(T) = \text{span}\{T(\mathbf{v}_1), \dots, T(\mathbf{v}_n)\}$$

从而 $\{T(\mathbf{v}_1), \dots, T(\mathbf{v}_n)\}$ 中的一组极大的线性无关的子集构成了 $\text{Im}(T)$ 的一组基。令其为：

$$\bar{\mathbf{w}} = \mathbf{w}_1, \dots, \mathbf{w}_m$$

从而 $\dim(\text{Im}(T)) = m$ ，不妨令对于所有的 $i \in [m]$ ：

$$T(\mathbf{v}_i) = \mathbf{w}_i$$

否则我们重新排列 $\mathbf{v}_i$ 的顺序。注意到 $\text{Ker}(T)$ 是 V 的子空间，从而 $\text{Ker}(T)$ 存在一组基：

$$\mathbf{u}_1, \dots, \mathbf{u}_p$$

其中 $p \leq n$ 。

我们下面证明：

陈述 3.6

$\mathbf{v}_1, \dots, \mathbf{v}_m, \mathbf{u}_1, \dots, \mathbf{u}_p$ 是 V 中的一组基。

若上述命题成立，则立马可以得到：

$$\dim(V) = \dim(\text{Im}(T)) + \dim(\text{Ker}(T)).$$

证明：[Fact3.6的证明] 首先我们证明 $\mathbf{v}_1, \dots, \mathbf{v}_m, \mathbf{u}_1, \dots, \mathbf{u}_p$ 是线性无关的。给定 $c_1, \dots, c_m, d_1, \dots, d_p \in \mathbb{R}$ 使得：令 $\mathbf{v} \in V$ ，则 $T(\mathbf{v}) \in \text{Im}(T)$ ，从而存在 $x_1, \dots, x_n \in \mathbb{R}$ 使得：

$$T(\mathbf{v}) = \sum_{i=1}^m x_i \mathbf{w}_i = \sum_{i=1}^m x_i T(\mathbf{v}_i) = T\left(\sum_{i=1}^m x_i \mathbf{v}_i\right).$$

从而:

$$T\left(\mathbf{v} - \sum_{i=1}^m x_i \mathbf{v}_i\right) = \mathbf{0} \implies \mathbf{v} - \sum_{i=1}^m x_i \mathbf{v}_i \in \text{Ker}(T).$$

即:

$$\mathbf{v} - \sum_{i=1}^m x_i \mathbf{v}_i \in \text{span}\{\mathbf{u}_1, \dots, \mathbf{u}_p\} \implies \mathbf{v} = \sum_{i=1}^m x_i \mathbf{v}_i + \sum_{i=1}^p y_i \mathbf{u}_i.$$

从而我们有:

$$\mathbf{v} \in \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_m, \mathbf{u}_1, \dots, \mathbf{u}_p\} \implies V = \text{span}\{\mathbf{v}_1, \dots, \mathbf{v}_m, \mathbf{u}_1, \dots, \mathbf{u}_p\}.$$

我们还需要证明 $\mathbf{v}_1, \dots, \mathbf{v}_m, \mathbf{u}_1, \dots, \mathbf{u}_p$ 是线性无关的。假设存在 $x_1, \dots, x_m, y_1, \dots, y_p \in \mathbb{R}$ 使得:

$$\sum_{i=1}^m x_i \mathbf{v}_i + \sum_{i=1}^p y_i \mathbf{u}_i = \mathbf{0}.$$

则:

$$\mathbf{0} = T\left(\sum_{i=1}^m x_i \mathbf{v}_i + \sum_{i=1}^p y_i \mathbf{u}_i\right) = \sum_{i=1}^m x_i T(\mathbf{v}_i) + \sum_{i=1}^p y_i T(\mathbf{u}_i) = \sum_{i=1}^m x_i T(\mathbf{v}_i) = \sum_{i=1}^m x_i \mathbf{w}_i.$$

由 $\mathbf{w}_1, \dots, \mathbf{w}_m$ 是线性无关的, 从而对任意的 $i \in [m]$ 都有 $x_i = 0$, 因此我们有:

$$\sum_{i=1}^p y_i \mathbf{u}_i = \mathbf{0}.$$

由 $\mathbf{u}_1, \dots, \mathbf{u}_p$ 是线性无关的, 我们也可以得到 $y_1 = \dots = y_p = 0$ 。从而 $\mathbf{v}_1, \dots, \mathbf{v}_m, \mathbf{u}_1, \dots, \mathbf{u}_p$ 是线性无关的。□

最后我们考察如下的问题来进一步理解定理3.4.

命题 3.7

令 A 是一个 $m \times n$ 的矩阵, B 是一个 $n \times l$ 的矩阵。我们有:

$$\text{rank}(A) + \text{rank}(B) \leq \text{rank}(AB) + n$$

我们首先给出一个关于这个例子更常见的具备技巧性的证明:

证明: [技巧性的证明]

$$\begin{aligned} \text{rank}(AB) + n &= \text{rank}\left(\begin{bmatrix} AB & O \\ O & I \end{bmatrix}\right) = \text{rank}\left(\begin{bmatrix} AB & O \\ B & I \end{bmatrix}\right) \\ &= \text{rank}\left(\begin{bmatrix} O & -A \\ B & I \end{bmatrix}\right) = \text{rank}\left(\begin{bmatrix} B & I \\ O & -A \end{bmatrix}\right) \\ &= \text{rank}\left(\begin{bmatrix} B & -I \\ O & A \end{bmatrix}\right) \geq \text{rank}(A) + \text{rank}(B). \end{aligned}$$

□

这个证明利用了矩阵的一些变换技巧，但是不是特别直观，下面我们从定理3.4的角度来理解一下这个不等式，注意到：

$$\text{rank}(A) + \text{rank}(B) \leq \text{rank}(AB) + n$$

等价于：

$$(n - \dim(\mathbf{N}(A))) + (l - \dim(\mathbf{N}(B))) \leq (l - \dim(\mathbf{N}(AB))) + n$$

即要证：

$$\dim(\mathbf{N}(A)) + \dim(\mathbf{N}(B)) \geq \dim(\mathbf{N}(AB))$$

从而现在问题就比较显然了，因为 $\mathbf{N}(AB)$ 的维数显然不可能超过 $\mathbf{N}(A)$ 与 $\mathbf{N}(B)$ 的维数之和，从而有下列的证明：

证明： [利用定理3.4的证明] 令 $\mathbf{x} \in \mathbb{R}^l$ ，则我们有：

$$\mathbf{x} \in \mathbf{N}(AB) \iff AB\mathbf{x} = \mathbf{0} \iff B\mathbf{x} \in \mathbf{N}(A).$$

定义：

$$W = \{B\mathbf{x} \mid \mathbf{x} \in \mathbb{R}^l, B\mathbf{x} \in \mathbf{N}(A)\} \implies W = \mathbf{C}(B) \cap \mathbf{N}(A) \subseteq \mathbb{R}^n.$$

从而 W 是 $\mathbf{N}(A)$ 的一个子空间。定义线性变换 $T: \mathbf{N}(AB) \rightarrow \mathbb{R}^n$ ：

$$T(\mathbf{x}) = B\mathbf{x}.$$

从而我们有：

$$\text{Im}(T) = W.$$

$$\text{Ker}(T) = \{\mathbf{x} \in \mathbf{N}(AB) \mid B\mathbf{x} = \mathbf{0}\} = \mathbf{N}(B).$$

从而由 Rank-Nullity 定理我们有：

$$\dim(\mathbf{N}(AB)) = \dim(\text{Im}(T)) + \dim(\text{Ker}(T)) = \dim(W) + \dim(\mathbf{N}(B)) \leq \dim(\mathbf{N}(A)) + \dim(\mathbf{N}(B)).$$

□

4 对偶性

注 4.1

本节内容如非特殊声明，均只考虑有限维的线性空间。

在本讲义的最后一节我们想探讨一些对偶性。这个的出发点在于想要从线性变换的角度理解一下矩阵核其转置矩阵的联系。为此我们需要引入一些特别的概念，也就是我们要考察一些特殊的函数。现在固定一个线性空间 V 。我们考察其到 $\mathbb{R}$ 上的线性映射，我们称之为线性泛函

定义 4.2 (线性泛函)

一个 V 上的泛函 L 是一个线性映射 $f: V \rightarrow \mathbb{R}$, 即: $L \in T(V, \mathbb{R})$ 。

例 4.3

1. $F: \mathbb{R}^3 \rightarrow \mathbb{R}$:

$$F(x, y, z) = 4x - 5y + 2z$$

是一个线性泛函。

2. 固定 $(c_1, \dots, c_n) \in \mathbb{R}^n$, 定义 $F: \mathbb{R}^n \rightarrow \mathbb{R}$:

$$F(\mathbf{x}) = \sum_{i=1}^n c_i x_i.$$

是一个线性泛函。

我们将 V 上所有的线性泛函所构成的集合称为 V 的对偶空间, 记为 V' :

定义 4.4 (对偶空间 (Dual Space))

V 的对偶空间 V' 是 V 上所有线性泛函的集合。即:

$$V' = T(V, \mathbb{R})$$

不难发现, 其是一个线性空间:

引理 4.5

V' 是一个线性空间。

证明: 给定 $L_1, L_2 \in V'$ 和 $c \in \mathbb{R}$, 定义:

$$(L_1 + L_2)(\mathbf{v}) = L_1(\mathbf{v}) + L_2(\mathbf{v}), \quad (cL_1)(\mathbf{v}) = cL_1(\mathbf{v}).$$

则 $L_1 + L_2$ 和 cL_1 都是 V 上的线性泛函, 因此 $L_1 + L_2 \in V'$ 和 $cL_1 \in V'$ 。从而 V' 是一个线性空间。□

现在我们来考察有限维的线性空间 V 上的一组基, 我们说明其可以生成一组 V' 的基。令

$$\mathbf{v}_1, \dots, \mathbf{v}_n$$

是 V 中的一组基。则考察如下的一组泛函:

$$L_1, \dots, L_n.$$

其满足对任意的 $i, j \in [n]$,

$$L_i(\mathbf{v}_j) = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

我们有:

定理 4.6

当 $\dim(V) < \infty$ 时, $L_1, \dots, L_n$ 是 V' 的一组基。

证明: 令 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 是 V 的一组基, $L_1, \dots, L_n$ 是其对偶基。假设存在 $c_1, \dots, c_n \in \mathbb{R}$ 使得:

$$T = c_1 L_1 + \dots + c_n L_n = 0.$$

则对任意的 $i \in [n]$:

$$0 = T(\mathbf{v}_i) = (c_1 L_1 + \dots + c_n L_n)(\mathbf{v}_i) = c_i L_i(\mathbf{v}_i) = c_i.$$

从而 $c_1 = \dots = c_n = 0$, 即 $L_1, \dots, L_n$ 是线性无关的。另一方面, 考虑 $T \in V' = T(V, \mathbb{R})$, 即 T 是一个 V 到 $\mathbb{R}$ 的线性映射。

对任意的 $i \in [n]$, 令:

$$c_i = T(\mathbf{v}_i).$$

则定义:

$$T' = c_1 L_1 + \dots + c_n L_n.$$

显然 $T' \in T(V, \mathbb{R}) = V'$, 并且对任意的 $i \in [n]$:

$$T'(\mathbf{v}_i) = c_i L_i(\mathbf{v}_i) = c_i = T(\mathbf{v}_i).$$

即 $T' = T$, 从而:

$$V' = \text{span}\{L_1, \dots, L_n\}.$$

□

从而立马可得:

推论 4.7

当 $\dim(V) < \infty$ 时, $\dim(V) = \dim(V')$ 。

上述这组基也被称作是 V 的对偶基 (Dual Basis):

定义 4.8 (对偶基 (Dual Basis))

令

$$\mathbf{v}_1, \dots, \mathbf{v}_n$$

是 V 中的一组基。则 $\mathbf{v}_1, \dots, \mathbf{v}_n$ 的**对偶基**是如下的一组泛函:

$$L_1, \dots, L_n$$

满足:

$$L_i(\mathbf{v}_j) = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

注 4.9

1. 对偶基的一个直观表示就是提取坐标的函数。比如说 $\mathbb{R}^n$ 中的标准基 $\mathbf{e}_1, \dots, \mathbf{e}_n$ 的对偶基就是 $L_1, \dots, L_n$, 其中 $L_i(\mathbf{x}) = x_i$ 。
2. 定理4.6和 Corollary4.7说明了, 有限维情况下, 线性空间和其对偶空间是同构的, 但在无限维的情况下, 线性空间和其对偶空间可能不是同构的。但在无限维情况下则不一定, 直觉上的解释是因为线性表示需要有限个元素。而关于无限维的线性空间, 本身其一组基就是需要利用 Zorn 引理来证明存在的, 因此我们在这不多考虑这部分的内容了。

现在我们要开始介绍**对偶变换**了, 直觉上来说, V 到 W 上的一个线性变换 T , 可以诱导出一个 W' 到 V' 上的线性变换:

定义 4.10 (对偶变换 (Dual Transformation))

对于一个线性变换 $T \in T(V, W)$, 定义其对偶变换 $T' \in (W', V')$:

$$T'(L) = LT, \text{ 即对任意的 } \mathbf{v} \in V \text{ 有 } T'(L)(\mathbf{v}) = L(T(\mathbf{v}))$$

命题 4.11

1. 对任意的 $L \in W'$, $T'(L)$ 是 V' 上的线性泛函, 即是 V 到 $\mathbb{R}$ 上的线性变换。
2. T' 是一个 W' 到 V' 上的线性变换。

证明: 首先我们说明 $T'(L) \in V'$: 注意到:

$$T'(L) = LT, \text{ 即对任意的 } \mathbf{v} \in V \text{ 有 } T'(L)(\mathbf{v}) = L(T(\mathbf{v}))$$

我们只需验证 $T'(L)$ 是 V' 到 $\mathbb{R}$ 上的线性变换即可。

- 向量加法: 令 $\mathbf{v}_1, \mathbf{v}_2 \in V$, 则:

$$\begin{aligned} T'(L)(\mathbf{v}_1 + \mathbf{v}_2) &= L(T(\mathbf{v}_1 + \mathbf{v}_2)) = L(T(\mathbf{v}_1) + T(\mathbf{v}_2)) \\ &= L(T(\mathbf{v}_1)) + L(T(\mathbf{v}_2)) = T'(L)(\mathbf{v}_1) + T'(L)(\mathbf{v}_2) \end{aligned}$$

- 数乘: 令 $\mathbf{v} \in V$, $c \in \mathbb{R}$, 则:

$$T'(L)(c\mathbf{v}) = L(T(c\mathbf{v})) = L(cT(\mathbf{v})) = cL(T(\mathbf{v})) = cT'(L)(\mathbf{v})$$

然后我们说明 T' 是一个 W' 到 V' 上的线性变换。注意到:

$$T'(L) = LT, \text{ 即对任意的 } \mathbf{v} \in V \text{ 有 } T'(L)(\mathbf{v}) = L(T(\mathbf{v}))$$

- 向量加法: 令 $L_1, L_2 \in W' = T(W, \mathbb{R})$, 则对于任意的 $\mathbf{v} \in V$:

$$\begin{aligned} T'(L_1 + L_2)(\mathbf{v}) &= (L_1 + L_2)(T(\mathbf{v})) = L_1(T(\mathbf{v})) + L_2(T(\mathbf{v})) \\ &= T'(L_1)(\mathbf{v}) + T'(L_2)(\mathbf{v}) \end{aligned}$$

$$\text{即 } T'(L_1 + L_2) = T'(L_1) + T'(L_2).$$

- 数乘: 令 $L \in W' = T(W, \mathbb{R})$, $c \in \mathbb{R}$, 则对于任意的 $v \in V$:

$$T'(cL)(v) = (cL)(T(v)) = cL(T(v)) = cT'(L)(v)$$

$$\text{即 } T'(cL) = cT'(L).$$

□

下面的定理则说明, 在基和对偶基的意义下, 线性变换 T 和其对偶变换 T' 的矩阵是互为转置的, 即转置矩阵描述了对偶变换。

定理 4.12

令 $\bar{v} = v_1 \cdots v_n, \bar{w} = w_1 \cdots w_m$ 是 V, W 的一组基, $L_1^{\bar{v}}, \dots, L_n^{\bar{v}}, L_1^{\bar{w}}, \dots, L_m^{\bar{w}}$ 是分别是两组基对应的对偶基。若 $T \in T(V, W)$ 并且 A_T 是 T 在基 $\bar{v}$ 和 $\bar{w}$ 下的矩阵。令 $A_{T'}$ 是其对偶变换 $T' \in T(W', V')$ 在基 $L_1^{\bar{w}}, \dots, L_m^{\bar{w}}$ 和 $L_1^{\bar{v}}, \dots, L_n^{\bar{v}}$ 下的矩阵。则:

$$A_{T'} = A_T^T.$$

证明: 记

$$A_T = \begin{bmatrix} a_{11} & \cdots & a_{n1} \\ \vdots & \ddots & \vdots \\ a_{1m} & \cdots & a_{nm} \end{bmatrix}, \quad A_{T'} = \begin{bmatrix} b_{11} & \cdots & b_{m1} \\ \vdots & \ddots & \vdots \\ b_{1n} & \cdots & b_{mn} \end{bmatrix}$$

即:

$$\begin{aligned} T(v_1) &= a_{11}w_1 + \cdots + a_{1m}w_m & T'(L_1^{\bar{w}}) &= b_{11}L_1^{\bar{v}} + \cdots + b_{1n}L_n^{\bar{v}} \\ T(v_2) &= a_{21}w_1 + \cdots + a_{2m}w_m & T'(L_2^{\bar{w}}) &= b_{21}L_1^{\bar{v}} + \cdots + b_{2n}L_n^{\bar{v}} \\ &\vdots & &\vdots \\ T(v_n) &= a_{n1}w_1 + \cdots + a_{nm}w_m & T'(L_m^{\bar{w}}) &= b_{m1}L_1^{\bar{v}} + \cdots + b_{mn}L_n^{\bar{v}} \end{aligned}$$

注意到对偶基的定义:

$$L_i^{\bar{v}}(v_j) = \begin{cases} 1 & i = j \\ 0 & i \neq j \end{cases}$$

从而对于任意的 $i \in [m], j \in [n]$ 有:

$$T'(L_i^{\bar{w}})(v_j) = (b_{i1}L_1^{\bar{v}} + \cdots + b_{in}L_n^{\bar{v}})(v_j) = b_{ij}L_j^{\bar{v}}(v_j) = b_{ij}$$

另一方面, 由定义可得:

$$\begin{aligned} T'(L_i^{\bar{w}})(v_j) &= L_i^{\bar{w}}(T(v_j)) = L_i^{\bar{w}}(a_{j1}w_1 + \cdots + a_{jm}w_m) \\ &= a_{j1}L_i^{\bar{w}}(w_1) + \cdots + a_{jm}L_i^{\bar{w}}(w_m) \\ &= a_{ji}L_i^{\bar{w}}(w_i) = a_{ji} \end{aligned}$$

从而:

$$b_{ij} = T'(L_i^{\bar{w}})(v_j) = a_{ji}$$

□

最后我们来考察一下对偶变换的像与核。对于一个线性变换 $T \in T(V, W)$, 其对偶变换 $T' \in T(W', V')$ 的核应该满足:

$$\begin{aligned} \text{Ker}(T') &= \{L \in W' \mid T'(L) = 0\} = \{L \in W' \mid LT = 0\} \\ &= \{L \in W' \mid L(T(\mathbf{v})) = 0, \forall \mathbf{v} \in V\} = \{L \in W' \mid L(\mathbf{w}) = 0, \forall \mathbf{w} \in \text{Im}(T)\} \\ &= \{\text{所有在 } \text{Im}(T) \text{ 上取值为 } 0 \text{ 的线性泛函}\}. \end{aligned}$$

也就是说 T 的对偶变换 T' 的核是 $\text{Im}(T)$ 上所有使其取值为 0 的线性泛函的集合, 其依赖于 $\text{Im}(T)$ 。注意到 $\text{Im}(T)$ 是 W 的一个子空间, 所以我们尝试从 W 上来分析这个问题, 具体我们定义一个子空间的零化子 (Annihilator):

定义 4.13 (零化子 (Annihilator))

令 V 是一个线性空间, $U \subseteq V$ 是其子空间。 U 的零化子, 记作 U^0 , 定义如下:

$$U^0 = \{L \in V' \mid L(\mathbf{u}) = 0, \forall \mathbf{u} \in U\}.$$

首先我们有:

引理 4.14

U^0 是 V' 的一个子空间。

证明:

- 显然零函数 $0 \in U^0$ 。
- 零 $L_1, L_2 \in U^0$, 则对任意的 $\mathbf{u} \in U$, 有:

$$(L_1 + L_2)(\mathbf{u}) = L_1(\mathbf{u}) + L_2(\mathbf{u}) = 0 + 0 = 0$$

即 $L_1 + L_2 \in U^0$ 。

- $L \in U^0$, $c \in \mathbb{R}$, 则对任意的 $\mathbf{u} \in U$, 有:

$$(cL)(\mathbf{u}) = cL(\mathbf{u}) = c \cdot 0 = 0$$

即 $cL \in U^0$ 。

□

现在我们来考察零化子的维度:

定理 4.15

令 V 是一个有限维的线性空间, $U \subseteq V$ 是其子空间。则:

$$\dim(U) + \dim(U^0) = \dim(V)$$

证明: 我们使用如下的包含映射 (Inclusion Linear Transformation): $T_{\text{incl}} : U \rightarrow V$:

$$\text{对任意的 } u \in U \text{ 有 } T_{\text{incl}}(u) = u$$

则其对偶映射为 $T'_{\text{incl}} \in T(V', U')$, 则由 Rank-Nullity 定理有:

$$\dim(V') = \dim(\text{Im}(T'_{\text{incl}})) + \dim(\text{Ker}(T'_{\text{incl}}))$$

我们将证明:

- $\text{Im}(T'_{\text{incl}}) = U'$ 。
- $\text{Ker}(T'_{\text{incl}}) = U^0$ 。

从而:

$$\dim(V) = \dim(V') = \dim(U') + \dim(U^0) = \dim(U) + \dim(U^0).$$

陈述 4.16

$$\text{Im}(T'_{\text{incl}}) = U'.$$

证明: 令 $L \in U' = T(U, \mathbb{R})$ 。注意到 V 是有限维的, 不妨令其一组基为:

$$v_1, \dots, v_m, v_{m+1}, \dots, v_n.$$

注意到 U 是 V 的子空间, 不妨进一步假设 $v_1, \dots, v_m$ 是 U 的一组基。我们定义 $L_V \in T(V, \mathbb{R})$:

$$L_V(v_i) = \begin{cases} L(v_i) & i \in [m] \\ 0 & i \in [m+1, n] \end{cases}.$$

则对任意的 $u \in U$ 有:

$$T'_{\text{incl}}(L_V)(u) = L_V(T_{\text{incl}}(u)) = L_V(u) = L(u).$$

这里最后一个等号是因为 $u \in U$ 可以写成:

$$u = u_1 v_1 + \dots + u_m v_m + 0 v_{m+1} + \dots + 0 v_n.$$

的形式, 从而:

$$\text{Im}(T'_{\text{incl}}) = U'.$$

□

陈述 4.17

$$\text{Ker}(T'_{\text{incl}}) = \mathcal{U}^0.$$

证明： 对于 $\text{Ker}(T'_{\text{incl}})$ 有：

$$\begin{aligned} \text{Ker}(T'_{\text{incl}}) &= \{L \in V' \mid \text{Ker}(T'_{\text{incl}})(L) = 0\} \\ &= \{L \in V' \mid \text{对任意的 } \mathbf{u} \in \mathcal{U} \text{ 有 } T'_{\text{incl}}(L)(\mathbf{u}) = 0\} \\ &= \{L \in V' \mid \text{对任意的 } \mathbf{u} \in \mathcal{U} \text{ 有 } L(T_{\text{incl}}(\mathbf{u})) = 0\} \\ &= \{L \in V' \mid \text{对任意的 } \mathbf{u} \in \mathcal{U} \text{ 有 } L(\mathbf{u}) = 0\} = \mathcal{U}^0. \end{aligned}$$

□

从而对于对偶变换的核我们有：

定理 4.18

假设 V 和 W 是有限维的线性空间，令 $T \in T(V, W)$ ，则：

1. $\text{Ker}(T') = (\text{Im}(T))^0$.
2. $\dim(\text{Ker}(T')) = \dim(\text{Ker}(T)) + \dim(W) - \dim(V)$.

证明： 我们先利用第一个结论来证明第二个，注意到：

$$\begin{aligned} \dim(\text{Ker}(T')) &= \dim((\text{Im}(T))^0) = \dim(W) - \dim(\text{Im}(T)) \\ &= \dim(W) - (\dim(V) - \dim(\text{Ker}(T))) = \dim(\text{Ker}(T)) + \dim(W) - \dim(V). \end{aligned}$$

现在回到 $\text{Ker}(T') = (\text{Im}(T))^0$ 的证明：

- 令 $L \in \text{Ker}(T')$ ，即 $T'(L) = 0 \in V' = T(V, \mathbb{R})$ ，也就是对任意的 $\mathbf{v} \in V$ 有

$$T'(L)(\mathbf{v}) = L(T(\mathbf{v})) = 0$$

从而对于任意的 $\mathbf{w} \in \text{Im}(T)$ ，我们都有 $L(\mathbf{w}) = 0$ ，即 $L \in (\text{Im}(T))^0$ ，即：

$$\text{Ker}(T') \subseteq (\text{Im}(T))^0$$

- 另一方面，考察 $L \in (\text{Im}(T))^0$ ，这意味着对任意的 $\mathbf{w} \in \text{Im}(T)$ 都有

$$L(\mathbf{w}) = 0$$

从而对任意的 $\mathbf{u} \in V$ ：

$$T'(L)(\mathbf{u}) = L(T(\mathbf{u})) = 0$$

即： $L \in \text{Ker}(T')$ ，也就是 $(\text{Im}(T))^0 \subseteq \text{Ker}(T')$ 。

□

而对于对偶变换的像，我们有：

定理 4.19

假设 V 和 W 是有限维的线性空间, 令 $T \in T(V, W)$, 则:

1. $\dim(\text{Im}(T')) = \dim(\text{Im}(T))$.
2. $\text{Im}(T') = (\text{Ker}(T))^0$.

证明:

1. $\dim(\text{Im}(T')) = \dim(W') - \dim(\text{Ker}(T')) = \dim(W) - \dim((\text{Im}(T))^0) = \dim(\text{Im}(T))$.
2. 令 $L \in \text{Im}(T') \subseteq V'$, 则存在 $L_w \in W'$ 使得: $T'(L_w) = L$

注意到对任意的 $u \in \text{Ker}(T)$ 我们有:

$$L(u) = T'(L_w)(u) = L_w(T(u)) = L_w(0) = 0$$

从而 $L \in (\text{Ker}(T))^0$, 即 $\text{Im}(T') \subseteq (\text{Ker}(T))^0$, 另一方面, 我们有:

$$\dim(\text{Im}(T')) = \dim(\text{Im}(T)) = \dim(V) - \dim(\text{Ker}(T)) = \dim((\text{Ker}(T))^0)$$

从而 $\text{Im}(T') = (\text{Ker}(T))^0$.

□

作为一个应用, 我们通过对偶变换来给出矩阵的列秩和行秩相等的一个证明:

定理 4.20

令 A 是一个 $m \times n$ 的矩阵, 则: $\text{row-rank}(A) = \text{column-rank}(A)$.

证明: 定义 $T: \mathbb{R}^n \rightarrow \mathbb{R}^m$:

$$T(v) = Av.$$

特别的, 在标准基 $e_1, \dots, e_n$ 下的 T 的矩阵为 A 。从而其对偶变换 T' 在对应的对偶基下的矩阵为 A^T 。

因此:

$$\begin{aligned} \text{column-rank}(A) &= \dim(\mathbf{C}(A)) = \dim(\text{Im}(T)) \\ &= \dim(\text{Im}(T')) = \dim(\mathbf{C}(A^T)) = \text{column-rank}(A^T) = \text{row-rank}(A). \end{aligned}$$

□